MING 的个人学习笔记

因果推断学习笔记：Brave and True

第 1 至 25 章与附录

中文校订排印版

阅读说明

保留讲义内容、个人直觉、问题、推导与边栏补充。阅读顺序按主题、左右页接续和原箭头关系整理；来源页码为原扫描 PDF 中从 1 开始的页码。中文重新排版，图形保留关系，曲线坐标仅作示意。

黑色、红色、蓝色对应原笔颜色。箭头连接原批注及其目标，不表示校订判断。

紫色：原手写笔记本身的错误。保留原表述，在旁边给出修正。

橙色：补充条件、字迹歧义或待确认问题。不一定表示原命题错误。

识别与翻译错误直接改正，仅在审计记录中说明。中英文版本使用相同校注编号和公式结构，校订说明与作者原批注明确区分。

本书合并整理自 54 页扫描。原扫描在核对期间保持不变，完成后按作者要求从当前目录删除；保留来源页码和审计记录以便追溯。

整理于 2026 年 10 月 31 日

目录

第 1 章：因果推断入门 3

第 2 章：随机实验 3

第 3 章：统计学回顾 4

第 4 章：图模型 4

第 5 章：线性回归的作用 5

第 6 章：分组与虚拟变量回归 7

第 7 章：控制混杂因素之外 7

第 8 章：工具变量 9

第 9 章：不依从与局部平均处理效应 10

第 10 章：匹配 12

第 11 章：倾向得分 13

第 12 章：双重稳健估计 15

第 13 章：双重差分 16

第 14 章：面板数据与固定效应 16

第 15 章：合成控制 18

第 16 章：断点回归设计 20

第二部分：应用 22

第 17 章：预测模型基础 22

第 18 章：异质处理效应与个性化 23

第 19 章：评价因果模型 23

第 20 章：即插即用估计量 25

第 21 章：元学习器 27

第 22 章：去偏 / 正交机器学习 **29**
尚未完成的非线性推广 30

第 23 章：效应异质性与非线性 **33**

第 24 章：双重差分的发展与问题 **35**
面板数据与双向固定效应 35
失效：处理效应异质性带来的问题 36
事件研究设计 38
改进：更灵活的函数形式 39

第 25 章：合成双重差分 **40**
面板数据的表示 40
回顾 DiD 与合成控制 41
将两者结合：合成 DiD 42
时间效应异质性与交错采用 44
安慰剂方差估计 45

附录：去偏与预测 **46**
通过正交化去偏 46
通过倾向得分去偏 47
当预测失效时 48

第 1 章：因果推断入门

原扫描页码： Chapter1-23.pdf, p. 1

T_i 表示是否接受处理，Y_i 是观测结果。笔记把“现实（分组）”与“真相”作了区分。

$$\text{ATE} = E[Y_1 - Y_0], \qquad \text{ATT} = E[Y_1 - Y_0 \mid T = 1].$$

ATE 是平均处理效应；ATT 是已接受处理者的平均处理效应。因果量来自潜在结果之差。观测到的相关关系可分解为

$$\underbrace{E[Y \mid T = 1] - E[Y \mid T = 0]}_{\text{相关关系}} = \underbrace{E[Y_1 - Y_0 \mid T = 1]}_{\text{ATT}} + \underbrace{E[Y_0 \mid T = 1] - E[Y_0 \mid T = 0]}_{\text{偏差}}.$$

我的批注。偏差为零时，相关关系代表 ATT；再用箭头把 ATT 连到 $E[Y_1 - Y_0]$，标作“因果关系”。

原笔记的指向关系。

偏差 $= 0$：相关关系代表 ATT	$\longrightarrow$	ATT
可转为因果关系（原笔记箭头）	$\longrightarrow$	$E[Y_1 - Y_0]$；条件见下方校注

补充条件 / 待确认 (B1-004): 选择偏差为零识别的是 ATT，不一定是 ATE

来源： Chapter1-23.pdf, pp. 1

这条箭头确实出现在原笔记的蓝色批注中。$E[Y_0 \mid T = 1] - E[Y_0 \mid T = 0]$ 为零时，相关关系 $=$ ATT。若要进一步把 ATT 换成 ATE，还需 $E[Y_1 - Y_0 \mid T = 1] = E[Y_1 - Y_0]$；处理与两个潜在结果均独立的随机分配是一个充分条件。实际上，$\text{ATE} = P(T = 1)\text{ATT} + P(T = 0)\text{ATU}$。

参考： 教材第 1 章.

第 2 章：随机实验

原扫描页码： Chapter1-23.pdf, p. 1

随机实验可以消除偏差。图中把已有条件与潜在结果的联系（需要消除）和处理与观测结果的联系（需要研究）分开。RCT 给出

$$(Y_0, Y_1) \perp T, \qquad E[Y_0 \mid T = 0] = E[Y_0 \mid T = 1] = E[Y_0],$$

因此选择偏差项为零。

原笔记的指向关系。

RCT 提供这一条件	$\longrightarrow$	$(Y_0, Y_1) \perp T$
需要消除的联系	$\longrightarrow$	已有条件 $\longrightarrow$ 潜在结果

需要研究的联系 ⟶ 处理 ⟶ 观测结果

第 3 章：统计学回顾

原扫描页码：Chapter1-23.pdf, p. 2

估计量的标准误写作 $\mathrm{SE} = \hat{\sigma}/\sqrt{n}$，其中

$$\hat{\sigma}^2 = \frac{1}{N-1}\sum_i (x_i - \bar{x})^2.$$

样本量更小 ⇒ 标准误更大 ⇒ 置信区间更宽。原假设是处理组与对照组的分布均值相等。两组各自的置信区间即使重叠，均值之差仍可能显著不为零。蓝色批注区分了两组均值各自的 95% 置信区间与两组均值之差。

笔记把 p 值写作 $P(\text{data} \mid H_0)$：在 H_0 下，观测到当前数据或更极端数据的概率，并提醒第一类错误。置信水平被描述为估计值与总体参数之差不超过某一范围的概率。置信水平更高 ⇒ 区间更宽 ⇒ 精度更低。显著性水平是第一类错误的概率。

我的直觉。若 p 值很小，那么在 H_0 下极不容易出现的数据却出现了，说明 H_0 可能不对。把样本算出的 p 值与理论上预先选定的显著性水平比较。

原笔记的指向关系。

$\mathrm{SE} = \hat{\sigma}/\sqrt{n}$ ⟶ $\hat{\sigma}^2 = (N-1)^{-1}\sum_i (x_i - \bar{x})^2$

各自的置信区间 ⟶ $T = 1$ 或 $T = 0$ 组均值的 95% 置信区间

差值仍可能显著 ⟶ 两组均值之差

补充条件 / 待确认 (B1-005): 抽样概率与置信区间覆盖率

来源：Chapter1-23.pdf, pp. 2

原笔记的简写需结合抽样来理解。对于独立同分布样本的均值，$\widehat{\mathrm{SE}}(\bar{X}) = s/\sqrt{n}$；这不是所有估计量通用的标准误。$p$ 值是 $P_{H_0}\{S \text{ 至少与} S_{\text{obs}} \text{ 一样极端}\}$，不是 $P(H_0 \mid \text{data})$。95% 置信区间程序的重复抽样覆盖率为 $P_\theta\{\theta \in C(X)\} = 0.95$。小 p 值提供反对原假设的证据，并不从逻辑上证明原假设为假。

参考： 教材第 3 章.

第 4 章：图模型

原扫描页码：Chapter1-23.pdf, p. 3

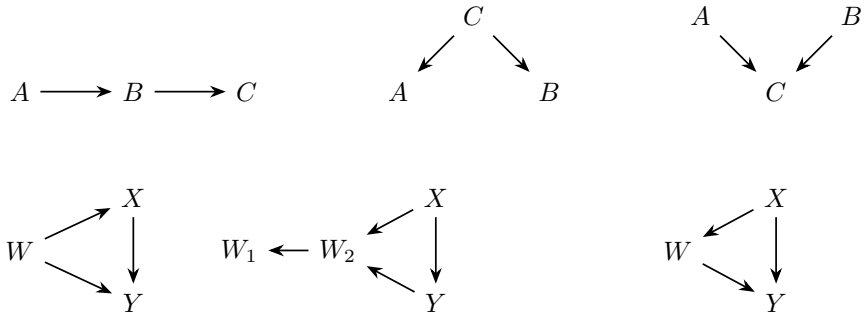
$A \to B$ 表示 A 影响 B；依赖关系沿箭头传递。

1. 链：$A \to B \to C$。边际上 $A \not\perp C$；给定已知的中间变量 B 后，路径被阻断：$A \perp C \mid B$。
2. 叉：$A \leftarrow C \to B$。未条件化时，$A \not\perp B$；给定 C 后，$A \perp B \mid C$。
3. 碰撞点：$A \to C \leftarrow B$。边际上 $A \perp B$；给定 C 后，$A \not\perp B \mid C$。

混杂偏差还可能涉及混杂因素的代理变量，以及不能直接测量的变量。

我的总结。混杂偏差来自没有控制住的开放路径，例如 $X \leftarrow W \to Y$，同时存在 $X \to Y$。选择偏差来自多余的条件化：控制共同结果会打开路径，控制因果路径上的中间变量则会阻断部分因

果作用。例子中 X 是教育，Y 是工资，W 是投资。碰撞点图为 $X \to W_2 \leftarrow Y$、$W_2 \to W_1$ 和 $X \to Y$，“投资”写在 W_1 旁；中介图则是教育先影响 W，再影响工资，同时还有教育到工资的直接箭头。笔记说控制 W 对这里的分析也有负面影响。



原扫描第 3 页：链、叉、碰撞点；下方依次为混杂及两种不当控制。

原笔记的指向关系。

额外控制共同结果，打开路径	$\longrightarrow$	碰撞点 W_2，或其后代 W_1
额外控制，阻断部分因果路径	$\longrightarrow$	$X \to W \to Y$ 中的中介变量 W

补充条件 / 待确认 (B1-006): 图上的分离与统计依赖

来源：Chapter1-23.pdf, pp. 3

以上是原笔记的三节点路径规则。在因果 Markov 性质下，若不存在其他开放路径，阻断路径可推出所写的独立关系。开放路径允许依赖，但若不另加忠实性（faithfulness）条件，并不必然产生依赖，因为效应可能相互抵消。调整中介变量会阻断部分总效应，属于过度控制；调整碰撞点则可能产生选择偏差。

参考： 教材第 4 章.

第 5 章：线性回归的作用

原扫描页码： Chapter1-23.pdf, p. 4

对个体 i，写作 $Y_{1i} = Y_{0i} + k$，目标是估计 k。一元回归为

$$Y_i = \beta_0 + kT_i + u_i, \qquad \hat{\beta}_1 = \frac{\mathrm{Cov}(Y_i, T_i)}{\mathrm{Var}(T_i)}.$$

图中的直线从 $T = 0$ 时的截距，连到 $T = 1$ 时的“截距加 k”（原图画的是负斜率）。当 T 随机分配时，其回归系数就是 ATE。

多元回归用来处理影响 T_i 的多个因素：

$$y_i = \beta_0 + kT_i + \beta_1 X_{1i} + \cdots + \beta_K X_{Ki} + u_i.$$

X 是辅助协变量。此时

$$k = \frac{\mathrm{Cov}(Y_i, \widetilde{T}_i)}{\mathrm{Var}(\widetilde{T}_i)}.$$

我的批注。先把 X 能解释的部分去掉，取残差 $\widetilde{T}$；剩下的就是 X 解释不了的部分。

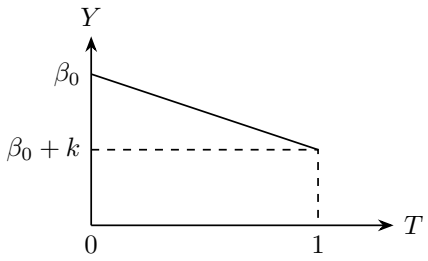
本来需要多元回归，却在一元回归中漏掉变量时，考虑正确模型

$$\text{Wage}_i = \alpha + k\,\text{Educ}_i + A_i'\beta + u_i,$$

其中 A_i 是能力。遗漏变量的计算为

$$\frac{\text{Cov}(\text{Wage}_i, \text{Educ}_i)}{\text{Var}(\text{Educ}_i)} = k + \beta'\delta_{\text{Ability}}.$$

δ_A 是把能力对教育回归得到的系数向量。多出来的项就是遗漏变量偏差（OVB）。 若所有混杂因素都纳入，就没有 OVB。**旁注：** RCT 打破这层关系；回归则控制它，使其固定。



原扫描第 4 页：二元处理回归，保留原图的负斜率。

原笔记的指向关系。

先用 X 预测，再取无法解释的部分	$\longrightarrow$	$\widetilde{T} = T - E\widehat{[T \mid X]}$（此处为线性投影）
遗漏项是能力	$\longrightarrow$	$A_i'\beta$
能力对教育回归	$\longrightarrow$	δ_A
OVB：遗漏变量偏差	$\longrightarrow$	$\beta'\delta_A$

原笔记纠错 (B1-007): 残差回归的方向

来源：Chapter1-23.pdf, pp. 4

原笔记黑色句子中的回归方向写反了，蓝色批注已指向正确做法。令 P_X 包含截距，取 $\widetilde{T} = (I - P_X)T$，则 $\hat{k} = \widetilde{T}'Y/(\widetilde{T}'\widetilde{T})$。反过来把 X 对 T 回归，得不到这个残差。

参考： 教材第 5 章.

补充条件 / 待确认 (B1-008): 回归调整仍需要因果识别条件

来源：Chapter1-23.pdf, pp. 4

纳入所有混杂因素，还需结合一致性、重叠性、条件可交换性及合适的调整模型。所写的 OVB 恒等式使用了 $\text{Cov}(\text{Educ}, u) = 0$。即使相关协变量都已测量，加性线性模型仍可能设定错误；在效应异质时，加入协变量也不会自动识别未加权的 ATE。

参考： 教材第 5 章.

第 6 章：分组与虚拟变量回归

原扫描页码： Chapter1-23.pdf, p. 5

异方差是指在不同协变量取值下，结果的方差不相同。分组越细，组内样本越少；分组减少变异，但系数标准误可能增大，t 统计量变小。各组的回归应按组内处理变量的方差加权。

处理为虚拟变量时（笔记举例："是否为 12 年教育"），

$$\text{wage}_i = \beta_0 + \beta_1 T_i + e_i.$$

$T = 0$ 时，期望等于截距；$T = 1$ 时，等于截距加 β_1。IQ 为连续变量时，

$$\text{wage}_i = \beta_0 + \beta_1 T_i + \beta_2 \text{IQ}_i + \beta_3 \text{IQ}_i T_i + e_i.$$

- β_0：$T = 0$、IQ $= 0$ 时的期望。
- β_1：IQ 为零时，T 增加一单位的影响（其他项均为零）。
- β_2：$T = 0$ 时，IQ 增加一单位的影响。
- β_3：$T = 1$ 时 IQ 也有回报；当 $\beta_3 > 0$，这一组的回归斜率更大。

分析 T_i 的系数，需要算各组对总系数的贡献：按教育年限分组（笔记以 12 年为例），求相应的类别教育 / 处理差异 $C(\text{educ})[T_i]$。

有更多协变量时，目标系数是各虚拟变量子组效应的加权平均：

$$E[\{E[Y_i \mid T = 1, G_i] - E[Y_i \mid T = 0, G_i]\}\, w(G_i)], \qquad w(G_i) \propto \text{Var}(T_i \mid G_i).$$

权重取决于子组内 T_i 的分布。旁注要求求出教育分组和 IQ 分箱的处理差异。

原笔记的指向关系。

二元处理从 0 变为 1	$\longrightarrow$	此回归中的 $E[Y \mid T = 1] - E[Y \mid T = 0] = \beta_1$
IQ 也改变 $T = 1$ 组的斜率	$\longrightarrow$	交互项系数 β_3

补充条件 / 待确认 (B1-009): 子组回归权重需归一化

来源：Chapter1-23.pdf, pp. 5

若每组有独立截距、共用一个处理系数，则 $\beta = \sum_g P(G = g) v_g \tau_g / \sum_g P(G = g) v_g$，其中 $v_g = \text{Var}(T \mid G = g)$。等价地，原笔记外层期望中的权重为 $w(g) = v_g / E[v_G]$。这一般是按方差加权的效应，而不是通常的 ATE；因果解释还需要组内调整有效。

参考： 教材第 6 章.

第 7 章：控制混杂因素之外

原扫描页码： Chapter1-23.pdf, p. 6

本章讨论控制特定变量的后果。在 $X \to Y \leftarrow T$ 中，研究 $X \to Y$ 时控制 T，可以把 X 的作用看得更清楚，降低其估计方差。第二幅图是 $B \to A \to X \to Y$ 及 $B \to Y$：A 只与 X 相关，B 则同时与 X、Y 相关。批注说加入仅与 X 相关的 A 会增大方差（原手写标的是 Y 的方差）。

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_i (y_i - \hat{y}_i)^2, \qquad \text{Var}(\hat{\beta}_2) = \frac{\hat{\sigma}^2}{\sum_i (x_i - \bar{x})^2}.$$

旁边的黑色文字写道：“标准误与 X 的方差成反比。”样本的变化越大，标准误越小。

没有控制共同原因而产生的是混杂偏差；控制共同结果，或控制因果路径上的变量，会产生选择偏差。

不当控制与参与行为。 若处理影响结果是否为零，RCT 下均值之差具有因果解释。笔记将其分为参与效应与正结果中的效应：

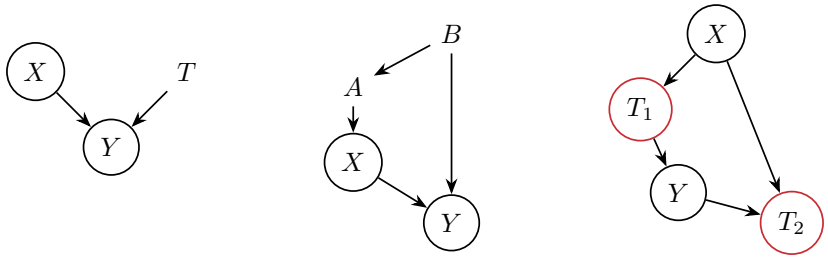
$$E[Y \mid T=1] - E[Y \mid T=0] = \{P(Y>0 \mid T=1) - P(Y>0 \mid T=0)\}E[Y \mid Y>0, T=1] + \{E[Y \mid Y>0, T=1] - E[Y \mid Y>0, T=0]\}P(Y>0 \mid T=0).$$

旁注把第一部分标为结果为正的概率变化，并区分顾客“是否参与”和“消费能力”。只分析参与者时，

$$E[Y_{i1} \mid Y_{i1}>0] - E[Y_{i0} \mid Y_{i0}>0] = \underbrace{E[Y_{i1} - Y_{i0} \mid Y_{i1}>0]}_{\text{参与者中的因果效应}} + \underbrace{E[Y_{i0} \mid Y_{i1}>0] - E[Y_{i0} \mid Y_{i0}>0]}_{\text{选择偏差}}.$$

最后一项比较参与者与未参与者［批注结尾被扫描边缘截去］。

配图为 $X \to T_1 \to Y \to T_2$，另有 $X \to T_2$。T_1, T_2 用红色标为不当选择 / 控制：“不要控制！”



原扫描第 6 页：改善精度的控制、处理变量的预测因素，以及红圈标出的不当控制。

原笔记的指向关系。

只与 X 有关；加入后增大方差（原文）	$\longrightarrow$	第二幅图中的 A
同时与 X、Y 有关	$\longrightarrow$	第二幅图中的 B
不当控制：不要条件化	$\longrightarrow$	下方图中的中介 T_1 和碰撞点 T_2
参与效应	$\longrightarrow$	$P(Y>0 \mid T=1) - P(Y>0 \mid T=0)$
选择偏差	$\longrightarrow$	$E[Y_0 \mid Y_1>0] - E[Y_0 \mid Y_0>0]$

补充条件 / 待确认 (B1-010): 精度、不当控制与参与行为

来源：Chapter1-23.pdf, pp. 6

在同方差的一元 OLS 中，$\mathrm{SE}(\hat{\beta}) = \sigma / \sqrt{\sum_i (x_i - \bar{x})^2}$：标准误与处理变量变异的平方根成反比。多元回归应使用残差化后的处理变量和正确的残差自由度。这里的方差直觉针对处理效应估计量，并

非说 Var(Y) 本身发生了变化。参与效应分解假设 $Y \geq 0$（或结果只可能为零和正数）；若无额外假设，两个代数分量不能分别解释为因果效应。

参考： 教材第 7 章.

第 8 章：工具变量

原扫描页码： Chapter1-23.pdf, pp. 7–8

假设

$$Y_i = \beta_0 + kT_i + \beta W_i + u_i,$$

其中 T 是处理，W 是混杂变量。当 W_i 不可观测时，拟合 $Y_i = \beta_0 + kT_i + v_i$，其中 $v_i = \beta W_i + u_i$。此时 $\mathrm{Cov}(T, v) \neq 0$，所以 k 的估计有偏。未观测项携带着联系 T、Y 的信息。

引入工具变量 Z：它与 T 相关，只通过 T 影响 Y，且 $\mathrm{Cov}(Z, v) = 0$。图为 $Z \to T \to Y$、$W \to T$、$W \to Y$。因此

$$\begin{aligned}
\mathrm{Cov}(Z, Y) &= \mathrm{Cov}(Z, \beta_0 + kT + v) \\
&= k\,\mathrm{Cov}(Z, T) + \mathrm{Cov}(Z, v) = k\,\mathrm{Cov}(Z, T), \\
k &= \frac{\mathrm{Cov}(Z, Y)}{\mathrm{Cov}(Z, T)} = \frac{\mathrm{Cov}(Y, Z)/\,\mathrm{Var}(Z)}{\mathrm{Cov}(T, Z)/\,\mathrm{Var}(Z)}.
\end{aligned}$$

分子、分母都是回归系数。分子是简约式（reduced form）系数：Z 只经过 T 对 Y 产生的影响。

我的微积分直觉。

$$k = \frac{dY/dZ}{dT/dZ} = \frac{dY}{dZ}\frac{dZ}{dT} = \frac{dY}{dT}.$$

若工具变量是二元的，Wald 估计量为

$$k = \frac{E[Y \mid Z = 1] - E[Y \mid Z = 0]}{E[T \mid Z = 1] - E[T \mid Z = 0]}.$$

笔记将其理解为：把 $Z \to Y$ 的变化换算回 $T \to Y$ 的作用。

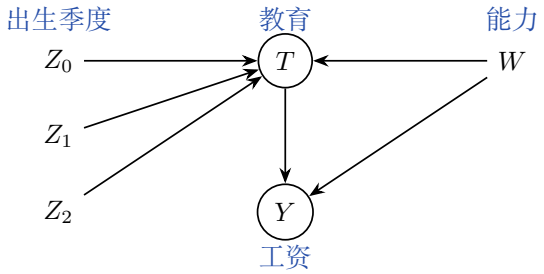
工具变量的使用。 例子中，Z_0 为 qob（出生季度），T 为教育，W 为能力，Y 为工资，另有变量 Z_1, Z_2。写出的要求是：(1) $\mathrm{Cov}(Z, T) \neq 0$，可直接用数据检验；(2) $Y \perp Z \mid T$，后面打了问号，并写“Z 仅通过 T 影响 Y”。**作者的红色更正：**“不准确，Chapter 09 中更正。” 因此这里保留的是作者后来已否定的旧说法，而非认可这一条件独立假设。

先回归 $T \sim Z_0$，检查第一阶段关系；再回归 $Y \sim Z_0$，看简约式关系。方法一是取两个回归系数之比。方法二是 2SLS：

1. 将 T 对 Z_0, Z_1, Z_2 回归。
2. 将 Y 对拟合后的 T 及 Z_1, Z_2 回归；图中用 (Z_0, Z_1, Z_2) 代指拟合后的 T。

代码旁注说可以指定 $T \sim Z_0$，因为其他项会在第二阶段自动加入。 用作比较的 OLS 写作 $Y \sim T + C(Z_0, Z_1, Z_2)$。

当 T 与 Z 的相关性很弱时，OLS 与 2SLS 的估计不同，标准误较大 [末尾括号内的词无法辨清]。2SLS 在有限样本中偏向 OLS，偏差方向与 OLS 相同；2SLS 一致，而 OLS 不一致。工具变量越多，偏差越大；工具变量过多时，2SLS 越来越像 OLS。



原扫描第 7–8 页：工具变量、处理、混杂因素与结果。

原笔记的指向关系。

联系 T、Y 的信息	$\longrightarrow$	$v_i = \beta W_i + u_i$
简约式：Z 经过 T 影响 Y	$\longrightarrow$	$\mathrm{Cov}(Y, Z)/\mathrm{Var}(Z)$
不准确；Chapter 09 中更正	$\longrightarrow$	原先提出的条件 $Y \perp Z \mid T$

原笔记纠错 (B1-011): 排除限制不是观测结果的条件独立

来源：Chapter1-23.pdf, pp. 8

作者的红色更正是恰当的。排除限制是 $Y(t, z) = Y(t)$，并需结合工具变量外生性；一般并不是 $Y \perp Z \mid T$。图中条件化碰撞点 T 会打开 $Z \to T \leftarrow W \to Y$。因此，一个有效工具变量在给定处理后，仍可能与观测到的 Y 相关。

参考： 教材第 9 章.

补充条件 / 待确认 (B1-012): IV 比值与有限样本结论

来源：Chapter1-23.pdf, pp. 7, 8

在所写的常斜率模型中，协方差比值来自 $\mathrm{Cov}(Z, v) = 0$ 与非零的第一阶段。导数约分适合帮助理解一条可微的单一路径，不能作为随机、异质 IV 模型的一般证明。通常的 2SLS 一致性要求有效且足够强的工具变量，以及维数固定的常规渐近条件；弱工具或工具过多时，不能无条件声称一致。这里的 Z_1, Z_2 应理解为纳入的外生控制变量，在两个阶段都保留。

参考： 教材第 8 章.

第 9 章：不依从与局部平均处理效应

原扫描页码： Chapter1-23.pdf, pp. 9–10

依从者（compliers）服从分配；从不接受者（never-takers）始终不接受处理；总是接受者（always-takers）始终接受处理；违抗者（defiers）则反着做。在 $Z \to T \to Y$、$W \to T$ 和 $W \to Y$ 中，从不接受者与总是接受者削弱第一阶段。蓝色直觉说明：例如从不接受者会把简约式中的结果差异拉向对照状态。

现在潜在结果有两个自变量：$Y_i(t, z)$；笔记以 $T_i = 1, Z_i = 0$ 时的 $Y_i(1, 0)$ 为例。潜在处理 T_{0i} 对应 $Z_i = 0$。

原笔记列出的 IV 假设。

1. $(T_{0i}, T_{1i}) \perp Z_i$ 且 $(Y_i(T_{1i}, 1), Y_i(T_{0i}, 0)) \perp Z_i$。$Z$ 与潜在处理无关，不同工具变量组中的人具有可比性。
2. 排除限制：$Y_i(1,0) = Y_i(1,1) = Y_{i1}$，$Y_i(0,0) = Y_i(0,1) = Y_{i0}$。工具变量只能通过处理影响结果。
3. $E[T_{1i} - T_{0i}] \neq 0$：存在第一阶段，工具变量确实会影响处理。
4. 原扫描写作 $T_{1i} > T_{0i}$，并说明打开工具变量会提高接受处理的概率。

推导 Wald 目标量。 原笔记起初把下面的比值标为“ATE”：

$$\frac{E[Y \mid Z = 1] - E[Y \mid Z = 0]}{E[T \mid Z = 1] - E[T \mid Z = 0]}.$$

利用排除限制和随机分配，

$$\begin{aligned} E[Y_i \mid Z_i = 1] &= E[Y_{i0} + T_{i1}(Y_{i1} - Y_{i0}) \mid Z_i = 1] \\ &= E[Y_{i0} + T_{i1}(Y_{i1} - Y_{i0})], \\ E[Y_i \mid Z_i = 0] &= E[Y_{i0} + T_{i0}(Y_{i1} - Y_{i0})]. \end{aligned}$$

分子为

$$E[(Y_{i1} - Y_{i0})(T_{i1} - T_{i0})] = E[Y_{i1} - Y_{i0} \mid T_{i1} > T_{i0}]P(T_{i1} > T_{i0}),$$

分母为 $E[T_{i1} - T_{i0}] = P(T_{i1} > T_{i0})$。所以比值为

$$E[Y_{i1} - Y_{i0} \mid T_{i1} > T_{i0}].$$

作者的红色批注：这个平均处理效应还附带一个条件：依从。IV 只识别依从者的处理效应。依从者满足 $T_{i1} > T_{i0}$；从不接受者满足 $T_{i1} = T_{i0} = 0$；总是接受者满足 $T_{i1} = T_{i0} = 1$；违抗者与分配方向相反。

原笔记的指向关系。

从不接受者 / 总是接受者削弱第一阶段	$\longrightarrow$	$Z \longrightarrow T$
工具变量各组具有可比性	$\longrightarrow$	工具变量外生性假设
工具变量只通过处理影响结果	$\longrightarrow$	$Y_i(t,0) = Y_i(t,1)$
这个条件表示依从	$\longrightarrow$	最终条件期望中的 $T_{i1} > T_{i0}$

原笔记纠错 (B1-013): 非严格单调性与 LATE 的名称

来源：Chapter1-23.pdf, pp. 9, 10, 23

原假设写了 $T_1 > T_0$，但随后列出的类型包含 $T_1 = T_0$。总体条件应改为几乎处处 $T_1 \geq T_0$，且 $P(T_1 > T_0) > 0$。在联合工具变量外生性和排除限制下，令 $C = \{T_1 > T_0\}$，分子为 $P(C)E[Y_1 - Y_0 \mid C]$，分母为 $P(C)$。比值是 LATE，而非总体 ATE。第 23 页模糊断点回归也应使用同样的非严格单调条件。

参考： 教材第 9 章; Imbens–Angrist，LATE 识别.

第 10 章：匹配

原扫描页码： Chapter1-23.pdf, pp. 11–12

按混杂因素分组估计 ATE 时，对各组处理效应加权。按样本量加权会更偏向大组，即使该组的处理变异很小；这里标为“非参数估计”。按方差加权时，方差较大的组权重更大；这与线性、参数回归更强调高变异协变量的做法相联系。

分层。 如果 X 造成混杂，就把 X 相同的观测分在一组。在 $(Y_0, Y_1) \perp T \mid X$ 下，

$$\text{ATE} = \int \{E[Y \mid X = x, T = 1] - E[Y \mid X = x, T = 0]\}\, dP(x),$$

$$\widehat{\text{ATE}} = \sum_{k=1}^{K} (\bar{Y}_{k1} - \bar{Y}_{k0}) \frac{N_k}{N}.$$

蓝色批注是在协变量取值 $\{x_1, \ldots, x_K\}$ 上取平均。

匹配估计量。 用观测之间的距离定义相似程度，再比较接受不同处理的相似 / 邻近个体。旁边记了 K 近邻。定义距离时，对坐标作标准化：$(x_i - \bar{x})/\sqrt{\text{Var}(x)}$。

$$\widehat{\text{ATE}} = \frac{1}{N} \sum_{i} (2T_i - 1)(Y_i - Y_{j(i)}).$$

$j(i)$ 是另一个处理组中与 i 最相似的观测。 $2T_i - 1$ 根据个体所属的处理组调整正负号。

匹配偏差及修正。 对处理组，考虑

$$\widehat{\text{ATET}} = \frac{1}{N_1} \sum_{i:T_i=1} (Y_i - Y_{j(i)}), \qquad \mu_0(x) = E[Y \mid X = x, T = 0].$$

中心化偏差写作

$$E[\sqrt{N_1}(\widehat{\text{ATET}} - \text{ATET})] = E[\sqrt{N_1}\{\mu_0(X_i) - \mu_0(X_{j(i)})\}],$$

它不一定趋于零。乘上 $\sqrt{N_1}$ 会把偏差放大。蓝色解释比较的是 X_i 对应个体未处理的潜在结果（因为 i 已接受处理，所以是反事实）与 X_j 对应个体实际观测到的未处理结果；用 $X_i \approx X_j$ 希望二者未处理结果也接近。 对估计量作修正，使其收敛：

$$\widehat{\text{ATET}}_{\text{bc}} = \frac{1}{N_1} \sum_{i:T_i=1} \left[(Y_i - Y_{j(i)}) - \{\hat{\mu}_0(X_i) - \hat{\mu}_0(X_{j(i)})\}\right].$$

$\hat{\mu}_0$ 可以用最小二乘等方法估计。局部 LS 修正不改变匹配估计量原本的目标。

维数灾难。协变量越多，匹配距离越大，因为每个小格子里的观测更少。

原笔记的指向关系。

对协变量取值求平均	$\longrightarrow$	$\int \tau(x)\, dP(x)$
按处理组调整符号	$\longrightarrow$	$2T_i - 1$
另一处理组里最相似的个体	$\longrightarrow$	$j(i)$
已处理个体未处理时的反事实均值	$\longrightarrow$	$\mu_0(X_i)$
观测对照个体的对应均值	$\longrightarrow$	$\mu_0(X_{j(i)})$
修正中心化偏差	$\longrightarrow$	减去 $\hat{\mu}_0(X_i) - \hat{\mu}_0(X_{j(i)})$
特征更多，匹配距离更大	$\longrightarrow$	每个格子内的观测更少

补充条件 / 待确认 (B1-014): 匹配偏差与目标量

来源： *Chapter1-23.pdf, pp. 11, 12*

相关偏差应为 $B_N = N_1^{-1} \sum_{i:T_i=1} [\mu_0(X_i) - \mu_0(X_{j(i)})]$，所以中心化后的偏差是 $\sqrt{N_1} B_N$；原笔记只写一个 i，是对该平均的简写。近邻估计一致，不代表根号 N 尺度的偏差就可忽略。偏差修正需要合适的光滑性、重叠性及一致的回归逼近。按样本占比加权以 ATE 为目标，按处理方差加权一般对应另一个平均量。

参考： 教材第 10 章; Abadie–Imbens，偏差修正匹配.

第 11 章：倾向得分

原扫描页码： Chapter1-23.pdf, pp. 13–14

处理混杂偏差的另一种办法，是用一个介于 0 和 1 之间的数概括混杂因素。图为 $X \to p(X) \to T \to Y$，并有 $X \to Y$。这一页把 $(Y_1, Y_0) \perp T \mid p(X)$ 与下面的平衡恒等式用双向箭头相连：

$$E[T \mid p(X), X] = E[T \mid p(X)].$$

我的例子。两个人，一个已处理，一个未处理。若接受处理的概率相同，即使他们的 X 不同，也可以比较。

$$\begin{aligned} E[T \mid p(X), X] &= E[T \mid X] = p(X), && \text{因为} p(X) \text{是} X \text{的函数,} \\ E[T \mid p(X)] &= E[E[T \mid p(X), X] \mid p(X)] \\ &= E[p(X) \mid p(X)] = p(X). \end{aligned}$$

逆倾向加权（IPW）。 条件差异可以改写为

$$\begin{aligned} E[Y \mid X, T=1] - E[Y \mid X, T=0] = p(X) E\left[\frac{Y}{p(X)} \,\middle|\, X, T=1 \right] \\ - \{1 - p(X)\} E\left[\frac{Y}{1 - p(X)} \,\middle|\, X, T=0 \right]. \end{aligned}$$

? **我的理解。**我们观测到个体 i 接受了处理，但 i 接受处理的概率只有由 X 决定的 $p(X_i)$。给每个观测到的处理个体乘上 $1/p(X_i)$ 来修正。若 $p(X_i)$ 很小，该观测在未加权的结果分布中占比不足，

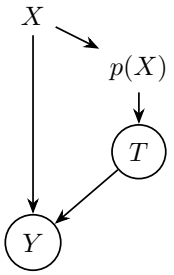
就用概率倒数提高其代表性。$T=1$ 和 $T=0$ 的权重分别为 $1/p(X)$ 与 $1/(1-p(X))$。这样重建“人人都处理”的总体（Y_1）和“人人都不处理”的总体（Y_0），两者之差就是 ATE。

笔记写出的加权方差为

$$\hat{\sigma}^2_w = \frac{\sum_{i=1}^{n} w_i (Y_i - \hat{\mu})^2}{\sum_{i=1}^{n} w_i}.$$

但倾向得分估计 $\hat{p}(X)$ 本身也有误差。随意加入并非混杂因素的协变量，可能使倾向得分估计变得非常不稳定。已处理者估计出的处理概率可能高于未处理者。页底提醒：倾向权重超过 20% 会增大方差（此阈值按原文保留）。

倾向得分匹配。 用 $p(X)$ 替代原本的匹配距离。作者评语是“这个不是很好”。处理预测更准确，不一定使因果估计更好，反而可能增加方差。处理组与未处理组的倾向得分分布若缺乏重叠，匹配就会有问题。



$$(Y_0, Y_1) \perp T \mid p(X)$$

$$\Updownarrow$$

$$E[T \mid p(X), X] = E[T \mid p(X)]$$

原扫描第 13 页：倾向得分图及原有双向箭头，其含义在校注中加以限定。

原笔记的指向关系。

平衡恒等式：分别展开两边	$\longrightarrow$	$E[T \mid p(X), X] = E[T \mid p(X)] = p(X)$
对观测处理组加权	$\longrightarrow$	构造人人都处理的 Y_1 总体
对观测对照组加权	$\longrightarrow$	构造人人都未处理的 Y_0 总体

原笔记纠错 (B1-015): 平衡不等价于可忽略性

来源：Chapter1-23.pdf, pp. 13

原图的双向箭头并不是逻辑等价。对真实的二元处理倾向得分 $e(X) = P(T = 1 \mid X)$，恒等式 $E[T \mid e(X), X] = E[T \mid e(X)]$ 成立。条件可交换性 $(Y_0, Y_1) \perp T \mid X$ 可推出 $(Y_0, Y_1) \perp T \mid e(X)$。要在目标总体上识别两个处理状态的均值，还需重叠性；但上述条件独立命题本身不需要重叠性。相同倾向得分平衡的是协变量分布，并不意味着两个具体个体的潜在结果完全相同。

参考： 教材第 11 章.

补充条件 / 待确认 (B1-016): 结果的加权离散程度不是 IPW 估计量的方差

来源：Chapter1-23.pdf, pp. 13, 14

$\sum w_i (Y_i - \hat{\mu})^2 / \sum w_i$ 衡量结果的加权离散程度，并非 IPW ATE 估计量的抽样方差。倾向得分已知时，定义 $\psi_i = T_i Y_i / e_i - (1 - T_i) Y_i / (1 - e_i)$；独立同分布样本下，其样本均值的方差估计为 s^2_ψ / n。

若干扰函数需要估计，则应使用恰当的影响函数或其他有效推断方法。原笔记的 20% 是没有说明归一化方式的经验提醒，不是通用阈值。

参考： 教材第 11 章.

第 12 章：双重稳健估计

原扫描页码： Chapter1-23.pdf, p. 15

结合线性结果回归与倾向加权，估计给定 X 时处理和对照的差异：

$$\widehat{\text{ATE}} = \frac{1}{N}\sum_i \left[\frac{T_i\{Y_i - \hat{\mu}_1(X_i)\}}{\hat{p}(X_i)} + \hat{\mu}_1(X_i)\right] - \frac{1}{N}\sum_i \left[\frac{(1-T_i)\{Y_i - \hat{\mu}_0(X_i)\}}{1-\hat{p}(X_i)} + \hat{\mu}_0(X_i)\right].$$

其中 $\hat{p}(X)$ 估计倾向得分（例如用 logistic 回归），$\hat{\mu}_1(X)$ 和 $\hat{\mu}_0(X)$ 分别估计 $E[Y \mid X, T=1]$ 和 $E[Y \mid X, T=0]$。第一个平均估计 $E[Y_1]$，第二个估计 $E[Y_0]$。倾向模型与结果模型只需有一个正确。

我的代数解释。对 $E[Y_1]$，

$$\widehat{E}[Y_1] = \frac{1}{N}\sum_i \left[\frac{T_i\{Y_i - \hat{\mu}_1(X_i)\}}{\hat{p}(X_i)} + \hat{\mu}_1(X_i)\right].$$

若 $\hat{p}$ 错了，但 $\hat{\mu}_1$ 正确：$T_i = 0$ 时第一项为零，$T_i = 1$ 时它的均值为零，所以剩下回归预测。原笔记简写为 $E[\hat{\mu}_1(X_i)] = Y_i$。

也可以改写为

$$\widehat{E}[Y_1] = \frac{1}{N}\sum_i \left[\frac{T_i Y_i}{\hat{p}(X_i)} - \frac{T_i - \hat{p}(X_i)}{\hat{p}(X_i)}\hat{\mu}_1(X_i)\right].$$

若结果模型错误、倾向模型正确，则给定 X_i 时 $T_i - \hat{p}(X_i)$ 的均值为零，修正项的期望因此消失。

最后提醒：理论与数据都要正确；即使从单个模型入手，也尽量使用 DRE。

原笔记的指向关系。

把两种方法结合	$\longrightarrow$	结果回归 + 倾向加权 $\longrightarrow$ 双重稳健估计量
第一组括号估计 $E[Y_1]$，第二组估计 $E[Y_0]$	$\longrightarrow$	两者相减即为 ATE
倾向模型错误、结果模型正确时	$\longrightarrow$	第一种写法中的残差均值抵消
原笔记星号条件：$E[T_i - \hat{p}(X_i)] = 0$	$\longrightarrow$	另一种写法；需给定 X_i 才能据此抵消

原笔记纠错 (B1-017): 双重稳健的抵消依赖条件期望

来源：Chapter1-23.pdf, pp. 15

原文 $E[\hat{\mu}_1(X_i)] = Y_i$ 不是恒等式。若 μ_1 正确，则 $E[T(Y - \mu_1(X))/q(X) \mid X] = 0$。若倾向得分 e 正确，则对任意固定函数 m，$E[TY/e - (T-e)m(X)/e \mid X] = \mu_1(X)$。对两个处理状态分别应用，再平均。这里需要一致性、条件可交换性、重叠性及恰当的估计控制；对 ATE，“结果模型正确”指两个处理状态的结果回归都正确。

参考： 教材第 12 章.

第 13 章：双重差分

原扫描页码： Chapter1-23.pdf, p. 17; placed before Chapter 14 on pp. 16 and 18

双重差分用于评估宏观干预的效果。D 表示处理，T 表示时间；$Y_D(T)$ 是在时期 T、处理状态 D 下的潜在结果。

两种比较及其问题。 处理组的目标为 $E[Y_1(1) - Y_0(1) \mid D = 1]$，即比较同一时期处理与未处理的结果；其中 $Y_0(1)$ 是反事实。处理前，$E[Y_1(0) \mid D = 1] = E[Y_0(0) \mid D = 1]$。前后比较用干预前的结果代替干预后未处理的结果；但若有时间趋势，这两个未处理潜在结果未必相同。

在干预后作处理组 / 对照组比较：

$$E[Y(1) \mid D = 1] - E[Y(1) \mid D = 0].$$

它用对照组干预后的未处理结果估计处理组的反事实。蓝色批注提醒：这种比较也可能失败。

将两种比较结合：

$$\begin{aligned}\widehat{\text{ATET}} = &\{E[Y(1) \mid D = 1] - E[Y(1) \mid D = 0]\} \\ &- \{E[Y(0) \mid D = 1] - E[Y(0) \mid D = 0]\}.\end{aligned}$$

连接箭头给出等价理解：实验组的“后减前”，再减去对照组的“后减前”。旁注记了带交互项的线性模型、未知方差，以及“检查平行［趋势］”。

原笔记的指向关系。

同一干预后时期的反事实	$\longrightarrow$	$Y_0(1) \mid D = 1$
前后比较可能失败	$\longrightarrow$	未处理潜在结果也可能随时间变化
弯曲连接箭头的另一种读法	$\longrightarrow$	(处理组后期 − 处理组前期) − (对照组后期 − 对照组前期)

补充条件 / 待确认 (B1-018): 平行趋势是识别假设

来源：Chapter1-23.pdf, pp. 16, 17, 18

两期 ATT 需要无预期效应以及 $E[Y_0(1) - Y_0(0) \mid D = 1] = E[Y_0(1) - Y_0(0) \mid D = 0]$，还需一致性、无溢出及可比的群体构成。这是关于未处理结果均值趋势的条件；它既不识别每个人的反事实，也不要求对 $d = 0, 1$ 都满足完全独立。前期检验不能证明未来仍满足平行趋势。组内变换消除的是加性的、不随时间变化的效应；固定效应的因果估计仍需外生性，通常为 $E[e_{it} \mid X_{i1}, \ldots, X_{iT}, U_i] = 0$。

参考： 教材第 13 章; 教材第 14 章.

第 14 章：面板数据与固定效应

原扫描页码： Chapter1-23.pdf, pp. 16 and 18

面板数据在多个时间反复观测同一个人，固定个体身份，避免固定特征造成的混杂偏差。笔记把固定效应模型理解为控制个体因素的办法［扫描中写有一个简短的“IV”缩写］。

回顾 DID。对处理城市，干预后的未处理反事实可用“其干预前未处理结果 + 未处理城市随时间的变化”估计：

$$Y_0(1) \mid D = 1 = Y_0(0) \mid D = 1 + \{Y_0(1) \mid D = 0 - Y_0(0) \mid D = 0\}.$$

于是 $\widehat{\text{ATT}} = Y_1(1) \mid D = 1 - \widehat{Y_0}(1) \mid D = 1$：第一项已知，第二项估计。例子旁注提到在 DMA 投放广告的效果。

平行趋势意味着处理分配与潜在结果随时间的增长无关。原扫描写作 $(Y_d(t) - Y_d(t-1)) \perp D$。

$$y_{it} = \beta X_{it} + \gamma U_i + e_{it}.$$

y_{it} 是个体 i 在时间 t 的结果，X_{it} 是随时间变化的处理 / 协变量，U_i 是一组无法观测、但不随时间变化的特征。

面板数据的局限（续页上方批注）。 面板数据不能解决反向因果：原因和结果互相增强，固定效应无法控制这种关系。它也不能消除随时间变化的未观测混杂因素。

线性面板模型的残差化。 对于两组特征 X_1, X_2，

$$\hat{y} = \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2.$$

图中的特征矩阵以观测为行、特征为列。

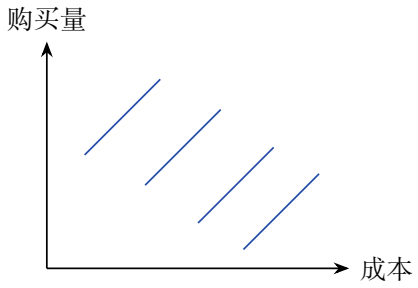
1. 将 y 对第二组特征回归：$\hat{y}^* = \hat{\gamma}_1 X_2$。
2. 将 X_1 对 X_2 回归：$\hat{X}_1 = \hat{\gamma}_2 X_2$。
3. 取残差 $\widetilde{X}_1 = X_1 - \hat{X}_1$ 和 $\widetilde{y} = y - \hat{y}^*$。
4. 将结果残差对特征残差回归，得到 X_1 的系数。

组内变换（within transformation）。 计算 $\ddot{Y}_{it} = Y_{it} - \bar{Y}_i$ 和 $\ddot{X}_{it} = X_{it} - \bar{X}_i$，再将 $\ddot{Y}_{it}$ 对 $\ddot{X}_{it}$ 回归。因为 $\bar{U}_i = U_i$，固定效应消失：

$$\begin{aligned} Y_{it} &= \beta X_{it} + \gamma U_i + e_{it}, \\ \bar{Y}_i &= \beta \bar{X}_i + \gamma \bar{U}_i + \bar{e}_i, \\ Y_{it} - \bar{Y}_i &= \beta(X_{it} - \bar{X}_i) + \gamma(U_i - \bar{U}_i) + (e_{it} - \bar{e}_i), \\ \ddot{Y}_{it} &= \beta \ddot{X}_{it} + \ddot{e}_{it}. \end{aligned}$$

这样去掉了所有不随时间变化的未观测特征。对通胀等时间效应，可为每个时期加入一个虚拟变量；随时间变化的因素也可能重要。按个体分组后，对偏差求和：固定特征的偏差总和为零，体现它在同一个体内部不变。

图中画了多条平行的“购买量—成本”直线。固定效应模型给每个城市拟合一条线，并假定不同条件下的因果效应相同。



原扫描第 18 页：各城市内部平行的购买量—成本直线，保留蓝色。

原笔记的指向关系。

反复观测同一个人	$\longrightarrow$	固定个体特征
个体 i 在时间 t 的结果	$\longrightarrow$	y_{it}
处理随时间变化	$\longrightarrow$	X_{it}
未观测特征不随时间变化	$\longrightarrow$	U_i
$\bar{U}_i = U_i$	$\longrightarrow$	组内变换消除固定效应

第 15 章：合成控制

原扫描页码： Chapter1-23.pdf, pp. 19–21

面板方法需要分解到个体的数据。如果只有聚合数据，或者找不到相似的对照单位，就把若干单位组合成一个相似单位。

共有 $J+1$ 个单位。单位 1 接受处理，$2,\ldots,J+1$ 未接受处理，组成供体库。Y^I_{jt}、Y^N_{jt} 是单位 j 在时间 t 有干预和无干预的潜在结果。处理从 T_0 开始。对 $t > T_0$，

$$\tau_{1t} = Y^I_{1t} - Y^N_{1t}.$$

已处理结果是事实，未处理结果是反事实；效应是时间的函数。 给定权重 $W = (w_2,\ldots,w_{J+1})$，

$$\widehat{Y}^N_{1t} = \sum_{j=2}^{J+1} w_j Y_{jt}.$$

可用回归选择这些权重：最小化干预前处理单位与供体加权平均之间的平方距离。

把合成控制看作回归。 用供体州构建一个虚拟加州。矩阵以年份为行、州为列，元素为香烟销量。将加州序列设为 Y，其他州序列设为 X，回归 $Y \sim X$。例子中的权重有 -0.436 和 -0.032（39 个州对应 39 个权重）。它们的加权和就是虚拟州，权重的选择使虚拟州与处理州尽量接近。

这样很容易过拟合：虚拟州在干预前几乎与加州重合，干预后却剧烈波动，甚至超过加州。笔记提到 Ridge 或 Lasso 回归。手写的规模比较是 “T 大，N 大”［无法明确其本意是哪种不等关系］。

避免外推。 前述过拟合归因于外推：权重把观测推到了数据范围以外。施加凸组合约束。合成控制仍为 $\widehat{Y}^N_{1t} = \sum_{j=2}^{J+1} w_j Y_{jt}$，但选择 W 来最小化

$$\|X_1 - X_0 W\|_V = \left\{ \sum_{h=1}^{k} v_h \left(X_{h1} - \sum_{j=2}^{J+1} w_j X_{hj} \right)^2 \right\}^{1/2}, \qquad w_j \geq 0, \quad \sum_{j=2}^{J+1} w_j = 1.$$

两幅图分别画出：从供体点无约束外推到三角形外的处理点；以及将拟合限制在供体凸包内。

v_h 反映各变量在匹配处理单位和合成控制时的重要性；不同 v_h 会得到不同权重。可把各变量标准化为均值零、方差一，或给更能预测 Y 的变量更高权重。这里的实现给各变量同等重要性：定义损失函数，用 SciPy 做二次优化，要求权重和为一，并将每个权重限制在 $[0,1]$。得到的权重稀疏、较小，且和为一（原手写示例向量含多个零及一个约为 0.3852 的元素）。

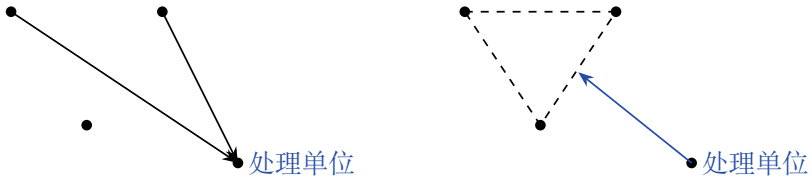
显著性与安慰剂比较。 采用 Fisher 精确 / 置换检验的思路。对 39 个州逐一重新拟合合成控制、估计效应。加州给出真实干预的估计，其他州给出安慰剂效应。若没有处理的州也出现很大效应，就有问题。干预后的变异大于干预前；一些单位在干预前就拟合不好，应剔除。用下式设置前期拟合阈值：

$$\text{MSE} = \frac{1}{N}\sum_{t}(Y_t - \widehat{Y}_t^{\text{synth}})^2.$$

笔记的检验步骤是算出各州效应，再计算

$$p = \frac{1}{N}\sum_{j}\mathbf{1}\{\hat{\tau}_{\text{California}} > \hat{\tau}_j\},$$

并提醒加州的效应为负。蓝色批注说只有一个州的效应“比加州高”，给出 $p = 0.0286$，认为加州的干预效应很极端（有效）。



外推　　凸包

原扫描第 20 页：外推与凸包约束，按原图几何关系示意。

原笔记的指向关系。

事实与反事实	⟶	Y_{1t}^{I} 与 Y_{1t}^{N}
效应是时间的函数	⟶	τ_{1t}
用回归寻找这些权重	⟶	$\widehat{Y}_{1t}^{N} = \sum_j w_j Y_{jt}$
前期几乎完美拟合也可能过拟合	⟶	合成单位在干预后大幅波动
对每个州重复同一程序	⟶	加州：实际效应；其他州：安慰剂效应
干预前拟合很差	⟶	设置前期 MSE 剔除阈值

补充条件 / 待确认 (B1-019): 聚合面板与合成控制的识别

来源： *Chapter1-23.pdf, pp. 19, 20*

面板也可以由城市或州的聚合数据构成，并不要求个体层面数据。合成控制还需要供体未受处理、无溢出 / 预期效应，以及把干预前后未处理结果联系起来的可信稳定关系。凸权重限制了供体凸包之外的外推，但本身不能消除过拟合，也不能保证因果识别。无法辨清的 T, N 大小批注应作为提醒，而非已证明的样本量规则。

参考： 教材第 15 章.

补充条件 / 待确认 (B1-020): 安慰剂检验的尾概率与分母

来源：Chapter1-23.pdf, pp. 21

负效应对应的单侧尾部应是 $\hat{\tau}_j \le \hat{\tau}_{\text{CA}}$，即“更负”，而不是“更高”。在均匀分配下，精确秩检验为 $p = \#\{j : S_j \le S_{\text{obs}}\}/J_{\text{eligible}}$，包含实际分配；抽样置换可用 $(1+b)/(B+1)$。精确性需要分配机制 / 可交换性的依据，并统一使用统计量和筛选规则。扫描中的信息不足以重建 0.0286；观察性研究中的安慰剂排名并不自动是 Fisher 精确检验。

参考： 教材第 15 章.

第 16 章：断点回归设计

原扫描页码： Chapter1-23.pdf, pp. 22–24

一个断点能告诉我们什么效应？令 R 为驱动变量，在阈值 c 处不连续地分配处理：

$$D_i = \mathbf{1}\{R_i > c\}.$$

低于 c 时处理为零，高于 c 时处理为一。 因而 $R > c$ 时观测 Y_1，$R < c$ 时观测 Y_0。图中潜在结果曲线 Y_1, Y_0 光滑，观测曲线在阈值处从 Y_0 切换到 Y_1。例子画年龄与所有死亡 / 机动车死亡 / 自杀之间的关系，寻找断点。

若潜在结果的均值光滑，左右极限相同，例如

$$\lim_{r \to c^-} E[Y_{1i} \mid R_i = r] = \lim_{r \to c^+} E[Y_{1i} \mid R_i = r].$$

因此观测结果的跳跃识别

$$\begin{aligned} &\lim_{r \to c^+} E[Y_i \mid R_i = r] - \lim_{r \to c^-} E[Y_i \mid R_i = r] \\ &\quad = \lim_{r \to c^+} E[Y_{1i} \mid R_i = r] - \lim_{r \to c^-} E[Y_{0i} \mid R_i = r] \\ &\quad = E[Y_{1i} - Y_{0i} \mid R_i = c]. \end{aligned}$$

原笔记称之为局部平均处理效应。**我的批注**。这是一个局部随机实验，最接近 RCT。

用断点两侧斜率不同的线性回归估计处理效应：

$$y_i = \beta_0 + \beta_1 r_i + \beta_2 \mathbf{1}\{r_i > c\} + \beta_3 \mathbf{1}\{r_i > c\} r_i.$$

低侧直线对应前一部分，高侧加上指示项和交互项。 下一页把 β_0 看作左极限，$\beta_0 + \beta_2$ 看作右极限，β_2 看作断点效应。用标准误判断显著性。

核加权。 RDD 很依赖线性回归的外推。拟合可能过于照顾远处观测，反而在断点处拟合不好。应给距离阈值更近的观测更高权重。三角核为

$$K(R, c, h) = \mathbf{1}\{|R - c| < h\} \left(1 - \frac{|R - c|}{h}\right).$$

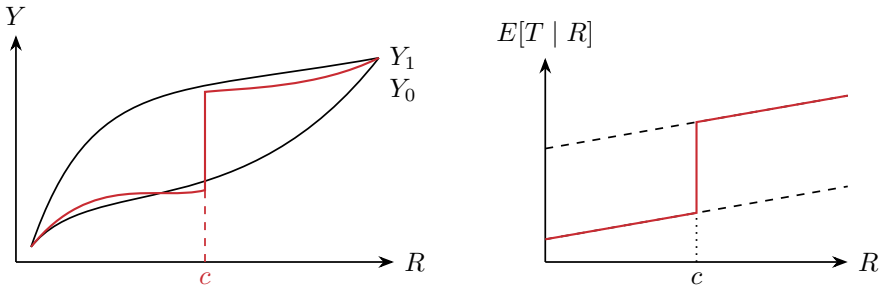
指示函数只保留 $c \pm h$ 内的观测，第二个因子随离 c 的距离增加而减小。使用 WLS，即加权最小二乘。

模糊断点回归。 在阈值处，处理不一定确定地从 0 变为 1，可能只是处理概率跳跃。把是否跨过阈值作为 IV；忽略不依从，会把处理估计拉向零。图中处理概率发生跳跃，结果也对应跳跃。原文假设所有 i 都有 $T_{1i} > T_{0i}$，没有负向变化［原说明较简略］。Wald 比值为

$$\frac{\lim_{r\to c^+} E[Y_i \mid R_i = r] - \lim_{r\to c^-} E[Y_i \mid R_i = r]}{\lim_{r\to c^+} E[T_i \mid R_i = r] - \lim_{r\to c^-} E[T_i \mid R_i = r]} = E[Y_{1i} - Y_{0i} \mid T_{1i} > T_{0i}, R_i = c].$$

旁注区分了单纯估计 RD 断点与使用 IV 估计。

续页写“大 p 值表示不显著，效应较小”［这是作者简写，显著性与效应大小并不等价］。McCrary 检验查看驱动变量分布是否聚集：阈值附近有没有尖峰？



原扫描第 22–23 页：黑色为潜在结果曲线；红色观测曲线在阈值处切换。

原笔记的指向关系。

局部实验，最接近 RCT	$\longrightarrow$	$E[Y_1 - Y_0 \mid R = c]$
阈值以下的回归	$\longrightarrow$	$\beta_0 + \beta_1 r_i$
阈值以上的回归再加上	$\longrightarrow$	$\beta_2 + \beta_3 r_i$
指示函数：仅用 $c \pm h$ 内的数据	$\longrightarrow$	$\mathbf{1}\{\lvert R - c\rvert < h\}$
离阈值越远，权重越小	$\longrightarrow$	$1 - \lvert R - c\rvert / h$
处理概率的跳跃作为第一阶段	$\longrightarrow$	结果跳跃除以处理跳跃：模糊 RD 的 Wald 比值

原笔记纠错 (B1-021): 解释截距前，先将驱动变量中心化

来源：Chapter1-23.pdf, pp. 22, 23

按原公式，$m(c^-) = \beta_0 + \beta_1 c$，$m(c^+) = \beta_0 + \beta_1 c + \beta_2 + \beta_3 c$，所以跳跃为 $\beta_2 + \beta_3 c$。令 $r_i = R_i - c$，并使用 $1\{r_i > 0\}$，才能得到笔记所说的截距解释和跳跃 β_2。

参考： 教材第 16 章.

补充条件 / 待确认 (B1-022): RD 的局部性、模糊依从与密度检验

来源：Chapter1-23.pdf, pp. 22, 23, 24

清晰 RD 在两个潜在结果均值连续、阈值两侧都有支持的条件下，识别阈值处的 ATE；把它严格理解为局部随机化，是更强的解释。模糊 RD 还需非零的处理概率跳跃、局部排除 / 外生性及单调

性。其简约式等于第一阶段跳跃乘依从者 LATE；这是目标量的缩放关系，不能普遍断言任何朴素估计都向零偏。McCrary 检验针对阈值处密度的不连续，而非附近任何尖峰，也不能证明 RD 的所有假设。

参考： 教材第 16 章; McCrary，驱动变量密度检验.

原笔记纠错 (B1-023): 不显著不意味着效应小

来源：Chapter1-23.pdf, pp. 24

原页顶端这一步推论不成立。$\hat{\tau}/\mathrm{SE}(\hat{\tau})$ 这样的检验统计量同时取决于效应大小和估计精度。估计值很大但标准误也很大，仍可能得到很大的 p 值。应报告估计值与区间；仅凭不显著，不能说明效应很小或不存在。

参考： 教材第 3 章.

第二部分：应用

第 17 章：预测模型基础

原扫描页码： Chapter1-23.pdf, p. 25

机器学习估计 $E[Y \mid X]$，即给定 X 的结果期望，得到 $\widehat{E}[Y \mid X]$。模型过于复杂就会过拟合。交叉验证图将训练数据、测试数据和未见过的数据区分开。还要区分预测与策略。笔记另记了估计量和极大似然。

R^2 用于评价连续结果模型，描述模型解释了多少结果变异。原文范围为 $(-\infty, 1)$，并提醒它衡量相对于均值预测的表现。树越深，训练集 R^2 越高，但测试集 R^2 可能下降，这就是过拟合。

`pandas.qcut` 按预测值的分位数分箱，也就是模型分群。收益策略可以设阈值，决定是否交易 / 放贷，以及投入多少金额。

原笔记的指向关系。

ML 从数据学习	$\longrightarrow$	$\widehat{E}[Y \mid X]$
深度增加，训练拟合变好，测试拟合变差	$\longrightarrow$	过拟合
决策阈值	$\longrightarrow$	是否放贷，以及投入多少

原笔记纠错 (B1-024): R 平方的范围应包含完美拟合

来源：Chapter1-23.pdf, pp. 25

结果不是常数且 $R^2 = 1 - \mathrm{SSE}/\mathrm{SST}$ 时，完美预测给出 $R^2 = 1$，所以范围为 $(-\infty, 1]$。含截距的样本内 OLS 满足 $0 \le R^2 \le 1$；样本外 R^2 可以为负。结果方差为零时，需另作约定。

参考： 教材第 17 章.

第 18 章：异质处理效应与个性化

原扫描页码： Chapter1-23.pdf, p. 26

与普通 ML 不同，这里的目标是进行干预，并预测干预的效果。考虑 $E[Y \mid X, T]$，其中 X 是不能控制的外在特征（原文举例为销量），T 是处理（如价格）。优化 $\arg\max_T E[Y \mid X, T]$。

从 ATE 转向 CATE。二元处理的 ATE 为 $E[Y_1 - Y_0]$；连续处理时，笔记用 $E[y'(t)]$，即结果对处理的导数。相应的条件版本为

$$E[Y_1 - Y_0 \mid X], \qquad E[y'(t) \mid X].$$

我的批注。加上条件 X，对每个 X 分别求期望，再制定个性化策略。

预测弹性就是估计 $\partial Y_i / \partial T_i$，近似为

$$\frac{Y(T_i) - Y(T_i + \varepsilon)}{T_i - (T_i + \varepsilon)}.$$

但同一个人的这两个结果不能同时观测，这就是因果推断的问题。一元处理的回归 $y_i = \beta_0 + \beta_1 t_i + \beta_2 X_i + e_i$ 中，导数只有 β_1，弹性对所有人都一样。加入交互项：

$$y_i = \beta_0 + \beta_1 t_i + \beta_2 X_i + \beta_3 t_i X_i + e_i, \qquad \frac{\partial \hat{y}_i}{\partial t_i} = \hat{\beta}_1 + \hat{\beta}_3 X_i.$$

交互项使 CATE 随协变量变化。β_1, β_3 决定导数关系。笔记还写了有限差分 $\{y(t+\varepsilon) - y(t)\}/\varepsilon$，以及实践中的一单位近似 $\hat{y}(t+1) - \hat{y}(t)$。

原笔记的指向关系。

给定 X，分别求平均	$\longrightarrow$	个性化策略
交互项	$\longrightarrow$	$\beta_3 t_i X_i$
协变量使效应发生变化	$\longrightarrow$	$\hat{\beta}_1 + \hat{\beta}_3 X_i$

补充条件 / 待确认 (B1-025): 因果条件均值与弹性的单位

来源： Chapter1-23.pdf, pp. 26

策略目标是 $\arg\max_t E[Y(t) \mid X = x]$；只有在一致性、可交换性及重叠性下，才等同于优化观测条件均值。X 必须是处理前变量，例如过去销量，而非受今天价格影响的销量。原尺度导数表示敏感度；弹性为 $(t/y)\,\partial y/\partial t = \partial \log y / \partial \log t$。一单位差分只有在线性响应下才等于导数，否则需说明它为何是合适近似。

参考： 教材第 18 章.

第 19 章：评价因果模型

原扫描页码： Chapter1-23.pdf, pp. 27–28

目的是预测与排序（分组）。用非随机数据估计因果模型，比较：

1. $\text{sales}_i = \beta_0 + \beta_1 \text{price}_i + \beta_2 X_i + \beta_3 X_i \text{price}_i + e_i$，线性模型（特征项可以是矩阵）。
2. $\text{sales}_i = G(X_i, \text{price}_i) + e_i$，用回归树。检查 R^2，判断是否过拟合。
3. 用随机数预测，作为安慰剂比较。

弹性模型按对处理的敏感程度给个体排序。在每个分组中，用一元回归 $y_i = \beta_0 + \beta_1 t_i + e_i$ 估计弹性：

$$\hat{\beta}_1 = \frac{\sum_i (t_i - \bar{t})(y_i - \bar{y})}{\sum_i (t_i - \bar{t})^2},$$

其中 $\bar{t}$ 为处理均值，$\bar{y}$ 为结果均值。

累计弹性曲线。 按预测弹性排序，最敏感的排在前面。先估计第一组的斜率，再不断加入后面的组，直到全部观测都纳入，曲线到达 ATE：

$$\widehat{y'}(t)_k = \hat{\beta}_k = \frac{\sum_{i=1}^{k} (t_i - \bar{t})(y_i - \bar{y})}{\sum_{i=1}^{k} (t_i - \bar{t})^2}.$$

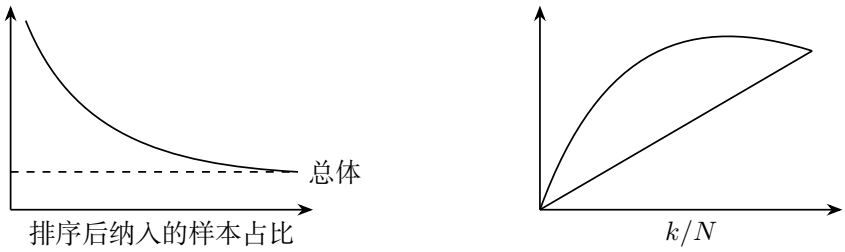
笔记中的目标是 $\widehat{y'}(t)_k > \widehat{y'}(t)_{k+a}$，并且差异要大。草图向总体效应下降，表示排序区分得好的模型更理想。

累计增益曲线。

$$\widehat{F}(k) = \hat{\beta}_k \frac{k}{N} = \frac{\sum_{i=1}^{k} (t_i - \bar{t})(y_i - \bar{y})}{\sum_{i=1}^{k} (t_i - \bar{t})^2} \frac{k}{N}.$$

图中把弯曲的增益线与直线基准比较。构造置信区间时，标准误为

$$S_{\hat{\beta}_1} = \sqrt{\frac{\sum_i \hat{\varepsilon}_i^2}{(n-2)\sum_i (t_i - \bar{t})^2}}.$$



原扫描第 27–28 页：左为累计斜率，右为累计增益与直线基准。

原笔记的指向关系。

特征项可以是矩阵	$\longrightarrow$	$\beta_2 X_i$ 和 $\beta_3 X_i \text{price}_i$
不断加入排序后的组	$\longrightarrow$	纳入全部观测时，累计斜率到达总体效应

补充条件 / 待确认 (B1-026): 用可识别的效应评价排序

来源： *Chapter1-23.pdf, pp. 27, 28*

排序模型的拟合与评价应分开。分组一元斜率在随机化评价样本上（或经有效调整后）才有因果含义，不能仅因模型在观察数据上训练就获得因果解释。每个 k 都应在前 k 个观测内重新计算 $\bar{t}_k, \bar{y}_k$。价格效应为负时，“最敏感”指更负或绝对值更大；原笔记正值递减曲线的约定需相应调整符号。所写标准误假设误差独立同分布、同方差且模型线性，给出的是逐点区间，不是整条曲线的同时置信带。

参考： 教材第 19 章.

第 20 章：即插即用估计量

原扫描页码： Chapter1-23.pdf, pp. 29–31

作者将本部分标为“翻译参考” 。此前通过可比的处理组和对照组得到 ATE。这里原文写 $Y(0), Y(1) \perp X$ [独立关系中的条件 / 分配符号与上下文不符] 。现在问：处理对谁更有效，谁更敏感?

$$\tau_i = Y_i(1) - Y_i(0), \qquad Y_i^{\text{obs}} = \begin{cases} Y_i(1), & t = 1, \\ Y_i(0), & t = 0, \end{cases}$$

$$\text{ATE} = \tau = E[Y_i(1) - Y_i(0)] = E[\tau_i], \qquad \text{CATE} = \tau(x) = E[Y_i(1) - Y_i(0) \mid X = x] = E[\tau_i \mid X = x].$$

在 $y_i = \beta_0 + \beta_1 t_i + \beta_2 X_i + \beta_3 t_i X_i + e_i$ 中，拟合效应为 $\hat{\tau}(x) = \hat{\beta}_1 + \hat{\beta}_3 x$。蓝色批注说，效应不涉及 β_2；但若 X 与结果无关，β_1, β_3 会有偏。

结果预测的 MSE 是 $E[(Y_i - \hat{Y}_i)^2]$。这里希望最小化的却是处理效应误差，原文写作

$$E[(\tau(x) - \hat{\tau}(x))^2] = E[(Y_i(1) - Y_i(0) - \hat{\tau}(x))^2].$$

二元处理的变换结果。 引入 $Y_i^* = 2Y_i T_i - 2Y_i(1 - T_i)$。在各半的随机分配下，$T \perp (Y(0), Y(1))$，所以 $E[TY(t)] = E[T]E[Y(t)]$。另外 $Y_i T_i = Y_i(1) T_i$，$Y_i(1 - T_i) = Y_i(0)(1 - T_i)$。因此

$$\begin{aligned} E[Y_i^* \mid X_i = x] &= 2E[Y_i(1) T_i \mid X_i = x] - 2E[Y_i(0)(1 - T_i) \mid X_i = x] \\ &= 2E[Y_i(1) \mid X_i = x]\, 0.5 - 2E[Y_i(0) \mid X_i = x]\, 0.5 \\ &= \tau(x). \end{aligned}$$

非随机分配时，引入倾向得分 $e(X_i)$，在相应的条件独立假设下使用

$$Y_i^* = Y_i \frac{T_i - e(X_i)}{e(X_i)(1 - e(X_i))}.$$

若已知随机处理概率为 p，则用 p 代替 $e(X_i)$。原扫描用红线强调的推导，是展开条件期望：

$$\begin{aligned} E[Y_i^* \mid X_i = x] = &\frac{E[Y_i(1) \mid X_i = x] E[T_i \mid X_i = x]}{e(x)} \\ &- \frac{E[Y_i(0) \mid X_i = x] E[1 - T_i \mid X_i = x]}{1 - e(x)} = \tau(x). \end{aligned}$$

从累计增益曲线来看，变换后的目标提供了个体处理效应的无偏但噪声很大的估计。数据量大时，这个问题会减轻。

连续处理。 目标为 $\tau(x) = E[\partial Y_i(t)/\partial t \mid X = x] = E[\tau_i \mid X = x]$。草图为需求随价格向下倾斜。线性斜率估计为

$$\hat{\tau}(x) = \frac{\text{Cov}(Y_i, T_i)}{\text{Var}(T_i)} = \frac{\sum_i (Y_i - \bar{Y})(T_i - \bar{T})}{\sum_i (T_i - \bar{T})^2}.$$

在随机处理下，对单个观测定义

$$Y_i^* = (Y_i - \bar{Y}) \frac{T_i - \bar{T}}{\sigma_T^2}.$$

设 $V_i = (T_i - \bar{T})/\sigma_T^2$。推导使用 $E[V_i \mid X_i = x] = 0$、$E[T_i V_i \mid X_i = x] = 1$，以及

$$E[T_i(T_i - \bar{T}) \mid X_i = x] = E[(T_i - \bar{T})^2 \mid X_i = x],$$

还使用 $E[T_i e_i \mid X_i = x] = E[T_i \mid X_i = x] E[e_i \mid X_i = x]$。在 $X_i = x$ 时，若 $Y_i = \alpha + \beta T_i + e_i$，

$$\begin{aligned} E[Y_i^* \mid X_i = x] &= E[(Y_i - \bar{Y}) V_i \mid X_i = x] \\ &= E[(\alpha + \beta T_i + e_i - \bar{Y}) V_i \mid X_i = x] = \beta = \tau(x). \end{aligned}$$

笔记提出的连续处理推广写作

$$Y_i^* = (Y_i - \bar{Y})\frac{T_i - M(T_i)}{\{T_i - M(T_i)\}^2},$$

旁注说明 M 估计 $E[T_i \mid X_i = x]$。作者红色批注说这个分母会带来数值问题；这里想要的只是相对排序，而非数值解释。

对于非线性关系，作者写“还没办法”，随后提出 $D_i = 1/P_i^{\alpha}$，于是 $\log D = -\alpha \log P_i$。

原笔记的指向关系。

CATE	$\longrightarrow$	加入处理与协变量的交互项
代数上，效应中没有 β_2	$\longrightarrow$	$\hat{\tau}(x) = \hat{\beta}_1 + \hat{\beta}_3 x$
最小化处理效应风险	$\longrightarrow$	$E[(\tau(X) - \hat{\tau}(X))^2]$
展开条件期望（原红色下划线）	$\longrightarrow$	在所列假设下，$E[Y^* \mid X = x] = \tau(x)$
连续处理的目标	$\longrightarrow$	需求对价格的斜率
数值困难；只需要相对排序	$\longrightarrow$	所提议的分母 $\{T_i - M(T_i)\}^2$

原笔记纠错 (B1-027): 随机分配的独立性涉及处理，而非协变量

来源： *Chapter1-23.pdf, pp. 29*

原扫描确实写了 $(Y(0), Y(1)) \perp X$。这不能使处理组具有可比性。随机分配应写 $(Y(0), Y(1)) \perp T$；调整观察数据时，则使用 $(Y(0), Y(1)) \perp T \mid X$ 并要求重叠性。CATE 可以随 X 变化。

参考： 教材第 20 章.

原笔记纠错 (B1-028): CATE 风险与个体效应风险不同

来源： *Chapter1-23.pdf, pp. 29*

令 $\Delta = Y(1) - Y(0)$，$\tau(X) = E[\Delta \mid X]$。对于独立于评价噪声的预测 $f(X)$，$E[(\Delta - f(X))^2] = E[(\tau(X) - f(X))^2] + E[\mathrm{Var}(\Delta \mid X)]$。交叉项因条件中心化而消失。因此两种风险有相同的最小化解，但除非条件效应方差为零，二者数值并不相等。

参考： 教材第 20 章.

补充条件 / 待确认 (B1-029): 变换结果究竟对什么无偏

来源： *Chapter1-23.pdf, pp. 30*

在条件可交换性和 $0 < e(X) < 1$ 下，$E[Y^* \mid X] = \tau(X)$；这是精确的条件均值保证。若要说对固定个体的个体效应具有设计无偏性，还需在随机分配下给定该个体的潜在结果。大 N 无法修复缺乏重叠，也不能消除逆权重导致的无限方差 / 重尾问题。公式推导中的期望分解必须在给定 X 后成立。

参考： 教材第 20 章.

补充条件 / 待确认 (B1-030): 连续处理的证明需要条件矩

来源：Chapter1-23.pdf, pp. 31

若 $E[Y \mid T, X = x] = a(x) + \tau(x)T$，定义 $m(x) = E[T \mid X = x]$、$v(x) = \mathrm{Var}(T \mid X = x) > 0$ 和 $\ell(x) = E[Y \mid X = x]$，则 $E[(Y - \ell(X))(T - m(X))/v(X) \mid X = x] = \tau(x)$。每个 x 下随机化分布相同时，使用全局处理矩就足够。若使用同一样本中的 $\bar{T}, \bar{Y}$，笔记的有限样本期望证明只是近似；应按具体情况使用总体矩、交叉拟合及一致性条件。

参考： 教材第 20 章.

原笔记纠错 (B1-031): 单个残差的平方不是处理方差

来源：Chapter1-23.pdf, pp. 31

两个问题都在原手写公式中。干扰函数的输入应为 X_i，即 $r_i = T_i - \hat{m}(X_i)$。除以 r_i^2 后，所提目标变成 $(Y_i - \bar{Y})/r_i$，在残差接近零时可能爆炸，并不是一般无偏的 CATE 目标。上方的条件矩目标使用 $v(X_i)$ 作分母。另一种思路是：以 r_i^2 为权重拟合 $\widetilde{Y}_i/r_i$，它等价于 R-loss；$r_i = 0$ 时应保留未作除法的原始损失形式。

参考： 教材第 20 章; Nie–Wager，R-learner.

原笔记纠错 (B1-043): 无关协变量不会自动导致 OLS 有偏

来源：Chapter1-23.pdf, pp. 29

原蓝色旁注中“无关”二字可辨，旧英文曾把含义译反。在正确设定、$E[e \mid T, X] = 0$ 且设计矩阵满秩的 OLS 中，无关协变量本身不会使 $\hat{\beta}_1$ 或 $\hat{\beta}_3$ 有偏：给定设计矩阵，$E[\hat{\beta}] = \beta$。它可能降低精度。偏差需要其他机制，例如遗漏混杂、模型设定错误、测量误差或正则化。β_2 从处理导数中消去这一代数观察仍正确。

参考： 教材第 5 章; 教材第 20 章.

第 21 章：元学习器

原扫描页码： Chapter1-23.pdf, pp. 32–33

这些是估计 CATE 的 ML 方法。笔记说在非随机数据上拟合、随机数据上验证，又补充必须先去掉混杂。目标是 $E[Y_i(1) - Y_i(0) \mid X]$，连续处理时则为条件导数。

S-learner（“Go-Horse Learner”）。 用一个 ML 模型 M_S 估计 $\mu(X, T) = E[Y \mid T, X]$。以 (X, T) 拟合，然后把同一个 X 分别与 $T = 0$、$T = 1$ 输入模型，两次预测之差得到 CATE。累计增益曲线可以检查过拟合，调节 `max_depth`。

缺点是容易把处理效应压向零。S-learner 是带正则化的 ML 模型，正则化会限制估计出的处理效应。如果其他协变量预测能力很强，模型甚至可能完全不用处理变量。

T-learner. 把数据分开，可以避免处理变量被彻底忽略。分别拟合

$$\mu_0(x) = E[Y \mid T = 0, X = x], \qquad \mu_1(x) = E[Y \mid T = 1, X = x],$$

再估计 $\hat{\tau}(x) = M_1(x) - M_0(x)$。流程图将处理组和对照组交给不同模型，再将同一个 X 输入两个模型，预测结果相减。

我的批注。分开之后，每份数据也变少。例如 $T = 0$ 数据很多，可以拟合得很好；$T = 1$ 数据很少，为避免过拟合，就只能用简单模型。这样正则化又和效应估计发生矛盾。

X-learner. 第一阶段类似 T-learner；再增加一层来拟合填补出的效应，并使用倾向模型。

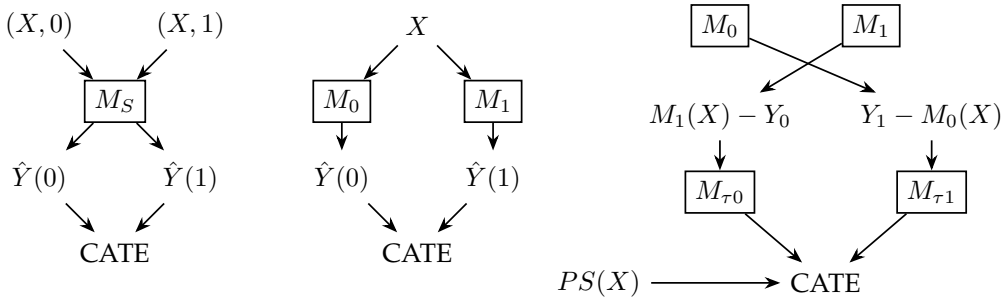
1. 拟合 $\hat{M}_0(x) \approx E[Y \mid T = 0, X = x]$ 和 $\hat{M}_1(x) \approx E[Y \mid T = 1, X = x]$。红色批注认为 $T = 0$ 与 $T = 1$ 下的关系可以不同。
2. 将观测结果与预测出的缺失结果作差，填补处理效应：

$$\hat{\tau}_i^{(0)} = \hat{M}_1(X_i) - Y_i \quad (T_i = 0), \qquad \hat{\tau}_i^{(1)} = Y_i - \hat{M}_0(X_i) \quad (T_i = 1).$$

3. 拟合效应模型 $\hat{M}_{\tau 0}(x) \approx E[\hat{\tau}^{(0)} \mid X = x, T = 0]$ 和 $\hat{M}_{\tau 1}(x) \approx E[\hat{\tau}^{(1)} \mid X = x, T = 1]$。
4. 将二者组合：

$$\hat{\tau}(x) = \hat{M}_{\tau 0}(x)\hat{e}(x) + \hat{M}_{\tau 1}(x)\{1 - \hat{e}(x)\}.$$

流程图将两个结果模型交叉用于另一组，构造 CATE 伪结果，再拟合两个模型，最后用倾向得分 $PS(X)$ 组合。红色批注说，$e(X)$ 较大意味着 $T = 1$ 的数据更多，对应结果模型更准，所以应给更大权重。 这里指的是为另一组效应回归提供反事实填补的结果模型。



原扫描第 32–33 页：S、T、X 三种学习器的指向关系。

原笔记的指向关系。

先去掉混杂	$\longrightarrow$	非随机数据拟合，随机数据评价
分组后，各组数据变少	$\longrightarrow$	处理组数据少，需要更强正则化
矛盾：既要简单拟合，又要估计效应	$\longrightarrow$	避免过拟合与正则化偏差
实际结果与填补的缺失结果作差	$\longrightarrow$	X-learner 的两组伪效应
$e(X)$ 大：处理数据多，M_1 更准确	$\longrightarrow$	给 $M_{\tau 0}(X)$ 更大权重

补充条件 / 待确认 (B1-032): 元学习器的识别与 X-learner 权重

来源：Chapter1-23.pdf, pp. 32, 33

S、T、X 学习器都需要一致性、条件可交换性、重叠性及充分的估计精度，才能识别 CATE。X-learner 中，较大的 $e(x)$ 有利于准确估计 M_1，再为对照组填补缺失的处理结果，因此可给 $M_{\tau 0}$ 更高权重。选择 $g(x) = e(x)$ 是有用的组合规则，但并非普遍的最小方差选择。正则化可能使效应收缩，但偏差并非总向零。

参考： Künzel 等，元学习器.

第 22 章：去偏 / 正交机器学习

原扫描页码： Chapter1-23.pdf, pp. 34–36

笔记引用了 2016 年的 "Double Machine Learning for Treatment and Causal Parameters"。ML 用于估计干扰参数。现有数据因特征互相关联而有偏；以销量为例，价格、温度、成本、星期几等关系可能很复杂。

Frisch–Waugh–Lovell. 对 $\hat{Y} = \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2$，$X_1, X_2$ 为特征矩阵（每列一个特征，每行一个观测），原文称 $\hat{\beta}_1, \hat{\beta}_2$ 为行向量。按下列步骤可得到相同的 X_1 系数：

1. 将 Y 对 X_2 回归，得到 $\hat{Y}^* = \hat{\gamma}_1 X_2$。
2. 将 X_1 对 X_2 回归，得到 $\hat{X}_1 = \hat{\gamma}_2 X_2$。
3. 取 $\widetilde{X}_1 = X_1 - \hat{X}_1$ 和 $\widetilde{Y} = Y - \hat{Y}^*$。
4. 将 $\widetilde{Y}$ 对 $\widetilde{X}_1$ 回归，恢复 $\hat{\beta}_1$。

所以 $(Y - \widehat{Y \sim X}) \sim (T - \widehat{T \sim X})$ 可以估计下式中的 τ：

$$Y_i - E[Y_i \mid X_i] = \tau\{T_i - E[T_i \mid X_i]\} + \varepsilon_i.$$

加强版 FWL：用 ML 估计 ATE。

$$Y_i - \hat{M}_Y(X_i) = \tau\{T_i - \hat{M}_T(X_i)\} + \varepsilon_i.$$

$\hat{M}_Y$ 估计 $E[Y \mid X]$，是去噪模型，解释 X 带来的 Y 变异。$\hat{M}_T$ 估计 $E[T \mid X]$，是去偏模型，去除与 X 相关的处理分配偏差。

1. 用灵活的 ML 回归 M_Y，从特征 X 估计结果 Y。
2. 用 M_T 从 X 估计处理 T。
3. 得到残差 $\widetilde{Y} = Y - M_Y(X)$ 和 $\widetilde{T} = T - M_T(X)$。
4. 将结果残差对处理残差回归：$\widetilde{Y} = \alpha + \tau \widetilde{T}$。

笔记称为 "两次预测，一次回归"；τ 是因果 ATE 参数。

我对过拟合的解释。若 M_Y 过拟合，它不只拟合了 Y 与 X 的关系，还吞掉了一部分 Y 与 T 的关系。因果关系被结果模型吸收，没有留给残差回归，因此最后的效应偏向零。若 M_T 过拟合，它解释了过多 T 的变异，剩下的处理残差方差很小，最后效应估计的方差就很大。旁注将此与倾向得分预测过准 / 过于极端、违反正值性联系起来。

为解决过拟合，把数据分成 K 折。每次用其余 $K-1$ 折训练 ML 模型，在留出的一折上计算残差。合并所有折的预测 / 残差，再拟合 $\widetilde{Y} = \alpha + \tau \widetilde{T}$。

CATE 与 R-learner。 让斜率随 X 变化：

$$Y_i - M_Y(X_i) = \tau(X_i)\{T_i - M_T(X_i)\} + \varepsilon_i.$$

最后一层回归可为 $\widetilde{Y}_i = \alpha + \beta_1 \widetilde{T}_i + \beta_2 X_i \widetilde{T}_i + \varepsilon_i$。最终模型用 $M(\text{Price}=1, X_i) - M(\text{Price}=0, X_i)$ 估计销量效应。底部红色标记为 “R-learner”。

非参数双重 / 去偏 ML。 对于价格与销量这样的连续关系，写作

$$Y_i = \hat{M}_Y(X_i) + \tau(X_i)\{T_i - \hat{M}_T(X_i)\} + \hat{\varepsilon}_i.$$

整理残差：

$$\hat{\varepsilon}_i = \{Y_i - \hat{M}_Y(X_i)\} - \tau(X_i)\{T_i - \hat{M}_T(X_i)\}.$$

最小化残差平方，得到因果 R-loss 并估计 CATE：

$$\begin{aligned}
\hat{L}_n(\tau) &= \frac{1}{n}\sum_{i=1}^{n}\Big[\{Y_i - \hat{M}_Y(X_i)\} - \tau(X_i)\{T_i - \hat{M}_T(X_i)\}\Big]^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}(\widetilde{Y}_i - \tau(X_i)\widetilde{T}_i)^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}\widetilde{T}_i^2\left(\frac{\widetilde{Y}_i}{\widetilde{T}_i} - \tau(X_i)\right)^2.
\end{aligned}$$

我的理解。 这就是用任意预测模型预测 $\widetilde{Y}_i/\widetilde{T}_i$，权重为 $\widetilde{T}_i^2$。

“哪里是非参数?” 这里区分非参数和非线性。基本方程 $\widetilde{Y}_i = \tau(X_i)\widetilde{T}_i + e_i$ 对残差处理仍是线性的。Double ML 对非线性 CATE 关系给出局部线性近似，相当于寻找某个 X_i 处的导数。

尚未完成的非线性推广

原扫描页码: Chapter1-23.pdf, p. 38 main discussion, then facing-page supplement p. 37

作者标注：未完成。 标题为 “Non-Scientific Double/Debiased ML”。作者希望从个体数据点出发，得到反事实预测（“CATE?”）乃至整条结果曲线。把

$$\widetilde{Y}_i = \tau(X_i)\widetilde{T}_i + e_i$$

替换为

$$\widetilde{Y}_i = \tau(X_i, \widetilde{T}_i) + e_i.$$

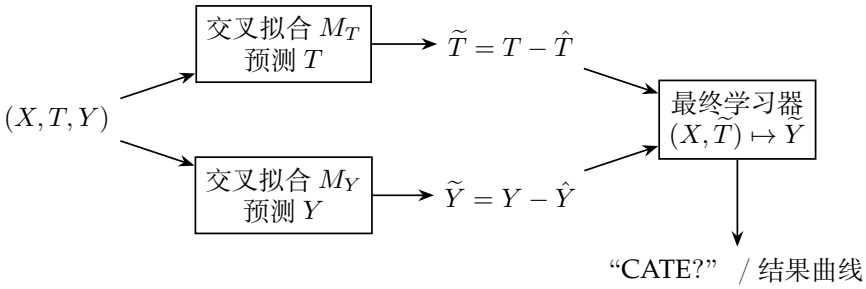
笔记说这是一个较特别的函数，可以用 ML 估计：先预测 $\widetilde{T}_i$，再用它和 X 拟合 $\widetilde{Y}$。可以用任意 ML 模型，尤其提到 LGBM。一处手写预测标签是 “price”，旁边函数却为 $\hat{\tau}(X_i, \widetilde{T}_i)$；这个标签与实际建模的结果变量不一致。

测试集按与训练集相同的流程处理。旁注还提到后续交叉预测，将模型预测平均为一个值 [前面的简短实现缩写无法从扫描中确定]。

流程图使用两个交叉拟合的处理模型和两个结果模型，得到 T 残差、Y 残差，再与 X 一起交给最终 CATE 模型。缺点：(1) 正则化使效应偏向零；(2) 结果依赖具体 ML 方法。提升树不容易给出光滑预测，也不擅长外推到未见过的价格，在那里可能得到奇怪的预测。

对页的逐步补充。 设 Y 为销量，T 为价格，X 为协变量。用五折 LGBM 交叉预测估计 $\hat{Y} \sim X$ 与 $\hat{T} \sim X$。计算 $\widetilde{Y} = Y - \hat{Y}$、$\widetilde{T} = T - \hat{T}$。用 $(\widetilde{T}, X)$ 拟合 $\widetilde{Y}$，可采用 LGBM，将最终模型记为 `finalM`。

预测时，给定 X，用五个 LGBM 模型得到 $\hat{T}'$。原手写步骤说用 $\hat{T}'$ 减去新设定的处理 T_{new}，形成 $\widetilde{T}'$。这里的新处理是一个反事实值。将 $(\widetilde{T}', X)$ 输入最终模型，对每个 T_{new} 得到 $\widetilde{Y}'$。笔记还说可以输入零作为参照残差。再把预测基线 $\hat{Y}$ 加回 $\widetilde{Y}'$，得到最终结果曲线。这一补充是在解释尚未完成的构想，并未将其视为已验证的估计方法。



原扫描第 37–38 页：交叉预测、残差与尚未完成的最终学习器。

原笔记的指向关系。

预测结果	⟶	第 36 页残差方程中的 $\hat{M}_Y(X)$
预测处理	⟶	第 36 页残差方程中的 $\hat{M}_T(X)$
R-loss：R-learner 最小化的损失	⟶	$\hat{L}_n(\tau)$
残差对残差回归	⟶	由 FWL 恢复 X_1 的系数
去噪模型	⟶	$\hat{M}_Y(X)$
去偏模型	⟶	$\hat{M}_T(X)$
结果模型过拟合	⟶	吸收处理信号，残差中的效应可能缩小
处理模型过拟合	⟶	处理残差变异缩小，效应估计方差增大
预测目标与权重	⟶	$\widetilde{Y}_i/\widetilde{T}_i$，权重 $\widetilde{T}_i^2$
未完成：替换线性的残差关系	⟶	$\widetilde{Y}_i = \tau(X_i, \widetilde{T}_i) + e_i$
假想的反事实价格	⟶	对页预测步骤中的 T_{new}

补充条件 / 待确认 (B1-033): 残差回归的目标不总是 ATE

来源： *Chapter1-23.pdf, pp. 34, 35*

部分线性模型 $Y = \theta T + g(X) + \varepsilon$、$E[\varepsilon \mid T, X] = 0$ 支持常数因果斜率。二元处理效应异质时，合并后的残差 OLS 目标是 $E[e(X)(1-e(X))\tau(X)]/E[e(X)(1-e(X))]$，一般不是 ATE。交叉拟合减少使用自身观测造成的过拟合，但不能替代可交换性、重叠性、矩条件或干扰函数收敛率条件。对 partialling-out 得分，一个充分的余项条件是 $\|\hat{m} - m\|_2(\|\hat{\ell} - \ell\|_2 + \|\hat{m} - m\|_2) = o_p(n^{-1/2})$。有关区别见 DML 第 4.1、5.1 节。

参考： Chernozhukov 等，DML 第 4.1 节; Chernozhukov 等，DML 第 5.1 节.

原笔记纠错 (B1-034): 仅靠 R-loss 不能识别局部导数

来源： *Chapter1-23.pdf, pp. 36*

这个说法在原笔记中确实存在，也延续了教材中过强的表述。最小化条件 R-loss 得到 $\tau^*(x) = \mathrm{Cov}(T, Y \mid X = x)/\mathrm{Var}(T \mid X = x)$。条件响应为线性时，它等于处理导数；但对一般非线性的 $E[Y \mid T, X]$，并非如此。例如 $Y = T^2$、$T \sim U(0,1)$ 时斜率为 1，导数却是 $2t$。对 x 使用非参数灵活拟合，本身并不意味着在处理 t 上做了局部化。

参考： Nie–Wager，第 2 节（R-loss）；教材第 22 章.

原笔记纠错 (B1-035): 预测残差的减法方向写反了

来源： *Chapter1-23.pdf, pp. 37*

第 37 页的减法方向是原笔记错误：训练使用 $\widetilde{T} = T - \hat{m}(X)$，预测也必须使用 $\widetilde{T}_{\text{new}} = T_{\text{new}} - \hat{m}(X)$。反转符号会改变拟合关系。第 38 页标为 “price” 的输出应是结果残差预测 $\widehat{\widetilde{Y}}$，因为最终学习器预测的是销量残差。

参考： 教材第 22 章.

补充条件 / 待确认 (B1-036): 保留非线性构想的未完成性质

来源： *Chapter1-23.pdf, pp. 37, 38*

作者标为 “未完成” 是合适的。给定函数 m, ℓ，固定 x 时变换 $r = t - m(x)$ 可逆：若一致地拟合 $f(x, r) = E[Y - \ell(X) \mid X = x, T - m(X) = r]$，可重建 $E[Y \mid x, t] = \ell(x) + f(x, t - m(x))$。称其为因果响应还需可交换性和支持条件；其导数或两个剂量之差才是效应。任意的残差 S-learning 不会自动继承 R-loss 估计量的正交性 / 收敛率保证，未见过的处理取值则需要无数据支持的外推。

参考： 教材第 22 章.

原笔记纠错 (B1-041): 矩阵乘积须与给定的排列约定一致

来源： *Chapter1-23.pdf, pp. 18, 34*

原扫描把观测放在 $X_j \in \mathbb{R}^{n \times p_j}$ 的行上，并称系数为行向量。按此约定，维度相容的公式应为 $\hat{Y} = X_1\hat{\beta}_1^{\mathsf{T}} + X_2\hat{\beta}_2^{\mathsf{T}}$，而非 $\hat{\beta}_1 X_1 + \hat{\beta}_2 X_2$。也可改用列系数向量，写成 $X_1\hat{\beta}_1 + X_2\hat{\beta}_2$。拟合投影为 $\hat{Y}^* = P_{X_2} Y$ 和 $\hat{X}_1 = P_{X_2} X_1$。这是对矩阵方向的修正，FWL 残差化论证不变。

参考： 教材第 5 章.

第 23 章：效应异质性与非线性

原扫描页码： Chapter1-23.pdf, pp. 39–40

处理效应异质性（TEH）指不同个体的处理效应不同。例子研究一个潜在连续结果：

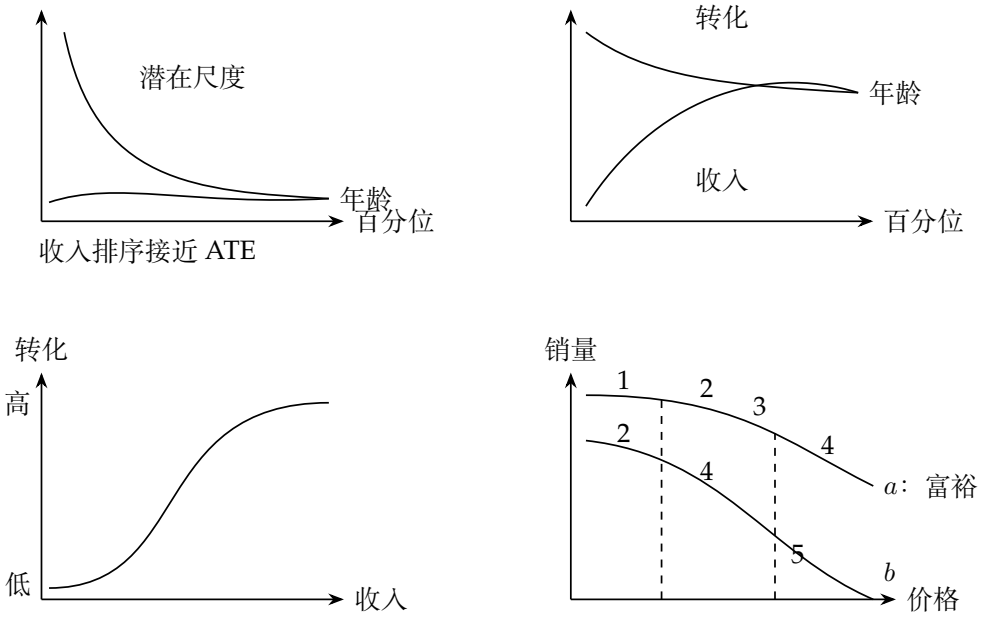
$$Y_{\text{latent}} \sim N(-4.5 + 0.001\,\text{income} + \text{nudge} + 0.01\,\text{nudge}\cdot\text{age},\ 1),$$
$$\text{nudge} \sim B(0.5), \qquad \text{age} \sim G(10, 4).$$

收入分布写作 $G(20, 2)$。收入的加性系数对所有人都相同；年龄才是划分异质处理效应的变量。定义 conversion $= \mathbf{1}\{Y_{\text{latent}} > 0\}$，阈值旁写了 “50%”。原文给出的真实 ATE，在潜在尺度为 1.4，转化结果为 0.394。转化不是线性的。

几幅草图的意思。 对潜在结果的效应，按年龄排序的累计效应曲线起点很高，随后下降至 ATE；按估计收入排序则一直在 ATE 附近。对转化的效应，年龄和估计收入都表现出处理效应异质性。即使收入在潜在尺度不与处理交互，它仍强烈预测转化。

第三幅图把转化概率画成估计收入的 S 形函数，低端标低转化率，高端标高转化率。两端曲线较平，处理效应都较小。最后的文字比较写 “高转化 / 高基础转化率，处理效应低”，接着又写 “低转化，高基础转化率，处理效应高”。

第二个例子：价格响应。 销量—价格图有两条向下的非线性曲线，分别为 a、b 两种人；a 标为富裕者。价格区间不断提高时，图上 a 的下降量约为 1、2、3、4，b 为 2、4、5。效应既依赖类型（a 或 b），也依赖价格，不能简单按一个固定弹性排序。最后建议变换价格，使它与 Y 线性，例子写作 $-(\text{price}^4)$；指数未完全辨清。



原扫描第 39–40 页：潜在尺度与转化尺度的排序、饱和效应，以及类型 / 价格依赖。

原笔记的指向关系。

对每个人都有相同的加性效应	$\longrightarrow$	潜在方程中的 0.001 income
划分处理效应的变量	$\longrightarrow$	0.01 nudge · age 中的 age
收入也可能呈现处理效应异质性	$\longrightarrow$	转化尺度的效应曲线
处理效应同时依赖类型和价格	$\longrightarrow$	a, b 的销量曲线；单一固定排序有问题

原笔记纠错 (B1-037): 所写模拟不能产生引用的转化效应

来源：Chapter1-23.pdf, pp. 39

原笔记的不一致可追溯到教材的文字与代码不一致。按 Gamma 的形状—尺度参数化，所写收入的均值为 40，不是 4000。教材代码用的是 income $= 100G(20, 2)$ 和 $\mathbf{1}\{Y_{\text{latent}} > 0.1\}$；报告的 0.39477 是模拟的处理组减对照组差异。潜在尺度 ATE 为 $1 + 0.01E[\text{age}] = 1.4$。按手写中未经放大的数据生成过程，基线潜在均值约为 -4.46，因此不能推出约 50% 的转化率或所引用的转化效应。

参考： 教材第 23 章.

原笔记纠错 (B1-038): 基础转化率低不一定意味着效应大

来源：Chapter1-23.pdf, pp. 39

重复出现的“高基础转化率”和笼统的“低转化、高效应”结论都在原扫描中。设潜在均值为 a、处理平移量 $\delta > 0$、正态噪声方差为一、阈值为 c，则转化效应为 $\Phi(a+\delta-c) - \Phi(a-c)$。当 $a \to -\infty$ 或 $a \to +\infty$ 时，效应均变小，在中间区域最大。作者前面“两端平缓”的直觉才是与此一致的。

参考： 教材第 23 章.

补充条件 / 待确认 (B1-039): 幂变换是一个模型设想

来源：Chapter1-23.pdf, pp. 40

价格变换是尝试性的建模思路，手写指数尚未完全辨清。只有曲线的函数形式支持这种选择时，变换 $q = h(p)$ 才能将其线性化。若 $E[Y \mid p, x] = a(x) + b(x)h(p)$，价格效应仍为 $b(x)h'(p)$，所以变换后价格的斜率恒定，不代表原价格效应恒定。应保留作者关于 a/b 类型与价格共同影响排序的洞见。

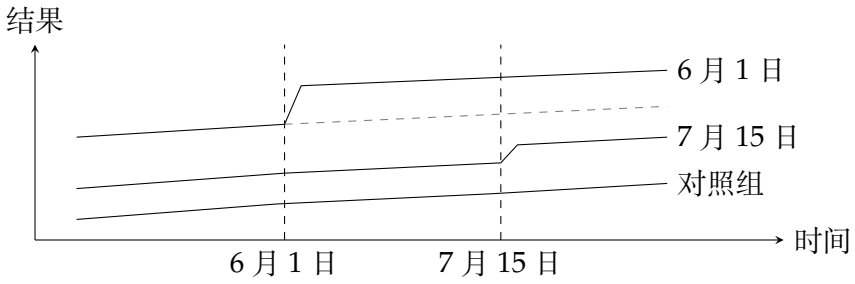
参考： 教材第 23 章.

第 24 章：双重差分的发展与问题

面板数据与双向固定效应

原扫描页码： Chapter24-25.pdf，第 2、1 页；第 1 页接续第 2 页底部的假设。

面板数据：在不同时点重复观测同一个单位。例子同时比较不同时间、不同地区的单位。图中有早期受处理组（6 月 1 日）、晚期受处理组（7 月 15 日）和对照组；另有一条较浅的轨迹，标为 *TWFE 预测 / 反事实*。



按手绘轨迹重建的示意图，不代表具体数值数据。

按干预开始日期 g 给单位分组（例中分为三组）。

干预开始日期 $\longrightarrow$ 队列标签 g

笔记写出的目标为

$$\mathrm{ATT} = E[Y_1 \mid t > g] - E[Y_0 \mid t > g].$$

补充条件 / 待确认 (B2-003): 明确队列—时间目标量

来源：Chapter24-25.pdf, pp. 2

更精确的定义是 $\mathrm{ATT}(g,t) = E[Y_t(g) - Y_t(\infty) \mid G = g]$，其中 g 是受处理队列，t 是处理后的时点。还需说明处理从 $t = g$ 开始，还是只在其后开始。总体 ATT 还需要明确聚合权重。

参考： 原始资料 1.

模型为

$$\mathrm{Install}_{it} = \tau D_{it} + \gamma_i + \theta_t + e_{it}.$$

这里 i 表示单位，t 表示时间，e_{it} 为噪声；γ_i 对应单位，θ_t 对应时间。用 OLS 估计，得到**双向固定效应（TWFE）**模型。

我的批注。 同时控制所有特征。

两组、两期 $\longrightarrow$ TWFE 就是 DiD。

原笔记纠错 (B2-002): 固定效应究竟控制了什么

来源：Chapter24-25.pdf，第 2 页

单位固定效应吸收单位之间不随时间变化的差异；时间固定效应吸收某一时点对所有单位共同发生的冲击。它们不能控制任意的、因单位而异且随时间变化的混杂因素。可加性与识别假设仍然重要。

参考： 原始资料 1.

TWFE 结果模型 $\longrightarrow$ 用同一组固定效应对结果与处理分别取残差。

笔记将残差化后的回归写为

$$\widetilde{\text{Install}}_{it} = \tau \widetilde{D}_{it} + e_{it},$$

对应的去均值表达式为：

$$\widetilde{\text{Install}}_{it} = \text{Install}_{it} - \underbrace{\frac{1}{T}\sum_{t=0}^{T} \text{Install}_{it}}_{\text{时间平均}} - \underbrace{\frac{1}{N}\sum_{i=0}^{N} \text{Install}_{it}}_{\text{单位平均}},$$

$$\widetilde{D}_{it} = D_{it} - \frac{1}{T}\sum_{t=0}^{T} D_{it} - \frac{1}{N}\sum_{i=0}^{N} D_{it}.$$

原笔记纠错 (B2-004): 双重去均值需要加回总体均值

来源：Chapter24-25.pdf, pp. 2, 6

对平衡面板，令 $i = 1, \ldots, N$、$t = 1, \ldots, T$，应使用

$$\widetilde{z}_{it} = z_{it} - \bar{z}_{i\cdot} - \bar{z}_{\cdot t} + \bar{z}_{\cdot\cdot}, \qquad z \in \{Y, D\}.$$

其中 $\bar{z}_{i\cdot} = T^{-1}\sum_{s=1}^{T} z_{is}$、$\bar{z}_{\cdot t} = N^{-1}\sum_{j=1}^{N} z_{jt}$、$\bar{z}_{\cdot\cdot} = (NT)^{-1}\sum_{j,s} z_{js}$。加回总体均值后，各行、各列均值才都为零。遗漏它只会使每个变换后的变量平移一个常数；若最后的回归另含截距，斜率不变。但这仍不是精确的固定效应残差，且无截距回归不一定给出相同斜率。非平衡面板应使用实际的固定效应投影，而不能直接套用这个简单公式。

参考： 原始资料 1, 原始资料 2.

失效：处理效应异质性带来的问题

效应异质时，TWFE 经常有偏。没有时间效应的固定效应模型写为

$$y_{it} = \tau D_{it} + \gamma_i + e_{it}.$$

笔记列出的假设包括：

1. **函数形式：** 效应不随时间异质变化（常数效应）；协变量线性进入；固定效应可加。
2. **严格外生性：** 平行趋势；无预期效应；无未观测的时变混杂；过去的处理不影响当前结果（无延续效应）；过去的结果不影响当前处理（无反馈）。

第二项接在左页，由主页面底部的箭头连接。

第 2 页底部的严格外生性列表 ⟶ 第 1 页接续：预期、混杂、延续效应和反馈。

补充条件 / 待确认 (B2-005): 严格外生性与 DiD 假设

来源：Chapter24-25.pdf，第 1、2 页

静态固定效应回归中的一个标准条件是 $E[e_{it} \mid D_{i1}, \ldots, D_{iT}, \gamma_i] = 0$（同时也以其他回归变量为条件）。平行趋势和无预期效应是 DiD 使用的潜在结果限制，并不与整张列表互相等价。通过改变模型与目标量，可以允许动态处理效应。

参考： 原始资料 1.

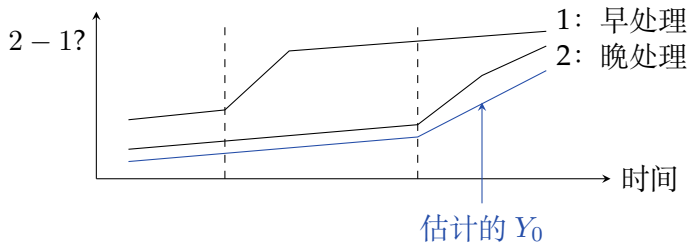
原扫描页码：Chapter24-25.pdf, p. 3.

接上：假设治疗效果存在时间异质性，而且反应是渐进的，例如从 $0.1, 0.2, \ldots$ 开始，每天增加。这时 TWFE 估计的 ATT 会有偏。图中早处理组记为 1，晚处理组记为 2，从未处理组记为 3。把 TWFE 分解成多个 2×2 DiD，可得：

$$1-3:\ \checkmark, \quad 2-3:\ \checkmark, \quad 1-2:\ \checkmark, \quad 2-1:\ ??$$

每个比较的第二项是对照。**我的直觉：**当早期组 1 被用作对照时，模型以为未处理结果 Y_0 会沿该组先前的趋势平行上升。

估计出的未处理轨迹 ⟶ 蓝色曲线是晚处理组的 $\widehat{Y_0}$。



此示意图恢复“比较方式指向曲线”的关系；曲线高度仅用于说明。

笔记将下面的简写归于 Goodman–Bacon（2019）：

$$\operatorname*{plim}_{n\to\infty} \hat{\tau}^{\mathrm{TWFE}} = \mathrm{VWATT} - \Delta\mathrm{ATT}.$$

Bias：ATT 随时间变化的程度 ⟶ ΔATT

若效果随时间增加（如图），Bias 向下；反之亦然。**我的提醒：**当效果为负且随时间递减，即变得更负时，估计甚至会出现正负号错误！

补充条件 / 待确认 (B2-006): 偏差方向的说法针对图示比较

来源：Chapter24-25.pdf，第 3 页

图解释了把已经受处理的单位当作对照造成的污染。总体 TWFE 偏差的方向和大小取决于各队列的效应、动态变化以及回归权重；该示意不是普遍成立的偏差符号定理。

参考： 原始资料 1.

事件研究设计

用事件时间指标改写 TWFE。笔记中的提前项 / 滞后项展开如下（保留其系数与下标标签）：

$$
\begin{aligned}
Y_{it} = \tau^{-K} D_{ik}^{<-K} + \sum_{k=-K}^{-2} \tau^{\text{lead}} D_{it}^{k} + \sum_{k=0}^{L} \gamma_k^{\text{lag}} D_{it}^{k} \\
+ \gamma_k^{L+} D_{it}^{>L} + \gamma_i + e_{it}, \\
D_{it}^{k} = \mathbf{1}\{t - \text{Cohort}_i = k\}.
\end{aligned}
$$

$D_{it}^{k} = \mathbf{1}\{t - \text{Cohort}_i = k\}$ $\longrightarrow$ 相对时期为 k 时取 1，否则取 0。

加入衡量单位距离开始受处理时期多远的变量 $\longrightarrow$ 事件时间指标 D_{it}^{k}。

这里标为部分改进。

原笔记纠错 (B2-007): 完整的提前项 / 滞后项回归

来源：Chapter24-25.pdf，第 3 页

省略基准期 $k = -1$ 的常见设定为

$$
\begin{aligned}
Y_{it} = \alpha_i + \theta_t + \beta_{<-K} \mathbf{1}\{t - G_i < -K\} \\
+ \sum_{k=-K}^{-2} \beta_k \mathbf{1}\{t - G_i = k\} + \sum_{k=0}^{L} \beta_k \mathbf{1}\{t - G_i = k\} \\
+ \beta_{>L} \mathbf{1}\{t - G_i > L\} + e_{it}.
\end{aligned}
$$

从未受处理单位的所有事件时间指标均为零。原稿在单位效应前的分隔符不清楚，此处读作加号；不一致的下标则属于原稿记号问题。

参考： 原始资料 1.

补充条件 / 待确认 (B2-008): 仅加入事件时间指标仍不能解决效应异质性

来源：Chapter24-25.pdf, pp. 3

在交错采用且效应异质时，一个提前项或滞后项系数可能混入其他相对时期的效应，表面上的处理前趋势也可能来自效应异质性。若要作因果解释，应使用明确构造有效队列比较的估计方法。

参考： 原始资料 1.

改进：更灵活的函数形式

原扫描页码： Chapter24-25.pdf, p. 4.

新模型给每个个体在每个时点分配一个处理效应：

$$\text{Installs}_{it} = \sum_{i=0}^{N}\sum_{t=0}^{T} \tau_{it} D_{it} + \gamma_i + \theta_t + e_{it}.$$

参数太多。改为给每个组 g 在每个时点分配一个效应：

$$\text{Installs}_{it} = \sum_{g=0}^{G}\sum_{t=0}^{T} \tau_{gt} D_{it} + \gamma_i + \theta_t + e_{it}.$$

这里被标为更好的版本。进一步删去处理前系数和对照组系数，以减少参数：

$$\text{Installs}_{it} = \sum_{g=q}^{G}\sum_{t\geq g}^{T} \tau_{gt} D_{it} + \gamma_i + \theta_t + e_{it}.$$

将 $g < q$ 的队列定义为对照。

需要手动创建队列 dummy，例如 $(0,1),(1,0),\ldots$ $\longrightarrow$ 队列与时间交互的处理项。

原笔记纠错 (B2-009): 需要显式写出队列与时间指标

来源：Chapter24-25.pdf，第 4 页

对观测 (i,s)，所要表达的展开应为

$$Y_{is} = \alpha_i + \theta_s + \sum_{g\in\mathcal{G}}\sum_{t\geq g} \tau_{g,t}\mathbf{1}\{G_i = g\}\mathbf{1}\{s = t\} + e_{is}.$$

队列指标与日历时间指标不可省略。这里修正的是公式记号，不是识别假设。

参考： 原始资料 1.

补充条件 / 待确认 (B2-010): 对照队列必须提供未处理比较

来源：Chapter24-25.pdf, pp. 4

若 g 是实际的采用日期，较早队列可能已经受处理，不能自动当作未处理对照。应采用从未处理单位，或在相关比较窗口内尚未处理的单位，并配合相应的平行趋势与无预期效应假设。教材示例把观测窗口结束后才采用的队列标为对照组。

参考： 原始资料 1.

仍然存在的限制：

1. 效果会随时间变化，之前没有考虑这一点。
2. DiD 和 TWFE 要满足平行趋势假设；这个限制很强。

DiD 与 TWFE ⟶ 需要相应的平行趋势限制。

第 25 章：合成双重差分

面板数据的表示

原扫描页码： Chapter24-25.pdf, p. 5.

多个单位、多个时期，受处理与未处理观测混合在一起。在 D 中，**行为时间，列为单位**：

$$D = \begin{pmatrix} 0 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 1 & 1 \\ 0 & 0 & 0 & \cdots & 1 & 1 \end{pmatrix}.$$

最后几列对应受处理单位。

采用后出现 1 的列 ⟶ 受处理单位

笔记称其为一次性处理，并用星号强调：单位一旦受处理，就不再回到未处理状态。

补充条件 / 待确认 (B2-011): 四块矩阵要求共同的处理区块

来源： Chapter24-25.pdf, pp. 5

图中的四块表示要求所纳入的受处理单位共享一个处理前 / 处理后的划分。若采用时间交错，应像后面的笔记那样，先构造有效的队列或时期子面板。

参考： 原始资料 1, 原始资料 2.

表示 1：合成控制。 将上面的矩阵概括为四块：

$$D = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}, \qquad Y = \begin{pmatrix} Y_{\text{pre,co}} & Y_{\text{pre,tr}} \\ Y_{\text{post,co}} & Y_{\text{post,tr}} \end{pmatrix}.$$

pre 表示处理前，post 表示处理后，co 表示对照组，tr 表示处理组。

表示 2：DiD。 用长表表示：各列记录单位、时间、结果、是否属于处理组，以及是否已经开始接受处理。可观测结果为

$$Y = \begin{pmatrix} Y(0)_{\text{pre,co}} & Y(0)_{\text{pre,tr}} \\ Y(0)_{\text{post,co}} & Y(1)_{\text{post,tr}} \end{pmatrix},$$

并且

$$\text{ATT} = Y(1)_{\text{post,tr}} - \underbrace{Y(0)_{\text{post,tr}}}_{\text{缺失}}.$$

回顾 DiD 与合成控制

原扫描页码： Chapter24-25.pdf，第 6、7 页；第 7 页补充两幅比较示意图。

DiD 回归为

$$Y_{it} = \beta_0 + \beta_1 \text{Post}_t + \beta_2 \text{Treated}_i + \beta_3 \text{Treated}_i \text{Post}_t + e_{it}.$$

其假设是

$$E[Y(0)_{\text{post,co}} - Y(0)_{\text{pre,co}}] = E[Y(0)_{\text{post,tr}} - Y(0)_{\text{pre,tr}}].$$

即若没有处理，对照组和处理组具有相同趋势。

将估计量写成可与 SDID 比较的形式：

$$\hat{\tau}^{\text{did}} = \underset{\mu,\alpha,\beta,\tau}{\text{argmin}} \left\{ \sum_{i=1}^{N} \sum_{t=1}^{T} [Y_{it} - (\mu + \alpha_i + \beta_t + \tau D_{it})]^2 \right\}.$$

笔记将它与去均值联系起来：

$$\widetilde{Y}_{it} = Y_{it} - \overline{Y}_i - \overline{Y}_t = Y_{it} - T^{-1} \sum_{t=0}^{T} Y_{it} - N^{-1} \sum_{i=0}^{N} Y_{it},$$

$$\widetilde{D}_{it} = D_{it} - \overline{D}_i - \overline{D}_t = D_{it} - T^{-1} \sum_{t=0}^{T} D_{it} - N^{-1} \sum_{i=0}^{N} D_{it}.$$

这与合成控制很像，但没有权重。

对 Y 和 D 去均值 $\longrightarrow$ 固定效应的最小二乘目标函数。

原笔记纠错 (B2-004): 再次出现的双重去均值遗漏

来源： Chapter24-25.pdf, p. 6

应加回总体均值，并统一求和上下限；见前面的 B2-004 校正。

参考： 原始资料 1, 原始资料 2.

合成控制使用处理前结果估计权重：

$$\hat{w}^{\text{sc}} = \underset{w}{\text{argmin}} \, \|\overline{y}_{\text{pre,tr}} - Y_{\text{pre,co}} w_{\text{co}}\|_2^2, \qquad \sum_i w_i = 1, \quad w_i > 0 \quad \forall i.$$

原笔记纠错 (B2-012): 应允许零对照权重

来源： Chapter24-25.pdf, pp. 6, 8, 10

标准单纯形约束为 $w_i \geq 0$、$\sum_{i \in \text{co}} w_i = 1$；同理，$\lambda_t \geq 0$、$\sum_{t \in \text{pre}} \lambda_t = 1$。允许零权重。开单纯形 $w_i > 0$ 可能排除最优解。第 8、10 页的手写约束还遗漏了求和号：并非每个权重都等于 1。下文公式恢复了权重总和为 1 的本意。

参考： 原始资料 1, 原始资料 2.

$Y_{\text{pre,co}}$ 是 $T_{\text{pre}} \times N_{\text{co}}$ 的结果矩阵：列为单位，行为时期。向量 w_{co} 的大小为 $N_{\text{co}} \times 1$。$\overline{y}_{\text{pre,tr}}$ 的每个分量，是某个处理前时点上处理组单位的平均结果。

我的批注。 给处理组拟合一个合成对照，类似线性回归。处理后，用对照组结果与已经拟合的权重计算：

$$y_{\text{sc}} = Y_{\text{co}}\widehat{w}^{\text{sc}}.$$

这给出了 $Y(0)_{\text{post,tr}}$ 的良好估计，因此

$$\widehat{\tau} = \overline{y}_{\text{post,tr}} - \overline{y}_{\text{post,sc}}.$$

也可以改写为

$$\widehat{\tau}^{\text{sc}} = \underset{\beta,\tau}{\text{argmin}} \left\{ \sum_{i=1}^{N}\sum_{t=1}^{T}(Y_{it} - \beta_t - \tau D_{it})^2 \widehat{w}_i^{\text{sc}} \right\}.$$

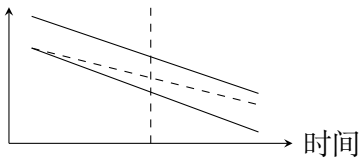
处理前的拟合给出对照组权重；每个处理组单位的权重为 $1/N_{\text{tr}}$。

没有总体截距 μ，也没有单位固定效应 α_i ⟶ 上面的 SC 加权回归目标函数。

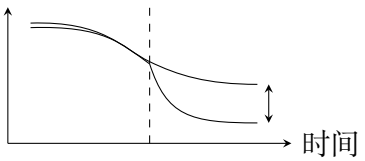
左页的图形直觉（第 7 页）。 DiD 图将轨迹平移，构造平行比较；手写批注说，这在图示例子中放大了效果。SC 图则从处理前数据得到权重，形成一个合成的、未受处理的处理组。处理后继续用同一组权重计算结果，并以两个处理后结果之差估计效果。图中曲线在处理前贴合，处理后分开。

处理前拟合 ⟶ 权重 $\widehat{w}$

处理后的对照结果与同一组权重 ⟶ 合成的处理后结果，再与处理组结果求差。



DiD：平移趋势



SC：加权轨迹

按原笔记草图重建的示意图。

将两者结合：合成 DiD

原扫描页码： Chapter24-25.pdf，第 8 页与第 10 页上、中部。

⋆ 星号标题将合成控制的加权目标与 DiD 固定效应目标结合起来：

$$\widehat{\tau}^{\text{sdid}} = \underset{\mu,\alpha,\beta,\tau}{\text{argmin}} \left\{ \sum_{i=1}^{N}\sum_{t=1}^{T}[Y_{it} - (\mu + \alpha_i + \beta_t + \tau D_{it})]^2 \underbrace{\widehat{w}_i^{\text{sdid}}}_{\text{单位权重}} \underbrace{\widehat{\lambda}_t^{\text{sdid}}}_{\text{时间权重}} \right\}.$$

时间权重。 用对照组处理前结果拟合其处理后平均结果：

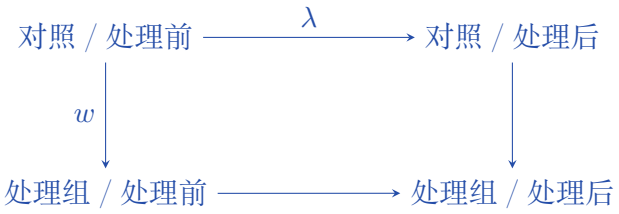
$$\widehat{\lambda}^{\text{sdid}} = \underset{\lambda}{\text{argmin}} \, \|\overline{y}_{\text{post,co}} - (\lambda_{\text{pre}} Y_{\text{pre,co}} + \lambda_0)\|_2^2, \qquad \sum_t \lambda_t = 1, \quad \lambda_t > 0.$$

- $Y_{\text{pre,co}}$ 为 $T_{\text{pre}} \times N_{\text{co}}$ 矩阵，行为时间、列为单位。
- $\overline{y}_{\text{post,co}}$ 是 $1 \times N_{\text{co}}$ 行向量，每个分量是某个对照单位在处理后各时期的平均结果。
- λ_{pre} 是 $1 \times T_{\text{pre}}$ 行向量，为每个处理前时期指定一个权重；λ 是时间权重。

第 8 页底部用于替代划掉文字的矩阵草图，沿时间维度相乘：在矩阵上方添加一行 1 表示截距，再用加权的处理前各行拟合 $\overline{y}_{\text{post,co}}$，从而得到 λ_t。

$$\begin{pmatrix} \mathbf{1}^{\mathsf{T}} \\ Y_{\text{pre,co}} \end{pmatrix} \xrightarrow{\text{时间拟合}} (\lambda_0, \lambda_{\text{pre}}) \longrightarrow \overline{y}_{\text{post,co}}$$

单位权重。 第 10 页顶部的小图用 λ 连接“对照 / 处理前”与“对照 / 处理后”，用 w 连接“对照 / 处理前”与“处理组 / 处理前”，从而得到相应的处理组 / 处理后比较。



$$\widehat{w}^{\text{sdid}} = \underset{w}{\operatorname{argmin}} \left\{ \|\overline{y}_{\text{pre,tr}} - (Y_{\text{pre,co}} w_{\text{co}} + w_0)\|_2^2 + \zeta^2 T_{\text{pre}} \|w_{\text{co}}\|_2^2 \right\}, \qquad \sum_i w_i = 1, \quad w_i > 0,$$

$$\zeta = (N_{\text{tr}} T_{\text{post}})^{1/4} \widehat{\sigma}(\Delta_{it}),$$

$$\Delta_{it} = Y_{it} - Y_{i,t-1}.$$

其中 Δ_{it} 是一阶差分，$\widehat{\sigma}(\Delta_{it})$ 是其标准差。

我的批注。

L_2 惩罚让非零权重分布得更广	$\longrightarrow$	$\zeta^2 T_{\text{pre}} \|w_{\text{co}}\|_2^2$
与之前 SC 相比：（1）有截距；（2）有 L_2 惩罚	$\longrightarrow$	SDID 的单位权重拟合。
有截距	$\longrightarrow$	w_0

原稿的实现说明写的是：在 $\overline{y}_{\text{pre,tr}}$ 前添加一行 *1* 作为截距，再做回归。

原笔记纠错 (B2-013): 截距应放在设计矩阵中

来源： *Chapter24-25.pdf, pp. 10*

在单位权重拟合中，$\overline{y}_{\text{pre,tr}}$ 是长度为 T_{pre} 的向量，设计矩阵应为

$$X = [\mathbf{1}_{T_{\text{pre}}} \;\; Y_{\text{pre,co}}].$$

应在预测变量中添加一列 1，而不是给结果向量加一行。拟合 (w_0, w_{co}) 时，只约束并惩罚对照单位的权重，不惩罚截距。相比之下，第 8 页时间权重采用行向量表示，因此在 $Y_{\text{pre,co}}$ 上方添加一行 1 是正确的。

参考： 原始资料 1, 原始资料 2.

补充条件 / 待确认 (B2-014): 应使用对照组处理前数据估计尺度

来源： *Chapter24-25.pdf, pp. 10*

标准 SDID 使用对照单位在处理前时期的结果一阶差分来估计 $\widehat{\sigma}$。若使用处理组的处理后结果，处理效应可能影响正则化尺度。笔记中的四次方根因子 $(N_{\text{tr}} T_{\text{post}})^{1/4}$（指数为正）是正确的。

参考： 原始资料 1.

处理组单位与处理后时期分别使用均匀权重 $1/N_{\text{tr}}$ 和 $1/T_{\text{post}}$。**我的直觉：**SDID 相比 SC，更关注干预近期起效果的数据。

补充条件 / 待确认 (B2-015): SDID 直觉中的字迹仍有歧义

来源：Chapter24-25.pdf，第 10 页

上面按时间接近程度理解是可能的，但原句中间几个字仍不清楚。数学上，时间权重使加权后的对照组处理前结果能够预测其处理后结果；它不会依据观测与某个未知处理效应有多接近来选数据，也不一定只选最近的时期。

参考： 原始资料 1, 原始资料 2.

时间效应异质性与交错采用

原扫描页码： Chapter24-25.pdf，第 10 页下部，随后接第 9 页补充。

SDID 可以方便地估计各个时期的效应：重复运行即可。下面手写矩阵中 0 和 1 的下标表示时期。

时间效应异质性。 例子为

$$D = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \\ 0_4 & 0_4 & 1_4 \end{pmatrix}.$$

对整个矩阵使用 SDID，可得第 3、4 期的平均 ATT。

完整矩阵 D $\longrightarrow$ SDID：第 3、4 期的平均 ATT。

若要分别估计这两期，则用

$$D_1 = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \end{pmatrix}, \qquad D_2 = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_4 & 0_4 & 1_4 \end{pmatrix}.$$

交错采用：左页补充。 笔记给出

$$D = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \\ 0_4 & 1_4 & 1_4 \end{pmatrix}.$$

第一种拆分为

$$D_1 = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_4 & 1_4 & 1_4 \end{pmatrix}, \qquad D_2 = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \end{pmatrix}.$$

将 D_1 的 ATT 赋予权重 $2/3$，将 D_2 的 ATT 赋予权重 $1/3$。

按时期拆分原处理矩阵 $\longrightarrow$ 第 4 期有两个受处理单元，第 3 期有一个：权重为 2/3、1/3。

也可以按受处理队列拆分：

$$D_1 = \begin{pmatrix} 0_1 & 0_1 \\ 0_2 & 0_2 \\ 0_3 & 0_3 \\ 0_4 & 1_4 \end{pmatrix}, \qquad D_2 = \begin{pmatrix} 0_1 & 0_1 \\ 0_2 & 0_2 \\ 0_3 & 1_3 \\ 0_4 & 1_4 \end{pmatrix}.$$

下面的例子写道：加州受处理 12 年，其他单位 8 年 $\times 3$。加权计算为

$$\text{ATT}_0 \frac{12}{36} + \left(\sum \text{ATT}\right) \frac{1}{3} \frac{3 \times 8}{36}.$$

这里保留了作者按处理持续时间加权的例子。

补充条件 / 待确认 (B2-017): 受处理单元的权重决定聚合目标

来源：Chapter24-25.pdf, pp. 9, 10

权重 $2/3, 1/3$ 按受处理的单位—时期单元计数。同理，$12/36$ 与 $24/36$ 按已观测的处理持续时间，平均加州与其他三个单位的效应，每个单位、每个时期的权重相等。其他目标总体可能需要不同聚合权重。各子面板都应使用真正未受处理的对照观测。

参考： 原始资料 1, 原始资料 2.

安慰剂方差估计

原扫描页码: Chapter24-25.pdf, p. 11.

笔记描述 SDID 相比 SC 有更小的误差棒。SDID 同时利用结果在时间和单位之间的变化，使置信区间改善，而且适用于只有一个受处理单位的情形。

补充条件 / 待确认 (B2-018): 精度并非总能提高

来源：Chapter24-25.pdf, pp. 11

SDID 在适当设计下可以提高精度和稳健性，但其有效标准误并不保证总比 SC 小。估计权重本身也带来不确定性，因此普通加权回归输出的标准误并不自动等于 SDID 的标准误。

参考： 原始资料 1, 原始资料 2.

轮流假设每个对照单位接受了处理，用 SDID 估计其安慰剂 ATT。笔记写为

$$\widehat{V}_\tau^{\text{placebo}} = B^{-1} \sum_{b=1}^{B} \left(\widehat{\tau}^{(b)} - \overline{\tau}^{(b)}\right)^2, \qquad \tau \in \widehat{\tau}^{\text{sdid}} \pm z_{\alpha/2} \sqrt{\widehat{V}_\tau}.$$

安慰剂 ATT 估计值的方差 ⟶ SDID 安慰剂方差 $\widehat{V}_\tau$，再构造置信区间。

括号中批注：和 SC 一样。

补充条件 / 待确认 (B2-019): 定义安慰剂均值与区间约定

来源：Chapter24-25.pdf, pp. 11

对 B 个安慰剂估计，定义 $\bar{\tau}^{\mathrm{pl}} = B^{-1}\sum_b \widehat{\tau}^{(b)}$，并令

$$\widehat{V}^{\mathrm{pl}} = B^{-1}\sum_b (\widehat{\tau}^{(b)} - \bar{\tau}^{\mathrm{pl}})^2.$$

若定义 $z_p = \Phi^{-1}(p)$，正态近似区间应为 $\widehat{\tau} \pm z_{1-\alpha/2}\sqrt{\widehat{V}^{\mathrm{pl}}}$。手写的 $z_{\alpha/2}$ 也可能约定为正的上尾临界值，但原稿未说明。置信区间是具有覆盖率声明的随机集合，并不保证每次实现出的区间都包含 τ。

参考： 原始资料 1.

补充条件 / 待确认 (B2-020): 单个处理单位的安慰剂推断需要假设

来源：Chapter24-25.pdf, pp. 11

安慰剂方法从对照组借用噪声信息。它要求不同单位的噪声可比较（SDID 论文的这一论证要求跨单位同方差），有适当的对照样本，并能合理使用相应的分布近似。若处理单位的噪声变异不同，方法可能失效。多个单位受处理时，每次安慰剂分配应保持相同的处理组规模。

参考： 原始资料 1.

附录：去偏与预测

原扫描页码： Chapter24-25.pdf, p. 12.

页首把非随机数据的处理与**倾向得分**、**正交化**联系起来。

通过正交化去偏

与第 22 章相同 ⟶ 正交化 / 对变量取残差。

所有特征包含在 X 中。

1. 取第一组特征，拟合

   $$y_i = \theta_0 + \theta_1 X_{1i} + e_i.$$

   得到残差

   $$y_i^* = y_i - (\widehat{\theta}_0 + \widehat{\theta}_1 X_{1i}).$$

2. 用第一组特征预测第二组：

   $$X_{2i} = \gamma_0 + \gamma_1 X_{1i} + e_i.$$

   得到残差

   $$X_{2i}^* = X_{2i} - (\widehat{\gamma}_0 + \widehat{\gamma}_1 X_{1i}).$$

3. 用特征残差回归结果残差：

   $$y_i^* = \beta_0 + \beta_2 X_{2i}^* + e_i.$$

通过倾向得分去偏

原扫描页码: Chapter24-25.pdf, p. 13.

见第 11 章 ⟶ 倾向得分加权。

对每个单位加权。二元处理时，

$$w_i = \frac{T}{P(T=1 \mid X)} + \frac{1-T}{1-P(T=1 \mid X)}.$$

原稿把下式标为连续：

$$w_i = \sum_{k=0}^{K} \frac{\mathbf{1}\{T=k\}}{P(T=k \mid X)}.$$

原笔记纠错 (B2-021): 所写扩展适用于离散类别

来源: Chapter24-25.pdf, pp. 13

这个表达式用于取值为 $0, \ldots, K$ 的离散处理。对于真正连续的剂量，常见连续模型在某个单点上满足 $P(T=k \mid X)=0$；广义倾向得分方法使用条件密度，并需要另行明确剂量—反应目标量与估计方法。

参考: 原始资料 1.

我的直觉。 受处理概率很高却未受处理的单位，本质上与处理组很像，但观测上属于对照组，可用于估计 $Y_0 \mid T=1$。

补充条件 / 待确认 (B2-022): ATE 与 ATT 的权重不同

来源: Chapter24-25.pdf, pp. 13

在一致性、条件可交换性与正值性成立时，上面的逆概率权重对应 ATE 比较。若目标为 ATT，处理组权重应为 1，对照组权重为 $e(X)/(1-e(X))$，并作适当归一化。高倾向得分的对照单位有助于代表处理组的协变量分布，但它并不真的就是受处理单位。

参考: 原始资料 1.

没有倾向得分时，可以用机器学习估计接受处理的概率。一个简短数值例子提到 20%、0.2，以及“收到邮件”记为 1；这一行的其余字迹不清。

补充条件 / 待确认 (B2-023): 邮件例子仍有字迹无法辨认

来源: Chapter24-25.pdf, pp. 13

保留可辨认的数值，不从缺失文字中推测额外的概率计算或因果结论。

倾向得分的弱点。

1. 倾向得分很小时（$e < 0.05$），权重过大，相当于该观测重复出现太多次，对去偏后的数据集影响很大。笔记提到人工裁剪。**高方差**。
2. **正值性或共同支持：** 处理单位与控制单位的特征之间必须有足够重叠。重叠过少时，用倾向得分消除相关性的效果不好。

人工干预不太好，可能引入过多主观偏差；不要外推到正值性不成立的人口子集。

补充条件 / 待确认 (B2-024): 大权重与样本裁剪

来源：Chapter24-25.pdf, pp. 13

二元 ATE 加权中，e 很小时膨胀的是处理单位的 $1/e$ 权重；e 接近 1 时膨胀的是对照单位的 $1/(1-e)$ 权重。针对重叠不足，可以按事先规定的原则裁剪样本，但这会改变目标总体，必须报告。良好的倾向得分预测本身并不能证明因果可交换性。

参考： 原始资料 1.

当预测失效时

原扫描页码: Chapter24-25.pdf, p. 14.

预测与因果。这一页只有标题，下面没有更多笔记。