个人学习笔记

因果推断学习笔记：Brave and True

第 1–25 章与附录

中文版

Ming

2026 年 11 月 1 日

教材：Matheus Facure, Causal Inference for the Brave and True

目录

第 1 章：因果推断入门 3

第 2 章：随机实验 3

第 3 章：统计学回顾 3

第 4 章：图模型 4

第 5 章：线性回归的作用 4

第 6 章：分组与虚拟变量回归 5

第 7 章：控制混杂因素之外 6

第 8 章：工具变量 6

第 9 章：不依从与局部平均处理效应 8

第 10 章：匹配 8

第 11 章：倾向得分 9

第 12 章：双重稳健估计 10

第 13 章：双重差分 11

第 14 章：面板数据与固定效应 11

第 15 章：合成控制 12

第 16 章：断点回归设计 13

第二部分：应用 15

第 17 章：预测模型基础 15

第 18 章：异质处理效应与个性化 15

第 19 章：评价因果模型 15

第 20 章：即插即用估计量 16

第 21 章：元学习器 18

第 22 章：去偏 / 正交机器学习 **19**
Non-Scientific Double/Debiased ML：未完成 20

第 23 章：效应异质性与非线性 **22**

第 24 章：双重差分的发展与问题 **23**
面板数据与双向固定效应 23
困境：效果异质性下的失效 23
事件研究设计 24
改进：更灵活的函数形式 25

第 25 章：合成双重差分 **25**
面板数据的表示 25
回看 DiD 与合成控制 26
将两者结合：合成 DiD 27
时间效应异质性与交错采用 28
安慰剂方差估计 29

附录：去偏与预测 **29**
用正交化去偏 29
用倾向得分去偏 30
当预测失效时 30

第 1 章：因果推断入门

T_i 表示是否接受处理，Y_i 是观测结果。我把实际分组与潜在结果所刻画的因果关系区分开。

$$\text{ATE} = E[Y_1 - Y_0], \qquad \text{ATT} = E[Y_1 - Y_0 \mid T = 1].$$

ATE 是平均处理效应；ATT 是已接受处理者的平均处理效应。因果量来自潜在结果之差。观测到的相关关系可分解为

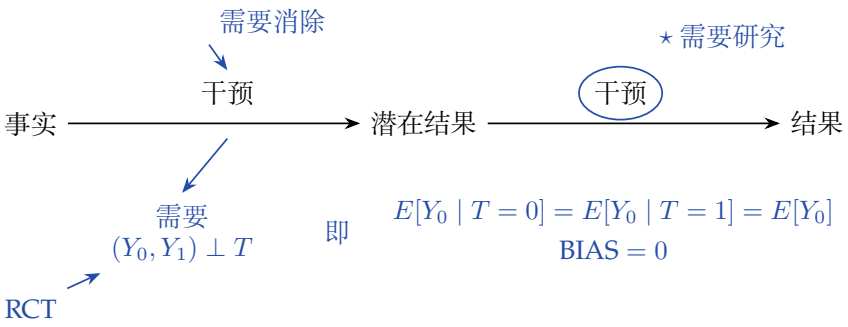
$$\underbrace{E[Y \mid T = 1] - E[Y \mid T = 0]}_{\text{相关关系}} = \underbrace{E[Y_1 - Y_0 \mid T = 1]}_{\text{ATT}} + \underbrace{E[Y_0 \mid T = 1] - E[Y_0 \mid T = 0]}_{\text{偏差}}.$$

偏差项为零时，相关关系给出 ATT。若还要进一步得到 ATE，处理者的平均效应必须等于总体平均效应；处理与两个潜在结果独立的随机分配是充分条件。

$$\text{bias} = 0 \implies \text{association} = \text{ATT} \xrightarrow{(Y_0, Y_1) \perp T} \text{ATE}.$$

第 2 章：随机实验

随机实验可以消除偏差。我的图解把需要消除的联系与需要研究的处理效应分开，并用 RCT 连接到所需的独立性条件。



第 3 章：统计学回顾

对于独立同分布样本均值，估计标准误为 $\text{SE} = \hat{\sigma}/\sqrt{n}$，其中

$$\hat{\sigma}^2 = \frac{1}{N-1}\sum_i (x_i - \bar{x})^2.$$

样本量更小 ⇒ 标准误更大 ⇒ 置信区间更宽。原假设是处理组与对照组的分布均值相等。两组各自的置信区间即使重叠，均值之差仍可能显著不为零。要区分两组均值各自的 95% 置信区间与两组均值之差。

p 值是在 H_0 下，检验统计量至少与观测值一样极端的概率；这是抽样概率，并非 H_0 为真的概率。95% 置信区间程序在重复抽样中有 95% 的区间覆盖固定的总体参数。在数据和方法不变时，置信水平更高 ⇒ 区间更宽 ⇒ 精度更低。显著性水平控制第一类错误的概率。

我的直觉。若 p 值很小，那么在 H_0 下极不容易出现的数据却出现了，说明 H_0 可能不对。把样本算出的 p 值与理论上预先选定的显著性水平比较。

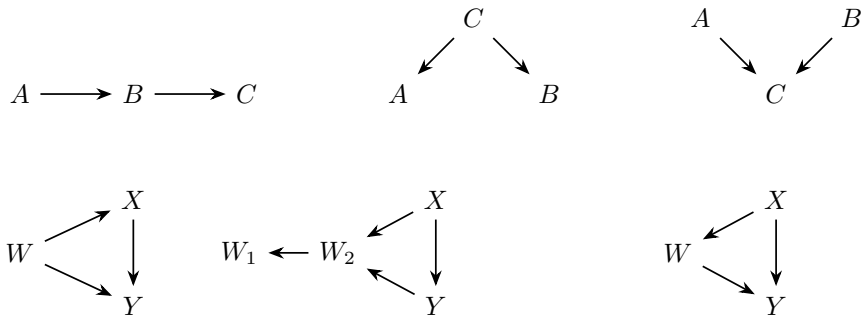
第 4 章：图模型

$A \to B$ 表示 A 影响 B。以下三节点图采用因果 Markov 性质，并假设没有其他开放路径。依赖关系描述通常的忠实情形：开放路径允许依赖，但效应抵消也可能使依赖消失。

1. 链：$A \to B \to C$。边际上 $A \not\perp C$；给定已知的中间变量 B 后，路径被阻断：$A \perp C \mid B$。
2. 叉：$A \leftarrow C \to B$。未条件化时，$A \not\perp B$；给定 C 后，$A \perp B \mid C$。
3. 碰撞点：$A \to C \leftarrow B$。边际上 $A \perp B$；给定 C 后，$A \not\perp B \mid C$。

混杂偏差还可能涉及混杂因素的代理变量，以及不能直接测量的变量。

我的总结。混杂偏差来自没有控制住的开放路径，例如 $X \leftarrow W \to Y$，同时存在 $X \to Y$。多余的条件化有两个不同问题：控制共同结果会打开路径，产生选择偏差；控制中介会阻断部分总因果效应，属于过度控制。例子中 X 是教育，Y 是工资，W 是投资。碰撞点图为 $X \to W_2 \leftarrow Y$、$W_2 \to W_1$ 和 $X \to Y$，“投资”写在 W_1 旁；中介图则是教育先影响 W，再影响工资，同时还有教育到工资的直接箭头。因此，以总效应为目标时，不应控制这个中介 W。



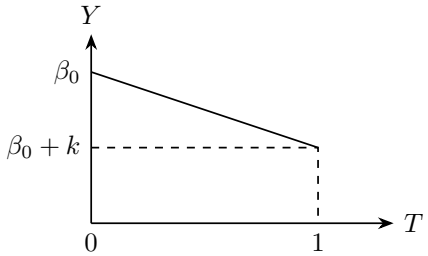
链、叉、碰撞点；下方依次为混杂及两种不当控制。

第 5 章：线性回归的作用

对个体 i，设 $Y_{1i} = Y_{0i} + k$：这里考虑常数处理效应，目标是估计 k。一元回归为

$$Y_i = \beta_0 + kT_i + u_i, \qquad \beta_1 = \frac{\text{Cov}(Y_i, T_i)}{\text{Var}(T_i)}.$$

当 T 随机分配时，两组均值之差就是 ATE，因此二元 T 的总体回归系数也是 ATE。



二元处理的两个拟合值相差 k，这里用 $k < 0$ 示意。

多元回归把与 T_i 相关的多个因素纳入：

$$y_i = \beta_0 + kT_i + \underbrace{\beta_1 X_{1i} + \cdots + \beta_K X_{Ki}}_{\text{辅助变量}} + u_i.$$

我的理解：先用 X 预测 T，再取残差 $\longrightarrow$ $\widetilde{T} = (I - P_X)T$：$X$ 解释不了的那部分 T；X 包含截距

残差化的处理变量提供了估计其回归系数时使用的变异：

$$k = \frac{\text{Cov}(Y_i, \widetilde{T}_i)}{\text{Var}(\widetilde{T}_i)}.$$

这里的协方差表达式对应总体线性投影；样本中的相应表达式为 $\hat{k} = \widetilde{T}'Y/(\widetilde{T}'\widetilde{T})$。

本来需要多元回归，却漏掉变量而使用一元回归，会发生什么？考虑常数效应的线性模型

$$\text{Wage}_i = \alpha + k\,\text{Educ}_i + \underbrace{A_i'\beta}_{\text{能力项}} + u_i.$$

在 $\text{Cov}(\text{Educ}, u) = 0$ 下，遗漏能力得到

$$\frac{\text{Cov}(\text{Wage}_i, \text{Educ}_i)}{\text{Var}(\text{Educ}_i)} = k + \underbrace{\beta'\delta_A}_{\text{OVB}}.$$

把能力 A 对教育回归 $\longrightarrow$ δ_A：这一投影的系数向量

多出来的项就是遗漏变量偏差。在这个正确设定的线性模型下，纳入混杂变量就能消除这一遗漏变量项。

RCT 切断处理与混杂因素的关系；回归则在比较时控制这些因素，使其固定。

这里的因果解释使用了已说明的常数效应模型和外生性。若存在效应异质性，或调整模型并不合适，调整后的回归系数不一定等于未加权的 ATE。

第 6 章：分组与虚拟变量回归

异方差是指在不同协变量取值下，结果的方差不相同。分组越细，组内样本越少；分组减少变异，但系数标准误可能增大，t 统计量变小。把分组回归合为共同处理系数时，组的样本占比与组内处理方差都进入权重。

处理为虚拟变量时（例如是否达到 12 年教育），

$$\text{wage}_i = \beta_0 + \beta_1 T_i + e_i.$$

$T = 0$ 时，期望等于截距；$T = 1$ 时，等于截距加 β_1。IQ 为连续变量时，

$$\text{wage}_i = \beta_0 + \beta_1 T_i + \beta_2 \text{IQ}_i + \beta_3 \text{IQ}_i T_i + e_i.$$

- β_0：$T = 0$、IQ $= 0$ 时的期望。
- β_1：IQ 为零时，T 增加一单位的影响（其他项均为零）。
- β_2：$T = 0$ 时，IQ 增加一单位的影响。
- β_3：$T = 1$ 时 IQ 也有回报；当 $\beta_3 > 0$，这一组的回归斜率更大。

分析 T_i 的系数，需要算各组对总系数的贡献：按教育年限分组（例如 12 年），求相应的类别教育 / 处理差异 $C(\text{educ})[T_i]$。

有更多协变量时，目标系数是各虚拟变量子组效应的加权平均：

$$E[\{E[Y_i \mid T = 1, G_i] - E[Y_i \mid T = 0, G_i]\}\, w(G_i)], \qquad w(g) = \frac{v_g}{E[v_G]}, \quad v_g = \text{Var}(T \mid G = g).$$

权重取决于子组内 T_i 的分布。还要计算教育分组和 IQ 分箱的处理差异。

在各组分别有截距、共用一个斜率的回归中，归一化后的系数为 $\sum_g P(G = g) v_g \tau_g / \sum_g P(G = g) v_g$。组内调整有效时才有因果解释；这个方差加权效应不一定等于通常的 ATE。

第 7 章：控制混杂因素之外

本章讨论控制特定变量的后果。在 $X \to Y \leftarrow T$ 中，研究 $X \to Y$ 时控制 T，可以把 X 的作用看得更清楚，降低其估计方差。第二幅图是 $B \to A \to X \to Y$ 及 $B \to Y$：B 同时与 X、Y 相关；控制 B 后，A 是 X 的额外预测变量。加入 A 可能减少 X 剩余的变异，使其系数估计方差增大。

$$\hat{\sigma}^2 = \frac{1}{n-2}\sum_i (y_i - \hat{y}_i)^2, \qquad \widehat{\mathrm{Var}}(\hat{\beta}_2) = \frac{\hat{\sigma}^2}{\sum_i (x_i - \bar{x})^2}.$$

同方差一元 OLS 的标准误为 $\widehat{\mathrm{SE}}(\hat{\beta}_2) = \hat{\sigma}/\sqrt{\sum_i (x_i - \bar{x})^2}$。样本变化越大，标准误越小。多元回归要使用控制其他变量后的残差变异，以及相应的残差自由度。

没有控制共同原因而产生的是混杂偏差；控制共同结果可能产生选择偏差；控制中介则会阻断部分总效应。

不当控制与参与行为。 若处理影响结果是否为零，RCT 下均值之差具有因果解释。当 $Y \geq 0$ 时，可将均值差分为参与部分与正结果条件均值部分：

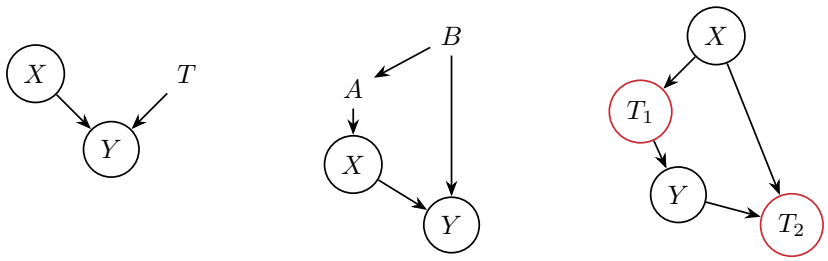
$$\begin{aligned} E[Y \mid T=1] - E[Y \mid T=0] = {} & \{P(Y>0 \mid T=1) - P(Y>0 \mid T=0)\} E[Y \mid Y>0, T=1] \\ & + \{E[Y \mid Y>0, T=1] - E[Y \mid Y>0, T=0]\} P(Y>0 \mid T=0). \end{aligned}$$

第一部分是结果为正的概率变化，并区分顾客“是否参与”和“消费能力”。只分析参与者时，

$$\begin{aligned} E[Y_{i1} \mid Y_{i1}>0] - E[Y_{i0} \mid Y_{i0}>0] = {} & \underbrace{E[Y_{i1} - Y_{i0} \mid Y_{i1}>0]}_{\text{参与者中的因果效应}} \\ & + \underbrace{E[Y_{i0} \mid Y_{i1}>0] - E[Y_{i0} \mid Y_{i0}>0]}_{\text{选择偏差}}. \end{aligned}$$

最后一项比较两种人群的未处理潜在结果：会在处理下参与者，与会在未处理下参与者。上面的代数分量不会仅因处理随机化就分别成为因果效应。

配图为 $X \to T_1 \to Y \to T_2$，另有 $X \to T_2$。T_1, T_2 用红色标为不当选择 / 控制：“不要控制！”



改善精度的控制、处理变量的预测因素，以及红圈标出的不当控制。

第 8 章：工具变量

假设

$$Y_i = \beta_0 + kT_i + \beta W_i + u_i,$$

其中 T 是处理，W 是混杂变量。当 W_i 不可观测时，拟合 $Y_i = \beta_0 + kT_i + v_i$，其中 $v_i = \beta W_i + u_i$。此时 $\mathrm{Cov}(T, v) \neq 0$，所以 k 的估计有偏。未观测项携带着联系 T、Y 的信息。

引入工具变量 Z：它与 T 相关，只通过 T 影响 Y，且 $\text{Cov}(Z,v)=0$。图为 $Z\to T\to Y$、$W\to T$、$W\to Y$。因此

$$\begin{aligned}\text{Cov}(Z,Y)&=\text{Cov}(Z,\beta_0+kT+v)\\&=k\,\text{Cov}(Z,T)+\text{Cov}(Z,v)=k\,\text{Cov}(Z,T),\\k&=\frac{\text{Cov}(Z,Y)}{\text{Cov}(Z,T)}=\frac{\text{Cov}(Y,Z)/\text{Var}(Z)}{\text{Cov}(T,Z)/\text{Var}(Z)}.\end{aligned}$$

分子、分母都是回归系数。分子是简约式（reduced form）系数：Z 只经过 T 对 Y 产生的影响。

我的微积分直觉。

$$k=\frac{dY/dZ}{dT/dZ}=\frac{dY}{dZ}\frac{dZ}{dT}=\frac{dY}{dT}.$$

若工具变量是二元的，Wald 估计量为

$$k=\frac{E[Y\mid Z=1]-E[Y\mid Z=0]}{E[T\mid Z=1]-E[T\mid Z=0]}.$$

我的理解是：把 $Z\to Y$ 的变化换算回 $T\to Y$ 的作用。

工具变量的使用。 例子中，Z_0 是出生季度，T 是教育，W 是能力，Y 是工资。相关性 $\text{Cov}(Z,T)\neq 0$ 可从第一阶段检查。我后来的修正：“Z 只通过 T 影响 Y”是排除限制，不是 $Y\perp Z\mid T$；第 9 章用潜在结果重新表述。 给定 T 反而可能打开碰撞路径 $Z\to T\leftarrow W\to Y$。

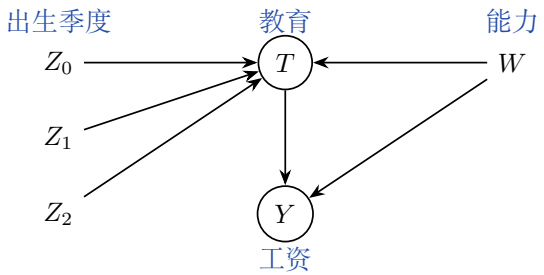
先回归 $T\sim Z_0$，检查第一阶段关系；再回归 $Y\sim Z_0$，看简约式关系。方法一是取两个回归系数之比。方法二是 2SLS：

1. 将 T 对 Z_0,Z_1,Z_2 回归。
2. 将 Y 对拟合后的 T 及 Z_1,Z_2 回归：

$$Y\sim \underbrace{\widehat{T}}_{\text{用}Z_0,Z_1,Z_2\text{ 拟合}}+Z_1+Z_2.$$

公式接口可以指定 $T\sim Z_0$，因为其他项会在第二阶段自动加入。 用作比较的 OLS 写作 $Y\sim T+C(Z_0,Z_1,Z_2)$。

第一阶段很弱时，IV 估计会不精确。在工具变量有效、足够强且数量固定的常规渐近设定下，2SLS 可以一致，而 OLS 仍不一致。有限样本中的 2SLS 可能偏向 OLS；加入过多弱工具变量会加重这一问题，不能仅凭工具数量增加就认为偏差单调下降。



工具变量、处理、混杂因素与结果。

导数约分是我对可微单一路径的直觉；本节常斜率模型的依据是上面的协方差推导。两阶段设定中的 Z_1,Z_2 是纳入的外生控制变量，两个阶段都要保留。

第 9 章：不依从与局部平均处理效应

依从者（compliers）服从分配；从不接受者（never-takers）始终不接受处理；总是接受者（always-takers）始终接受处理；违抗者（defiers）则反着做。在 $Z \to T \to Y$、$W \to T$ 和 $W \to Y$ 中，从不接受者与总是接受者削弱第一阶段。例如从不接受者会把简约式中的结果差异拉向对照状态。

现在潜在结果有两个自变量：$Y_i(t,z)$；笔记以 $T_i = 1, Z_i = 0$ 时的 $Y_i(1,0)$ 为例。潜在处理 T_{0i} 对应 $Z_i = 0$。

IV 假设。

1. $(Y_{i0}, Y_{i1}, T_{0i}, T_{1i}) \perp Z_i$. 工具变量各组的潜在结果与潜在处理具有可比性。
2. 排除限制：$Y_i(1,0) = Y_i(1,1) = Y_{i1}$，$Y_i(0,0) = Y_i(0,1) = Y_{i0}$。工具变量只能通过处理影响结果。
3. $E[T_{1i} - T_{0i}] \neq 0$：存在第一阶段，工具变量确实会影响处理。
4. 单调性：几乎处处 $T_{1i} \geq T_{0i}$。存在依从者，所以 $P(T_{1i} > T_{0i}) > 0$。

推导 Wald 目标量。 考虑 Wald 比值：

$$\frac{E[Y \mid Z=1] - E[Y \mid Z=0]}{E[T \mid Z=1] - E[T \mid Z=0]}.$$

利用排除限制和随机分配，

$$\begin{aligned} E[Y_i \mid Z_i = 1] &= E[Y_{i0} + T_{i1}(Y_{i1} - Y_{i0}) \mid Z_i = 1] \\ &= E[Y_{i0} + T_{i1}(Y_{i1} - Y_{i0})], \\ E[Y_i \mid Z_i = 0] &= E[Y_{i0} + T_{i0}(Y_{i1} - Y_{i0})]. \end{aligned}$$

分子为

$$E[(Y_{i1} - Y_{i0})(T_{i1} - T_{i0})] = E[Y_{i1} - Y_{i0} \mid T_{i1} > T_{i0}] P(T_{i1} > T_{i0}),$$

分母为 $E[T_{i1} - T_{i0}] = P(T_{i1} > T_{i0})$。所以比值为

$$E[Y_{i1} - Y_{i0} \mid T_{i1} > T_{i0}].$$

这个平均处理效应有一个条件：依从。因此它是 LATE，而非总体 ATE。IV 只识别依从者的处理效应。依从者满足 $T_{i1} > T_{i0}$；从不接受者满足 $T_{i1} = T_{i0} = 0$；总是接受者满足 $T_{i1} = T_{i0} = 1$；违抗者与分配方向相反。

第 10 章：匹配

按混杂因素分组估计 ATE 时，对各组处理效应加权。按样本量加权会更偏向大组，即使该组的处理变异很小；这里标为“非参数估计”。按方差加权时，方差较大的组权重更大；这与线性、参数回归更强调高变异协变量的做法相联系。

分层。 如果 X 造成混杂，就把 X 相同的观测分在一组。在 $(Y_0, Y_1) \perp T \mid X$、一致性与重叠性下，

$$\text{ATE} = \int \{E[Y \mid X = x, T = 1] - E[Y \mid X = x, T = 0]\} \, dP(x),$$

$$\widehat{\text{ATE}} = \sum_{k=1}^{K} (\bar{Y}_{k1} - \bar{Y}_{k0}) \frac{N_k}{N}.$$

在协变量取值 $\{x_1, \ldots, x_K\}$ 上取平均。

匹配估计量。 用观测之间的距离定义相似程度，再比较接受不同处理的相似 / 邻近个体。K 近邻。定义距离时，对坐标作标准化：$(x_i - \bar{x})/\sqrt{\text{Var}(x)}$。

$$\widehat{\text{ATE}} = \frac{1}{N}\sum_i (2T_i - 1)(Y_i - Y_{j(i)}).$$

$j(i)$ 是另一个处理组中与 i 最相似的观测。$2T_i - 1$ 根据个体所属的处理组调整正负号。

匹配偏差及修正。 对处理组，考虑

$$\widehat{\text{ATET}} = \frac{1}{N_1}\sum_{i:T_i=1} (Y_i - Y_{j(i)}), \qquad \mu_0(x) = E[Y \mid X = x, T = 0].$$

中心化偏差写作

$$B_N = \frac{1}{N_1}\sum_{i:T_i=1} \{\mu_0(X_i) - \mu_0(X_{j(i)})\}, \qquad \sqrt{N_1}B_N,$$

它不一定趋于零。乘上 $\sqrt{N_1}$ 会把偏差放大。我比较的是 X_i 对应个体未处理的潜在结果（因为 i 已接受处理，所以是反事实）与 X_j 对应个体实际观测到的未处理结果；用 $X_i \approx X_j$ 希望二者未处理结果也接近。减去这个偏差的估计：

$$\widehat{\text{ATET}}_{\text{bc}} = \frac{1}{N_1}\sum_{i:T_i=1} \left[(Y_i - Y_{j(i)}) - \{\hat{\mu}_0(X_i) - \hat{\mu}_0(X_{j(i)})\}\right].$$

$\hat{\mu}_0$ 可以用最小二乘等方法估计。局部 LS 修正不改变匹配估计量原本的目标。

维数灾难。协变量越多，匹配距离越大，因为每个小格子里的观测更少。

偏差修正依赖重叠性、光滑性和恰当的回归逼近。样本占比权重针对 ATE，方差权重一般对应另一种平均效应。

第 11 章：倾向得分

处理混杂偏差的另一种办法是倾向得分 $p(X) = P(T = 1 \mid X)$。图中连接 $X \to p(X) \to T \to Y$，并有 $X \to Y$。二元处理的平衡恒等式为

$$E[T \mid p(X), X] = E[T \mid p(X)].$$

若 $(Y_0, Y_1) \perp T \mid X$，这个平衡性质使调整可缩减到 $p(X)$：$(Y_0, Y_1) \perp T \mid p(X)$。识别两个处理状态的均值还需 $0 < p(X) < 1$ 的重叠性。

我的例子。两个人，一个已处理，一个未处理。若接受处理的概率相同，即使他们的 X 不同，可在这一得分组内比较；这里平衡的是分布，并非保证这一对个体的潜在结果相同。

$$\begin{aligned} E[T \mid p(X), X] &= E[T \mid X] = p(X), && \text{因为} p(X) \text{是} X \text{的函数,} \\ E[T \mid p(X)] &= E[E[T \mid p(X), X] \mid p(X)] \\ &= E[p(X) \mid p(X)] = p(X). \end{aligned}$$

逆倾向加权（IPW）。 条件差异可以改写为

$$\begin{aligned} E[Y \mid X, T = 1] - E[Y \mid X, T = 0] = p(X)E\left[\frac{Y}{p(X)} \,\middle|\, X, T = 1\right] \\ - \{1 - p(X)\}E\left[\frac{Y}{1 - p(X)} \,\middle|\, X, T = 0\right]. \end{aligned}$$

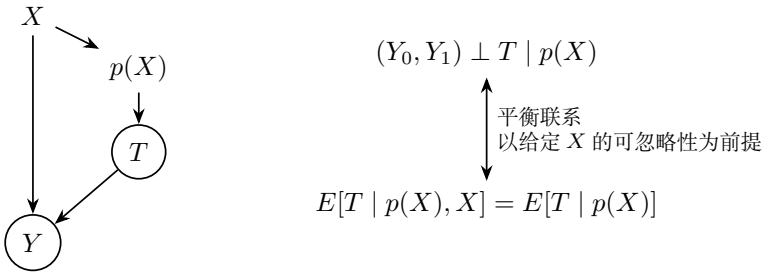
? **我的理解**。我们观测到个体 i 接受了处理，但 i 接受处理的概率只有由 X 决定的 $p(X_i)$。给每个观测到的处理个体乘上 $1/p(X_i)$ 来修正。若 $p(X_i)$ 很小，该观测在未加权的结果分布中占比不足，就用概率倒数提高其代表性。$T=1$ 和 $T=0$ 的权重分别为 $1/p(X)$ 与 $1/(1-p(X))$。这样重建“人人都处理”的总体（Y_1）和“人人都不处理”的总体（Y_0），两者之差就是 ATE。

结果的加权离散程度为

$$\hat{\sigma}^2_w = \frac{\sum_{i=1}^n w_i (Y_i - \hat{\mu})^2}{\sum_{i=1}^n w_i}.$$

但倾向得分估计 $\hat{p}(X)$ 本身也有误差。随意加入并非混杂因素的协变量，可能使倾向得分估计变得非常不稳定。已处理者估计出的处理概率可能高于未处理者。我的提醒是：权重很大，例如超过二十，会增大方差；二十是实践提醒，并非通用阈值。上面的加权离散程度不是 IPW ATE 估计量的抽样方差。

倾向得分匹配。 用 $p(X)$ 替代原本的匹配距离。我在这里的担心是：这是否真正改善因果比较？处理预测更准确，不一定使因果估计更好，反而可能增加方差。处理组与未处理组的倾向得分分布若缺乏重叠，匹配就会有问题。



倾向得分调整：在所述假设下联系平衡与条件可交换性。

第 12 章：双重稳健估计

在一致性、条件可交换性与重叠性下，结合结果回归与倾向加权，再对 X 取平均：

$$\widehat{\text{ATE}} = \frac{1}{N}\sum_i \left[\frac{T_i\{Y_i - \hat{\mu}_1(X_i)\}}{\hat{p}(X_i)} + \hat{\mu}_1(X_i)\right] - \frac{1}{N}\sum_i \left[\frac{(1-T_i)\{Y_i - \hat{\mu}_0(X_i)\}}{1-\hat{p}(X_i)} + \hat{\mu}_0(X_i)\right].$$

其中 $\hat{p}(X)$ 估计倾向得分（例如用 logistic 回归），$\hat{\mu}_1(X)$ 和 $\hat{\mu}_0(X)$ 分别估计 $E[Y \mid X, T=1]$ 和 $E[Y \mid X, T=0]$。第一个平均估计 $E[Y_1]$，第二个估计 $E[Y_0]$。一致性要求倾向模型或两个处理状态的结果回归这一组模型正确，并恰当控制估计误差。

我的代数解释。对 $E[Y_1]$，

$$\widehat{E}[Y_1] = \frac{1}{N}\sum_i \left[\frac{T_i\{Y_i - \hat{\mu}_1(X_i)\}}{\hat{p}(X_i)} + \hat{\mu}_1(X_i)\right].$$

若 $\hat{p}$ 错了，但 $\hat{\mu}_1$ 正确：$T_i=0$ 时第一项为零，$T_i=1$ 时它的均值为零，所以剩下回归预测。抵消依赖条件期望：对非零的候选倾向函数 q，$E[T\{Y-\mu_1(X)\}/q(X) \mid X] = 0$。

也可以改写为

$$\widehat{E}[Y_1] = \frac{1}{N}\sum_i \left[\frac{T_i Y_i}{\hat{p}(X_i)} - \frac{T_i - \hat{p}(X_i)}{\hat{p}(X_i)}\hat{\mu}_1(X_i)\right].$$

若结果模型错误、倾向模型正确，则给定 X_i 时 $T_i - \hat{p}(X_i)$ 的均值为零，修正项的期望因此消失。

我的实践偏好是尽量用 DRE 把两类模型结合起来；识别假设和数据质量仍要检查。

第 13 章：双重差分

双重差分用于评估宏观干预的效果。D 表示处理，T 表示时间；$Y_D(T)$ 是在时期 T、处理状态 D 下的潜在结果。

两种比较及其问题。 处理组的目标为 $E[Y_1(1) - Y_0(1) \mid D = 1]$，即比较同一时期处理与未处理的结果；其中 $Y_0(1)$ 是反事实。处理前，$E[Y_1(0) \mid D = 1] = E[Y_0(0) \mid D = 1]$。前后比较用干预前的结果代替干预后未处理的结果；但若有时间趋势，这两个未处理潜在结果未必相同。

在干预后作处理组 / 对照组比较：

$$E[Y(1) \mid D = 1] - E[Y(1) \mid D = 0].$$

它用对照组干预后的未处理结果估计处理组的反事实。我在这里提醒自己：这种比较也可能失败。

将两种比较结合：

$$\begin{aligned}\widehat{\text{ATET}} = &\{E[Y(1) \mid D = 1] - E[Y(1) \mid D = 0]\} \\ &- \{E[Y(0) \mid D = 1] - E[Y(0) \mid D = 0]\}.\end{aligned}$$

等价地，实验组的“后减前”，再减去对照组的“后减前”。线性模型纳入处理与时间的交互项，估计其不确定性，并检查平行趋势。

识别条件是未处理结果的均值趋势平行：

$$E[Y_0(1) - Y_0(0) \mid D = 1] = E[Y_0(1) - Y_0(0) \mid D = 0].$$

再结合无预期效应、一致性、无溢出和可比的群体构成，可识别 ATT。检查前期趋势有帮助，但不能证明未来的反事实趋势。

第 14 章：面板数据与固定效应

面板数据在多个时间反复观测同一单位。固定个体身份后，可用个体固定效应消除加性且不随时间变化的特征。

回顾 DID。对处理城市，干预后的未处理反事实可用“其干预前未处理结果 + 未处理城市随时间的变化”估计：

$$E[Y_0(1) \mid D = 1] = E[Y_0(0) \mid D = 1] + E[Y_0(1) - Y_0(0) \mid D = 0].$$

于是 $\widehat{\text{ATT}} = \widehat{E}[Y_1(1) \mid D = 1] - \widehat{E}[Y_0(1) \mid D = 1]$：第一项已知，第二项估计。例子旁注提到在 DMA 投放广告的效果。

平行趋势约束的是前述未处理均值的变化，并非每个个体潜在结果的恒等式。面板模型为

$$y_{it} = \beta X_{it} + \gamma U_i + e_{it}.$$

y_{it} 是单位 i 在时期 t 的结果，X_{it} 随时间变化，U_i 无法观测且不随时间变化。

面板数据的局限。 面板数据不能解决反向因果：原因和结果互相增强，固定效应无法控制这种关系。它也不能消除随时间变化的未观测混杂因素。

线性面板模型的残差化。 对于两组特征 X_1, X_2，

$$\hat{y} = X_1\hat{\beta}_1 + X_2\hat{\beta}_2.$$

特征矩阵以观测为行、特征为列。

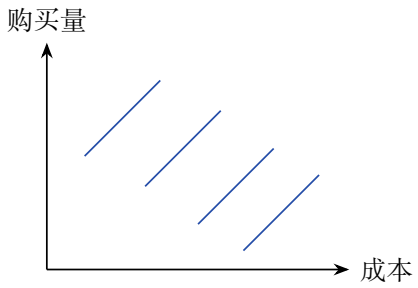
1. 将 y 对第二组特征回归：$\hat{y}^* = P_{X_2}Y$。
2. 将 X_1 对 X_2 回归：$\hat{X}_1 = P_{X_2}X_1$。
3. 取残差 $\widetilde{X}_1 = X_1 - \hat{X}_1$ 和 $\widetilde{y} = y - \hat{y}^*$。
4. 将结果残差对特征残差回归，得到 X_1 的系数。

组内变换（within transformation）。 计算 $\ddot{Y}_{it} = Y_{it} - \bar{Y}_i$ 和 $\ddot{X}_{it} = X_{it} - \bar{X}_i$，再将 $\ddot{Y}_{it}$ 对 $\ddot{X}_{it}$ 回归。因为 $\bar{U}_i = U_i$，固定效应消失：

$$\begin{aligned} Y_{it} &= \beta X_{it} + \gamma U_i + e_{it}, \\ \bar{Y}_i &= \beta \bar{X}_i + \gamma \bar{U}_i + \bar{e}_i, \\ Y_{it} - \bar{Y}_i &= \beta(X_{it} - \bar{X}_i) + \gamma(U_i - \bar{U}_i) + (e_{it} - \bar{e}_i), \\ \ddot{Y}_{it} &= \beta \ddot{X}_{it} + \ddot{e}_{it}. \end{aligned}$$

这样去掉了所有不随时间变化的未观测特征。对通胀等时间效应，可为每个时期加入一个虚拟变量；随时间变化的因素也可能重要。个体内去均值后的变量总和为零；这一中心化恒等式对时变变量也成立。固定特征消失，是因为其每个去均值值都为零。因果解释仍需外生性，通常为 $E[e_{it} \mid X_{i1}, \ldots, X_{iT}, U_i] = 0$。

图中画了多条平行的“购买量—成本”直线。固定效应模型给每个城市拟合一条线，并假定不同条件下的因果效应相同。



各城市内部平行的购买量—成本直线，保留蓝色。

第 15 章：合成控制

若找不到与处理城市或州相似的单个对照单位，就把多个未处理单位组合为合成对照。城市、州的聚合数据本身也可以组成面板。因果比较需要供体未受处理、无预期效应或溢出，并有可信的稳定关系连接干预前后的未处理结果。

共有 $J+1$ 个单位。单位 1 接受处理，$2, \ldots, J+1$ 未接受处理，组成供体库。Y_{jt}^I、Y_{jt}^N 是单位 j 在时间 t 有干预和无干预的潜在结果。处理从 T_0 开始。对 $t > T_0$，

$$\tau_{1t} = Y_{1t}^I - Y_{1t}^N.$$

已处理结果是事实，未处理结果是反事实；效应是时间的函数。给定权重 $W = (w_2, \ldots, w_{J+1})$，

$$\widehat{Y}_{1t}^N = \sum_{j=2}^{J+1} w_j Y_{jt}.$$

可用回归选择这些权重：最小化干预前处理单位与供体加权平均之间的平方距离。

把合成控制看作回归。 用供体州构建一个虚拟加州。矩阵以年份为行、州为列，元素为香烟销量。将加州序列设为 Y，其他州序列设为 X，回归 $Y \sim X$。例子中的权重有 -0.436 和 -0.032（39 个州对应 39 个权重）。它们的加权和就是虚拟州，权重的选择使虚拟州与处理州尽量接近。

这样可能过拟合：虚拟州在干预前几乎与加州重合，干预后却剧烈波动。供体序列较多时，可考虑用 Ridge 或 Lasso 正则化回归。

避免外推。 前述过拟合归因于外推：权重把观测推到了数据范围以外。施加凸组合约束。合成控制仍为 $\widehat{Y}_{1t}^{N} = \sum_{j=2}^{J+1} w_j Y_{jt}$，但选择 W 来最小化

$$\|X_1 - X_0 W\|_V = \left\{ \sum_{h=1}^{k} v_h \left(X_{h1} - \sum_{j=2}^{J+1} w_j X_{hj} \right)^2 \right\}^{1/2}, \qquad w_j \geq 0, \quad \sum_{j=2}^{J+1} w_j = 1.$$

两幅图分别画出：从供体点无约束外推到三角形外的处理点；以及将拟合限制在供体凸包内。

v_h 反映各变量在匹配处理单位和合成控制时的重要性；不同 v_h 会得到不同权重。可把各变量标准化为均值零、方差一，或给更能预测 Y 的变量更高权重。这里的实现给各变量同等重要性：定义损失函数，用 SciPy 做二次优化，要求权重和为一，并将每个权重限制在 $[0, 1]$。这个例子的权重较稀疏，且和为一（示例向量含多个零及一个约为 0.3852 的元素）。

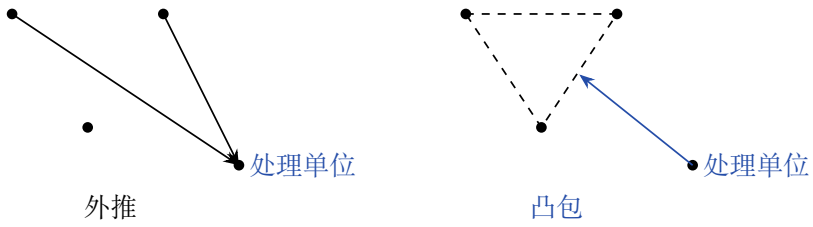
显著性与安慰剂比较。 采用受置换检验启发的安慰剂比较。对 39 个州逐一重新拟合合成控制、估计效应。加州给出真实干预的估计，其他州给出安慰剂效应。若没有处理的州也出现很大效应，就有问题。干预后的变异大于干预前；一些单位在干预前就拟合不好，应剔除。对所有分配统一应用前期拟合阈值：

$$\text{MSE} = \frac{1}{N} \sum_{t} (Y_t - \widehat{Y}_t^{\text{synth}})^2.$$

算出各州效应后，再计算

$$p = \frac{1}{J_{\text{eligible}}} \sum_{j \in \mathcal{E}} \mathbf{1}\{\hat{\tau}_j \leq \hat{\tau}_{\text{California}}\},$$

其中 $\mathcal{E}$ 包括所有合格分配及实际分配。加州效应为负，所以数的是至少同样负的效应。例子中，加州相对于安慰剂效应显得很极端。 称它为精确 p 值还需分配机制或可交换性依据；在观察研究中，安慰剂排名本身是一种诊断。凸权重限制外推，却不保证反事实拟合正确。



外推与凸包约束的几何示意。

第 16 章：断点回归设计

一个断点能告诉我们什么效应？令 R 为驱动变量，在阈值 c 处不连续地分配处理：

$$D_i = \mathbf{1}\{R_i > c\}.$$

低于 c 时处理为零，高于 c 时处理为一。 因而 $R > c$ 时观测 Y_1，$R < c$ 时观测 Y_0。图中潜在结果曲线 Y_1, Y_0 光滑，观测曲线在阈值处从 Y_0 切换到 Y_1。例子画年龄与所有死亡 / 机动车死亡 / 自杀之间的关系，寻找断点。

若两个潜在结果的均值在阈值处连续，且两侧都有支持，左右极限相同，例如

$$\lim_{r\to c^-} E[Y_{1i} \mid R_i = r] = \lim_{r\to c^+} E[Y_{1i} \mid R_i = r].$$

因此观测结果的跳跃识别

$$\begin{aligned}
&\lim_{r\to c^+} E[Y_i \mid R_i = r] - \lim_{r\to c^-} E[Y_i \mid R_i = r] \\
&= \lim_{r\to c^+} E[Y_{1i} \mid R_i = r] - \lim_{r\to c^-} E[Y_{0i} \mid R_i = r] \\
&= E[Y_{1i} - Y_{0i} \mid R_i = c].
\end{aligned}$$

这是阈值处的 ATE。我的直觉：断点附近的比较很接近局部随机实验。 连续性论证本身并不意味着真的随机分配。

先中心化驱动变量 $r_i = R_i - c$，再允许断点两侧有不同斜率：

$$y_i = \beta_0 + \beta_1 r_i + \beta_2 \mathbf{1}\{r_i > 0\} + \beta_3 \mathbf{1}\{r_i > 0\} r_i.$$

低侧直线对应前一部分，高侧加上指示项和交互项。 这时把 β_0 看作左极限，$\beta_0 + \beta_2$ 看作右极限，β_2 看作断点效应。用标准误判断显著性。

核加权。 RDD 很依赖线性回归的外推。拟合可能过于照顾远处观测，反而在断点处拟合不好。应给距离阈值更近的观测更高权重。三角核为

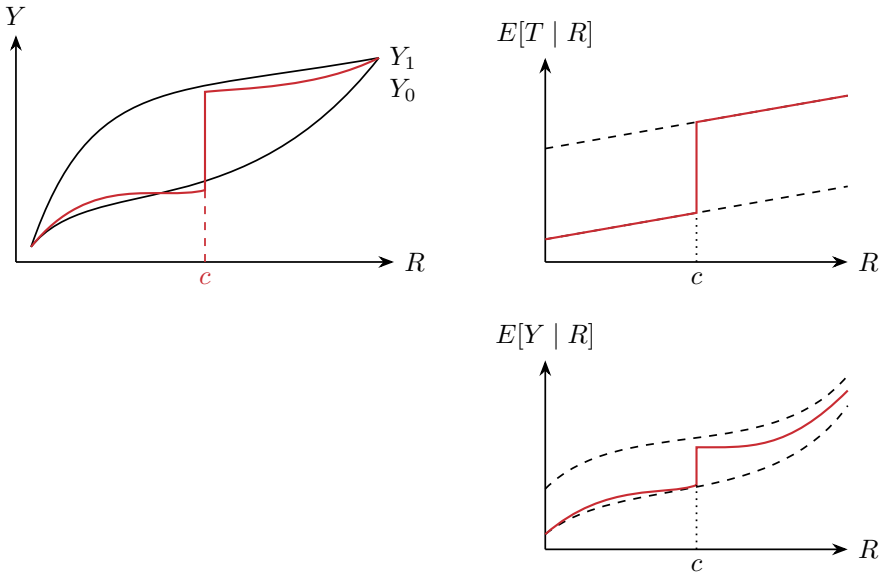
$$K(R, c, h) = \mathbf{1}\{|R - c| < h\} \left(1 - \frac{|R - c|}{h}\right).$$

指示函数只保留 $c \pm h$ 内的观测，第二个因子随离 c 的距离增加而减小。使用 WLS，即加权最小二乘。

模糊断点回归。 在阈值处，处理不一定确定地改变，而是处理概率跳跃。把是否跨过阈值作为 IV。在局部排除与外生性、非零第一阶段、连续性和单调性 $T_{1i} \geq T_{0i}$ 下，结果跳跃等于第一阶段跳跃乘依从者效应。Wald 比值为

$$\frac{\lim_{r\to c^+} E[Y_i \mid R_i = r] - \lim_{r\to c^-} E[Y_i \mid R_i = r]}{\lim_{r\to c^+} E[T_i \mid R_i = r] - \lim_{r\to c^-} E[T_i \mid R_i = r]} = E[Y_{1i} - Y_{0i} \mid T_{1i} > T_{0i}, R_i = c].$$

较大的 p 值表示数据没有提供强烈的拒绝原假设证据，不能据此判定效应很小。应同时看估计值和区间。McCrary 检验查看驱动变量密度在阈值处是否不连续，以诊断可能的操纵；它不检验所有 RD 假设。



左为清晰 RD；右上为模糊 RD 的处理跳跃，右下为结果跳跃。黑色表示潜在关系，红色表示观测断点。

第二部分：应用

第 17 章：预测模型基础

机器学习估计 $E[Y \mid X]$，即给定 X 的结果期望，得到 $\widehat{E}[Y \mid X]$。模型过于复杂就会过拟合。交叉验证要把训练数据、测试数据和未见过的数据区分开。还要区分预测与策略。相关概念还有估计量和极大似然。

R^2 用于评价连续结果模型，描述模型解释了多少结果变异。结果不是常数时，范围为 $(-\infty, 1]$，并提醒它衡量相对于均值预测的表现。树越深，训练集 R^2 越高，但测试集 R^2 可能下降，这就是过拟合。

`pandas.qcut` 按预测值的分位数分箱，也就是模型分群。更细的策略从“是否参与”的阈值决定，走向“投入多少”的连续选择。

第 18 章：异质处理效应与个性化

与普通预测不同，目标是进行干预并预测其效果。令 X 包含处理前特征（例如过去销量），T 为价格。策略目标是 $\arg\max_t E[Y(t) \mid X = x]$。在一致性、条件可交换性和重叠性下，可从 $E[Y \mid X = x, T = t]$ 学习它。

从 ATE 转向 CATE。二元处理的 ATE 为 $E[Y_1 - Y_0]$；连续处理时，用 $E[y'(t)]$，即结果对处理的导数。相应的条件版本为

$$E[Y_1 - Y_0 \mid X], \qquad E[y'(t) \mid X].$$

我的批注。加上条件 X，对每个 X 分别求期望，再制定个性化策略。

这里把敏感度非正式地称为“弹性”，即估计 $\partial Y_i / \partial T_i$，近似为

$$\frac{Y(T_i) - Y(T_i + \varepsilon)}{T_i - (T_i + \varepsilon)}.$$

但同一个人的这两个结果不能同时观测，这就是因果推断的问题。一元处理的回归 $y_i = \beta_0 + \beta_1 t_i + \beta_2 X_i + e_i$ 中，导数只有 β_1，弹性对所有人都一样。加入交互项：

$$y_i = \beta_0 + \beta_1 t_i + \beta_2 X_i + \beta_3 t_i X_i + e_i, \qquad \frac{\partial \hat{y}_i}{\partial t_i} = \hat{\beta}_1 + \hat{\beta}_3 X_i.$$

交互项使 CATE 随协变量变化。β_1, β_3 决定导数关系。也可以使用有限差分 $\{y(t+\varepsilon) - y(t)\}/\varepsilon$，以及实践中的一单位近似 $\hat{y}(t+1) - \hat{y}(t)$。

一单位差分只有在该区间响应足够接近线性时才适合作为导数近似。无量纲弹性是 $(t/y)\,\partial y/\partial t = \partial \log y / \partial \log t$。

第 19 章：评价因果模型

目的是预测与排序（分组）。可在非随机数据中作有效调整来拟合，再用独立的随机化数据（或另有识别依据且已调整的评价样本）评价。比较：

1. $\text{sales}_i = \beta_0 + \beta_1 \text{price}_i + \beta_2 X_i + \beta_3 X_i \text{price}_i + e_i$，线性模型（特征项可以是矩阵）。
2. $\text{sales}_i = G(X_i, \text{price}_i) + e_i$，用回归树。检查 R^2，判断是否过拟合。
3. 用随机数预测，作为安慰剂比较。

弹性模型按对处理的敏感程度给个体排序。在每个分组中，用一元回归 $y_i = \beta_0 + \beta_1 t_i + e_i$ 估计弹性：

$$\hat{\beta}_1 = \frac{\sum_i (t_i - \bar{t})(y_i - \bar{y})}{\sum_i (t_i - \bar{t})^2},$$

其中 $\bar{t}$ 为处理均值，$\bar{y}$ 为结果均值。

累计弹性曲线。 按预测弹性排序，最敏感的排在前面。先估计第一组的斜率，再不断加入后面的组，直到全部观测都纳入，曲线到达全样本斜率：

$$\widehat{y'}(t)_k = \hat{\beta}_k = \frac{\sum_{i=1}^{k} (t_i - \bar{t}_k)(y_i - \bar{y}_k)}{\sum_{i=1}^{k} (t_i - \bar{t}_k)^2}.$$

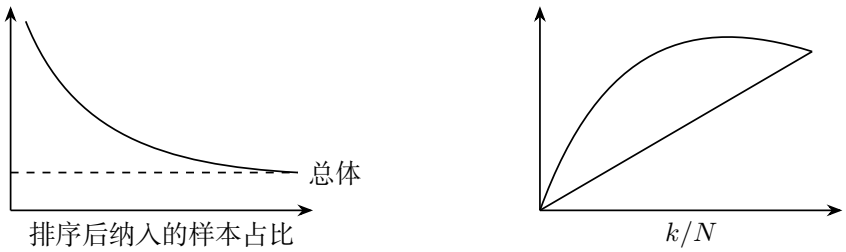
我的排序目标是 $\widehat{y'}(t)_k > \widehat{y'}(t)_{k+a}$，并且差异要大。草图向总体效应下降，表示排序区分得好的模型更理想。

累计增益曲线。

$$\widehat{F}(k) = \hat{\beta}_k \frac{k}{N} = \frac{\sum_{i=1}^{k} (t_i - \bar{t}_k)(y_i - \bar{y}_k)}{\sum_{i=1}^{k} (t_i - \bar{t}_k)^2} \frac{k}{N}.$$

图中把弯曲的增益线与直线基准比较。构造置信区间时，标准误为

$$S_{\hat{\beta}_1} = \sqrt{\frac{\sum_i \hat{\varepsilon}_i^2}{(n-2)\sum_i (t_i - \bar{t})^2}}.$$



左为累计斜率，右为累计增益与直线基准。

每个前缀都要重新计算 $\bar{t}_k, \bar{y}_k$。向下的草图采用正收益约定；价格效应为负时，应按更负的斜率排序，或一致地变换符号。所示标准误是独立同分布、同方差线性误差下的逐点标准误，并非整条曲线的同时置信带。

第 20 章：即插即用估计量

此前通过可比的处理组和对照组得到 ATE：随机分配用 $(Y(0), Y(1)) \perp T$，调整后的观察比较用 $(Y(0), Y(1)) \perp T \mid X$ 并要求重叠性。现在我问：处理对谁更有效，谁更敏感？

$$\tau_i = Y_i(1) - Y_i(0), \qquad Y_i^{\text{obs}} = \begin{cases} Y_i(1), & T_i = 1, \\ Y_i(0), & T_i = 0. \end{cases}$$

$$\text{ATE} = \tau = E[\tau_i], \qquad \text{CATE} = \tau(x) = E[\tau_i \mid X = x].$$

在 $y_i = \beta_0 + \beta_1 t_i + \beta_2 X_i + \beta_3 t_i X_i + e_i$ 中，拟合效应为 $\hat{\tau}(x) = \hat{\beta}_1 + \hat{\beta}_3 x$。主效应系数 β_2 从这个差值中消去。我起初把无关的 X 与效应估计偏差联系起来；但在正确设定、未正则化的 OLS 中，无关协变量并不必然造成偏差，可能只是降低精度。

结果预测的 MSE 是 $E[(Y_i - \hat{Y}_i)^2]$。我的目标则是处理效应预测：

$$\min_f E[(\tau(X) - f(X))^2].$$

补充说明。 令 $\Delta = Y(1) - Y(0)$，个体效应风险还多出与 f 无关的一项：

$$E[(\Delta - f(X))^2] = E[(\tau(X) - f(X))^2] + E[\text{Var}(\Delta \mid X)].$$

因此两种风险有相同最优解，却一般不相等。

二元处理的变换结果。 引入 $Y_i^* = 2Y_iT_i - 2Y_i(1-T_i)$。在各半的随机分配下，$T \perp (Y(0), Y(1))$，所以 $E[TY(t)] = E[T]E[Y(t)]$。另外 $Y_iT_i = Y_i(1)T_i$，$Y_i(1-T_i) = Y_i(0)(1-T_i)$。因此

$$\begin{aligned} E[Y_i^* \mid X_i = x] &= 2E[Y_i(1)T_i \mid X_i = x] - 2E[Y_i(0)(1-T_i) \mid X_i = x] \\ &= 2E[Y_i(1) \mid X_i = x]\,0.5 - 2E[Y_i(0) \mid X_i = x]\,0.5 \\ &= \tau(x). \end{aligned}$$

非随机分配时，引入倾向得分 $e(X_i)$，在条件可交换性与重叠性下使用

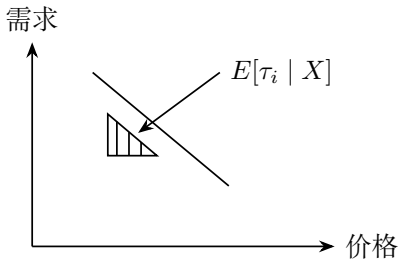
$$Y_i^* = Y_i \frac{T_i - e(X_i)}{e(X_i)(1-e(X_i))}.$$

若已知随机处理概率为 p，则用 p 代替 $e(X_i)$。关键在于展开条件期望：

$$\begin{aligned} E[Y_i^* \mid X_i = x] = &\frac{E[Y_i(1) \mid X_i = x]E[T_i \mid X_i = x]}{e(x)} \\ &- \frac{E[Y_i(0) \mid X_i = x]E[1 - T_i \mid X_i = x]}{1 - e(x)} = \tau(x). \end{aligned}$$

我从累计增益曲线看到，这个变换目标很嘈杂。其保证为 $E[Y^* \mid X] = \tau(X)$，即给定 X 平均后针对 CATE。随机分配下，给定一个人的潜在结果，它也可对该人的效应设计无偏。权重矩条件合适时，更多数据有助于平均噪声，但不能补救缺乏重叠。

连续处理。 目标为 $\tau(x) = E[\partial Y_i(t)/\partial t \mid X = x] = E[\tau_i \mid X = x]$。草图为需求随价格向下倾斜。



在 $X = x$ 的分组内，条件投影斜率及其样本对应量为

$$\hat{\tau}(x) \approx \frac{\text{Cov}(Y_i, T_i \mid X = x)}{\text{Var}(T_i \mid X = x)} = \frac{\sum_i (Y_i - \bar{Y})(T_i - \bar{T})}{\sum_i (T_i - \bar{T})^2}.$$

设条件均值对处理线性，$E[Y \mid T, X = x] = a(x) + \tau(x)T$。在各 x 处具有相同随机处理分布时，记 $\mu_T = E[T]$、$\mu_Y = E[Y]$、$\sigma_T^2 = \text{Var}(T) > 0$。对单个观测定义

$$Y_i^* = (Y_i - \mu_Y)\frac{T_i - \mu_T}{\sigma_T^2}.$$

设 $V_i = (T_i - \mu_T)/\sigma_T^2$。推导使用 $E[V_i \mid X_i = x] = 0$、$E[T_iV_i \mid X_i = x] = 1$，以及

$$E[T_i(T_i - \mu_T) \mid X_i = x] = E[(T_i - \mu_T)^2 \mid X_i = x],$$

还使用 $E[T_i e_i \mid X_i = x] = E[T_i \mid X_i = x]E[e_i \mid X_i = x]$。在 $X_i = x$ 时，若 $Y_i = \alpha + \beta T_i + e_i$，

$$\begin{aligned} E[Y_i^* \mid X_i = x] &= E[(Y_i - \mu_Y)V_i \mid X_i = x] \\ &= E[(\alpha + \beta T_i + e_i - \mu_Y)V_i \mid X_i = x] = \beta = \tau(x). \end{aligned}$$

我的推广尝试是把处理均值换成模型 $m(X_i)$：

$$Y_i^{*,\text{try}} = (Y_i - \mu_Y)\frac{T_i - \hat{m}(X_i)}{\{T_i - \hat{m}(X_i)\}^2}.$$

方差很难估计。如果只需要比较排序，能不能不估计方差？

补充说明。 单个观测的残差平方不等于条件处理方差。在上述条件线性模型中，有效的矩目标为

$$\frac{\{Y_i - \ell(X_i)\}\{T_i - m(X_i)\}}{v(X_i)}, \quad \ell(x) = E[Y \mid X = x], \quad v(x) = \text{Var}(T \mid X = x) > 0.$$

它的条件均值为 $\tau(x)$。省去 $v(x)$ 后，排序针对的是 $v(x)\tau(x)$；只有额外条件下，例如 $v(x)$ 为正常数，才保留效应排序。尝试中的单个残差分母还可能在零附近爆炸。第 22 章给出相关的加权 R-loss 写法。

非线性关系：目前还没有解决方式。 Maybe：$D_i = 1/P_i^{\alpha}$，于是 $\log D_i = -\alpha \log P_i$。这是一个可以继续探索的变换，并非已经完成的一般解法。

第 21 章：元学习器

这些 ML 构造用于估计 CATE。在非随机数据上拟合仍要处理混杂，尽可能在独立随机化数据上评价。二元处理目标为 $E[Y_i(1) - Y_i(0) \mid X]$；因果解释需要一致性、条件可交换性与重叠性。连续处理的条件导数还需要适合剂量响应关系的模型。

S-learner（"Go-Horse Learner"）。 用一个 ML 模型 M_S 估计 $\mu(X, T) = E[Y \mid T, X]$。以 (X, T) 拟合，然后把同一个 X 分别与 $T = 0$、$T = 1$ 输入模型，两次预测之差得到 CATE。累计增益曲线可以检查过拟合，调节 `max_depth`。

缺点是容易把处理效应压向零。S-learner 是带正则化的 ML 模型，正则化会限制估计出的处理效应。如果其他协变量预测能力很强，模型甚至可能完全不用处理变量。

T-learner. 把数据分开，可以避免处理变量被彻底忽略。分别拟合

$$\mu_0(x) = E[Y \mid T = 0, X = x], \qquad \mu_1(x) = E[Y \mid T = 1, X = x],$$

再估计 $\hat{\tau}(x) = M_1(x) - M_0(x)$。流程图将处理组和对照组交给不同模型，再将同一个 X 输入两个模型，预测结果相减。

我的批注。分开之后，每份数据也变少。例如 $T = 0$ 数据很多，可以拟合得很好；$T = 1$ 数据很少，为避免过拟合，就只能用简单模型。这样正则化又和效应估计发生矛盾。

X-learner. 第一阶段类似 T-learner；再增加一层来拟合填补出的效应，并使用倾向模型。

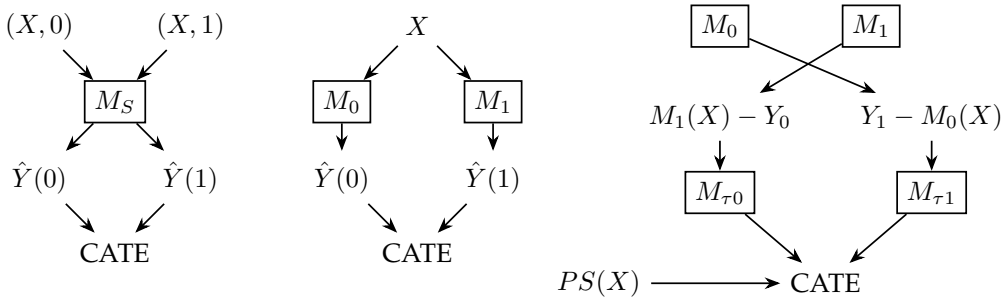
1. 拟合 $\hat{M}_0(x) \approx E[Y \mid T = 0, X = x]$ 和 $\hat{M}_1(x) \approx E[Y \mid T = 1, X = x]$。$T = 0$ 与 $T = 1$ 下的关系可以不同。
2. 将观测结果与预测出的缺失结果作差，填补处理效应：

$$\hat{\tau}_i^{(0)} = \hat{M}_1(X_i) - Y_i \quad (T_i = 0), \qquad \hat{\tau}_i^{(1)} = Y_i - \hat{M}_0(X_i) \quad (T_i = 1).$$

3. 拟合效应模型 $\hat{M}_{\tau 0}(x) \approx E[\hat{\tau}^{(0)} \mid X = x, T = 0]$ 和 $\hat{M}_{\tau 1}(x) \approx E[\hat{\tau}^{(1)} \mid X = x, T = 1]$。
4. 将二者组合：

$$\hat{\tau}(x) = \hat{M}_{\tau 0}(x)\hat{e}(x) + \hat{M}_{\tau 1}(x)\{1 - \hat{e}(x)\}.$$

流程图将两个结果模型交叉用于另一组，构造 CATE 伪结果，再拟合两个模型，最后用倾向得分 $PS(X)$ 组合。我的理解是：$e(X)$ 较大意味着 $T = 1$ 的数据更多，对应结果模型更准，所以应给更大权重。 这里指的是为另一组效应回归提供反事实填补的结果模型。



S、T、X 三种学习器的指向关系。

用倾向得分作这个组合权重是一条有用规则，并非普遍的最小方差选择。正则化偏差依赖学习器，并不总朝向零。

第 22 章：去偏 / 正交机器学习

参考 “Double Machine Learning for Treatment and Causal Parameters”（2016）。ML 用于估计干扰函数。销量例子中，价格以及温度、成本、星期几等特征可能有复杂联系；混杂使朴素价格回归不可靠。

Frisch–Waugh–Lovell. 对 $\hat{Y} = X_1\hat{\beta}_1 + X_2\hat{\beta}_2$，$X_1, X_2$ 为特征矩阵（每列一个特征，每行一个观测），$\hat{\beta}_1, \hat{\beta}_2$ 取列系数向量。按下列步骤可得到相同的 X_1 系数：

1. 将 Y 对 X_2 回归，得到 $\hat{Y}^* = P_{X_2}Y$。
2. 将 X_1 对 X_2 回归，得到 $\hat{X}_1 = P_{X_2}X_1$。
3. 取 $\widetilde{X}_1 = X_1 - \hat{X}_1$ 和 $\widetilde{Y} = Y - \hat{Y}^*$。
4. 将 $\widetilde{Y}$ 对 $\widetilde{X}_1$ 回归，恢复 $\hat{\beta}_1$。

所以 $(Y - \widehat{Y \sim X}) \sim (T - \widehat{T \sim X})$ 可以估计下式中的 τ：

$$Y_i - E[Y_i \mid X_i] = \tau\{T_i - E[T_i \mid X_i]\} + \varepsilon_i.$$

加强版 FWL：用 ML 估计 ATE。

$$Y_i - \hat{M}_Y(X_i) = \tau\{T_i - \hat{M}_T(X_i)\} + \varepsilon_i.$$

$\hat{M}_Y$ 估计 $E[Y \mid X]$，是去噪模型，解释 X 带来的 Y 变异。$\hat{M}_T$ 估计 $E[T \mid X]$，是去偏模型，去除与 X 相关的处理分配偏差。

1. 用灵活的 ML 回归 M_Y，从特征 X 估计结果 Y。
2. 用 M_T 从 X 估计处理 T。
3. 得到残差 $\widetilde{Y} = Y - M_Y(X)$ 和 $\widetilde{T} = T - M_T(X)$。
4. 将结果残差对处理残差回归：$\widetilde{Y} = \alpha + \tau\widetilde{T}$。

我的理解是“两次预测，一次回归”。在常效应部分线性模型 $Y = \tau T + g(X) + \varepsilon$、$E[\varepsilon \mid T, X] = 0$ 下，τ 是因果斜率（二元处理时为 ATE）。二元效应异质时，合并残差回归针对的是 $E[e(X)(1-e(X))\tau(X)]/E[e(X)(1-e(X))]$。

我对过拟合的解释。若 M_Y 过拟合，它不只拟合了 Y 与 X 的关系，还吞掉了一部分 Y 与 T 的关系。因果关系被结果模型吸收，没有留给残差回归，因此最后的效应可能偏向零。若 M_T 过拟合，它解释了过多 T 的变异，剩下的处理残差方差很小，最后效应估计的方差就很大。我把这与拟合倾向得分过于极端联系起来。但残差接近零也可能来自过拟合，并不能单凭它就判定真实倾向得分违反正值性。

为解决过拟合，把数据分成 K 折。每次用其余 $K-1$ 折训练 ML 模型，在留出的一折上计算残差。合并所有折的预测 / 残差，再拟合 $\widetilde{Y} = \alpha + \tau \widetilde{T}$。

CATE 与 R-learner。 让斜率随 X 变化：

$$Y_i - M_Y(X_i) = \tau(X_i)\{T_i - M_T(X_i)\} + \varepsilon_i.$$

最后一层回归可为 $\widetilde{Y}_i = \alpha + \beta_1 \widetilde{T}_i + \beta_2 X_i \widetilde{T}_i + \varepsilon_i$。最终模型用 $M(\text{Price}=1, X_i) - M(\text{Price}=0, X_i)$ 估计销量效应。R-learner。

非参数双重 / 去偏 ML。 对于价格与销量这样的连续关系，写作

$$Y_i = \hat{M}_Y(X_i) + \tau(X_i)\{T_i - \hat{M}_T(X_i)\} + \hat{\varepsilon}_i.$$

整理残差：

$$\hat{\varepsilon}_i = \{Y_i - \hat{M}_Y(X_i)\} - \tau(X_i)\{T_i - \hat{M}_T(X_i)\}.$$

最小化残差平方得到 R-loss。在所述识别条件下，它估计二元处理 CATE；若响应对连续处理线性，则估计条件斜率：

$$\begin{aligned}
\hat{L}_n(\tau) &= \frac{1}{n}\sum_{i=1}^{n}\Big[\{Y_i - \hat{M}_Y(X_i)\} - \tau(X_i)\{T_i - \hat{M}_T(X_i)\}\Big]^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}(\widetilde{Y}_i - \tau(X_i)\widetilde{T}_i)^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}\widetilde{T}_i^2\left(\frac{\widetilde{Y}_i}{\widetilde{T}_i} - \tau(X_i)\right)^2.
\end{aligned}$$

我的理解。这就是用任意预测模型预测 $\widetilde{Y}_i/\widetilde{T}_i$，权重为 $\widetilde{T}_i^2$。残差为零时使用未除开的平方损失，不计算这个比值。

哪里是非参数？ 方程 $\widetilde{Y}_i = \tau(X_i)\widetilde{T}_i + e_i$ 对残差处理仍然线性，但 τ 可以灵活地随 X 变化。对于真正非线性的处理响应，条件 R-loss 的最小化解为

$$\tau^*(x) = \frac{\text{Cov}(T, Y \mid X = x)}{\text{Var}(T \mid X = x)}.$$

这是条件投影斜率，并不自动等于某一处理值处的导数。这一区别引出下一步尝试。

Non-Scientific Double/Debiased ML：未完成

未完成。沿着教材的非线性构造，我想理清如何从个体数据点得到反事实预测—— “CATE?” ——乃至整条结果曲线。把

$$\widetilde{Y}_i = \tau(X_i)\widetilde{T}_i + e_i$$

换成对处理残差非线性的函数：

$$\widetilde{Y}_i = g(X_i, \widetilde{T}_i) + e_i.$$

先用 X 预测处理并取残差，再用 $(X, \widetilde{T})$ 拟合结果残差。可以尝试合适的 ML 模型，例子使用 LGBM；拟合输出为 $\widehat{\widetilde{Y}}$。

我的逐步理解。 设 Y 为销量，T 为价格，X 为协变量。

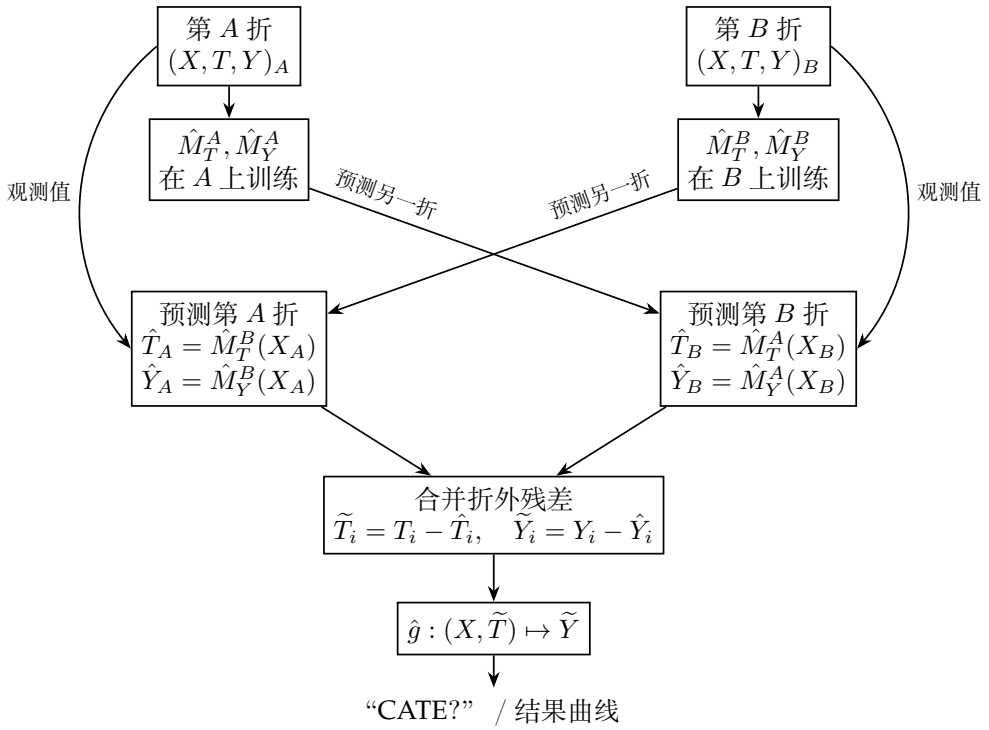
1. 用五折 LGBM 交叉预测得到 $\hat{Y} = \hat{M}_Y(X)$、$\hat{T} = \hat{M}_T(X)$，每折都由其他折训练的模型预测。
2. 计算 $\widetilde{Y} = Y - \hat{Y}$、$\widetilde{T} = T - \hat{T}$。
3. 用 $(\widetilde{T}, X)$ 拟合 $\widetilde{Y}$，将最终模型记为 `finalM`，或 $\hat{g}$。
4. 对新的 X，平均五个处理模型的预测，得到 $\hat{T}'$。对每个假想反事实价格 T_{new}，使用

$$\widetilde{T}' = T_{\text{new}} - \hat{T}', \qquad \widetilde{Y}' = \hat{g}(X, \widetilde{T}').$$

   训练与预测必须使用同一残差方向。[1]
5. 加回基线预测：$\hat{Y}(T_{\text{new}}, X) = \hat{M}_Y(X) + \widetilde{Y}'$。结果残差以零为中心；加回基线恢复结果水平。

这里得到的是结果曲线；效应还要通过两点比较或求导得到。我还没有完成这个非线性构造的因果论证。

下面用两折画出两类干扰模型共同的交叉预测关系；五折时重复同一原则。



我想记住的缺点：正则化可能使因果估计收缩，具体 ML 算法也很重要。提升树给出阶梯式而非光滑曲线，也不擅长外推到未见价格，预测可能很奇怪。

补充说明：非线性拟合识别什么

固定 m, ℓ 后，$r = t - m(x)$ 在给定 x 时可逆。若一致拟合 $g(x, r) = E[Y - \ell(X) \mid X = x, T - m(X) = r]$，可重建 $E[Y \mid x, t] = \ell(x) + g(x, t - m(x))$。因果响应还需要可交换性与支持条件。这个灵活残差学习器不会自动继承 R-loss 的正交性或收敛率保证。交叉拟合控制使用自身观测造成的过拟合，识别假设和足够准确的干扰函数估计仍然必要。

[1] 教材第 22 章文字把减法方向写反，并把结果残差预测标为 “Price”；其代码采用反事实价格减预测价格。这里按代码与训练残差定义统一。

第 23 章：效应异质性与非线性

处理效应异质性（TEH）指不同个体的处理效应不同。例子研究一个潜在连续结果：

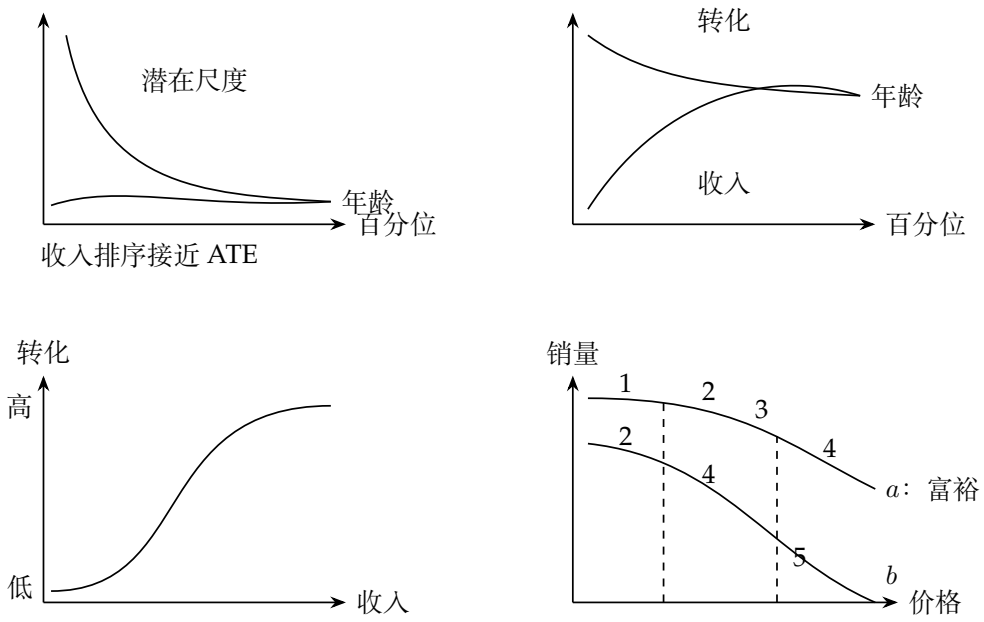
$$Y_{\text{latent}} \sim N(-4.5 + 0.001\,\text{income} + \text{nudge} + 0.01\,\text{nudge}\cdot\text{age},\ 1),$$
$$\text{nudge} \sim B(0.5), \qquad \text{age} \sim G(10, 4).$$

用 Gamma 的形状—尺度参数化，取 $\text{income} = 100G(20, 2)$、$\text{conversion} = \mathbf{1}\{Y_{\text{latent}} > 0.1\}$。[2]收入的加性系数对所有人相同；年龄在潜在尺度上调节处理效应。潜在尺度 ATE 为 $1 + 0.01E[\text{age}] = 1.4$。例子模拟出的处理组减对照组转化差约为 0.394。转化是非线性的，因此它属于另一种效应尺度。

几幅草图的意思。 对潜在结果的效应，按年龄排序的累计效应曲线起点很高，随后下降至 ATE；按估计收入排序则一直在 ATE 附近。对转化的效应，年龄和估计收入都表现出处理效应异质性。即使收入在潜在尺度不与处理交互，它仍强烈预测转化。

我的第三幅图把转化概率画成估计收入的 S 形函数。两端都平缓：基础转化率极低或极高时，同样大小的正向潜在平移作用很小；中间区域可能更敏感。因此，“基础转化率更低，效应就更大”只能是在曲线适当区间内的比较，并非一般规则。

第二个例子：价格响应。 销量—价格图有两条向下的非线性曲线，分别为 a、b 两种人；a 标为富裕者。价格区间不断提高时，图上 a 的下降量约为 1、2、3、4，b 为 2、4、5。效应既依赖类型（a 或 b），也依赖价格，不能简单按一个固定弹性排序。我的建模想法是尝试变换价格，例如 $-(\text{price}^4)$，使其与 Y 线性。变换仍要符合响应形状，是有待检查的设想。



潜在尺度与转化尺度的排序、饱和效应，以及类型 / 价格依赖。

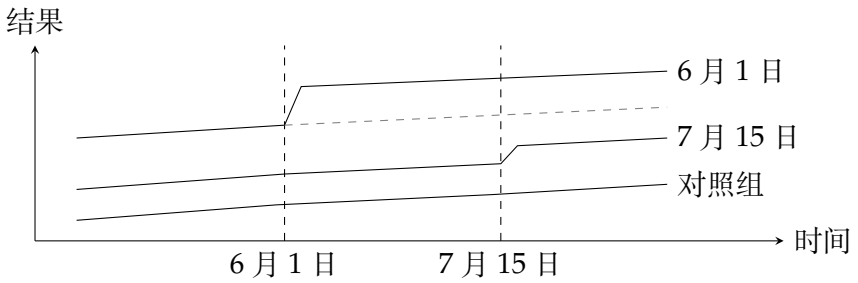
补充说明。 潜在均值为 a、正向平移为 δ、噪声为单位正态、阈值为 c 时，转化效应是 $\Phi(a + \delta - c) - \Phi(a - c)$，在两端都很小。若价格变换给出 $E[Y \mid p, x] = a(x) + b(x)h(p)$，原价格尺度上的效应仍是 $b(x)h'(p)$；变换后线性不意味着价格效应恒定。

[2]这是教材模拟代码的设定。教材文字以及我最初跟随文字记录的版本遗漏了 100 倍缩放，并用阈值 0；所引用的转化差值对应代码设定。

第 24 章：双重差分的发展与问题

面板数据与双向固定效应

面板数据：跨时间重复观察同一个单位。这里同时比较不同时间、不同地区的单位。



灰色虚线表示 TWFE 反事实轨迹。

按干预开始日期 g 给单位分组。

干预开始日期 $\longrightarrow$ 队列标签 g

约定 $t = g$ 为开始受处理的时期，队列—时间目标量为

$$\mathrm{ATT}(g,t) = E[Y_t(g) - Y_t(\infty) \mid G = g], \qquad t \geq g.$$

其中 $Y_t(\infty)$ 是始终不接受处理的结果。对队列—时间效应求平均时，还需指定权重。

模型为

$$\mathrm{Install}_{it} = \tau D_{it} + \gamma_i + \theta_t + e_{it}.$$

这里 i 表示单位，t 表示时间，e_{it} 是噪声；γ_i 对应单位差异，θ_t 对应共同时间冲击。用 OLS 估计，就得到双向固定效应（TWFE）：同时吸收单位不随时间变化的特征与共同时间效应。 仅靠这两项不能控制因单位而异、又随时间变化的混杂。

两组、两期 $\longrightarrow$ TWFE 系数等于 DiD 差分。

TWFE 结果模型 $\longrightarrow$ 用同一组固定效应对结果与处理分别取残差。

对平衡面板，令 $z \in \{\mathrm{Install}, D\}$：

$$\widetilde{\mathrm{Install}}_{it} = \tau \widetilde{D}_{it} + e_{it}.$$

$$\widetilde{z}_{it} = z_{it} - \underbrace{\bar{z}_{i\cdot}}_{\text{时间平均}} - \underbrace{\bar{z}_{\cdot t}}_{\text{单位平均}} + \bar{z}_{\cdot\cdot},$$

$$\bar{z}_{i\cdot} = \frac{1}{T}\sum_{s=1}^{T} z_{is}, \qquad \bar{z}_{\cdot t} = \frac{1}{N}\sum_{j=1}^{N} z_{jt}, \qquad \bar{z}_{\cdot\cdot} = \frac{1}{NT}\sum_{j=1}^{N}\sum_{s=1}^{T} z_{js}.$$

加回总体均值后，各行和各列的均值才为零。若省略这个常数，最终回归中的截距可以吸收平移；不含截距时，斜率可能改变。非平衡面板应使用固定效应投影。

困境：效果异质性下的失效

处理效应存在异质性时，TWFE 系数未必等于我们想估计的 ATT。先看静态模型

$$y_{it} = \tau D_{it} + \gamma_i + e_{it}.$$

① **函数形式**。共同的处理系数、所纳入协变量的线性关系、可加的固定效应。尤其是，单一的 τ 排除了随受处理时长而变化的效应。

② **外生性与时间关系**。静态回归需要检查严格外生性

$$E[e_{it} \mid D_{i1}, \ldots, D_{iT}, \gamma_i] = 0,$$

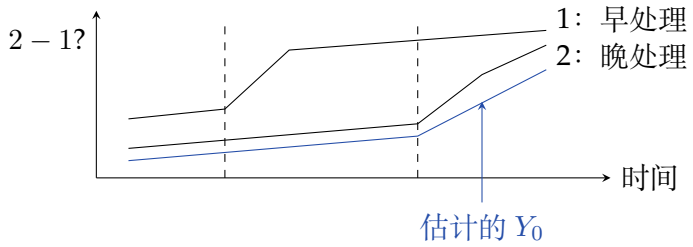
以及相关问题：提前反应、不可观测且随时间变化的混杂、过去处理对当前结果的延续作用、过去结果对当前处理的反馈。这些检查与 DiD 中的平行趋势、无提前反应限制相互关联，但不能互相替代。若允许动态处理效应，需要相应的模型和目标量。

假设处理反应逐渐增加：$0.1, 0.2, \ldots$，每天变化。将早期受处理组记为 1，晚期受处理组记为 2，从不受处理组记为 3。TWFE 混合了若干个 2×2 DiD 比较：

$$1-3: \checkmark, \quad 2-3: \checkmark, \quad 1-2: \checkmark, \quad 2-1: \text{??}$$

第二个组充当对照。$1-2$ 使用组 2 尚未受处理的时间窗。有问题的是 $2-1$：组 1 已经受处理。

我的理解：若用早期受处理组作对照，它随时间变化的处理效应会被当成未处理趋势的一部分。蓝线表示由此估计的晚期组 Y_0。



Goodman-Bacon 分解可概括为

$$\operatorname*{plim}_{n\to\infty} \hat{\tau}^{\text{TWFE}} = \text{VWATT} - \Delta\text{ATT}.$$

ATT 随时间变化所带来的偏差 $\longrightarrow$ ΔATT

在上图的比较中，效果随时间增加会污染对照趋势，使差分向下偏；效果递减时方向相反。若负效果变得更负，估计甚至可能连正负号都错！ 总体 TWFE 的偏离还取决于各队列效应与比较权重，不能仅由这幅图判断所有设计中的偏差方向。

事件研究设计

将单一处理指示变量换成事件时间指示变量，并以 $k = -1$ 为省略的参照期：

$$\begin{aligned} Y_{it} &= \alpha_i + \theta_t + \beta_{<-K}\mathbf{1}\{t - G_i < -K\} \\ &\quad + \sum_{k=-K}^{-2} \beta_k D_{it}^k + \sum_{k=0}^{L} \beta_k D_{it}^k + \beta_{>L}\mathbf{1}\{t - G_i > L\} + e_{it}, \\ D_{it}^k &= \mathbf{1}\{t - G_i = k\}. \end{aligned}$$

$D_{it}^k = \mathbf{1}\{t - G_i = k\}$ $\longrightarrow$ 处于相对时期 k 时为 1，否则为 0。

衡量单位距离开始受处理有多远 $\longrightarrow$ 事件时间指示变量 D_{it}^k。

从不受处理单位的事件时间指示变量均为零。这只是部分改进：交错采用且效应异质时，lead/lag 系数仍可能混入其他相对时期的效应，因果解释仍需要有效的队列比较。

改进：更灵活的函数形式

先试着让每个单位、每个时期都有自己的处理效应：

$$Y_{is} = \alpha_i + \theta_s + \sum_{j=1}^{N}\sum_{t=1}^{T} \tau_{jt}\mathbf{1}\{i=j\}\mathbf{1}\{s=t\}D_{is} + e_{is}.$$

参数太多！改成按采用队列分组：

$$Y_{is} = \alpha_i + \theta_s + \sum_{g\in\mathcal{G}}\sum_{t=1}^{T} \tau_{gt}\mathbf{1}\{G_i=g\}\mathbf{1}\{s=t\}D_{is} + e_{is}.$$

效果参数由“单位 × 时期”降为“队列 × 时期”。显式指示变量说明观测 (i,s) 对应哪个系数。

再删除处理前以及对照队列的效应系数：

$$Y_{is} = \alpha_i + \theta_s + \sum_{g\in\mathcal{G}_{\text{tr}}}\sum_{t\geq g} \tau_{gt}\mathbf{1}\{G_i=g\}\mathbf{1}\{s=t\} + e_{is}.$$

这里 $\mathcal{G}_{\text{tr}}$ 包含观测期内受处理的队列。对照在比较时间窗内必须尚未受处理：可以是从不受处理单位，或适当选择的尚未受处理单位。“采用日期更早”本身不能使队列成为对照。[3]

手工建立队列虚拟变量：$(0,1),(1,0),\ldots$ $\longrightarrow$ 队列与时期交互的处理项。

还有两点：

1. 处理效应会随时间推移而改变，之前的固定效果模型没有考虑。
2. DiD 与 TWFE 仍须满足相应的平行趋势限制。这个限制很强、很强。

第 25 章：合成双重差分

面板数据的表示

在多个时期观测多个单位。在 D 中，行是时间，列是单位：

$$D = \begin{pmatrix} 0 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 1 & 1 \\ 0 & 0 & 0 & \cdots & 1 & 1 \end{pmatrix}.$$

采用后出现 1 的列 $\longrightarrow$ 受处理单位

一次进入处理状态：单位一旦受处理，就不会返回未处理状态。这里的四块表示还要求受处理单位共用处理前 / 后的分界。这些是设计限制；因果识别仍需关于未处理结果的假设。交错采用将在后面通过子面板处理。

表示方法 1：合成控制。 将观测组织为四块：

$$D = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}, \qquad Y = \begin{pmatrix} Y_{\text{pre,co}} & Y_{\text{pre,tr}} \\ Y_{\text{post,co}} & Y_{\text{post,tr}} \end{pmatrix}.$$

pre/post 表示处理前 / 后，co/tr 表示对照 / 处理组。

[3] 教材的求和式和对照队列排序采用了示意性写法；其实现例子使用的是观测时间窗内尚未受处理的队列。

表示方法 2：DiD。 使用长表，列分别为单位、时间、结果、是否属于处理组、是否已经开始受处理。

观测到的四块与缺失的反事实为

$$Y = \begin{pmatrix} Y(0)_{\text{pre,co}} & Y(0)_{\text{pre,tr}} \\ Y(0)_{\text{post,co}} & Y(1)_{\text{post,tr}} \end{pmatrix}, \qquad \text{ATT} = \overline{Y}(1)_{\text{post,tr}} - \underbrace{\overline{Y}(0)_{\text{post,tr}}}_{\text{反事实}}.$$

横线表示对受处理单位在处理后时期的单元格求平均。

回看 DiD 与合成控制

DiD 回归及其平行趋势限制为

$$Y_{it} = \beta_0 + \beta_1 \text{Post}_t + \beta_2 \text{Treated}_i + \beta_3 \text{Treated}_i \text{Post}_t + e_{it},$$
$$E[Y(0)_{\text{post,co}} - Y(0)_{\text{pre,co}}] = E[Y(0)_{\text{post,tr}} - Y(0)_{\text{pre,tr}}].$$

若没有处理，两组的平均变化相同。

$\hat{\tau}^{\text{did}}$ 是下列最小化问题中的处理系数：

$$\min_{\mu,\alpha,\beta,\tau} \sum_{i=1}^{N}\sum_{t=1}^{T}[Y_{it} - (\mu + \alpha_i + \beta_t + \tau D_{it})]^2.$$

$$\widetilde{Y}_{it} = Y_{it} - \overline{Y}_{i\cdot} - \overline{Y}_{\cdot t} + \overline{Y}_{\cdot\cdot},$$
$$\widetilde{D}_{it} = D_{it} - \overline{D}_{i\cdot} - \overline{D}_{\cdot t} + \overline{D}_{\cdot\cdot}.$$

平衡面板中对 Y 与 D 去均值 $\longrightarrow$ 固定效应最小二乘目标。

这个形式与合成控制相似，但没有权重。

合成控制先用处理前结果拟合权重：

$$\widehat{w}^{\text{sc}} = \underset{w_{\text{co}}}{\text{argmin}} \, \|\overline{y}_{\text{pre,tr}} - Y_{\text{pre,co}} w_{\text{co}}\|_2^2, \quad \sum_{i\in\text{co}} w_i = 1, \quad w_i \geq 0.$$

$Y_{\text{pre,co}}$ 为 $T_{\text{pre}} \times N_{\text{co}}$：行是时间，列是单位。$w_{\text{co}}$ 为 $N_{\text{co}} \times 1$。$\overline{y}_{\text{pre,tr}}$ 的每一项是在某个处理前时点对处理组单位求平均。让合成对照贴合处理组，这类似线性回归。对照单位的权重可以为零。

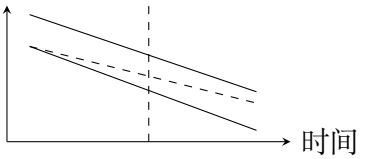
处理后，用加权对照预测缺失的结果，再平均处理后的差值。相应的 SC 回归目标也写在下面：

$$\widehat{Y}(0)_{\text{post,tr}} = Y_{\text{post,co}} \widehat{w}^{\text{sc}}_{\text{co}}, \qquad \widehat{\text{ATT}} = \text{average}_{t\in\text{post}}[\overline{y}_{t,\text{tr}} - \widehat{Y}(0)_{t,\text{tr}}].$$

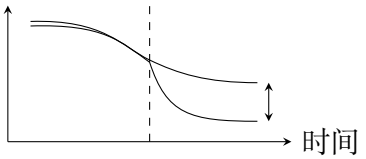
$$\min_{\beta,\tau} \sum_{i=1}^{N}\sum_{t=1}^{T}[Y_{it} - (\beta_t + \tau D_{it})]^2 \widehat{w}^{\text{sc}}_i, \qquad \widehat{w}^{\text{sc}}_i = 1/N_{\text{tr}} \quad (i \in \text{tr}).$$

与 DiD 相比，这个目标没有总体截距 μ，也没有单位固定效应 α_i。将差值解释为因果效应，需要合成比较在处理后的未处理结果上仍有效；处理前拟合接近本身并不能保证这一点。

我的图解。 第一幅图中，平移对照组趋势来构造处理组的未处理轨迹，在这个例子里放大了效果。第二幅图用前事结果生成权重，组成虚拟的“未受处理的处理组”；再用这些权重计算后事均值，以两个均值之差作估计。



DiD：平移趋势



SC：加权轨迹

将两者结合：合成 DiD

⋆ 先并列两个组成部分：

$$\begin{aligned}\text{SC}: &\quad \min_{\beta,\tau}\sum_{i,t}[Y_{it}-(\beta_t+\tau D_{it})]^2\widehat{w}_i^{\text{sc}},\\ \text{DiD}: &\quad \min_{\mu,\alpha,\beta,\tau}\sum_{i,t}[Y_{it}-(\mu+\alpha_i+\beta_t+\tau D_{it})]^2.\end{aligned}$$

SC 的权重与 DiD 的固定效应 $\longrightarrow$ 合并，并加入时间权重。

$\widehat{\tau}^{\text{sdid}}$ 是以下目标中的处理系数：

$$\min_{\mu,\alpha,\beta,\tau}\sum_{i=1}^{N}\sum_{t=1}^{T}[Y_{it}-(\mu+\alpha_i+\beta_t+\tau D_{it})]^2\ \underbrace{\widehat{w}_i^{\text{sdid}}}_{\text{单位权重}}\ \underbrace{\widehat{\lambda}_t^{\text{sdid}}}_{\text{时间权重}}.$$

时间权重。 用对照组处理前的结果，拟合它们处理后的平均结果：

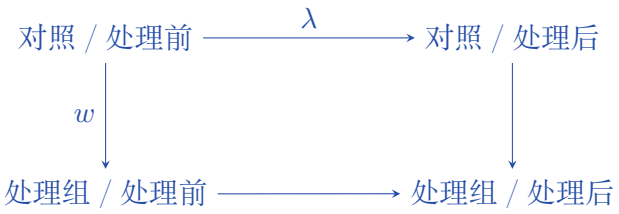
$$(\widehat{\lambda}_0,\widehat{\lambda}_{\text{pre}})=\underset{\lambda_0,\lambda_{\text{pre}}}{\text{argmin}}\,\|\overline{y}_{\text{post,co}}-(\lambda_{\text{pre}}Y_{\text{pre,co}}+\lambda_0\mathbf{1}^{\mathsf{T}})\|_2^2,\quad \sum_{t\in\text{pre}}\lambda_t=1,\quad \lambda_t\geq 0.$$

- $Y_{\text{pre,co}}$：$T_{\text{pre}}\times N_{\text{co}}$，行是时间，列是单位。
- $\overline{y}_{\text{post,co}}$：$1\times N_{\text{co}}$，对每个对照单位在处理后的时期求平均。
- λ_{pre}：$1\times T_{\text{pre}}$，每个处理前时期一个权重。

按这里的行向量写法，在矩阵上方加一行 1 来表示截距。拟合 $(\lambda_0,\lambda_{\text{pre}})$，预测对照组的处理后均值：

$$\begin{pmatrix}\mathbf{1}^{\mathsf{T}}\\ Y_{\text{pre,co}}\end{pmatrix}\xrightarrow{\text{时间拟合}}(\lambda_0,\lambda_{\text{pre}})\longrightarrow\overline{y}_{\text{post,co}}$$

单位权重。 两种加权方向的联系：



$$\begin{aligned}(\widehat{w}_0,\widehat{w}_{\text{co}})=\underset{w_0,w_{\text{co}}}{\text{argmin}}\,\{&\|\overline{y}_{\text{pre,tr}}-(Y_{\text{pre,co}}w_{\text{co}}+w_0\mathbf{1})\|_2^2\\ &+\zeta^2T_{\text{pre}}\|w_{\text{co}}\|_2^2\},\\ \sum_{i\in\text{co}}w_i=1,&\quad w_i\geq 0,\\ \zeta=(N_{\text{tr}}T_{\text{post}})^{1/4}\widehat{\sigma}(\Delta_{it}),&\qquad \Delta_{it}=Y_{it}-Y_{i,t-1}.\end{aligned}$$

用对照组处理前结果的一阶差分估计 $\widehat{\sigma}$。

L_2 惩罚倾向于让非零权重分布得更广 $\longrightarrow$ $\zeta^2 T_{\text{pre}} \|w_{\text{co}}\|_2^2$

在预测变量矩阵中加一列 1：

$$X = [\mathbf{1}_{T_{\text{pre}}} \; Y_{\text{pre,co}}].$$

拟合 (w_0, w_{co})，截距不受单纯形约束，也不加惩罚。

有截距 $\longrightarrow$ w_0

与 SC 相比：截距能改善对处理组轨迹的贴合，L_2 惩罚则对对照权重作正则化。

受处理单位与处理后时期分别使用均匀权重 $1/N_{\text{tr}}$ 和 $1/T_{\text{post}}$。**我的直觉：**起初我把 SDID 相比 SC 的特点理解为，只关注干预近期起效果的数据。从时间权重的目标看，实际是用对照组的处理前结果去贴合处理后平均结果，因此有帮助的较早时期也可以获得权重，并不按离干预日期的远近直接分配。

时间效应异质性与交错采用

要分别估计每一期的效果，可以在不同子面板上重复运行 SDID。0 和 1 的下标标记原来的时期。

时间效应异质性。 完整矩阵对应第 3、4 期的平均 ATT。将它拆开，就能分别估计两期：

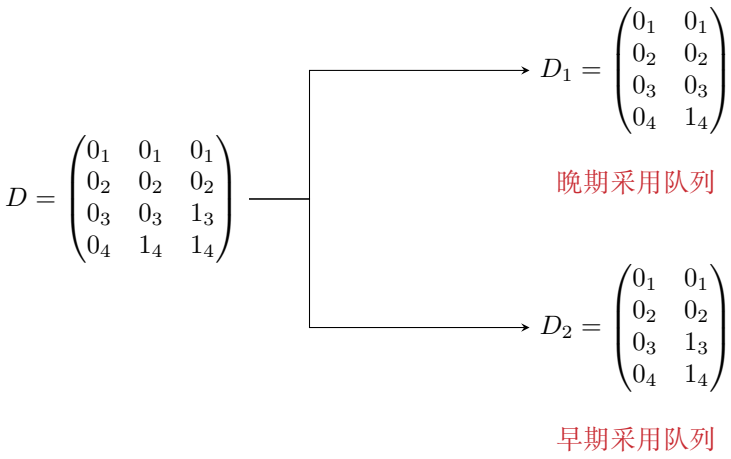
$$D = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \\ 0_4 & 0_4 & 1_4 \end{pmatrix} \longrightarrow \begin{cases} D_1 = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \end{pmatrix} & \text{第 3 期 ATT} \\ D_2 = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_4 & 0_4 & 1_4 \end{pmatrix} & \text{第 4 期 ATT} \end{cases}$$

交错采用。 现在各单位开始受处理的时期不同。先按处理后的时期拆分：

$$D = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \\ 0_4 & 1_4 & 1_4 \end{pmatrix} \longrightarrow \begin{cases} D_1 = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_4 & 1_4 & 1_4 \end{pmatrix} & \widehat{\text{ATT}}_1 \times 2/3 \\ D_2 = \begin{pmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \end{pmatrix} & \widehat{\text{ATT}}_2 \times 1/3 \end{cases}$$

第 4 期有两个受处理单元格，第 3 期有一个，因此使用 2/3 与 1/3 的权重。每个子面板中的对照观测都须确实未受处理。

也可以按受处理队列拆分，并保留从不受处理单位作对照：



例如，加利福尼亚受处理 12 年，另外 3 个单位各受处理 8 年：

$$\text{ATT}_0 \frac{12}{36} + \left(\sum_{j=1}^{3} \text{ATT}_j \right) \frac{1}{3} \frac{3 \times 8}{36}.$$

这些权重对应观测到的受处理“单位—时期”单元格平均效应。若目标人群不同，聚合权重也可能不同。

安慰剂方差估计

在例子中，SDID 的误差条比 SC 更小：同时调整单位与时间差异，能够减少结果变异。这可以提高精度，但并不保证在所有设计中都比 SC 有更小的有效不确定性。只有一个受处理单位时，安慰剂推断尤其有用。

依次假设各个对照单位受到了处理，用 SDID 估计它们的安慰剂 ATT。

安慰剂 ATT 估计 $\longrightarrow$ 计算其方差，再构造近似置信区间。

$$\bar{\tau}^{\text{pl}} = \frac{1}{B} \sum_{b=1}^{B} \widehat{\tau}^{(b)}, \qquad \widehat{V}_{\tau}^{\text{pl}} = \frac{1}{B} \sum_{b=1}^{B} (\widehat{\tau}^{(b)} - \bar{\tau}^{\text{pl}})^2,$$

$$\left[\widehat{\tau}^{\text{sdid}} - z_{1-\alpha/2} \sqrt{\widehat{V}_{\tau}^{\text{pl}}}, \quad \widehat{\tau}^{\text{sdid}} + z_{1-\alpha/2} \sqrt{\widehat{V}_{\tau}^{\text{pl}}} \right].$$

其中 $z_{1-\alpha/2}$ 是标准正态分位数。比较安慰剂效应的想法与 SC 相通。要让这个方差反映实际处理效应的不确定性，安慰剂单位与受处理单位的噪声特征须具有可比性。若有多个受处理单位，安慰剂分组应复制相同的组规模；普通加权回归的标准误不能替代这一步推断。

附录：去偏与预测

处理非随机数据的两条调整思路：倾向得分与正交化。

用正交化去偏

第 22 章 $\longrightarrow$ 正交化：对变量取残差。

所有特征记在 X 中。

1. 用第一组特征回归结果，取残差：

$$y_i = \theta_0 + \theta_1 X_{1i} + e_i, \qquad y_i^* = y_i - (\widehat{\theta}_0 + \widehat{\theta}_1 X_{1i}).$$

2. 用第一组特征预测第二组特征，取残差：

$$X_{2i} = \gamma_0 + \gamma_1 X_{1i} + e_i, \qquad X^*_{2i} = X_{2i} - (\widehat{\gamma}_0 + \widehat{\gamma}_1 X_{1i}).$$

3. 将结果残差对特征残差回归：

$$y^*_i = \beta_0 + \beta_2 X^*_{2i} + e_i.$$

用倾向得分去偏

第 11 章 ⟶ 倾向得分加权。

对每个单位加权。第一个公式适用于二元处理；第二个推广到 $0, \ldots, K$ 个离散类别：

$$w_i = \frac{T_i}{e(X_i)} + \frac{1 - T_i}{1 - e(X_i)}, \qquad e(X_i) = P(T_i = 1 \mid X_i).$$

$$w_i = \sum_{k=0}^{K} \frac{\mathbf{1}\{T_i = k\}}{P(T_i = k \mid X_i)}.$$

真正连续的处理则需要条件密度，并明确剂量—反应目标。

我的理解：倾向得分很高却没有受处理的单位，在特征上类似处理组，却被观测在对照组。它可以帮助估计处理组缺失的未处理结果。

这个直觉指向 ATT 比较：处理单位权重为 1，对照单位使用 $e(X)/(1 - e(X))$，并适当归一化。上面展示的逆概率权重则向总体分布平衡，用于 ATE 比较。两种因果解释都需要一致性、条件可交换性及相应的重叠性。

倾向得分未知时，以观测到的处理 T_i 为响应训练模型，估计 $P(T_i = 1 \mid X_i)$。二元观测值与模型预测的概率是两种不同的量。一个邮件小例子：20%（0.2）是概率，实际收到邮件记作 1。概率为 0.2 不表示某个人必定收到邮件。

倾向得分加权的弱点。 ① **权重过大**。当 $e < 0.05$ 时，受处理观测的权重 $1/e$ 很大：相当于出现很多次，对加权数据有很强的影响。对照观测若 e 接近 1，$1/(1 - e)$ 也会很大。高方差。

② **正值性 / 共同支撑**。处理组和对照组的特征须有足够重叠。不存在重叠时，加权不能凭空恢复缺失的比较。

我对手工删减观测持谨慎态度：主观选择可能引入偏差。不能外推到正值性不成立的人群子集。

预先规定的截尾可以应对有限重叠，但会改变研究人群，需要说明。仅仅预测处理状态准确，并不能建立因果可交换性。

当预测失效时

预测与因果。待续。