个人学习笔记

STATS 361：因果推断笔记

第 1–14 讲

中文版

Ming

2026 年 11 月 1 日

教材：Stefan Wager, STATS 361: Causal Inference, Spring 2022

目录

第 1 讲：随机对照试验 **4**
线性结果模型与方差缩减 4
一般结果回归下的 OLS 5

第 2 讲：无混杂性与倾向得分 **5**
汇总各组的均值差估计 5
连续协变量与倾向得分 6
按倾向得分分层 7
逆倾向得分加权 7

第 3 讲：通过增广 IPW 高效估计处理效应 **8**
ATE 的两种表征 8
增广 IPW 估计量 8
双重稳健性 9
半参数效率 9
AIPW 与交叉拟合 9
置信区间 10

第 4 讲：估计处理效应的异质性 **11**
正则化偏差 11
半参数建模 11
用于处理效应异质性的损失函数 12

第 5 讲：断点回归设计 **13**
局部线性回归估计 14
估计量性质与光滑性 14
驱动变量中的噪声 15

第 6 讲：断点回归的有限样本推断 **16**
极小极大线性估计 16
推导极小极大线性权重 16
线性估计量的推断 17
超出同方差情形 18

第 7 讲：平衡估计量 **18**
回顾 IPW 18
总体平衡与样本平衡 19
倾向得分估计的平衡损失 19
高维混杂变量下的 ATE 估计 20

近似平衡权重与回归增广 20

第 8 讲：面板数据方法 **22**
常数处理效应模型 22
双向模型 22
交互效应面板模型 23
通过可交换性识别 24

第 9 讲：工具变量回归 **25**
结构模型 25
利用工具变量识别 26
最优工具变量 26
交叉拟合与可行估计 27
非参数工具变量回归 28

第 10 讲：局部平均处理效应 **29**
不依从情形下的处理效应 29
供给与需求 30
阈值跨越与支付意愿 31
单次跳跃、多次跳跃与连续阈值 32
估计边际处理效应 33

第 11 讲：策略学习 **34**
通过经验最大化学习策略 35
将策略学习转化为加权分类 35
策略学习的有效得分 36
策略类的作用 37

第 12 讲：动态策略评估 **37**
处理与混杂因素之间的反馈 38
序贯可忽略性下的序贯推断 39
逆倾向概率加权 40
向后递推的回归调整 40
双重稳健估计量 41

第 13 讲：结构方程建模 **41**
非参数 SEM 41
Do-calculus：分离与图的修改 42
三条规则 43
例 1：后门准则 43
例 2：前门准则 44

例 3：工具变量 45
SEM 与潜在结果 45

第 14 讲：自适应实验 **45**
设定与记号 45
面对不确定性时保持乐观 46
UCB 的 regret 上界 47
自适应随机化方案 49
自适应实验中的统计推断 49

第 1 讲：随机对照试验

在随机对照试验（RCT）中，用回归分析平均处理效应，是为了减小方差；ATE 的识别并不依赖回归。

RCT 中的回归 $\longrightarrow$ 减小方差；ATE 的识别来自随机分配。

$$\Delta_i = Y_i(1) - Y_i(0), \qquad \tau = E[Y_i(1) - Y_i(0)].$$

用均值差估计量估计 τ，并进行统计推断：

$$\widehat{\tau}_{\text{DM}} = \frac{1}{n_1}\sum_{W_i=1} Y_i - \frac{1}{n_0}\sum_{W_i=0} Y_i, \qquad n_w = |\{i : W_i = w\}|.$$

在随机分配下，该估计量是一致且无偏的。

均值差 $\longrightarrow$ $\widehat{\tau}_{\text{DM}}$

本讲假设独立同分布抽样、有限二阶矩且两组均非空，并采用平衡分配 $P(W=1) = 1/2$ 及中心化协变量 $E[X] = 0$；正态分布表示渐近近似。

补充：假设。

$$Y_i = Y_i(W_i), \qquad W_i \perp \{Y_i(0), Y_i(1)\}.$$

第二式表示随机分配。SUTVA 要求单位之间没有干扰，且每一种指定处理都有定义明确的版本；加上一致性，就有 $Y_i = Y_i(W_i)$。独立抽样是另外的假设。

$Y_i = Y_i(W_i)$；SUTVA $\longrightarrow$ 无干扰和定义明确的处理。

线性结果模型与方差缩减

$$Y_i(w) = c_{(w)} + X_i\beta_{(w)} + \varepsilon_i(w), \quad E[\varepsilon_i(w) \mid X_i] = 0, \quad \text{Var}[\varepsilon_i(w) \mid X_i] = b^2.$$

两种处理状态分别拟合各自的系数。记 $A = \text{Var}[X]$，$\|v\|_A^2 = v'Av$。渐近方差为

$$V_{\text{DM}} = 4b^2 + \|\beta_{(0)} + \beta_{(1)}\|_A^2 + \|\beta_{(0)} - \beta_{(1)}\|_A^2.$$

另有

$$\tau = c_{(1)} - c_{(0)} + E[X](\beta_{(1)} - \beta_{(0)}), \qquad \widehat{\tau}_{\text{OLS}} = \widehat{c}_{(1)} - \widehat{c}_{(0)} + \overline{X}(\widehat{\beta}_{(1)} - \widehat{\beta}_{(0)}).$$

误差分解为

$$\begin{aligned}\widehat{\tau}_{\text{OLS}} - \tau = (\widehat{c}_{(1)} - c_{(1)}) - (\widehat{c}_{(0)} - c_{(0)}) + \overline{X}(\beta_{(1)} - \beta_{(0)}) \\ + \overline{X}(\widehat{\beta}_{(1)} - \widehat{\beta}_{(0)} - \beta_{(1)} + \beta_{(0)}).\end{aligned}$$

前两项的渐近近似分别为 $N(0, b^2/n_1)$、$N(0, b^2/n_0)$；第三项的渐近近似为 $N(0, \|\beta_{(1)} - \beta_{(0)}\|_A^2/n)$；最后一项是 $O_p(1/n)$。斜率估计带来的不确定性在一阶渐近中消失。因此

$$\sqrt{n}(\widehat{\tau}_{\text{OLS}} - \tau) \Rightarrow N(0, V_{\text{OLS}}), \qquad V_{\text{OLS}} = 4b^2 + \|\beta_{(0)} - \beta_{(1)}\|_A^2,$$

$$V_{\text{DM}} = V_{\text{OLS}} + \|\beta_{(0)} + \beta_{(1)}\|_A^2.$$

一般结果回归下的 OLS

即使结果回归并非线性，OLS 也可以减小渐近方差。设

$$Y_i(w) = \mu_{(w)}(X_i) + \varepsilon_i(w), \quad E[\varepsilon_i(w) \mid X_i] = 0, \quad \mathrm{Var}[\varepsilon_i(w) \mid X_i] = b^2.$$

对于均值差估计量，

$$\sqrt{n}(\widehat{\tau}_{\mathrm{DM}} - \tau) \Rightarrow N(0, V_{\mathrm{DM}}), \quad V_{\mathrm{DM}} = 4b^2 + 2\,\mathrm{Var}[\mu_{(0)}(X_i)] + 2\,\mathrm{Var}[\mu_{(1)}(X_i)].$$

对于 OLS，Huber–White 方差计算从总体投影出发：

$$(c^*_{(w)}, \beta^*_{(w)}) = \arg\min_{c,\beta} E[(Y_i(w) - X_i\beta - c)^2].$$

可得

$$\sqrt{n_w}\left\{\begin{pmatrix}\widehat{c}_{(w)}\\ \widehat{\beta}_{(w)}\end{pmatrix} - \begin{pmatrix}c^*_{(w)}\\ \beta^*_{(w)}\end{pmatrix}\right\} \Rightarrow N\left(0, Q^{-1}E[r_w^2 qq^{\mathsf{T}}]Q^{-1}\right),$$

其中 $c^*_{(w)} = E[Y_i(w)]$。令 $q = (1, X^{\mathsf{T}})^{\mathsf{T}}$，$Q = E[qq^{\mathsf{T}}]$ 非奇异，$r_w = Y(w) - c^*_w - X\beta^*_w$。三明治协方差不必为分块对角阵：$E[r_w X] = 0$ 并不蕴含 $E[r_w^2 X] = 0$。在 $E[X] = 0$ 下，截距方差是 $E[r_w^2]$。[1]

$$\mathrm{MSE}^*_{(w)} = E[(Y_i(w) - X_i\beta^*_{(w)} - c^*_{(w)})^2].$$

由此得到

$$\sqrt{n}(\widehat{\tau}_{\mathrm{OLS}} - \tau) \Rightarrow N(0, V_{\mathrm{OLS}}), \qquad V_{\mathrm{OLS}} = V_{\mathrm{DM}} - \|\beta^*_{(0)} + \beta^*_{(1)}\|^2_A.$$

$V_{\mathrm{OLS}} \le V_{\mathrm{DM}}$ 在本节平衡试验设定下成立。当 $\|\beta^*_{(0)} + \beta^*_{(1)}\|^2_A > 0$ 时方差严格下降；该平方范数为零时取等号。若 A 非奇异，等号条件就是 $\beta^*_{(0)} + \beta^*_{(1)} = 0$。

个人理解。 OLS 可以看作

$$\widehat{\tau}_{\mathrm{OLS}} = \frac{1}{n}\sum_{i=1}^{n}\{(\widehat{c}_{(1)} + X_i\widehat{\beta}_{(1)}) - (\widehat{c}_{(0)} + X_i\widehat{\beta}_{(0)})\} = \frac{1}{n}\sum_i[\widehat{\mu}_{(1)}(X_i) - \widehat{\mu}_{(0)}(X_i)].$$

这里 $\widehat{\mu}_{(w)}(x)$ 是 OLS 在 x 处的拟合值，也可以换成其他方法。

第 2 讲：无混杂性与倾向得分

无混杂性：目的是消除混杂因素的影响。倾向得分：给定协变量后接受处理的概率。

汇总各组的均值差估计

直接按照概率加权。对离散且取数值的 X_i，假设

$$\{Y_i(0), Y_i(1)\} \perp W_i \mid X_i = x, \qquad x \in \mathcal{X}.$$

这里 x 是分组变量。定义各组的 ATE：

$$\tau(x) = E[Y_i(1) - Y_i(0) \mid X_i = x].$$

[1] 讲义式 (1.16) 中的非对角块不一定为零。

则

$$\begin{aligned}\widehat{\tau}_{\text{AGG}} &= \sum_{x\in\mathcal{X}} \frac{n_x}{n}\widehat{\tau}(x),\\ \widehat{\tau}(x) &= \frac{1}{n_{x1}}\sum_{X_i=x,W_i=1} Y_i - \frac{1}{n_{x0}}\sum_{X_i=x,W_i=0} Y_i,\\ n_x &= |\{i: X_i = x\}|, \qquad n_{xw} = |\{i: X_i = x, W_i = w\}|.\end{aligned}$$

令 $e(x) = P(W_i = 1 \mid X_i = x)$。组内的极限分布为

$$\begin{aligned}\sqrt{n_x}(\widehat{\tau}(x) - \tau(x)) &\Rightarrow N\left(0, \frac{\text{Var}[Y_i(0) \mid X_i = x]}{1-e(x)} + \frac{\text{Var}[Y_i(1) \mid X_i = x]}{e(x)}\right)\\ &= N\left(0, \frac{b^2(x)}{e(x)(1-e(x))}\right),\end{aligned}$$

第二个等号使用了两种处理状态具有相同条件方差的假设。定义 $\pi(x) = P(X_i = x)$，$\widehat{\pi}(x) = n_x/n$。固定分层数下的极限需要层数有限、各层总体概率为正、层内处理重叠，以及有限条件二阶矩。于是

$$\begin{aligned}\widehat{\tau}_{\text{AGG}} = &\sum_x \pi(x)\tau(x) + \sum_x \pi(x)(\widehat{\tau}(x) - \tau(x))\\ &+ \sum_x (\widehat{\pi}(x) - \pi(x))\tau(x) + \sum_x (\widehat{\pi}(x) - \pi(x))(\widehat{\tau}(x) - \tau(x)).\end{aligned}$$

第一项是 τ。第二项渐近正态，其方差为

$$\sum_x \pi^2(x)\,\text{Var}[\widehat{\tau}(x)].$$

第三项的方差是 $n^{-1}\,\text{Var}[\tau(X_i)]$，最后一项为 $O_p(1/n)$。合并这些项，

汇总估计量的四项展开 $\longrightarrow$ 汇总估计量的方差 V_{AGG}。

$$\sqrt{n}(\widehat{\tau}_{\text{AGG}} - \tau) \Rightarrow N(0, V_{\text{AGG}}),$$

$$\begin{aligned}V_{\text{AGG}} &= \text{Var}[\tau(X_i)] + \sum_{x\in\mathcal{X}} \pi^2(x)\frac{1}{\pi(x)}\frac{b^2(x)}{e(x)(1-e(x))}\\ &= \text{Var}[\tau(X_i)] + E\left[\frac{b^2(X_i)}{e(X_i)(1-e(X_i))}\right].\end{aligned}$$

连续协变量与倾向得分

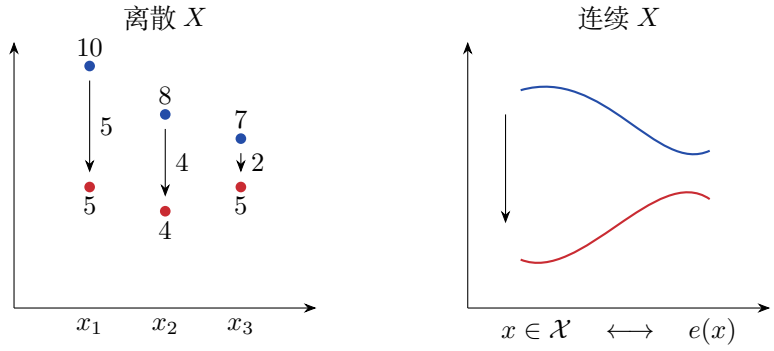
给定 X_i 后，W_i 不能“偷看” Y_i：这是我对无混杂性的直觉理解。若

$$\{Y_i(0), Y_i(1)\} \perp W_i \mid X_i, \quad e(x) = P(W_i = 1 \mid X_i = x),$$

则

$$\{Y_i(0), Y_i(1)\} \perp W_i \mid e(X_i).$$

补充图示与计算。



条件化后积分可得

$$\begin{aligned}
&P(W_i = w \mid \{Y_i(0), Y_i(1)\}, e(X_i)) \\
&= \int_{\mathcal{X}} P(W_i = w \mid \{Y_i(0), Y_i(1)\}, X_i = x) dP(X_i = x \mid Y_i(0), Y_i(1), e(X_i)) \\
&= \int_{\mathcal{X}} P(W_i = w \mid X_i = x) dP(X_i = x \mid Y_i(0), Y_i(1), e(X_i)) \\
&= e(X_i)\mathbf{1}_{\{w=1\}} + (1 - e(X_i))\mathbf{1}_{\{w=0\}}.
\end{aligned}$$

这里是对条件概率测度积分。

按倾向得分分层

1. 排序，使 $\widehat{e}(X_{i_1}) \le \widehat{e}(X_{i_2}) \le \cdots \le \widehat{e}(X_{i_n})$。
2. 将样本分为 J 层，在每一层内估计均值差。若 I_j 包含排序后第 $\lfloor (j-1)n/J \rfloor + 1$ 到第 $\lfloor jn/J \rfloor$ 个样本，则的简写公式可表示为

$$\widehat{\tau}_j = \frac{\sum_{i \in I_j} W_i Y_i}{\sum_{i \in I_j} W_i} - \frac{\sum_{i \in I_j} (1 - W_i) Y_i}{\sum_{i \in I_j} (1 - W_i)}.$$

   使处理组与对照组更相似 $\longrightarrow$ 按 $\widehat{e}(X_i)$ 排序，并按倾向得分分层。
3. 对各层估计取平均：$\widehat{\tau}_{\text{STRAT}} = J^{-1} \sum_{j=1}^{J} \widehat{\tau}_j$。当分层越来越细且每层样本充足时，它具有一致性。要得到一致性，应让 J 随 n 适当增加，使分层越来越细，同时每层仍有足够的处理与对照样本，并满足重叠性及 $\widehat{e}$ 的一致收敛。固定的宽分层可能留下混杂。

逆倾向得分加权

$$\widehat{\tau}_{\text{IPW}} = \frac{1}{n} \sum_{i=1}^{n} \left\{ \frac{W_i Y_i}{\widehat{e}(X_i)} - \frac{(1 - W_i) Y_i}{1 - \widehat{e}(X_i)} \right\}.$$

理想的 IPW（oracle IPW）假定完全知道 $e(x)$：

$$\widehat{\tau}^*_{\text{IPW}} = \frac{1}{n} \sum_{i} \left\{ \frac{W_i Y_i}{e(X_i)} - \frac{(1 - W_i) Y_i}{1 - e(X_i)} \right\}.$$

假设满足重叠性：所有 $x \in \mathcal{X}$ 上均有 $\eta \le e(x) \le 1 - \eta$，且 $|Y_i| < M$。若

$$\sup_{x \in \mathcal{X}} |e(x) - \widehat{e}(x)| = O_p(a_n) \longrightarrow 0,$$

可得

$$|\widehat{\tau}_{\text{IPW}} - \widehat{\tau}^*_{\text{IPW}}| = O_p(a_n M / \eta).$$

因此，理想估计量的一致性可以传递给使用估计倾向得分的 IPW。另外，

$$E[\hat{\tau}^*_{\text{IPW}}] = E[Y_i(1) - Y_i(0)] = \tau.$$

满足重叠性时，理想 IPW 的收敛尺度是 $1/\sqrt{n}$。

方差计算：结果模型。 使用模型

$$\begin{aligned} Y_i(0) &= c(X_i) - (1 - e(X_i))\tau(X_i) + \varepsilon_i(0), \\ Y_i(1) &= c(X_i) + e(X_i)\tau(X_i) + \varepsilon_i(1), \\ E[\varepsilon_i(w) \mid X_i] = 0, &\qquad \text{Var}[\varepsilon_i(w) \mid X_i = x] = b^2(x). \end{aligned}$$

随后可得

补充的结果模型 $\longrightarrow$ 理想 IPW 的方差 V_{IPW^*}。

$$\begin{aligned} n\,\text{Var}[\hat{\tau}^*_{\text{IPW}}] = V_{\text{IPW}^*} &= E\left[\frac{c^2(X_i)}{e(X_i)(1-e(X_i))}\right] + \text{Var}[\tau(X_i)] \\ &\quad + E\left[\frac{b^2(X_i)}{e(X_i)(1-e(X_i))}\right], \\ \sqrt{n}(\hat{\tau}^*_{\text{IPW}} - \tau) &\Rightarrow N(0, V_{\text{IPW}^*}). \end{aligned}$$

个人比较。 $c(x)$ 描述的是 X 与 Y 的关系，而不是 X 与 ΔY 的关系。与分组汇总相比，

$$V_{\text{IPW}^*} = V_{\text{AGG}} + E\left[\frac{c^2(X_i)}{e(X_i)(1-e(X_i))}\right].$$

$V_{\text{IPW}^*} - V_{\text{AGG}}$ $\longrightarrow$ 额外方差恰好在 $c(X) = 0$ 几乎处处成立时消失。

与线性模型相比：IPW 基于 $\{Y_i(0), Y_i(1)\} \perp W_i \mid X_i$，线性模型则依赖线性关系。线性结果模型同样需要无混杂性等因果识别依据；线性本身只是对估计模型的限制。

第 3 讲：通过增广 IPW 高效估计处理效应

普通 IPW 的大样本性质较差。例如，X 离散时，它不如汇总估计量 $\hat{\tau}$。

ATE 的两种表征

1. 利用 $e(x) = P(W_i = 1 \mid X_i = x)$，有 $\tau = E[\hat{\tau}^*_{\text{IPW}}]$；理想估计量定义如上。
2. 利用 $\mu_{(w)}(x) = E[Y_i(w) \mid X_i = x]$，

   $$\tau(x) = \mu_{(1)}(x) - \mu_{(0)}(x), \quad \tau = E[\mu_{(1)}(X_i) - \mu_{(0)}(X_i)],$$

   由此得到

   $$\hat{\tau}_{\text{REG}} = \frac{1}{n}\sum_i [\hat{\mu}_{(1)}(X_i) - \hat{\mu}_{(0)}(X_i)].$$

增广 IPW 估计量

$$\begin{aligned} \hat{\tau}_{\text{AIPW}} = \frac{1}{n}\sum_i \Bigg[&\hat{\mu}_{(1)}(X_i) - \hat{\mu}_{(0)}(X_i) + W_i\frac{Y_i - \hat{\mu}_{(1)}(X_i)}{\hat{e}(X_i)} \\ &- (1 - W_i)\frac{Y_i - \hat{\mu}_{(0)}(X_i)}{1 - \hat{e}(X_i)}\Bigg]. \end{aligned}$$

个人直觉。 先用 $\mu(x)$ 估计结果，再对回归残差做 IPW。IPW 让数据的协变量构成变得“公平”。

双重稳健性

只要结果回归 $\widehat{\mu}_{(w)}(x)$ 或倾向得分 $\widehat{e}(x)$ 中有一方一致，AIPW 就一致。这里假设重叠性与可积性成立，另一类干扰函数估计也须保持良好行为。对于拟合函数，下方的期望论证还要条件于独立训练折；交叉拟合提供这种分离。

当 $\widehat{\mu}_{(w)}(x) \approx \mu_{(w)}(x)$ 时，回归均值是一致的，加权残差项的均值近似为零，因为

$$E[Y_i - \widehat{\mu}_{(W_i)}(X_i) \mid X_i, W_i] \approx 0.$$

这里通过条件化把倾向得分项固定下来。若是 $\widehat{e}(x) \approx e(x)$，则改写为

$$\begin{aligned}\widehat{\tau}_{\text{AIPW}} = \frac{1}{n}\sum_i \left[\frac{W_i Y_i}{\widehat{e}(X_i)} - \frac{(1-W_i)Y_i}{1-\widehat{e}(X_i)}\right] \\ + \frac{1}{n}\sum_i \left[\widehat{\mu}_{(1)}(X_i)\left(1 - \frac{W_i}{\widehat{e}(X_i)}\right) - \widehat{\mu}_{(0)}(X_i)\left(1 - \frac{1-W_i}{1-\widehat{e}(X_i)}\right)\right].\end{aligned}$$

第一部分是 IPW。第二部分均值近似为零，因为 $E[1 - W_i/\widehat{e}(X_i) \mid X_i] \approx 0$；条件化后把拟合的结果回归视为固定。

半参数效率

AIPW 在该非参数模型的正则估计量中达到半参数效率界。当辅助函数估计足够准确时，

$$\sqrt{n}(\widehat{\tau}_{\text{AIPW}} - \widehat{\tau}^*_{\text{AIPW}}) \longrightarrow_p 0,$$

星号表示理想 AIPW。该理想估计量只是独立同分布变量的均值，因此其中心极限定理可以传递给使用估计函数的版本：

$\sqrt{n}(\widehat{\tau}_{\text{AIPW}} - \widehat{\tau}^*_{\text{AIPW}}) \to_p 0$ $\longrightarrow$ 理想估计量的独立同分布中心极限定理可用于估计得到的 AIPW。

$$\sqrt{n}(\widehat{\tau}_{\text{AIPW}} - \tau) \Rightarrow N(0, V^*),$$

$$V^* = \text{Var}[\tau(X_i)] + E\left[\frac{b_0^2(X_i)}{1-e(X_i)}\right] + E\left[\frac{b_1^2(X_i)}{e(X_i)}\right].$$

这类似 Cramér–Rao 约束：它是正则估计量可达到的方差下界。

AIPW 与交叉拟合

将数据随机分成两半 I_1 和 I_2。把数据随机分开。令

$$\widehat{\tau}_{\text{AIPW}} = \frac{|I_1|}{n}\widehat{\tau}^{I_1} + \frac{|I_2|}{n}\widehat{\tau}^{I_2},$$

$$\begin{aligned}\widehat{\tau}^{I_1} = \frac{1}{|I_1|}\sum_{i\in I_1}\left[\widehat{\mu}^{I_2}_{(1)}(X_i) - \widehat{\mu}^{I_2}_{(0)}(X_i) + W_i\frac{Y_i - \widehat{\mu}^{I_2}_{(1)}(X_i)}{\widehat{e}^{I_2}(X_i)}\right. \\ \left. - (1-W_i)\frac{Y_i - \widehat{\mu}^{I_2}_{(0)}(X_i)}{1-\widehat{e}^{I_2}(X_i)}\right].\end{aligned}$$

渐近分析可以不依赖所选机器学习调整方法的具体形式，而依赖以下条件：

1. 重叠性：对所有 $x \in \mathcal{X}$，有 $\eta < e(x) < 1-\eta$，其中 $\eta > 0$。

2. 辅助函数估计的一致性：

$$\sup_x |\widehat{\mu}^{I_2}_{(w)}(x) - \mu_{(w)}(x)| \longrightarrow_p 0, \quad \sup_x |\widehat{e}^{I_2}(x) - e(x)| \longrightarrow_p 0.$$

这里要求所选机器学习方法满足一致性，不能自动假设所有方法都满足。

3. 结果模型与倾向得分模型的风险衰减：

$$E[(\widehat{\mu}^{I_2}_{(w)}(X_i) - \mu_{(w)}(X_i))^2]\, E[(\widehat{e}^{I_2}(X_i) - e(X_i))^2] = o(1/n).$$

若两者均以 $\sqrt{n}$ 速度一致收敛，则乘积为 $1/n^2$ 阶。一个简单的充分条件是，两种回归调整的均方根误差（RMSE）都以 $o(n^{-1/4})$ 收敛。

证明。 把理想估计量写作 $\widehat{\tau}^* = |I_1|\widehat{\tau}^{I_1,*}/n + |I_2|\widehat{\tau}^{I_2,*}/n$. 要证明 $\sqrt{n}(\widehat{\tau}_{\text{AIPW}} - \widehat{\tau}^*) \to_p 0$，只需对处理状态下的均值证明相应结果；其余部分类似。定义

$$\widehat{\tau}^{I_1} = \widehat{\mu}^{I_1}_{(1)} - \widehat{\mu}^{I_1}_{(0)}, \qquad \widehat{\mu}^{I_1}_{(1)} = \frac{1}{|I_1|}\sum_{i\in I_1}\left[\widehat{\mu}^{I_2}_{(1)}(X_i) + W_i\frac{Y_i - \widehat{\mu}^{I_2}_{(1)}(X_i)}{\widehat{e}^{I_2}(X_i)}\right].$$

减去对应的理想估计量，得到

$$\begin{aligned}\widehat{\mu}^{I_1}_{(1)} - \widehat{\mu}^{I_1,*}_{(1)} = {}& \frac{1}{|I_1|}\sum_{i\in I_1}(\widehat{\mu}^{I_2}_{(1)}(X_i) - \mu_{(1)}(X_i))\left(1 - \frac{W_i}{e(X_i)}\right)\\ &+ \frac{1}{|I_1|}\sum_{i\in I_1} W_i(Y_i - \mu_{(1)}(X_i))\left(\frac{1}{\widehat{e}^{I_2}(X_i)} - \frac{1}{e(X_i)}\right)\\ &- \frac{1}{|I_1|}\sum_{i\in I_1} W_i(\widehat{\mu}^{I_2}_{(1)}(X_i) - \mu_{(1)}(X_i))\left(\frac{1}{\widehat{e}^{I_2}(X_i)} - \frac{1}{e(X_i)}\right).\end{aligned}$$

第一项的条件方差为 $o_p(1)/n$；最后一项为 $o_p(1/\sqrt{n})$。将第一项平均记为 T_1、训练数据记为 $\mathcal{D}_2$，则

$$E[T_1 \mid \mathcal{D}_2] = 0, \qquad E[T_1^2 \mid \mathcal{D}_2] \le \frac{E[(\widehat{\mu}_1(X) - \mu_1(X))^2 \mid \mathcal{D}_2]}{\eta|I_1|} = o_p(n^{-1}).$$

因此 $T_1 = o_p(n^{-1/2})$。第二项同理，最后一项由 Cauchy–Schwarz 不等式和乘积风险条件控制。

对 K 折交叉拟合，在构造第 i 个观测的辅助估计时，排除其所在的第 $k(i)$ 折：

$$\begin{aligned}\widehat{\tau}_{\text{AIPW}} = \frac{1}{n}\sum_i \Bigg[&\widehat{\mu}^{(-k(i))}_{(1)}(X_i) - \widehat{\mu}^{(-k(i))}_{(0)}(X_i) + W_i\frac{Y_i - \widehat{\mu}^{(-k(i))}_{(1)}(X_i)}{\widehat{e}^{(-k(i))}(X_i)}\\ &- (1 - W_i)\frac{Y_i - \widehat{\mu}^{(-k(i))}_{(0)}(X_i)}{1 - \widehat{e}^{(-k(i))}(X_i)}\Bigg].\end{aligned}$$

置信区间

补充：术语。 普通似然得分是

$$S(\theta) = \frac{d\log L(\theta)}{d\theta},$$

其中 $L(\theta)$ 为似然函数。n 个样本得分的经验方差为

$$\frac{1}{n-1}\sum_i (S_\theta(O_i) - \overline{S}_\theta)^2.$$

存在干扰参数时，有效得分还要扣除干扰得分分量。对 ATE，下方中心化 AIPW 单项 $\psi_i^* - \tau$ 是有效影响函数，其方差是效率界；它不同于原始似然得分，后者的方差是 Fisher 信息。

方差估计。 定义理想估计量中的单项

$$\psi_i^* = \mu_{(1)}(X_i) - \mu_{(0)}(X_i) + \frac{W_i(Y_i - \mu_{(1)}(X_i))}{e(X_i)} - \frac{(1-W_i)(Y_i - \mu_{(0)}(X_i))}{1-e(X_i)}.$$

它的经验方差收敛到有效方差：

$$\frac{1}{n-1}\sum_i (\psi_i^* - \hat{\tau}^*)^2 \longrightarrow_p V^*.$$

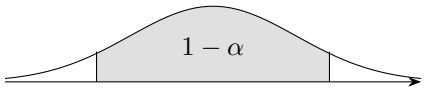
这里 $\hat{\tau}^*$ 是理想 AIPW 估计量。

未交叉拟合的理想 AIPW 估计 $\longrightarrow$ $\sum_i(\psi_i^* - \hat{\tau}^*)^2/(n-1)$ 中的 $\hat{\tau}^*$。

将每个辅助函数替换为排除第 $k(i)$ 折后训练的估计，得到交叉拟合单项 $\widehat{\psi}_i$，以及

$$\widehat{V}_{\text{AIPW}} = \frac{1}{n-1}\sum_i (\widehat{\psi}_i - \widehat{\tau}_{\text{AIPW}})^2 \longrightarrow_p V^*.$$

正态分布中央概率区域下画出的置信区间为



该区间的渐近覆盖率为 $1-\alpha$：

$$\widehat{\tau}_{\text{AIPW}} \pm \frac{1}{\sqrt{n}}\Phi^{-1}(1-\alpha/2)\sqrt{\widehat{V}_{\text{AIPW}}}.$$

第 4 讲：估计处理效应的异质性

对于观测 (X_i, Y_i, W_i)，其中 $X_i \in \mathcal{X}$，之前关注的是 ATE $E[Y_i(1) - Y_i(0)]$。异质性分析转而考虑条件平均处理效应（CATE）：

$$\tau(x) = E[Y_i(1) - Y_i(0) \mid X_i = x].$$

X_i 某一类中的平均效应 $\longrightarrow$ $\tau(x) = E[Y_i(1) - Y_i(0) \mid X_i = x]$。

正则化偏差

在 $\{Y_i(0), Y_i(1)\} \perp W_i \mid X_i$ 下，

$$\tau(x) = \mu_{(1)}(x) - \mu_{(0)}(x), \qquad \mu_{(w)}(x) = E[Y_i \mid X_i = x, W_i = w].$$

一个直接的 CATE 估计量为 $\widehat{\tau}_T(x) = \widehat{\mu}_{(1)}(x) - \widehat{\mu}_{(0)}(x)$。

个人疑虑。 如果 $\widehat{\mu}_{(1)}$ 的样本太少，就可能受到很强的正则化，向一条直线收缩。而 $\widehat{\mu}_{(0)}$ 样本很多时可能拟合得很好；这样，两者之差 $\widehat{\tau}_T(x)$ 就会因为前者拟合不准而出问题。

半参数建模

$$Y_i(w) = f(X_i) + w\tau(X_i) + \varepsilon_i(w), \qquad P(W_i = 1 \mid X_i) = e(X_i), \qquad \tau(x) = \psi(x)\beta.$$

f 是 X_i 的函数，$\psi(x)$ 是 X 的非参数表示；β 是处理效应的系数。在无混杂性下，Robinson 变换为

$Y_i(w) = f(X_i) + w\tau(X_i) + \varepsilon_i(w)$ $\longrightarrow$ Robinson：减去 $m(X_i)$，并用 $e(X_i)$ 对 W_i 残差化。

$$Y_i - m(X_i) = (W_i - e(X_i))\psi(X_i)\beta + \varepsilon_i, \quad m(x) = E[Y_i \mid X_i = x] = f(x) + e(x)\tau(x),$$

其中 $\varepsilon_i = \varepsilon_i(W_i)$。

$\varepsilon_i = \varepsilon_i(W_i)$ $\longrightarrow$ $Y_i - m(X_i) = (W_i - e(X_i))\psi(X_i)\beta + \varepsilon_i$ 中的误差。

构造残差对残差的 OLS 回归，令

$$\widetilde{Y}_i^* = Y_i - m(X_i), \qquad \widetilde{Z}_i^* = (W_i - e(X_i))\psi(X_i).$$

将 $\widetilde{Y}_i^*$ 对 $\widetilde{Z}_i^*$ 回归，得到 $\widehat{\beta}_R^*$。这些变换只用到已观测数据和辅助函数；这就是数据预处理。可得

$$\sqrt{n}(\widehat{\beta}_R^* - \beta) \Rightarrow N(0, V_R),$$

$$V_R = Q^{-1}E[ZZ^{\mathsf{T}}\varepsilon^2]Q^{-1}.$$

同方差时，$\mathrm{Var}(\varepsilon_i \mid X_i, W_i) = b^2$ 为常数，V_R 是 β 的半参数有效方差。异方差时，三明治方差仍适用，但未必达到效率界。这里 $Z = (\widetilde{Z}_i^*)^{\mathsf{T}}$，$Q = E[ZZ^{\mathsf{T}}]$ 非奇异，$\varepsilon = \widetilde{Y}_i^* - Z^{\mathsf{T}}\beta$。正规方程给出影响函数 $Q^{-1}Z\varepsilon$，所以中间项使用回归残差；条件同方差下为 b^2Q^{-1}。[2]

可实施的交叉拟合版本。 前面的回归是理想形式，因为 $m(X_i)$、$e(X_i)$ 未知。拟合非参数回归 $Y \sim X$ 和 $W \sim X$；构造下式时，排除第 i 个观测所在的折：

$$\widetilde{Y}_i = Y_i - \widehat{m}^{(-k(i))}(X_i), \qquad \widetilde{Z}_i = (W_i - \widehat{e}^{(-k(i))}(X_i))\psi(X_i).$$

将 $\widetilde{Y}_i$ 对 $\widetilde{Z}_i$ 回归得到 $\widehat{\beta}_R$。若两个辅助函数估计的 RMSE 均为 $o_p(n^{-1/4})$，可得

$$\sqrt{n}(\widehat{\beta}_R^* - \widehat{\beta}_R) \longrightarrow_p 0.$$

用于处理效应异质性的损失函数

前面的估计量假设 $\tau(x) = \psi(x)\beta$。实际关系往往不是线性的，因此使用机器学习。令

$$\mu_{(w)}(x) = E[Y(w) \mid X = x], \quad \varepsilon_i(w) = Y_i(w) - [\mu_{(0)}(X_i) + w\tau(X_i)],$$

由无混杂性得到 $E[\varepsilon_i(w) \mid X_i, W_i] = 0$。这里 $\mu_{(0)}$ 起到前面 f 的作用。仍有

$$Y_i - m(X_i) = (W_i - e(X_i))\tau(X_i) + \varepsilon_i, \quad m(x) = \mu_{(0)}(x) + e(x)\tau(x), \quad \varepsilon_i = \varepsilon_i(W_i).$$

等价地，

$$\tau(\cdot) = \arg\min_t E[((Y_i - m(X_i)) - (W_i - e(X_i))t(X_i))^2].$$

若 m 和 e 已知，最小化该式即可得到 $\tau(\cdot)$。事实上，$L(t) - L(\tau) = E[e(X)(1-e(X))(t(X)-\tau(X))^2]$，所以在 $0 < e(X) < 1$ 的区域，最小化目标识别 τ（忽略零测集）。理想的惩罚估计量为

$$\widehat{\tau}_R^*(\cdot) = \arg\min_t \left\{ \frac{1}{n}\sum_i [(Y_i - m(X_i)) - (W_i - e(X_i))t(X_i)]^2 + \Lambda_n(t) \right\}.$$

[2] 讲义式 (4.6) 的这一项也需要使用残差。

对 $\tau(\cdot)$ 的复杂度进行正则化 $\longrightarrow$ $\Lambda_n(\tau)$：例如 lasso / 岭回归及神经网络。

通常 m 和 e 未知，因此进行交叉拟合；RCT 中 e 由设计已知，但 m 一般仍需估计：

$$\widehat{L}_n(t) = \frac{1}{n}\sum_i [(Y_i - \widehat{m}^{(-k(i))}(X_i)) - (W_i - \widehat{e}^{(-k(i))}(X_i))t(X_i)]^2,$$
$$\widehat{\tau}_R = \arg\min_t \{\widehat{L}_n(t) + \Lambda_n(t)\}.$$

对于 lasso，$\widehat{\tau}(x) = x\widehat{\beta}$，其中

$$\widehat{\beta} = \arg\min_\beta \left\{ \frac{1}{n}\sum_i [(Y_i - \widehat{m}^{(-k(i))}(X_i)) - (W_i - \widehat{e}^{(-k(i))}(X_i))X_i\beta]^2 + \lambda\|\beta\|_1 \right\}.$$

个人补充理解。 处理效应为常数时，$Y_i(w) = f(X_i) + \tau w + \varepsilon_i$，且 $E[\varepsilon_i \mid X_i, W_i] = 0$；残差估计量为

$$\widehat{\tau}_R = \frac{\sum_i (Y_i - \widehat{m}^{(-k(i))}(X_i))(W_i - \widehat{e}^{(-k(i))}(X_i))}{\sum_i (W_i - \widehat{e}^{(-k(i))}(X_i))^2}. \tag{4.5}$$

前提是辅助部分收敛足够快。即使 τ 不为常数，该估计量也会收敛到 $\tau(x)$ 的某个非负加权平均。

$\overline{Y}_{(1)} - \overline{Y}_{(0)}$ $\longrightarrow$ 前述 $\tau(x)$ 的非负加权平均。

异质性较小而重叠性存在困难时，可用式 (4.5) 替代。

常系数残差回归及其加权效应解释 $\longrightarrow$ 用于灵活处理效应函数的 R 损失。

其总体目标为

$$\frac{E[e(X)(1-e(X))\tau(X)]}{E[e(X)(1-e(X))]},$$

分母须为正。它强调重叠较好的区域；效应为常数，或重叠权重与 $\tau(X)$ 不相关时才等于 ATE。处理完全确定的区域仍不能由此识别效应。

第 5 讲：断点回归设计

使用驱动变量 $Z_i \in \mathbb{R}$ 引入一个阈值：

$$W_i = \mathbf{1}_{\{Z_i \geq c\}}, \qquad c \text{ 为阈值。}$$

当 $Z_i \to c$，靠近 c 的观测特征相似，区别在于是否接受干预。令 $\mu_{(w)}(z) = E[Y_i(w) \mid Z_i = z]$。若两个条件均值连续，则 $z = c$ 处的 CATE 为

$$\tau_c = \mu_{(1)}(c) - \mu_{(0)}(c) = \lim_{z \to c^+} E[Y_i \mid Z_i = z] - \lim_{z \to c^-} E[Y_i \mid Z_i = z].$$

个人补充：普通 IPW 为什么不适用？ 此前假设无混杂性 $\{Y_i(0), Y_i(1)\} \perp W_i \mid Z_i$ 和重叠性 $\eta \leq P(W_i = 1 \mid Z_i) \leq 1 - \eta$。在 RDD 中，无混杂性成立，但重叠性不成立，因为给定 $Z_i = z$ 后，处理概率不是零就是一。无论如何选择非退化的 η，都不成立。必须比较 c 附近的观测，借助相似性而非重叠性。重叠性不成立意味着不能以 $\sqrt{n}$ 速度估计 τ_c。其极小极大误差以非参数速度收敛，取决于 $\mu_{(w)}(z)$ 的光滑性。例如，c 处二阶导数一致有界时，可以得到 $n^{-2/5}$ 的估计误差速度。该速率使用独立观测、截点两侧正且连续的设计密度、截点邻域内有界二阶导数，以及有界条件方差。更强的参数限制可能带来不同速率。

局部线性回归估计

选择小带宽 $h_n \to 0$ 和对称权函数 K，在局部拟合两个条件均值。下式中 W_i 的系数

$$\arg\min_{a,\tau,\beta_{(0)},\beta_{(1)}} \sum_i K\left(\frac{|Z_i - c|}{h_n}\right)[Y_i - a - \tau W_i - \beta_{(0)}(Z_i - c)_- - \beta_{(1)}(Z_i - c)_+]^2$$

就是 $\widehat{\tau}_c$。

权重；负侧；正侧 $\longrightarrow$ $K(|Z_i - c|/h_n)$；$(Z_i - c)_-$；$(Z_i - c)_+$。

截距 a 和斜率 $\beta_{(w)}$ 是辅助参数；常见核函数包括窗口函数 $K(x) = \mathbf{1}_{\{|x|\le 1\}}$ 和三角核 $K(x) = (1 - |x|)_+$。

估计量性质与光滑性

通过以下假设量化连续性：$\mu_{(w)}$ 二次可微，且二阶导数一致有界：

$$\left|\frac{d^2}{dz^2}\mu_{(w)}(z)\right| \le B, \qquad z \in \mathbb{R}, \quad w \in \{0,1\}.$$

若仅有 Lipschitz 光滑性，即 $|f(x) - f(y)| \le L|x - y|$，函数可以存在尖角；局部线性趋势不明显时，局部平均可能更合适。若光滑性更强，$k \ge 3$ 阶导数有界，则更高阶的局部回归可能改善收敛速度。

在 c 处做 Taylor 展开：

$$\mu_{(w)}(z) = a_{(w)} + \beta_{(w)}(z - c) + \tfrac{1}{2}\rho_{(w)}(z - c), \qquad |\rho_{(w)}(u)| \le Bu^2.$$

最后一项为余项，且 $\tau_c = a_{(1)} - a_{(0)}$。分别拟合两侧：

$$(\widehat{a}_{(1)}, \widehat{\beta}_{(1)}) = \arg\min_{a,\beta} \sum_{Z_i \ge c} K\left(\frac{|Z_i - c|}{h_n}\right)[Y_i - a - \beta(Z_i - c)]^2,$$

对照侧同理；然后 $\widehat{\tau}_c = \widehat{a}_{(1)} - \widehat{a}_{(0)}$。

窗口核的闭式权重。 在 $c \le Z_i \le c + h_n$ 上，设

$$\widehat{a}_{(1)} = \sum_i \gamma_i Y_i, \qquad \gamma_i = \frac{m_2 - m_1(Z_i - c)}{N_+(m_2 - m_1^2)},$$

其中 $N_+ = |\{i : c \le Z_i \le c + h_n\}|$，$m_j = N_+^{-1}\sum_{c \le Z_i \le c+h_n}(Z_i - c)^j$。假设 $m_2 - m_1^2 > 0$。因子 N_+ 使权重归一化，因此

$$\sum_i \gamma_i = 1, \qquad \sum_i \gamma_i(Z_i - c) = 0.$$

分解为

$$\widehat{a}_{(1)} = a_{(1)} + \underbrace{\tfrac{1}{2}\sum_i \gamma_i \rho_{(1)}(Z_i - c)}_{\text{曲率偏差}} + \underbrace{\sum_i \gamma_i (Y_i - \mu_{(1)}(Z_i))}_{\text{抽样噪声}}.$$

对照侧的截距也有相同形式的分解。局部线性权重可能为负，因此曲率偏差绝对值的上界为 $\frac{B}{2}\sum_i |\gamma_i|(Z_i - c)^2$；规则局部设计下它是 $O(h_n^2)$。

曲率偏差与抽样噪声 ⟶ 这两项都需要上界。

曲率偏差的阶为 Bh_n^2，其中 B 是二阶导数的界，h_n 是带宽。抽样噪声均值为零；若 $\mathrm{Var}[Y_i \mid Z_i] \le b^2$，则其方差不超过 $b^2 \sum_i \gamma_i^2$。若 Z_i 在 c 附近具有连续且非零的密度 f，

$$b^2 \sum_i \gamma_i^2 \approx \frac{4b^2}{|\{i : c \le Z_i \le c + h_n\}|} \approx \frac{4b^2}{f(c) n h_n}.$$

因此平方偏差为 h_n^4 阶，方差为 $(nh_n)^{-1}$ 阶，从而

$$\widehat{\tau}_c = \tau_c + O_p(n^{-2/5}), \qquad h_n \asymp n^{-1/5}.$$

这里 $n^{-2/5}$ 是估计误差；在 k 阶光滑性下，$h_n \asymp n^{-1/(2k+1)}$。

驱动变量中的噪声

可能有噪声 ⟶ 驱动变量 Z_i。

引入潜在变量 $U_i \sim G$，并给出两个条件：

1. 含噪声的驱动变量：设 $Z_i \mid U_i \sim N(U_i, \nu^2)$，其中 $\nu > 0$。
2. 驱动变量的无混杂性：$\{Y_i(0), Y_i(1)\} \perp Z_i \mid U_i$。

由 $Y_i = Y_i(W_i)$ 以及 $\{Y_i(0), Y_i(1)\} \perp W_i \mid U_i$，

$$e(u) = P(W_i = 1 \mid U_i = u) = P(Z_i \ge c \mid U_i = u) = 1 - \Phi\left(\frac{c - u}{\nu}\right),$$

$$\alpha_{(w)}(u) = E[Y_i(w) \mid U_i = u], \qquad \tau(u) = E[Y_i(1) - Y_i(0) \mid U_i = u].$$

定义标准正态分布函数：倾向得分表达式来自 $Z = U + \nu\xi$，其中 $\xi \sim N(0,1)$ 与 U 独立。仅归一化权重并不消除混杂：当 $h_+ = h_-$，或另有条件使第二个积分为零时，混杂项才消失。

$\Phi(x) = (2\pi)^{-1/2} \int_{-\infty}^{x} e^{-t^2/2}\, dt.$

U_i 无法观测，因此不能直接使用其倾向得分。考虑反卷积型估计量：

U_i 未观测：不能直接使用其倾向得分 ⟶ 反卷积权重 $\gamma_+(z), \gamma_-(z)$。

$$\widehat{\tau}_\gamma = \frac{1}{n} \sum_{Z_i \ge c} \gamma_+(Z_i) Y_i - \frac{1}{n} \sum_{Z_i < c} \gamma_-(Z_i) Y_i.$$

选择权重，使

$$E[\mathbf{1}_{\{Z_i \ge c\}} \gamma_+(Z_i)] = E[\mathbf{1}_{\{Z_i < c\}} \gamma_-(Z_i)] = 1.$$

则

$$E[\widehat{\tau}_\gamma] = \underbrace{\int h_+(u)\tau(u)\, dG(u)}_{\text{加权处理效应}} + \underbrace{\int (h_+(u) - h_-(u))\alpha_{(0)}(u)\, dG(u)}_{\text{混杂偏差}},$$

其中权函数为

$$h_+(u) = \int_c^\infty \gamma_+(z)\varphi_\nu(z - u)\, dz, \qquad h_-(u) = \int_{-\infty}^c \gamma_-(z)\varphi_\nu(z - u)\, dz,$$

$$\varphi_\nu(z - u) = \frac{1}{\sqrt{2\pi\nu^2}} \exp\left[-\frac{1}{2}\left(\frac{z - u}{\nu}\right)^2\right].$$

第 6 讲：断点回归的有限样本推断

有限样本 RDD 允许不连续 / 离散的驱动变量，或更复杂的阈值规则。局部线性回归的解 (6.2) 可以写成线性估计量：

$$\widehat{\tau}_c(\gamma) = \sum_{i=1}^{n} \gamma_i Y_i. \tag{6.3}$$

权重仅依赖 Z_i。

局部线性解 (6.2) $\longrightarrow$ 线性估计量 (6.3)，下面继续分析其性质。

若

$$Y_i(w) = \mu_{(w)}(Z_i) + \varepsilon_i(w), \qquad \varepsilon_i(w) \mid Z_i \sim N(0, b^2),$$

则在给定 $Z_1, \ldots, Z_n$ 后，

$$\widehat{\tau}_c(\gamma) \sim N(\widehat{\tau}_c^*(\gamma), b^2\|\gamma\|_2^2), \qquad \widehat{\tau}_c^*(\gamma) = \sum_i \gamma_i \mu_{(W_i)}(Z_i).$$

这里 $W_i = \mathbf{1}_{\{Z_i \geq c\}}$，且 $\|\gamma\|_2 = (\gamma_1^2 + \cdots + \gamma_n^2)^{1/2}$ 是欧几里得范数。

极小极大线性估计

极小极大是指最小化最坏情形的均方误差（MSE）。同方差下，线性估计量的条件方差可以直接写为 $b^2\|\gamma\|_2^2$。其偏差则依赖未知的条件均值：

$$\mathrm{Bias}(\widehat{\tau}_c(\gamma) \mid Z_1, \ldots, Z_n) = \sum_i \gamma_i \mu_{(W_i)}(Z_i) - [\mu_{(1)}(c) - \mu_{(0)}(c)].$$

光滑性限制 $|\mu''_{(w)}(z)| \leq B$ 给出偏差的上界

$$I_B(\gamma) = \sup_{|\mu''_{(w)}| \leq B} \left\{ \sum_i \gamma_i \mu_{(W_i)}(Z_i) - [\mu_{(1)}(c) - \mu_{(0)}(c)] \right\}.$$

因为二阶导数约束的函数类对称，取上确界时不需要绝对值。因此

$$|\mathrm{Bias}(\widehat{\tau}_c(\gamma) \mid Z_1, \ldots, Z_n)| \leq I_B(\gamma),$$

$$\mathrm{MSE}(\widehat{\tau}_c(\gamma) \mid Z_1, \ldots, Z_n) \leq b^2\|\gamma\|_2^2 + I_B^2(\gamma).$$

MSE = 方差 + 偏差平方；这个界不依赖未知的 μ。接着定义

$$\gamma^B = \arg\min_{\gamma} \{b^2\|\gamma\|_2^2 + I_B^2(\gamma)\}, \qquad \widehat{\tau}_c(\gamma^B) = \sum_i \gamma_i^B Y_i. \tag{6.8}$$

比较：在同一曲率约束下，优化后的最坏 MSE 不大于局部线性估计的最坏 MSE。条件于设计，假设误差独立且服从已知方差 b^2 的高斯分布，并使用有效曲率上界 B。极小极大准则最小化该函数类中的最坏 MSE，并非对每个回归函数都更好。离散设计要求约束可行，区间宽度可能保持为正。

推导极小极大线性权重

分解为

$$\mu_{(w)}(z) = a_{(w)} + \beta_{(w)}(z - c) + \rho_{(w)}(z),$$

其中 $\rho_{(w)}(c) = \rho'_{(w)}(c) = 0$，二阶导数以 B 为界。截距和斜率没有限制，因此除非满足下列条件，否则 $I_B(\gamma)$ 可以为无穷大：

$$\sum_i \gamma_i W_i = 1, \qquad \sum_i \gamma_i = 0, \qquad \sum_i \gamma_i (Z_i - c)_+ = 0, \qquad \sum_i \gamma_i (Z_i - c)_- = 0.$$

加上这些约束后，只需控制余项。将式 (6.8) 改写为

$$(\gamma^B, t) = \arg\min_{\gamma,t}\{b^2\|\gamma\|_2^2 + B^2t^2\},$$

约束为

$$\sum_i \gamma_i W_i \rho_{(1)}(Z_i) + \sum_i \gamma_i(1-W_i)\rho_{(0)}(Z_i) \le t$$

对所有满足 $\rho_{(w)}(c) = \rho'_{(w)}(c) = 0$、$|\rho''_{(w)}(z)| \le 1$ 的 $\rho_{(w)}$ 都成立，同时满足

$$\sum_i \gamma_i W_i = 1, \quad \sum_i \gamma_i = 0, \quad \sum_i \gamma_i W_i(Z_i - c) = 0, \quad \sum_i \gamma_i(1-W_i)(Z_i - c) = 0. \tag{6.10}$$

提示：求解对应的对偶问题。

原始极小极大优化问题 (6.10) $\longrightarrow$ 转化为对偶问题求解。

个人补充：为什么权重之和为零？ 最终估计的是一个差。将求和拆成处理组和对照组两部分：

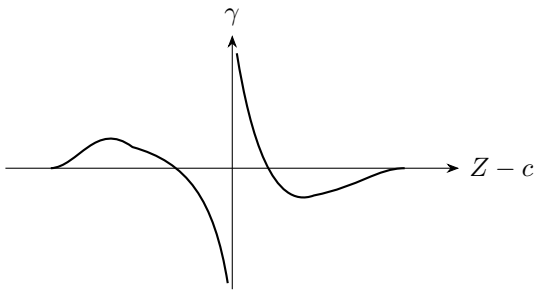
$$\widehat{\tau}_c(\gamma) = \sum_i \gamma_i^{(1)} Y_i + \sum_i \gamma_i^{(2)} Y_i.$$

处理组权重之和为 1，对照组权重之和为 -1，所以

$W = 1$ 组；$W = 0$ 组 $\longrightarrow$ 权重分别加总为 1、-1；总和为 0。

$$\sum_i \gamma_i = 1 + (-1) = 0, \quad \sum_i \gamma_i^{(1)} = \sum_i \gamma_i W_i = 1, \quad \sum_i \gamma_i^{(2)} = \sum_i \gamma_i(1-W_i) = -1.$$

图中的权重在阈值左侧近处有负的尖峰，右侧近处有正的尖峰；离阈值更远时，权重改变符号，然后趋近零。



线性估计量的推断

构造 $\widehat{\tau}_c(\gamma^B)$ 的置信区间。令

$$\text{err} = \widehat{\tau}_c - \tau_c, \qquad \text{err} \mid Z_1, \ldots, Z_n \sim N(\text{bias}, b^2\|\gamma^B\|_2^2),$$

其中由式 (6.10) 得到 $|\text{bias}| \le Bt$。根据高斯分布的单峰性，对于 $S \sim N(0,1)$，

$$P(|\text{err}| \ge \zeta) \le P(|Bt + b\|\gamma^B\|_2 S| \ge \zeta).$$

条件覆盖率至少为 $1-\alpha$ 的置信区间是

$$I_\alpha = (\widehat{\tau}_c(\gamma^B) - \zeta_\alpha^B, \widehat{\tau}_c(\gamma^B) + \zeta_\alpha^B),$$

$$\zeta_\alpha^B = \inf\{\zeta : P(|Bt + b\|\gamma^B\|_2 S| > \zeta) \le \alpha\}. \tag{6.13}$$

强调：条件于 Z_i，因此驱动变量服从任何分布都可以，包括非标准的 RDD 情形。

离散驱动变量。 单独限制 $|\mu''_{(w)}(z)| \le B$ 不一定能识别 τ_c，但式 (6.13) 仍有效。Z_i 连续时，区间以 $n^{-2/5}$ 速度缩小；Z_i 离散时，长度未必趋于零。当 c 不在驱动变量的支持集内，需要用满足二阶导数界的插值函数表示 $\mu_{(w)}(z)$。

多维驱动变量。 例如二维、三维区域以及地理边界。不能直接使用一维阈值 RDD；有的方法将其化为一维距离，这样可能丢失相关空间信息。极小极大方法则可以直接推广到多维。

超出同方差情形

当误差 $\varepsilon_i = Y_i - \mu_{(W_i)}(Z_i)$ 不再是方差为 b^2 的同方差高斯误差时，式 (6.11) 的精确正态分布结论不成立。利用中心极限定理来说明

$$\widehat{\tau}_c(\gamma) \mid Z_1, \ldots, Z_n \;\approx\; N\left(\widehat{\tau}^*_c(\gamma), \sum_i \gamma_i^2 \operatorname{Var}[Y_i \mid Z_i, W_i]\right). \tag{6.14}$$

若高斯近似有效，仍可构造置信区间。将条件方差估计为

$$\widehat{V}_n = \sum_i \gamma_i^2 (Y_i - \widehat{\mu}_{(W_i)}(Z_i))^2,$$

其中拟合均值来自局部线性回归。

局部线性拟合的均值 $\longrightarrow$ 残差方差估计量中的 $\widehat{\mu}_{(W_i)}(Z_i)$。

在独立评估数据上，如果均值拟合错了 $\longrightarrow$ 残差平方期望增加了均值误差的平方。

极小极大准则 (6.8) 针对同方差；异方差下，将各个方差 b_i^2 引入用于构造对偶问题的式 (6.10)。残差膨胀的直觉适用于独立评估数据：残差平方期望等于条件方差加均值误差平方。样本内过拟合反而可能缩小残差。应使用有效的留一法或交叉拟合方差估计，并要求不存在支配性观测的加权中心极限定理。

第 7 讲：平衡估计量

平衡性指导 $\widehat{e}(x)$ 的构造。

平衡性 / $\widehat{e}(x)$ 的设计原理 $\longrightarrow$ 构造倾向得分的平衡损失函数；高维 ATE 估计。

两个目标是：构造倾向得分的平衡损失函数，以及在高维协变量下估计 ATE。IPW、AIPW 都使用倾向得分；这一讲通过凸优化推导如何估计 $e(x)$。

回顾 IPW

给定独立同分布观测 $(X_i, Y_i, W_i) \in \mathcal{X} \times \mathbb{R} \times \{0,1\}$，目标为 $\tau = \mu_{(1)} - \mu_{(0)}$，其中 $\mu_{(w)} = E[Y_i(w)]$。假设

$$\{Y_i(0), Y_i(1)\} \perp W_i \mid X_i, \qquad 0 < \eta \le e(X_i) \le 1 - \eta < 1,$$

其中 $e(x) = P(W_i = 1 \mid X_i = x)$，$\eta$ 为正常数。用下式估计处理状态下的均值：

$$\widehat{\mu}_{\mathrm{IPW}}(1) = \frac{1}{n} \sum_i \frac{W_i Y_i}{\widehat{e}(X_i)}. \tag{7.3}$$

下面简略地分三步说明一致性：

1. 总体平衡：无混杂性下，$\mu_{(1)} = E[W_i Y_i / e(X_i)]$。
2. 理想估计量：使用真实的 $e(x)$ 时无偏；重叠性给出有限方差。

3. 可实施近似：若估计的倾向得分也满足重叠性，由 Cauchy–Schwarz 不等式可得

$$\begin{aligned}|\widehat{\mu}_{\mathrm{IPW}}(1)-\widehat{\mu}^{*}_{\mathrm{IPW}}(1)| &\le \left[\frac{1}{n}\sum_i\left(\frac{1}{\widehat{e}(X_i)}-\frac{1}{e(X_i)}\right)^2\right]^{1/2}\left[\frac{1}{n}\sum_i(W_iY_i)^2\right]^{1/2}\\ &\le \frac{1}{\eta^2}\left[\frac{1}{n}\sum_i(\widehat{e}(X_i)-e(X_i))^2\right]^{1/2}\left[\frac{1}{n}\sum_i(W_iY_i)^2\right]^{1/2}.\end{aligned}$$

回顾 $|a\cdot b|^2\le\|a\|^2\|b\|^2$，在乘积风险条件下，$n\to\infty$ 时，相应的 AIPW 误差相对于 $1/\sqrt{n}$ 可以忽略。

总体平衡与样本平衡

用预先指定的基展开条件均值：

$$\mu_{(w)}(x)=\sum_{j=1}^{\infty}\beta_{j(w)}\psi_j(x).$$

多项式基或 Fourier 基 $\longrightarrow$ 条件均值展开中的 $\psi_j(x)$。

在合理的正则条件下，

$$\mu_{(w)}=\sum_{j=1}^{\infty}\beta_{j(w)}E[\psi_j(X_i)].$$

两边取期望 $\longrightarrow$ $\mu_{(w)}=\sum_j\beta_{j(w)}E[\psi_j(X)]$。

这些正则条件会不会有问题?

补充说明。 交换求和与期望的一个充分条件是 $\sum_j|\beta_{j(w)}|E|\psi_j(X)|<\infty$；部分和在 L^1 中收敛也足够，概率分布下的 L^2 收敛蕴含它。仅逐点收敛并不够。总体平衡也可直接条件于 X 来证明。在无混杂性下，$Y_i=\mu_{(W_i)}(X_i)+\varepsilon_i$，且 $E[\varepsilon_i\mid X_i,W_i]=0$。总体 IPW 论证为

$$\begin{aligned}E\left[\frac{W_iY_i}{e(X_i)}\right]&=E\left[\frac{W_i}{e(X_i)}\sum_j\beta_{j(1)}\psi_j(X_i)\right]\\&=\sum_j\beta_{j(1)}E\left[\frac{W_i\psi_j(X_i)}{e(X_i)}\right]=\sum_j\beta_{j(1)}E[\psi_j(X_i)]=\mu_{(1)}.\end{aligned}$$

核心：$E[W_i\mid X_i]=e(X_i)$ $\longrightarrow$ $E[W_i\psi_j(X_i)/e(X_i)]=E[\psi_j(X_i)]$。

因此选择权重，使样本中满足

$$\frac{1}{n}\sum_i\frac{W_i\psi_j(X_i)}{\widehat{e}(X_i)}\approx\frac{1}{n}\sum_i\psi_j(X_i),\qquad j=1,2,\ldots. \tag{7.8}$$

倾向得分估计的平衡损失

假设结果模型为线性：$\mu_{(w)}(x)=x\beta_{(w)}$，倾向得分模型为 logistic：

$$e(x)=\frac{1}{1+\exp(-x\theta)}.$$

此时样本平衡只涉及协变量 X_i，平衡的目标是均值。式 (7.8) 变为

$$\frac{1}{n}\sum_i (1+e^{-X_i\widehat{\theta}})W_iX_i = \frac{1}{n}\sum_i X_i. \tag{7.9}$$

这是以下凸优化问题的 KKT 条件：

$$\widehat{\theta} = \arg\min_\theta \frac{1}{n}\sum_i \ell_\theta(X_i,Y_i,W_i), \qquad \ell_\theta(X_i,Y_i,W_i) = W_i e^{-X_i\theta} + (1-W_i)X_i\theta. \tag{7.10}$$

因此可以用 Newton 下降法求解。

平衡方程 (7.9) 是凸损失的 KKT 条件 $\longrightarrow$ 当存在合适的有限最小点时，可用 Newton 下降法。

这可以作为平衡损失函数。Hessian $n^{-1}\sum_i W_i e^{-X_i\theta}X_i^{\mathsf{T}}X_i$ 为半正定。唯一有限最小点还需要足够的秩和解的存在性；目标均值位于处理组协变量凸支撑之外时，精确平衡可能无法实现。为分别实现两组的平衡，可以拟合两个校准损失。真实处理机制仍只有一个倾向得分 $e(x)$，对照概率为 $1-e(x)$。

高维混杂变量下的 ATE 估计

设 $X_i \in \mathbb{R}^p$，可能有 $p \gg n$，且 $\mu_{(w)}(x) = x\beta_{(w)}$。高维下很难充分准确地估计 $e(x)$，精确权重无法得到，因此寻求近似平衡。由 Hölder 不等式，

$$\begin{aligned}
&\frac{1}{n}\sum_i \frac{W_i\mu_{(1)}(X_i)}{\widehat{e}(X_i)} - \frac{1}{n}\sum_i \mu_{(1)}(X_i) \\
&= \left(\frac{1}{n}\sum_i \frac{W_iX_i}{\widehat{e}(X_i)} - \frac{1}{n}\sum_i X_i\right)\beta_{(1)} \\
&\le \left\|\frac{1}{n}\sum_i \frac{W_iX_i}{\widehat{e}(X_i)} - \frac{1}{n}\sum_i X_i\right\|_\infty \|\beta_{(1)}\|_1.
\end{aligned}$$

第一个范数衡量不平衡程度。回顾 Hölder 不等式：$\sum_i |a_ib_i| \le (\sum_i |a_i|^p)^{1/p}(\sum_i |b_i|^q)^{1/q}$.

个人理解与问题。 好的逆概率权重使最坏情形下的不平衡程度尽可能小。还剩两个问题：(1) 如何参数化 $\widehat{e}(X_i)$，实现上确界范数下的近似平衡；(2) 只有 $\|\beta_{(1)}\|_1$ 有界时，该界才有意义。高维统计通常假设系数向量稀疏，而不是直接限制其 1 范数。

补充：范数回顾。 非零元素数为 $\|x\|_0 = \sum_i \mathbf{1}\{x_i \neq 0\}$，它并非范数。1 范数为 $\sum_i |x_i|$，2 范数为 $(\sum_i x_i^2)^{1/2}$，无穷范数为 $\max_i |x_i|$；对 $p \ge 1$，$\|x\|_p = (\sum_i |x_i|^p)^{1/p}$。Holder 不等式要求 $p, q \ge 1$ 且 $1/p + 1/q = 1$，包括 $(1,\infty)$ 端点。该端点给出上方不平衡误差绝对值的界。

近似平衡权重与回归增广

选择合适的调节参数 ζ，求解

$$\widehat{\gamma} = \arg\min_{\gamma_i \ge 1}\left\{\frac{1}{n^2}\|\gamma\|_2^2 + \zeta\left\|\frac{1}{n}\sum_i(\gamma_iW_i - 1)X_i\right\|_\infty^2\right\}. \tag{7.12}$$

L_2 大小的平方；不平衡程度；调节权重 $\longrightarrow$ $n^{-2}\|\gamma\|_2^2$；无穷范数的平方；ζ。

然后将 $1/\widehat{e}(X_i) = \widehat{\gamma}_i$ 作为逆倾向得分权重。利用次高斯集中不等式，可对理想权重验证如下形式的界：

$$\frac{1}{n^2}\|1/e(X_i)\|_2^2 \le \frac{\eta^{-2}}{n}, \qquad \left\|\frac{1}{n}\sum_i(\gamma_i W_i - 1)X_i\right\|_\infty^2 = O_p\left(\frac{\eta^{-2}\log p}{n}\right).$$

$\widehat{e}(X_i)$ 不需要很好地估计 $e(X_i)$；选择合适的 ζ 后，这些逆权重仍满足偏差界。接着用高维回归增广加权估计量，以去掉对 $\|\beta_{(1)}\|_1$ 的依赖。增广平衡估计量为

$$\widehat{\mu}_{\mathrm{AB}}(1) = \frac{1}{n}\sum_i\left[\widehat{\mu}_{(1)}(X_i) + \widehat{\gamma}_i W_i(Y_i - \widehat{\mu}_{(1)}(X_i))\right], \quad \widehat{\mu}_{(1)}(X_i) = X_i\widehat{\beta}_{(1)}. \tag{7.14}$$

其分解为

$$\widehat{\mu}_{\mathrm{AB}}(1) = \underbrace{\frac{1}{n}\sum_i X_i\beta_{(1)}}_{\mu_{(1)}(X_i)\text{的均值}} + \underbrace{\frac{1}{n}\sum_i \widehat{\gamma}_i W_i(Y_i - X_i\beta_{(1)})}_{\text{零均值噪声}} + \left[\frac{1}{n}\sum_i(1-\widehat{\gamma}_i W_i)X_i\right](\widehat{\beta}_{(1)} - \beta_{(1)}).$$

最后一项的绝对值上界为

$$\left\|\frac{1}{n}\sum_i(1-\widehat{\gamma}_i W_i)X_i\right\|_\infty \|\widehat{\beta}_{(1)} - \beta_{(1)}\|_1.$$

权重只需修正 $\beta_{(1)} - \widehat{\beta}_{(1)}$，不必修正整个系数向量 $\longrightarrow$ 不平衡程度乘回归误差的余项。

高维回归给出该误差的界：在稀疏性 $\|\beta_{(1)}\|_0 \le k$ 与限制特征值条件下，lasso 可达到

$$\|\widehat{\beta}_{(1)} - \beta_{(1)}\|_1 = O_p\left(k\sqrt{\frac{\log p}{n}}\right).$$

将步骤组合起来。 假设设计满足上述界所需的条件，$\beta_{(1)}$ 为 k 稀疏，且 $k \ll \sqrt{n}/\log p$。

1. 在处理组上拟合 lasso；系数的 1 范数误差为 $o_p(1/\sqrt{\log p})$。
2. 用式 (7.12) 拟合 $\widehat{\gamma}$，得到无穷范数不平衡程度 $O_p(\sqrt{\log(p)/n})$。
3. 使用式 (7.14)，将这些界代入分解：

$$\widehat{\mu}_{\mathrm{AB}}(1) - \frac{1}{n}\sum_i X_i\beta_{(1)} = \frac{1}{n}\sum_i \widehat{\gamma}_i W_i(Y_i - X_i\beta_{(1)}) + o_p(n^{-1/2}). \tag{7.17}$$

噪声项为 $O_p(n^{-1/2})$。这些速率使用受控次高斯协变量、适当 lasso 调参、限制特征值及噪声矩条件。权重依赖 (X, W)，而非结果噪声。学生化要求不存在支配性的加权残差，并论证替换估计系数的有效性。

还成立中心极限定理：

$$\frac{\sum_i \widehat{\gamma}_i W_i(Y_i - X_i\beta_{(1)})}{\sqrt{\sum_i \widehat{\gamma}_i^2 W_i^2(Y_i - X_i\beta_{(1)})^2}} \Rightarrow N(0,1).$$

个人保留意见。 这比预想的弱：只给出了样本均值 $\bar{\mu}_{(1)} = n^{-1}\sum_i X_i\beta_{(1)}$ 的置信区间，而不是 $\mu_{(1)}$ 本身的区间。要得到总体均值的结果，一个可行途径是证明估计权重 $\widehat{\gamma}_i$ 的收敛性。

对总体目标，还须加入 $n^{-1}\sum_i \mu_{(1)}(X_i) - E[\mu_{(1)}(X)]$，并确定它与加权噪声的联合极限。权重收敛到稳定函数是一个充分途径。

第 8 讲：面板数据方法

面板（纵向）数据在时刻 $t = 1, \ldots, T$ 观测单位 $i = 1, \ldots, n$。把观测排成矩阵：各行对应单位，各列对应时间点 $t_1, t_2, \ldots, T$。

	$t = t_1$	$t = t_2$	$\cdots$	$t = T$
$i = 1$				
$i = 2$				
$\vdots$				
$i = n$				

常数处理效应模型

结果为 $Y_{it} \in \mathbb{R}$，处理分配为 $W_{it} \in \{0, 1\}$。基本模型是

$$Y_{it} = Y_{it}(0) + W_{it}\tau, \qquad i = 1, \ldots, n, \quad t = 1, \ldots, T. \tag{8.1}$$

这个非常基础的模型没有考虑处理效应异质性及动态效应。这里，所有单位、所有时点的处理效应相同；单位在 t 时点的结果只依赖该时点的处理，不依赖之前的处理。τ 不依赖 i, t；过去的时点不进入模型。

双向模型

$$Y_{it} = \alpha_i + \beta_t + W_{it}\tau + \varepsilon_{it}, \qquad E[\varepsilon \mid \alpha, \beta, W] = 0. \tag{8.2}$$

α_i、β_t 分别为单位和时间的平移。严格外生性条件于完整处理路径及固定效应：决策不能响应任一时期的个体噪声。这比同时期的均值外生性更强。

例如有两个时期，一组的处理路径为 $(0, 0)$，另一组为 $(0, 1)$。双重差分的闭式估计为

DID $\longrightarrow$ 两组各自的前后差，再做组间差。

$$\widehat{\tau} = \frac{1}{|\{i : W_{i2} = 1\}|}\sum_{W_{i2}=1}(Y_{i2} - Y_{i1}) - \frac{1}{|\{i : W_{i2} = 0\}|}\sum_{W_{i2}=0}(Y_{i2} - Y_{i1}).$$

理解。 局限是：当 n, T 很大且处理分配分布一般时，模型 (8.2) 可能不成立。类似地，多于两个时期的 OLS 有时也称为 DID，但一般 OLS 系数不再由两组前后差的简单式子描述。其优点是平行趋势要求比较直观（单位只在 α_i 上存在差异）；没有平行趋势就不能使用。在平衡面板中，对单位和时间指标残差化：$\widetilde{W}_{it} = W_{it} - \overline{W}_{i\cdot} - \overline{W}_{\cdot t} + \overline{W}_{\cdot\cdot}$，$Y$ 同理。若 $\sum_{it}\widetilde{W}_{it}^2 > 0$，

$$\widehat{\tau} = \frac{\sum_{it}\widetilde{W}_{it}\widetilde{Y}_{it}}{\sum_{it}\widetilde{W}_{it}^2}.$$

这里平行趋势指条件均值路径，而非带噪声的实际结果。

补充：噪声建模与方差估计。 将各行向量 $\varepsilon_i = (\varepsilon_{i1}, \ldots, \varepsilon_{iT})$ 视为在单位之间独立同分布，并有 $\mathrm{Var}[\varepsilon_i] = \Sigma$。假设每个 ε_{it} 都相互独立，很难论证，也不合理。$T = 2$ 时，直接估计差分的方差：

$$\widehat{\mathrm{Var}}[\widehat{\tau}] = \frac{\widehat{\mathrm{Var}}[Y_{i2} - Y_{i1} \mid W_{i2} = 1]}{|\{i : W_{i2} = 1\}|} + \frac{\widehat{\mathrm{Var}}[Y_{i2} - Y_{i1} \mid W_{i2} = 0]}{|\{i : W_{i2} = 0\}|}. \tag{8.4}$$

同一行 / 单位内的误差相关时，该方法仍稳健。

交互效应面板模型

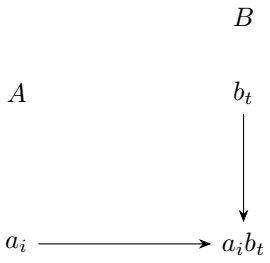
考虑交互效应面板模型

$$Y_{it} = A_i . B_{t\cdot}^{\mathsf{T}} + W_{it}\tau + \varepsilon_{it}, \qquad \mathbb{E}[\varepsilon \mid A, B, W] = 0, \tag{8.5}$$

其中 $A \in \mathbb{R}^{n \times k}$、$B \in \mathbb{R}^{T \times k}$，$k$ 是秩参数。等价地，

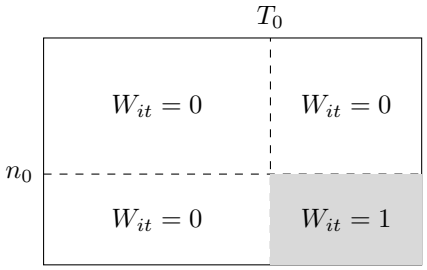
$$Y_{it} = L_{it} + W_{it}\tau + \varepsilon_{it} \qquad \text{对某个秩至多为 } k \text{ 的矩阵} L.$$

我的矩阵直觉。 将 A 的取值沿行往下放，B 的取值沿列横向放。秩为一时，交点的元素就是 $a_i b_t$；若 $k \neq 1$，则该元素是一个和 $a_{i1}b_{t1} + a_{i2}b_{t2} + \cdots$。



当 $k > 1$ 时：$\sum_{j=1}^{k} a_{ij} b_{tj}$

处理这个模型，可以考虑合成控制和合成双重差分。假设当且仅当 $i > n_0$ 且 $t > T_0$ 时，$W_{it} = 1$。图中在第 n_0 行、第 T_0 列分割结果矩阵，只有右下角区块接受处理。



用未处理个体拟合处理组在处理前的轨迹：

$$\sum_{i=1}^{n_0} \gamma_i Y_{it} \approx \alpha + \frac{1}{n - n_0} \sum_{i=n_0+1}^{n} Y_{it}, \qquad t = 1, \ldots, T_0.$$

第一组从不接受处理；第二组在 T_0 之后接受处理。截距 α 的作用类似于固定效应。权重选择为

$$(\widehat{\gamma}, \widehat{\alpha}) \in \operatorname*{arg\,min}_{\gamma', \alpha} \left\| \sum_{i=1}^{n_0} \gamma_i' Y_{i,1:T_0} - \frac{1}{n - n_0} \sum_{i=n_0+1}^{n} Y_{i,1:T_0} - \alpha \mathbf{1} \right\|_2^2,$$

$$\text{约束为} \quad \sum_{i=1}^{n_0} \gamma_i' = 1, \qquad \gamma_i' \geq 0. \tag{8.7}$$

γ_i 的目的是创造平行趋势，从而平衡潜在的 A_i 项。

最后，在加权的双向模型中估计处理系数：

$$(\widehat{\tau}, \widehat{\alpha}, \widehat{\beta}) \in \underset{\tau', \alpha', \beta'}{\arg\min} \sum_{i,t} \gamma_i (Y_{it} - \alpha_i' - \beta_t' - W_{it}\tau')^2, \tag{8.8}$$

其中，对 $i > n_0$，$\gamma_i = 1/(n - n_0)$。

加权回归中处理个体的权重 $\longrightarrow$ 对 $i > n_0$，$\gamma_i = 1/(n - n_0)$。

处理系数的闭式解为

$$\widehat{\tau} = \frac{1}{n - n_0} \sum_{i=n_0+1}^{n} \left\{ \frac{1}{T - T_0} \sum_{t=T_0+1}^{T} Y_{it} - \frac{1}{T_0} \sum_{t=1}^{T_0} Y_{it} \right\} - \sum_{i=1}^{n_0} \gamma_i \left\{ \frac{1}{T - T_0} \sum_{t=T_0+1}^{T} Y_{it} - \frac{1}{T_0} \sum_{t=1}^{T_0} Y_{it} \right\}.$$

这依赖 T_0 和 n。在适当的大面板渐近框架下，$n_0, n_1, T \to \infty$ 时，估计量一致。一致性要求处理前因子能够揭示处理后相关的方向，处理前信息足够，并控制噪声与权重集中。仅有良好的处理前拟合并不充分。完整合成 DID 还使用时间权重和正则化；这里的式子突出单位加权思路。

其他方法。 合成控制并非处理交互式固定效应的唯一方法。例如，通过 k-均值聚类矩阵 Y 的行，然后分别为每个群组拟合时变基线模型。

通过可交换性识别

回顾 $Y_{it} = Y_{it}(0) + W_{it}\tau$。一个基于设计的假设为

$$Y_{i\cdot}(0) \perp W_{i\cdot} \mid S_i, \qquad S_i = \sum_{t=1}^{T} W_{it}. \tag{8.10}$$

其一个推论：考虑线性估计量

$$\widehat{\tau} = \sum_{i,t} \gamma_{it} Y_{it}, \tag{8.11}$$

权重矩阵只依赖 W。在 (8.10) 下，给定同一个 S_i 值，未处理潜在结果可交换，并且

$$\mathbb{E}[\widehat{\tau} \mid W, \gamma] = \sum_{i,t} \gamma_{it} \mathbb{E}[Y_{it}(0) \mid S_i] + \tau \sum_{i,t} \gamma_{it} W_{it}.$$

因此，只要满足下列条件，就可得无偏性：

$$\sum_{i,t} \gamma_{it} W_{it} = 1, \qquad \sum_{i:S_i=s} \gamma_{it} = 0 \quad \text{对每个} t \text{ 和} s \in \mathcal{S},$$

其中 $\mathcal{S}$ 是 S_i 的支持集。

同一层内，条件期望为常数 $\longrightarrow$ $\sum_{i:S_i=s} \gamma_{it} = 0$ 消去 $\sum_i \gamma_{it} E[Y_{it}(0) \mid S_i]$。

这里假设各行独立同分布，且条件均值共同为 $E[Y_{it}(0) \mid S_i = s] = m_t(s)$。准则 $\sum_{it} \gamma_{it}^2$ 对应条件不相关且同方差的单元格；单位内协方差为 Σ_i 时使用 $\sum_i \gamma_i^{\mathsf{T}} \Sigma_i \gamma_i$。只要平衡约束可行，即使该工作方差模型错设，无偏性仍成立。

在这些无偏性约束下，选择使方差最小的 γ：

$$\begin{aligned}\gamma \in \arg\min_{\gamma'} \quad & \sum_{i,t}(\gamma'_{it})^2, \\ \text{约束为} \quad & \sum_{i,t}\gamma'_{it}W_{it} = 1, \quad \sum_{i:S_i=s}\gamma'_{it} = 0 \quad \text{对所有} s,t.\end{aligned} \tag{8.14}$$

大致说，需要相同 S_i 的个体之间存在 W_{it} 的变异。

两组识别约束。 回顾双向模型

$$Y_{it} = \alpha_i + \beta_t + W_{it}\tau + \varepsilon_{it}, \qquad \mathbb{E}[\varepsilon \mid \alpha, \beta, W] = 0. \tag{8.2，回顾}$$

在这个模型下，若满足下列条件，估计量 (8.11) 也无偏：

$$\sum_t \gamma_{it} = 0 \text{ 对每个} i, \qquad \sum_i \gamma_{it} = 0 \text{ 对每个} t, \qquad \sum_{i,t}\gamma_{it}W_{it} = 1.$$

前两个等式消去固定效应 α_i 和 β_t，第三个等式将处理系数归一化。

合并这些约束可得到双重稳健估计量：最小化 $\sum_{i,t}\gamma_{it}^2$，约束为

$$\sum_{i,t}\gamma_{it}W_{it} = 1, \qquad \sum_{i:S_i=s}\gamma_{it} = 0 \quad \text{对所有} s,t,$$

$$\sum_t \gamma_{it} = 0 \quad \text{对所有} i, \qquad \sum_i \gamma_{it} = 0 \quad \text{对所有} t.$$

只要 (8.2) 或 (8.10) 任一成立，它就无偏。

第 9 讲：工具变量回归

工具变量回归处理内生的处理效应问题，即 $Y_i(0)$ 与 W_i 相互依赖的情形。

结构模型

从常数效应模型开始：

$$Y_i(w) = Y_i(0) + w\tau, \qquad Y_i = Y_i(W_i). \tag{9.1}$$

通常，无混杂性指 $\{Y_i(w)\} \perp W_i$；在 (9.1) 中，它就是 $Y_i(0) \perp W_i$。将模型改写为

常数效应潜在结果与无混杂性 $\longrightarrow$ $Y_i = \alpha + W_i\tau + \varepsilon_i$。

$$Y_i = \alpha + W_i\tau + \varepsilon_i, \tag{9.2}$$

其中 $\alpha = \mathbb{E}[Y_i(0)]$，$\varepsilon_i = Y_i(0) - \mathbb{E}[Y_i(0)]$。在无混杂性下，$\mathbb{E}[\varepsilon_i \mid W_i] = 0$，因此将 Y_i 对 W_i 作 OLS 回归即可估计 τ。

存在混杂时，式 (9.2) 仍成立，但 $\mathbb{E}[\varepsilon_i \mid W_i] \neq 0$。此时 OLS 的目标为

$$\begin{aligned}\tau_{\text{OLS}} &= \frac{\text{Cov}(Y_i, W_i)}{\text{Var}(W_i)} \\ &= \frac{\text{Cov}(\tau W_i + \varepsilon_i, W_i)}{\text{Var}(W_i)} = \tau + \frac{\text{Cov}(\varepsilon_i, W_i)}{\text{Var}(W_i)}.\end{aligned}$$

这个比值就是 OLS 系数。当 $\text{Cov}(\varepsilon, W) \neq 0$ 时，该系数才偏离 τ；依赖本身不必造成线性偏差。IV 识别需要第一阶段协方差非零。

利用工具变量识别

引入 Z_i：

$$Y_i = \alpha + W_i\tau + \varepsilon_i, \qquad \varepsilon_i \perp Z_i, \qquad W_i = Z_i\gamma + \eta_i. \tag{9.4}$$

由于 Z_i 与 ε_i 不相关，

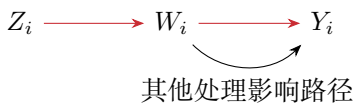
$$\mathrm{Cov}(Y_i, Z_i) = \mathrm{Cov}(\tau W_i + \varepsilon_i, Z_i) = \tau\,\mathrm{Cov}(W_i, Z_i).$$

因此

$$\tau = \frac{\mathrm{Cov}(Y_i, Z_i)}{\mathrm{Cov}(W_i, Z_i)}, \qquad \widehat{\tau} = \frac{\widehat{\mathrm{Cov}}(Y_i, Z_i)}{\widehat{\mathrm{Cov}}(W_i, Z_i)}.$$

我的 IV 条件检查表。

1. **外生性：** $\varepsilon_i \perp Z_i$。
2. **相关性：** $\mathrm{Cov}(W_i, Z_i) \neq 0$。
3. **排除限制：** Z_i 对 Y_i 的所有影响都必须经过 W_i。



最优工具变量

允许工具变量 $Z_i \in \mathcal{Z}$ 为高维：

$$Y_i = \tau W_i + \varepsilon_i, \qquad \varepsilon_i \perp Z_i, \qquad Y_i, W_i \in \mathbb{R}.$$

对函数 $w : \mathcal{Z} \to \mathbb{R}$，

$$\tau = \frac{\mathrm{Cov}(Y_i, w(Z_i))}{\mathrm{Cov}(W_i, w(Z_i))}, \tag{9.8}$$

其中分母非零。哪个变换 $w(\cdot)$ 最优？估计量为

$$\begin{aligned}\widehat{\tau}_w &= \frac{\widehat{\mathrm{Cov}}(Y_i, w(Z_i))}{\widehat{\mathrm{Cov}}(W_i, w(Z_i))} \\ &= \frac{n^{-1}\sum_i (Y_i - \overline{Y})(w(Z_i) - \overline{w(Z)})}{n^{-1}\sum_i (W_i - \overline{W})(w(Z_i) - \overline{w(Z)})},\end{aligned} \tag{9.9}$$

其中 $\overline{Y} = n^{-1}\sum_i Y_i$，其他均值类似定义。它求解以下估计方程：

$$\frac{1}{n}\sum_i (w(Z_i) - \overline{w(Z)})\{Y_i - \overline{Y} - \widehat{\tau}_w(W_i - \overline{W})\} = 0. \tag{9.10}$$

极限为

$$\sqrt{n}(\widehat{\tau}_w - \tau) \Rightarrow \mathcal{N}(0, V_w), \qquad V_w = \frac{\mathrm{Var}(\varepsilon_i)\,\mathrm{Var}(w(Z_i))}{\mathrm{Cov}(W_i, w(Z_i))^2}. \tag{9.11}$$

该极限使用独立同分布观测、所需有限矩、中心化误差和非零第一阶段极限协方差，其一阶项为

$$\sqrt{n}(\widehat{\tau}_w - \tau) = \frac{n^{-1/2}\sum_i (w(Z_i) - E[w(Z)])\varepsilon_i}{\mathrm{Cov}(W, w(Z))} + o_p(1).$$

由于 $Z_i \perp \varepsilon_i$ 且 $\mathbb{E}[\varepsilon_i] = 0$，

$$\mathrm{Var}\{\varepsilon_i(w(Z_i) - \mathbb{E}[w(Z_i)])\} = \mathrm{Var}(\varepsilon_i)\,\mathrm{Var}(w(Z_i)).$$

为最小化渐近方差，最大化其倒数比值：

使用方差相关比值的倒数 $\longrightarrow$ 下方定义 $w^*(\cdot)$ 的最大化问题。

$$w^*(\cdot) \in \arg\max_{w'} \frac{\mathrm{Cov}(W_i, w'(Z_i))^2}{\mathrm{Var}(w'(Z_i))}.$$

给出的解为

$$w^*(z) \propto \mathbb{E}[W_i \mid Z_i = z].$$

$w^*(z) \propto E[W_i \mid Z_i = z]$ $\longrightarrow$ 用 Z_i 对 W_i 的最佳预测。

记 $m(Z) = E[W \mid Z]$，由 Cauchy–Schwarz，$\mathrm{Cov}(W, w)^2 = \mathrm{Cov}(m, w)^2 \le \mathrm{Var}(m)\,\mathrm{Var}(w)$。当 $\mathrm{Var}(m) > 0$ 时，$w = a + bm$、$b \neq 0$ 取等号。这一最优性采用上方独立性设定。

以协变量为条件。 条件可拓展为 $\varepsilon_i \perp Z_i \mid X_i$，得到

$$\tau(x) = \frac{\mathrm{Cov}(Y_i, w(Z_i) \mid X_i = x)}{\mathrm{Cov}(W_i, w(Z_i) \mid X_i = x)}.$$

这启发我构建平均效应 $\tau = \mathbb{E}[\tau(X)]$ 的双重稳健估计量，以及 $\tau(\cdot)$ 的随机森林估计量。

在 $Y = a(X) + W\tau(X) + \varepsilon$、$E[\varepsilon \mid Z, X] = 0$ 且条件第一阶段非零时，比值等于 $\tau(x)$。无限制的个体异质性下，有效工具变量不必识别 CATE；适当单调性可以识别条件局部效应。

另一个有用的提醒：若 X_1, X_2 独立，

$$\begin{aligned}\mathrm{Var}(X_1X_2) = {} & \mathrm{Var}(X_1)\,\mathrm{Var}(X_2) \\ & + \mathbb{E}[X_2]^2\,\mathrm{Var}(X_1) + \mathbb{E}[X_1]^2\,\mathrm{Var}(X_2).\end{aligned}$$

星号补充：估计方程与 delta 方法。 若函数 ψ_i 满足 $\mathbb{E}[\psi_i(\theta)] = 0$，且通过下式估计 $\widehat{\theta}$：

$$\frac{1}{n}\sum_{i=1}^{n} \psi_i(\widehat{\theta}) = 0,$$

那么，在可微、导数非奇异及适当矩条件下，

$$\sqrt{n}(\widehat{\theta} - \theta) \Rightarrow \mathcal{N}(0, V), \qquad V = \frac{\mathrm{Var}(\psi_i(\theta))}{\mathbb{E}[\psi_i'(\theta)]^2}.$$

交叉拟合与可行估计

最优工具变量为 $w^*(z) = \mathbb{E}[W_i \mid Z_i = z]$。一般步骤为：

1. 拟合非参数的第一阶段回归，估计 $\mathbb{E}[W_i \mid Z_i = z]$，得到 $\widehat{w}(\cdot)$。
2. 用 $\widehat{w}(\cdot)$ 作为 (9.9) 中的工具变量，得到 $\widehat{\tau}_w$。

但当工具变量很多时，这会产生过拟合偏差。若用整份数据拟合 $\widehat{w}(Z_i)$，它未必独立于 ε_i：拟合工具变量可能继承 W_i 对 ε_i 的依赖。

我的过拟合例子。 设 $W_i = \alpha + \beta Z_i + \eta_i$，拟合值为 $\widehat{W}_i = \widehat{\alpha} + \widehat{\beta} Z_i$。原结构方程是 $Y_i = \gamma + \delta W_i + \varepsilon_i$；代入拟合处理后，

$$Y_i = \gamma + \delta\widehat{W}_i + \{\varepsilon_i + \delta(W_i - \widehat{W}_i)\}.$$

用拟合处理 $\widehat{W}_i$ 改写 $\longrightarrow$ 回到结构方程 $Y_i = \gamma + \delta W_i + \varepsilon_i$：残差也随之改变。

我的担心是：过拟合第一阶段可能把 W_i 中与 ε_i 相关的噪声学进去，并不能消除这种依赖。

如果 Z 是纯噪声，相关性条件就不成立。交叉拟合避免重复使用同一观测的噪声，却不能制造有效的第一阶段。

改用 K 折交叉拟合。用 $k(i)$ 表示观测 i 所属的折，

$$\widehat{\tau} = \frac{\widehat{\mathrm{Cov}}(Y_i, \widehat{w}^{(-k(i))}(Z_i))}{\widehat{\mathrm{Cov}}(W_i, \widehat{w}^{(-k(i))}(Z_i))}. \tag{9.13}$$

在所述采样设定下，对应的拟合工具变量独立于该观测的误差。特别地，如果 $\widehat{w}^{(-k(i))}(z)$ 对 $\mathbb{E}[W_i \mid Z_i = z]$ 均方一致，那么 (9.13) 与 (9.9) 的 oracle 版本渐近等价。将这个一致性写为

$$\lim_{n\to\infty} \mathbb{E}[(\widehat{w}_n - \mathbb{E}[W \mid Z])^2] = 0,$$

其中 n 为样本量。 在第一阶段不退化、矩条件适当且第一阶段均方一致时，交叉拟合估计具有 oracle 极限。独立性应条件于各自训练折理解；训练样本重叠并不使全部拟合观测彼此独立。

非参数工具变量回归

前面的模型对处理 W_i 是线性的：$Y_i = W_i\tau + \varepsilon_i$。

将模型推广为

$$Y_i = g(W_i) + \varepsilon_i, \qquad Z_i \perp \varepsilon_i, \qquad Y_i, W_i \in \mathbb{R}, \quad Z_i \in \mathcal{Z},$$

其中 g 是一般的光滑函数。

提醒： 不能直接将 Y_i 对 W_i 作非参数回归，因为

$$\mathbb{E}[Y_i \mid W_i = w] = g(w) + \mathbb{E}[\varepsilon_i \mid W_i = w],$$

而条件误差均值未必为零。

由于 $Z_i \perp \varepsilon_i$ 且 $\mathbb{E}[\varepsilon_i] = 0$，

$$\begin{aligned}\mathbb{E}[Y_i \mid Z_i = z] &= \mathbb{E}[g(W_i) + \varepsilon_i \mid Z_i = z] \\ &= \mathbb{E}[g(W_i) \mid Z_i = z] = \int_{\mathbb{R}} g(w) f(w \mid z)\, dw.\end{aligned} \tag{9.15}$$

其中 $f(w \mid z)$ 是给定 $Z_i = z$ 时 W_i 的条件密度。

学习步骤：

1. 用交叉拟合估计 $\widehat{f}(w \mid z)$。
2. 选择合适的函数类 $\mathcal{G}$，通过最小化损失估计 g：

$$\widehat{g} \in \arg\min_{g\in\mathcal{G}} \frac{1}{n}\sum_{i=1}^{n} \left\{ Y_i - \int_{\mathbb{R}} g(w)\widehat{f}^{(-k(i))}(w \mid Z_i)\, dw \right\}^2. \tag{9.16}$$

实际求解时，可用基函数展开逼近 g：

$$g_K(w) = \sum_{k=1}^{K} \beta_k \psi_k(w),$$

其中 ψ_k 是预先确定的基函数。随着 K 增大，g_K 对 g 的逼近更好。于是

$$\widehat{\beta} \in \arg\min_{\beta} \frac{1}{n}\sum_{i=1}^{n} \{Y_i - \widehat{m}^{(-k(i))}(Z_i)^{\mathsf{T}}\beta\}^2, \tag{9.17}$$

其分量为

$$\widehat{m}_k^{(-k(i))}(Z_i) = \int_{\mathbb{R}} \psi_k(w)\widehat{f}^{(-k(i))}(w \mid Z_i)\, dw.$$

我的理解：对 $g(\cdot)$ 的一致估计需要条件；积分方程 (9.15) 很复杂，而基展开 (9.17) 将它变成回归。还要付出正则化的代价，这与交叉拟合第一阶段 (9.13) 的思路相联系。

识别与正则化

令 $(Th)(z) = E[h(W) \mid Z = z]$。识别要求它在所选函数类上为单射：$Th = 0$ 蕴含 $h(W) = 0$ 几乎处处成立，即完备性。逆运算仍可能病态，因此要用筛维数或其他正则化控制不稳定性与逼近误差。

第 10 讲：局部平均处理效应

回顾第 9 讲的 IV 模型：

$$Y_i = \alpha + W_i\tau + \varepsilon_i, \quad \varepsilon_i \perp Z_i, \qquad W_i = Z_i\gamma + \eta_i. \tag{10.1}$$

当 Z_i 为二元变量时，

$$\begin{aligned}\tau &= \frac{\mathrm{Cov}(Y_i, Z_i)}{\mathrm{Cov}(W_i, Z_i)} \\ &= \frac{\mathbb{E}[Y_i \mid Z_i = 1] - \mathbb{E}[Y_i \mid Z_i = 0]}{\mathbb{E}[W_i \mid Z_i = 1] - \mathbb{E}[W_i \mid Z_i = 0]}.\end{aligned} \tag{10.2}$$

不依从情形下的处理效应

在存在不依从的 RCT 中，$Y_i \in \mathbb{R}$ 是通常的结果变量；$W_i \in \{0,1\}$ 是实际接受的处理，并未随机化；$Z_i \in \{0,1\}$ 是随机化的处理分配。

(10.1) 中的常数 τ 可能并不合适，而且是否接受处理可能与处理效应相关。定义潜在的处理接受状态 $W_i(0), W_i(1)$，满足 $W_i = W_i(Z_i)$ 以及 $Y_i = Y_i(W_i(Z_i))$。

IV 有效性假设为：

- **排除限制：** $Y_i(w,z) = Y_i(w)$。分配仅通过实际接受的处理影响结果。
- **外生性：** $\{Y_i(0), Y_i(1), W_i(0), W_i(1)\} \perp Z_i$。分配是随机的。
- **相关性：** $\mathbb{E}[W_i(1) - W_i(0)] \neq 0$。分配会影响是否接受处理。

有四种依从类型：

	$W_i(1) = 0$	$W_i(1) = 1$
$W_i(0) = 0$	从不接受者	依从者
$W_i(0) = 1$	反向依从者	总是接受者

假设没有反向依从者，即满足**单调性**：

$$W_i(1) \geq W_i(0) \quad \text{对每个} i.$$

于是

$$\begin{aligned}&\mathbb{E}[Y_i \mid Z_i = 1] - \mathbb{E}[Y_i \mid Z_i = 0] \\ &\quad = \mathbb{E}[Y_i(W_i(1)) \mid Z_i = 1] - \mathbb{E}[Y_i(W_i(0)) \mid Z_i = 0] \\ &\quad = \mathbb{E}[Y_i(W_i(1)) - Y_i(W_i(0))] \\ &\quad = \mathbb{E}[\mathbf{1}\{C_i = \text{complier}\}(Y_i(1) - Y_i(0))].\end{aligned}$$

若依从者存在，使用 Bayes 法则得到

$$\begin{aligned}\tau_{\text{LATE}} &= \frac{\mathbb{E}[Y_i \mid Z_i = 1] - \mathbb{E}[Y_i \mid Z_i = 0]}{\mathbb{E}[W_i \mid Z_i = 1] - \mathbb{E}[W_i \mid Z_i = 0]} \\ &= \mathbb{E}[Y_i(1) - Y_i(0) \mid C_i = \text{complier}]. \end{aligned} \tag{10.3}$$

这就是依从者平均处理效应。 还须假设 $0 < P(Z = 1) < 1$ 且依从者比例为正。由此识别依从者平均效应，一般并非总体 ATE。

我的蓝色补记。 当常数效应模型 (10.1) 不成立，并存在从不接受者、总是接受者、反向依从者等类型时，个体差值 $Y_i(1) - Y_i(0)$ 一般不可观测。尤其是，从不接受者永远不会被观测到 $W_i = 1$。总体 ATE 为 $\mathbb{E}[Y_i(1) - Y_i(0)]$，仅依从者的结果并不足以识别它。

供给与需求

对每个市场 $i = 1, \dots, n$，设供给曲线为 $S_i(p, z)$，需求曲线为 $Q_i(p, z)$，其中价格 $p \in \mathbb{R}$，工具变量 $z \in \{0, 1\}$。假设供给随价格连续且严格递增，需求连续且严格递减，并且两条曲线相交。均衡价格 P_i 是下式的唯一解：

$$S_i(P_i, Z_i) = Q_i(P_i, Z_i).$$

因此，Z_i 是 IV，P_i 是处理，$Q_i(P_i, Z_i)$ 是结果 Y_i。

$$Z_i \longrightarrow S_i \longrightarrow P_i \longrightarrow Q_i(P_i).$$

约束条件：

- 排除限制：对每个 p, z，$Q_i(p, z) = Q_i(p)$。
- 外生性：$\{Q_i(p), S_i(p, z)\} \perp Z_i$。
- 相关性：$\text{Cov}(P_i, Z_i) \neq 0$。
- 单调性：对所有相关的 p，$S_i(p, 1) \leq S_i(p, 0)$。

下面的普通积分公式假设需求在受影响的价格区间上绝对连续，并满足 Fubini 所需的可积性。我的进一步想法是：即使没有普通导数，单调需求也存在分布意义的导数。

$$\begin{aligned}\tau_{\text{LATE}} &= \frac{\mathbb{E}[Q_i \mid Z_i = 1] - \mathbb{E}[Q_i \mid Z_i = 0]}{\mathbb{E}[P_i \mid Z_i = 1] - \mathbb{E}[P_i \mid Z_i = 0]} \\ &= \frac{\displaystyle\int \mathbb{E}[Q_i'(p) \mid P_i(0) \leq p \leq P_i(1)] P[P_i(0) \leq p \leq P_i(1)]\, dp}{\displaystyle\int P[P_i(0) \leq p \leq P_i(1)]\, dp}. \end{aligned}$$

分母是总权重。

补充说明：分布导数

对仅单调的需求函数，导数是有符号测度 dQ_i，且 $Q_i(P_i(1)) - Q_i(P_i(0)) = \int_{(P_i(0), P_i(1)]} dQ_i$。这种解释包括普通导数密度未必捕捉的奇异连续变化。

推导。

$$\begin{aligned}
&\mathbb{E}[Q_i \mid Z_i = 1] - \mathbb{E}[Q_i \mid Z_i = 0] \\
&\quad = \mathbb{E}[Q_i(P_i(1)) \mid Z_i = 1] - \mathbb{E}[Q_i(P_i(0)) \mid Z_i = 0] \\
&\quad = \mathbb{E}[Q_i(P_i(1)) - Q_i(P_i(0))] \\
&\quad = \mathbb{E}\left[\int_{P_i(0)}^{P_i(1)} Q_i'(p)\,dp\right] \\
&\quad = \int \mathbb{E}[Q_i'(p) \mid P_i(0) \le p \le P_i(1)] P[P_i(0) \le p \le P_i(1)]\,dp.
\end{aligned}$$

Fubini：交换积分次序 $\longrightarrow$ $E[\int Q_i'(p)\,dp]$ 变成期望的积分。

阈值跨越与支付意愿

假设每个受试者都有不可观测的内生变量 U_i，满足

$$W_i = \mathbf{1}\{U_i \ge c(Z_i)\},$$

其中 $c(z)$ 是依赖工具变量的阈值函数。不失一般性，取 $U_i \sim \text{Unif}[0,1]$，于是

$$c(z) = 1 - P(W_i = 1 \mid Z_i = z).$$

这里使用 $U \perp Z$ 及有效截点 $c(z) \in [0,1]$。连续潜变量分布可以直接作均匀秩变换；含原子的分布需要另行论证。

IV 设定要求：

1. 潜在结果 $Y_i(0), Y_i(1)$ 满足 $Y_i = Y_i(W_i)$：工具变量不存在直通结果的路径。
2. $\{Y_i(0), Y_i(1), U_i\} \perp Z_i$：外生性。
3. $c(Z_i)$ 具有非平凡分布：相关性。
4. $c(z)$ 是 càdlàg（右连续且存在左极限）的非减函数。此时 W_i 随 Z_i 非增。 反转工具变量方向后，转换组就具有前面的依从者解释。两个 IV 协方差的符号同时反转，比值不变。

定义边际处理效应（MTE）

$$\tau(u) = \mathbb{E}[Y_i(1) - Y_i(0) \mid U_i = u]. \tag{10.6}$$

IV 的目标参数是 $\tau(u)$ 的加权平均。设 $Z_i \sim \mathcal{N}(0,1)$，密度为 φ。令 $S \subset \mathbb{R}$ 为 c 的不连续点集，并定义

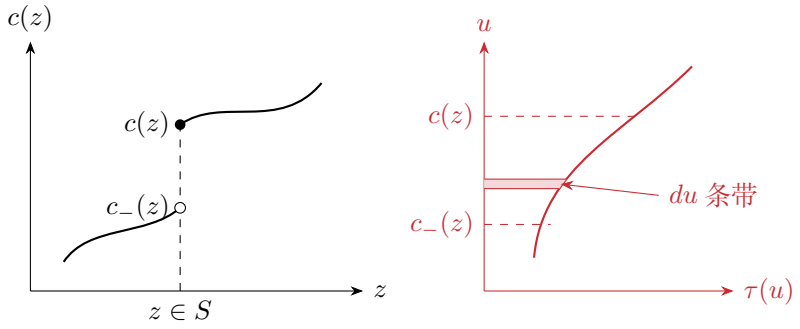
$$c_-(z) = \lim_{a \uparrow z} c(a).$$

若 c 仅有绝对连续变化和跳跃，表示式为

$$\tau_{\text{LATE}} = \frac{\displaystyle\sum_{z \in S} \left\{ \int_{c_-(z)}^{c(z)} \tau(u)\,du \right\} \varphi(z) + \int_{\mathbb{R}\setminus S} \tau(c(z)) c'(z) \varphi(z)\,dz}{\displaystyle\sum_{z \in S} (c(z) - c_-(z))\varphi(z) + \int_{\mathbb{R}\setminus S} c'(z)\varphi(z)\,dz}.$$

这将 IV 目标参数表示为边际处理效应的凸平均。

我对权重的解释。 图中画出 $c(z)$ 随 z 的变化，在左极限处画空心点，跳跃后的函数值处画实心点。跳跃位置属于 S。



在跳跃处，对从 $c_-(z)$ 到 $c(z)$ 的条带内的 $\tau(u)$ 积分，再乘以 $\varphi(z)$。在连续部分，取 $u = c(z)$ 处的处理效应，以 $c'(z)\varphi(z)$ 加权。

高斯密度因子 $\longrightarrow$ $\varphi(z)$。

$u = c(z)$ 处的处理效应 $\longrightarrow$ $\tau(c(z))$。

权重 $\longrightarrow$ $c'(z)\varphi(z)$。

分母累加总权重。$\varphi(z)$ 是密度值，而非 $P(Z = z)$。归一化前，跳跃权重是 $(c(z) - c_-(z))\varphi(z)$。第二幅草图在跳跃对应的 u 区间内标出窄的 du 阴影条带，使其贡献更直观。

关于单调性。 有界单调截点 c 具有有界变差，可以用 Stieltjes 测度 dc 描述。若进一步绝对连续，则

$$c(z) = c_0 + \int_{-\infty}^{z} c'(a)\, da,$$

且 $c' \geq 0$。仅有单调性时，普通导数积分可能遗漏跳跃或奇异连续变化。

单次跳跃、多次跳跃与连续阈值

例 1：一次跳跃。 设阈值除一次跳跃外保持常数：

$$c(z) = c_0 + \delta_1 \mathbf{1}\{z \geq z_1\},$$

各组为（反转工具变量方向后，中间组为依从者）

$$\begin{aligned} &\text{从不接受者：} && U_i < c_0, \\ &\text{转换组：} && c_0 \leq U_i < c_0 + \delta_1, \\ &\text{总是接受者：} && U_i \geq c_0 + \delta_1. \end{aligned}$$

当有 K 次跳跃时，

$$c(z) = c_0 + \sum_{k=1}^{K} \delta_k \mathbf{1}\{z \geq z_k\},$$

可得

$$\tau_{\text{LATE}} = \frac{\displaystyle\sum_{k=1}^{K} \mathbb{E}[\tau(U_i) \mid c_-(z_k) \leq U_i < c(z_k)](c(z_k) - c_-(z_k))\varphi(z_k)}{\displaystyle\sum_{k=1}^{K} (c(z_k) - c_-(z_k))\varphi(z_k)}.$$

这是各个转换层内平均处理效应的凸组合。权重依赖各层在 U 空间中的大小，以及 $\varphi(z_k)$。

例 2：连续阈值。 若 $c(z)$ 绝对连续，公式变为

$$\tau_{\text{LATE}} = \frac{\displaystyle\int_{\mathbb{R}} \tau(c(z))c'(z)\varphi(z)\,dz}{\displaystyle\int_{\mathbb{R}} c'(z)\varphi(z)\,dz}.$$

协方差推导为

$$\begin{aligned}\operatorname{Cov}(Y_i, Z_i) &= \operatorname{Cov}(Y_i(0) + (Y_i(1) - Y_i(0))W_i, Z_i)\\ &= \operatorname{Cov}((Y_i(1) - Y_i(0))W_i, Z_i)\\ &= \operatorname{Cov}((Y_i(1) - Y_i(0))\mathbf{1}\{U_i \geq c(Z_i)\}, Z_i)\\ &= \operatorname{Cov}(\tau(U_i)\mathbf{1}\{U_i \geq c(Z_i)\}, Z_i).\end{aligned}$$

定义

$$H(z) = \mathbb{E}[\tau(U_i)\mathbf{1}\{U_i \geq c(z)\}].$$

对标准高斯变量 Z_i，若 H 绝对连续并满足所需可积性，高斯分部积分给出

$$\operatorname{Cov}(H(Z_i), Z_i) = \mathbb{E}[H'(Z_i)].$$

我的疑问：分布导数。 $H'(z)$ 表示 $H(\cdot)$ 的分布导数吗？我尝试把跳跃与连续部分写在一起：

$$-H' \stackrel{?}{=} \begin{cases} \left\{\displaystyle\int_{c_-(z)}^{c(z)} \tau(u)\,du\right\}\delta_z, & z \in S,\\ \tau(c(z))c'(z), & \text{其他部分}. \end{cases}$$

这里想到的是位于 z 的 Dirac delta：质量集中于一点，总质量为 1。这个分段式只是我对测度与密度的尝试性简写。

补充推导：把分布导数写成测度

令 $F(u) = \int_0^u \tau(v)\,dv$。由于 $H = F(1) - F \circ c$，正确的整体表达是 $-dH = d(F \circ c)$。在跳跃 z 处，其质量为 $\int_{c_-(z)}^{c(z)} \tau(u)\,du$；在绝对连续部分，其密度为 $\tau(c(z))c'(z)$，还可能有奇异连续部分。Dirac delta 应作为测度或分布理解，并非普通函数。对右连续、非减、取值于 $[0,1]$ 的非平凡截点，假设 τ 可积且所需协方差矩存在，高斯分部积分给出

$$\tau_{\text{IV}} = \frac{\int_{\mathbb{R}} \varphi(z)\,d[F(c(z))]}{\int_{\mathbb{R}} \varphi(z)\,dc(z)}.$$

两个协方差各带一个负号，取比值时抵消。这保留了我对跳跃条带权重的理解，也包括普通积分可能遗漏的变化。[3]

估计边际处理效应

在 $c(z)$ 的光滑点处，

$$\tau(c(z)) = \frac{\dfrac{d}{dz}\mathbb{E}[Y_i \mid Z_i = z]}{\dfrac{d}{dz}P(W_i = 1 \mid Z_i = z)}. \tag{10.12}$$

假设这些导数性质良好，分子、分母可估计，而且分母非零。该式识别的潜在秩限于工具变量倾向得分覆盖的范围。目标点处需要 $c'(z) \neq 0$，且对 $F(u) = \int_0^u \tau(v)\,dv$ 有 $F'(c(z)) = \tau(c(z))$；τ 在该点连续是充分条件。

[3] 讲义第 10 讲脚注 4 的有界变差论述也需要这一测度解释。

证明。

$$\begin{aligned}\mathbb{E}[Y_i \mid c(Z_i) = c] &= \mathbb{E}[Y_i(0) + \mathbf{1}\{U_i \geq c\}(Y_i(1) - Y_i(0)) \mid c(Z_i) = c] \\ &= \mathbb{E}[Y_i(0) + \mathbf{1}\{U_i \geq c\}(Y_i(1) - Y_i(0))] \\ &= \mathbb{E}[Y_i(0)] + \int_c^1 \tau(u)\, du.\end{aligned}$$

最后一步由 Fubini 定理交换积分次序。因此

$$\tau(c) = -\frac{d}{dc}\mathbb{E}[Y_i \mid c(Z_i) = c].$$

由链式法则，

$$\frac{d}{dz}\mathbb{E}[Y_i \mid Z_i = z] = \frac{d}{dc}\mathbb{E}[Y_i \mid c(Z_i) = c]\Big|_{c=c(z)} c'(z).$$

由于 $U_i \sim \text{Unif}(0,1)$ 且独立于 Z_i，

$$c'(z) = -\frac{d}{dz}P(W_i = 1 \mid Z_i = z).$$

合并这些恒等式，就得到 (10.12)，结论成立。

第 11 讲：策略学习

研究如何分配处理，使收益最大。决策就是让一个人进入哪一组：处理组还是对照组。

处理策略是一个映射

$$\pi : \mathcal{X} \longrightarrow \{0,1\}.$$

特征为 $X_i = x$ 的个体，当且仅当 $\pi(x) = 1$ 时接受处理。目标是找到使期望效用最大的策略：

$$V(\pi) = \mathbb{E}[Y_i(\pi(X_i))].$$

（把 $Y_i = 1$ 视为好的结果。）对于策略类 Π，定义

$$\pi^* = \arg\max_{\pi' \in \Pi} V(\pi').$$

另一个策略的遗憾（regret）为

$$R(\pi) = \sup_{\pi' \in \Pi} V(\pi') - V(\pi).$$

这里的损失是 regret，而不是平方误差损失。目标是学到一个策略，并保证其最坏情况下的 regret 有上界，即 minimax regret 准则。

假设观测 $(X_i, Y_i, W_i) \in \mathcal{X} \times \mathbb{R} \times \{0,1\}$，$i = 1, \ldots, n$，独立同分布（IID），且满足

$$\{Y_i(0), Y_i(1)\} \perp W_i \mid X_i, \qquad Y_i = Y_i(W_i),$$

$$0 < \eta \leq e(X_i) \leq 1 - \eta < 1, \qquad e(x) = \mathbb{P}(W_i = 1 \mid X_i = x).$$

学到 $\hat{\pi}$ 后，令 $W_i = \hat{\pi}(X_i)$，希望 $Y_i = Y_i(\hat{\pi}(X_i))$ 尽可能大。**我的观察：**这样分配处理后，处理分配就没有随机性了，不能再用同样的方法从中学习因果效应。

仅凭实施确定性策略得到的数据会失去重叠性：$e(x) \in \{0,1\}$。此前的随机实验数据或额外假设仍可能支持因果学习。

通过经验最大化学习策略

一般地，

$$\widehat{\pi} = \arg\max_{\pi \in \Pi} \widehat{V}(\pi).$$

如果 $e(x)$ 已知，可以使用无偏的 IPW 估计：

$$\widehat{V}_{\mathrm{IPW}}(\pi) = \frac{1}{n}\sum_{i=1}^{n} \frac{\mathbf{1}\{W_i = \pi(X_i)\}Y_i}{\mathbb{P}[W_i = \pi(X_i) \mid X_i]}, \qquad \widehat{\pi}_{\mathrm{IPW}} = \arg\max_{\pi \in \Pi} \widehat{V}_{\mathrm{IPW}}(\pi).$$

直观地说，保留实际处理 W_i 与策略 $\pi(X_i)$ 一致的观测，再用分配概率的倒数对其结果加权。由无混杂性，

$$\begin{aligned}
\mathbb{E}[\widehat{V}_{\mathrm{IPW}}(\pi)] &= \mathbb{E}\left[\frac{\mathbf{1}\{W_i = \pi(X_i)\}Y_i(\pi(X_i))}{\mathbb{P}[W_i = \pi(X_i) \mid X_i]}\right] \\
&= \mathbb{E}\left[\mathbb{E}\left[\frac{\mathbf{1}\{W_i = \pi(X_i)\}}{\mathbb{P}[W_i = \pi(X_i) \mid X_i]}\middle| X_i\right]\mathbb{E}[Y_i(\pi(X_i)) \mid X_i]\right] \\
&= \mathbb{E}[Y_i(\pi(X_i))] = V(\pi).
\end{aligned}$$

指示变量除以其概率，条件期望等于 1。

$$\boxed{E\left[\frac{\mathbf{1}\{W_i = \pi(X_i)\}}{P[W_i = \pi(X_i) \mid X_i]}\middle| X_i\right]} = 1.$$

类比：ATE 的 IPW 估计量为何无偏。

$$\begin{aligned}
\mathbb{E}[\widehat{\tau}^*_{\mathrm{IPW}}] &= \mathbb{E}\left[\frac{W_iY_i}{e(X_i)} - \frac{(1-W_i)Y_i}{1-e(X_i)}\right] \\
&= \mathbb{E}\left[\frac{W_iY_i(1)}{e(X_i)} - \frac{(1-W_i)Y_i(0)}{1-e(X_i)}\right] \\
&= \mathbb{E}\left[\mathbb{E}\left[\frac{W_iY_i(1)}{e(X_i)}\middle| e(X_i)\right] - \mathbb{E}\left[\frac{(1-W_i)Y_i(0)}{1-e(X_i)}\middle| e(X_i)\right]\right] \\
&= \mathbb{E}[Y_i(1) - Y_i(0)].
\end{aligned}$$

因此它是 τ 的无偏估计。

将策略学习转化为加权分类

分解价值函数：

$$V(\pi) = \underbrace{\mathbb{E}[Y_i(0)]}_{E_0} + \mathbb{E}[(Y_i(1) - Y_i(0))\pi(X_i)].$$

我的理解：这里展示了基线结果 E_0，以及策略 $\pi(\cdot)$ 选择接受处理的那些人的处理效应所作的贡献。

用 $\tau(x)$ 表示 CATE，策略的优势为

$$\begin{aligned}
A(\pi) &= 2\mathbb{E}[Y_i(\pi(X_i))] - \mathbb{E}[Y_i(0) + Y_i(1)] \\
&= \mathbb{E}[(2\pi(X_i) - 1)\tau(X_i)].
\end{aligned}$$

$A(\pi)$ 是策略 $\pi(\cdot)$ 的 advantage。同一个 π^* 也使 $A(\pi)$ 在 Π 中最大。

改写 IPW：$\widehat{\pi}_{\mathrm{IPW}}$ 使下式最大，

$$\begin{aligned}
\widehat{A}_{\mathrm{IPW}}(\pi) &= 2\widehat{V}_{\mathrm{IPW}}(\pi) - \frac{1}{n}\sum_{i=1}^{n}\left\{\frac{W_iY_i}{e(X_i)} + \frac{(1-W_i)Y_i}{1-e(X_i)}\right\} \\
&= \frac{1}{n}\sum_{i=1}^{n}(2\pi(X_i) - 1)\left\{\frac{W_iY_i}{e(X_i)} - \frac{(1-W_i)Y_i}{1-e(X_i)}\right\}. \qquad (11.10)
\end{aligned}$$

对固定 π，这是优势的无偏估计。

这个无偏性结论针对固定策略，或由独立数据学得的策略；在同一样本上将估计值最大化后，无偏性未必保留。

记

$$\widehat{A}_{\mathrm{IPW}}(\pi) = \frac{1}{n}\sum_{i=1}^{n}(2\pi(X_i)-1)\Gamma_i^{\mathrm{IPW}}, \qquad \Gamma_i^{\mathrm{IPW}} = \frac{W_iY_i}{e(X_i)} - \frac{(1-W_i)Y_i}{1-e(X_i)}. \tag{11.11}$$

其中 Γ_i^{IPW} 就是 ATE 估计中使用的 IPW 得分：$\widehat{\tau}_{\mathrm{IPW}} = n^{-1}\sum_i \Gamma_i^{\mathrm{IPW}}$. **我的理解：** $\widehat{A}_{\mathrm{IPW}}(\pi)$ 与 ATE 的 IPW 估计量很像。当 $\pi(X_i)=1$ 时，我们“赚取”这个人的处理效应；当 $\pi(X_i)=0$ 时，我们“支付”这个人的处理效应。

为进行优化，写成

$$\widehat{A}_{\mathrm{IPW}}(\pi) = \frac{1}{n}\sum_{i=1}^{n}\underbrace{(2\pi(X_i)-1)\,\mathrm{sign}(\Gamma_i)}_{\text{分类目标}}\underbrace{|\Gamma_i|}_{\text{权重}\star}. \tag{11.12}$$

符号决定分类目标，$|\Gamma_i|$ 是权重。最大化优势等价于优化一个加权分类目标。实践中，常常通过最小化加权替代损失来学习。但估计可能不对。 参见 Wager（2020），*On regression tables for policy learning: Comment on a paper by Jiang, Song, Li and Zeng*。

精确得分等价于最小化加权分类错误率，因为 $(2\pi(X_i)-1)\Gamma_i = |\Gamma_i|[1-2\mathbf{1}\{\pi(X_i)\neq \mathbf{1}\{\Gamma_i>0\}\}]$。在受限策略类内，替代损失未必保持同一个最优解。

补充：复杂度与 regret 的收敛速度。 VC 维衡量 Π 的复杂度；查一下它的精确定义。若 $|Y_i|\le M$，$\eta \le e(X_i) \le 1-\eta$（于是得分有界），且 Π 的 Vapnik–Chervonenkis 维有限，则

$$R(\widehat{\pi}_{\mathrm{IPW}}) = O_P\left(\frac{M}{\eta}\sqrt{\frac{\mathrm{VC}(\Pi)}{n}}\right), \quad \widehat{\pi}_{\mathrm{IPW}} = \arg\max_{\pi\in\Pi}\widehat{A}_{\mathrm{IPW}}(\pi).$$

这是最优收敛速度。但是否也有超效率：固定 $\pi(x)$ 后，有 n 个观测时，收敛速度能否快于 $\sqrt{\mathrm{VC}(\Pi)/n}$?

这里是最坏情况下的学习速度。在较容易的分布下 regret 可以更快；估计固定策略的价值则是另一个问题。

策略学习的有效得分

有没有更好的学习方法？注意到

$$\begin{aligned} A(\pi) &= 2\mathbb{E}[Y_i(\pi(X_i))] - \mathbb{E}[Y_i(0)+Y_i(1)] \\ &= \mathbb{E}[Y_i(\pi(X_i))] - \mathbb{E}[Y_i(1-\pi(X_i))]. \end{aligned}$$

因此，$A(\pi)$ 就是在一个实验中，比较实施 $\pi(\cdot)$ 与实施其相反策略所得的 ATE。

Oracle IPW 可以使用，但并不有效。Oracle AIPW 估计量使用有效得分，达到半参数效率界：

$$\widehat{A}^*_{\mathrm{AIPW}}(\pi) = \frac{1}{n}\sum_{i=1}^{n}(2\pi(X_i)-1)\Gamma_i^*,$$

$$\Gamma_i^* = \mu_1(X_i)-\mu_0(X_i) + W_i\frac{Y_i-\mu_1(X_i)}{e(X_i)} - (1-W_i)\frac{Y_i-\mu_0(X_i)}{1-e(X_i)}.$$

进一步假设回归调整 $\widehat{\mu}_w(x)$ 和 $\widehat{e}(x)$ 都以 $o_P(n^{-1/4})$ 的速度一致。当 $n\to\infty$ 时，两个 nuisance 估计误差都是 $o_P(n^{-1/4})$。构造一个接近有效 oracle 的双重稳健估计量：

$$\widehat{A}_{\mathrm{AIPW}}(\pi) = \frac{1}{n}\sum_{i=1}^{n}(2\pi(X_i)-1)\widehat{\Gamma}_i,$$

$$\widehat{\Gamma}_i = \widehat{\mu}_1^{(-k(i))}(X_i) - \widehat{\mu}_0^{(-k(i))}(X_i) + W_i \frac{Y_i - \widehat{\mu}_1^{(-k(i))}(X_i)}{\widehat{e}^{(-k(i))}(X_i)} - (1 - W_i) \frac{Y_i - \widehat{\mu}_0^{(-k(i))}(X_i)}{1 - \widehat{e}^{(-k(i))}(X_i)}.$$

这同样是加权分类目标。若 Π 是 VC 类，则可行目标与 oracle 目标一致地渐近等价，差异比 $1/\sqrt{n}$ 更快趋于零：

$$\sqrt{n} \sup_{\pi \in \Pi} \left| \widehat{A}_{\text{AIPW}}(\pi) - \widehat{A}^*_{\text{AIPW}}(\pi) \right| \xrightarrow{P} 0. \tag{11.17}$$

这里使用 $L_2(P_X)$ 收敛速度、交叉拟合、固定且有限的 VC 维、有界结果，以及远离 0 和 1 的估计倾向概率。特别地，$\|\widehat{e} - e\|_2 \max_w \|\widehat{\mu}_w - \mu_w\|_2 = o_P(n^{-1/2})$。

续记：regret 与效率。 结合前面的结果与经验过程集中性质，可得

$$R(\widehat{\pi}_{\text{AIPW}}) = O_P\left(\sqrt{\frac{V^* \, \text{VC}(\Pi)}{n}}\right), \quad \widehat{\pi}_{\text{AIPW}} = \arg\max_{\pi \in \Pi} \widehat{A}_{\text{AIPW}}(\pi),$$

$$V^* = \mathbb{E}[\tau^2(X_i)] + \mathbb{E}\left[\frac{\text{Var}(Y_i(0) \mid X_i)}{1 - e(X_i)}\right] + \mathbb{E}\left[\frac{\text{Var}(Y_i(1) \mid X_i)}{e(X_i)}\right].$$

Athey 和 Wager（2017 年预印本），*Policy learning with observational data*。

上式的 V^* 分解。 $\longrightarrow$ 当处理效应刚刚从噪声中显现出来时，这个界是最优的。

不太对…… 这里 $V^* = E[(\Gamma_i^*)^2]$，且 $\text{Var}((2\pi(X) - 1)\Gamma_i^*) = V^* - A(\pi)^2$。最优性针对模型内的最坏情况，并不是对每个分布都成立的逐点结论。

策略类的作用

从非参数模型出发：$\mu_w(x)$ 和 $e(x)$ 可以是任意函数。此时 Bayes 最优处理分配规则是

$$\pi_{\text{Bayes}}(x) = \mathbf{1}\{\tau(x) > 0\}.$$

不过，我们的目标是在给定的策略类 Π 中求解，不一定要逼近这个 Bayes 规则。例如，Π 可以包含线性决策规则、k-稀疏决策规则，或深度为 ℓ 的决策树。不要求 $\pi_{\text{Bayes}} \in \Pi$。

原因：

1. 使用 X_i 是为了使无混杂性假设合理：$\{Y_i(0), Y_i(1)\} \perp W_i \mid X_i$。掌握更丰富且合适的处理前混杂变量，可以让这个假设更可信；任意增加变量，例如 collider，则未必如此。为了可靠建模，最好使用更丰富的特征，以及灵活的非参数模型来估计 $e(x)$ 和 $\mu_w(x)$。
2. 策略有具体形式，也受现实限制：某些特征可能不能用于决策；资源或处理预算可能有限；$\pi(\cdot)$ 的函数形式也可能受限。

第 12 讲：动态策略评估

这一主题与强化学习有关。我们评估动态策略，也就是随时间改变的策略。

有 n 个 IID 个体 $i = 1, \ldots, n$，以及时点 $t = 1, \ldots, T$。每个时点观测随时间变化的协变量 X_{it} 和处理 $W_{it} \in \{0, 1\}$。在最后一个时点 T，还观测结果 $Y_i \in \mathbb{R}$。

为了体现动态结构，每个随时间变化的观测都可能依赖之前的全部处理。对每个 $X_{it} \in \mathcal{X}_t$，定义 2^{t-1} 个潜在取值 $X_{it}(w_{1:t-1})$，且

$$X_{it} = X_{it}(W_{i,1:t-1}).$$

最终结果有 2^T 个潜在结果 $Y_i(w_{1:T})$，且

$$Y_i = Y_i(W_{i,1:T}).$$

类似地，写为 $W_{it} = W_{it}(W_{i,1:t-1})$：第 t 期的处理依赖已观测的协变量历史 $X_{i,1:t}$ 和之前的处理取值。

我的直觉。 想象对一个人按 $1,\dots,T$ 各期逐列观测，记录协变量 $X_{i1}, X_{i2}, \dots$ 和决策 $W_{i1}, W_{i2}, \dots$。每一期做一个决策。第 t 期的决策依赖截至 $t-1$ 期发生的事情，最后有 2^T 个可能的结果。

$X_{i1}, W_{i1};\ X_{i2}, W_{i2};\ \dots;\ X_{iT}, W_{iT}$ $\longrightarrow$ 2^T 个潜在最终结果 $Y_i(w_{1:T})$

有两类目标参数：

1. 评估一个固定处理序列 $w \in \{0,1\}^T$：

$$V(w) = \mathbb{E}[Y_i(w)].$$

2. 评估一个策略，其决策规则 π_t 将可用历史映射到 $\{0,1\}$：

$$V(\pi) = \mathbb{E}\big[Y_i\big(\pi_1(X_{i1}),\ \pi_2(X_{i1}, \pi_1(X_{i1}), X_{i2}(\pi_1(X_{i1}))), \dots\big)\big]. \tag{12.2}$$

第二次决策依赖协变量历史和先前的处理取值。 $\longrightarrow$ 式 (12.2) 中 π_2 的参数。

这两个问题都用潜在处理序列定义目标参数，包括对生成数据的处理分配分布实施干预。

考虑两种自然的无混杂性假设：

1. **序贯无混杂性 / 序贯可忽略性（sequential ignorability）：**

$$\{\text{时点}t\text{ 之后的潜在结果}\} \perp W_{it} \mid \{\text{时点}t\text{ 的历史}\}.$$

   在每一期，给定截至该期收集的数据，处理分配不存在混杂。
2. **完全随机化：**

$$\{\text{所有潜在结果}\} \perp W_{i,1:T}.$$

   对这里的自适应设计，这不合理。

识别还要求一致性，以及在 π 可到达的每段历史上，目标动作的概率为正。对整个处理序列完全随机化是另一种可行设计，但通常不描述这里的自适应分配。

处理与混杂因素之间的反馈

一个可能出问题的例子。所有个体都有 $X_{i1} = 0$，且

$$\mathbb{P}(W_{i1} = 1) = 0.5, \qquad \mathbb{P}(W_{i2} = 1 \mid X_{i2} = 1) = 0.8, \qquad \mathbb{P}(W_{i2} = 1 \mid X_{i2} = 0) = 0.4.$$

比较始终处理与始终不处理，目标为 $\tau = \mathbb{E}[Y(1,1) - Y(0,0)]$。分析得到

$$\mathbb{E}[Y_i \mid W_{i1} = 0] = \mathbb{E}[Y_i \mid W_{i1} = 1],$$

$$\mathbb{E}[Y_i \mid W_{i2} = 0, W_{i1} = w_1, X_{i2} = x] = \mathbb{E}[Y_i \mid W_{i2} = 1, W_{i1} = w_1, X_{i2} = x]$$

对每个 w_1, x 都成立。

第一种错误是忽略自适应采样，直接使用通常的均值差：

$$\widehat{\tau} = \widehat{\mathbb{E}}[Y \mid W_1 = W_2 = 1] - \widehat{\mathbb{E}}[Y \mid W_1 = W_2 = 0].$$

第二种错误是按 X_{i2} 分层：

$$\begin{aligned}\widehat{\tau}_0 &= \mathbb{E}[Y \mid W_1 = W_2 = 1, X_{i2} = 0] - \mathbb{E}[Y \mid W_1 = W_2 = 0, X_{i2} = 0],\\ \widehat{\tau}_1 &= \mathbb{E}[Y \mid W_1 = W_2 = 1, X_{i2} = 1] - \mathbb{E}[Y \mid W_1 = W_2 = 0, X_{i2} = 1],\\ \widehat{\tau} &= \frac{n_0\widehat{\tau}_0 + n_1\widehat{\tau}_1}{n_0 + n_1}.\end{aligned}$$

为什么会想这样做？我们知道形如 $Y_i(\cdots) \perp W_{i2} \mid X_{i2}$ 的结论，但这种分层实际需要

$$Y_i(\cdots) \perp (W_{i1}, W_{i2}) \mid X_{i2}.$$

考虑三类人：

类型	$W_{i1} = 0$ 时的 X_{i2}	$W_{i1} = 1$ 时的 X_{i2}
稳定型（1）	0	0
响应型（2）	1	0
急性型（3）	1	1

由一致性，$W_1 = 1, X_{i2} = 0$ 组包含第（1）、（2）类，而 $W_1 = 0, X_{i2} = 0$ 组仅包含第（1）类；$W_1 = 1, X_{i2} = 1$ 组包含第（3）类，而 $W_1 = 0, X_{i2} = 1$ 组包含第（2）、（3）类。因此，即使实验是序贯随机化的，这样分层也不能控制混杂。

序贯可忽略性下的序贯推断

简单分层不起作用，便直接专注于估计 $V(\pi)$。定义过滤族

$$\mathcal{F}_t = \sigma(X_1, W_1, X_2, W_2, \ldots, W_{t-1}, X_t),$$

它包含选择第 t 期处理之前的所有可用信息。用 $\mathbb{E}_\pi$ 表示按照策略 π 分配处理时的期望。于是 (12.2) 变为 $V(\pi) = \mathbb{E}_\pi[Y]$。

定义价值函数

$$V_{\pi,t}(X_1, W_1, \ldots, W_{t-1}, X_t) = \mathbb{E}_\pi[Y \mid \mathcal{F}_t].$$

这个函数衡量：从 $\mathcal{F}_t$ 所代表的状态开始遵循 π，预计会获得的回报。策略 π 的整体价值为 $V_{\pi,0}$。

由塔式法则，

$$\begin{aligned}&\mathbb{E}_\pi[V_{\pi,t+1}(X_1, W_1, \ldots, W_t, X_{t+1}) \mid \mathcal{F}_t]\\ &\quad= \mathbb{E}_\pi[\mathbb{E}_\pi[Y \mid \mathcal{F}_{t+1}] \mid \mathcal{F}_t]\\ &\quad= \mathbb{E}_\pi[Y \mid \mathcal{F}_t] = V_{\pi,t}(X_1, W_1, \ldots, W_{t-1}, X_t).\end{aligned} \tag{12.6}$$

我的理解：即当已知 $\mathcal{F}_t$，从 t 到 $t+1$，我以后的预期一直不变。把它联系到“贝尔曼方程”：

$$V(s) = R(s) + \gamma \sum_{s'} P(s' \mid s, a) V(s').$$

这是与 Bellman 方程的类比：固定确定性策略时取 $a = \pi(s)$。基于完整历史的塔式恒等式本身不需要 Markov 假设或折扣因子。

若已有 $V_{\pi,t+1}$ 的好估计，就设法得到 $V_{\pi,t}$ 的好估计，一直向前回溯，直到恢复 $V(\pi)$。

记 $X_{T+1} = Y$。联合分布可分解为

$$P_\pi(X_1, W_1, \ldots, X_T, W_T, Y) = P_\pi(X_1) \prod_{t=1}^{T} P_\pi(W_t \mid \mathcal{F}_t) P_\pi(X_{t+1} \mid \mathcal{F}_t, W_t).$$

无混杂性意味着：分解中非处理项不依赖于策略，

$$P_\pi(X_1) = P(X_1), \qquad P_\pi(X_{t+1} \mid \mathcal{F}_t, W_t) = P(X_{t+1} \mid \mathcal{F}_t, W_t), \quad \text{对所有} \pi.$$

处理对后续协变量的影响与选择处理的策略无关。 $\longrightarrow$ 不变的转移项 $P(X_{t+1} \mid \mathcal{F}_t, W_t)$。

逆倾向概率加权

为了把 (12.6) 用于 off-policy 数据，需要改变测度：实际数据并不是由 $\pi(\cdot)$ 生成的。

$$\begin{aligned} V_{\pi,t} &= \mathbb{E}_\pi[V_{\pi,t+1} \mid \mathcal{F}_t] \\ &= \mathbb{E}\left[\frac{P_\pi(W_t, X_{t+1} \mid \mathcal{F}_t)}{P(W_t, X_{t+1} \mid \mathcal{F}_t)} V_{\pi,t+1} \middle| \mathcal{F}_t\right] \\ &= \mathbb{E}\left[\frac{P_\pi(W_t \mid \mathcal{F}_t) P_\pi(X_{t+1} \mid \mathcal{F}_t, W_t)}{P(W_t \mid \mathcal{F}_t) P(X_{t+1} \mid \mathcal{F}_t, W_t)} V_{\pi,t+1} \middle| \mathcal{F}_t\right] \\ &= \mathbb{E}\left[\frac{\mathbf{1}\{W_t = \pi_t(\ldots, X_t)\}}{P[W_t = \pi_t(\ldots, X_t) \mid \mathcal{F}_t]} V_{\pi,t+1} \middle| \mathcal{F}_t\right]. \end{aligned}$$

从观测策略换到 π，消去转移项。 $\longrightarrow$ 两个转移项相消。

对每个 $t = 1, \ldots, T$ 都进行测度变换。由于

$$V(\pi) = \mathbb{E}[V_{\pi,1}(X_1)],$$

$$V_{\pi,1}(X_1) = \mathbb{E}\left[\frac{\mathbf{1}\{W_1 = \pi_1(X_1)\}}{P[W_1 = \pi_1(X_1) \mid \mathcal{F}_1]} V_{\pi,2}(X_1, W_1, X_2) \middle| \mathcal{F}_1\right],$$

反复代入，最后留下 $V_{\pi,T+1} = \mathbb{E}_\pi[Y \mid \mathcal{F}_{T+1}] = Y$，从而得到

$$V(\pi) = \mathbb{E}\left[\left\{\prod_{t=1}^{T} \frac{\mathbf{1}\{W_t = \pi_t(\ldots, X_t)\}}{P[W_t = \pi_t(\ldots, X_t) \mid \mathcal{F}_t]}\right\} Y\right].$$

这里需要以 $\mathcal{F}_1$ 为条件吗？ $\longrightarrow$ 匹配概率 $P[W_1 = \pi_1(X_1) \mid \mathcal{F}_1]$。

需要：分母必须以 $\mathcal{F}_1$ 为条件。$\pi_1(X_1)$ 随历史变化时，仅有 W_1 与 X_1 独立，并不能保证匹配概率不变。

IPW 估计量为

$$\widehat{V}_{\mathrm{IPW}}(\pi) = \frac{1}{n} \sum_{i=1}^{n} \gamma_{iT}(\pi) Y_i, \qquad \gamma_{it}(\pi) = \gamma_{i,t-1}(\pi) \frac{\mathbf{1}\{W_{it} = \pi_t(\ldots, X_{it})\}}{P[W_{it} = \pi_t(\ldots, X_{it}) \mid \mathcal{F}_{it}]}.$$

递推的初值为 $\gamma_{i0}(\pi) = 1$。

我的理解： 对符合 π 的结果取平均，用 IPW 去除已观测的时变变量造成的混杂影响。如果权重，即每一期的条件分配概率，都是已知的，那么 $\widehat{V}_{\mathrm{IPW}}$ 无偏。

向后递推的回归调整

利用 (12.6) 与序贯无混杂性，从后向前迭代。在 $t = T$ 时，

$$\begin{aligned} V_{\pi,T}(X_1, W_1, \ldots, X_T) &= \mathbb{E}_\pi[Y \mid \mathcal{F}_T] \\ &= \mathbb{E}_\pi[Y \mid \mathcal{F}_T, W_T = \pi_T(X_1, W_1, \ldots, X_T)] \\ &= \mathbb{E}[Y \mid \mathcal{F}_T, W_T = \pi_T(X_1, W_1, \ldots, X_T)]. \end{aligned}$$

直接用非参数回归学习 $\widehat{V}_{\pi,T}$。给定下一期价值函数的合理估计，

$$V_{\pi,t}(X_1, W_1, \ldots, X_t) \approx \mathbb{E}[\widehat{V}_{\pi,t+1}(\ldots, X_{t+1}) \mid \mathcal{F}_t, W_t = \pi_t(\ldots, X_t)]. \tag{12.12}$$

继续向前回溯，直到得到 $V(\pi)$ 的估计。

与 IPW 不同，需要量化回归误差在向后递推中如何传播。 $\longrightarrow$ Q-learning

上面的递推评估固定策略；最优 Q-learning 还需要对动作取最大。两者都有误差传播的问题。

双重稳健估计量

现在同时有 IPW 和回归两种方法。式 (12.12) 给出价值估计 $\widehat{V}_{\pi,1}(X_1)$，于是

$$\widehat{V}_{\mathrm{REG}}(\pi) = \frac{1}{n}\sum_{i=1}^{n} \widehat{V}_{\pi,1}(X_{i1}).$$

向后回归 (12.12) $\longrightarrow$ $\widehat{V}_{\pi,1}$，再取 $n^{-1}\sum_i \widehat{V}_{\pi,1}(X_{i1})$

如果相比 $\widehat{V}_{\pi,1}$ 更相信 $\widehat{V}_{\pi,2}$，就用后者给前者去偏：

$$\widehat{V}(\pi) = \frac{1}{n}\sum_{i=1}^{n}\left[\widehat{V}_{\pi,1}(X_{i1}) + \gamma_{i1}(\pi)\{\widehat{V}_{\pi,2}(X_{i1}, W_{i1}, X_{i2}) - \widehat{V}_{\pi,1}(X_{i1})\}\right].$$

权重 γ_{i1}；修正项。 $\longrightarrow$ $\gamma_{i1}(\widehat{V}_{\pi,2} - \widehat{V}_{\pi,1})$

$$\widehat{V}_{\mathrm{AIPW}}(\pi) = \frac{1}{n}\sum_{i=1}^{n}\left[\gamma_{iT}(\pi)Y_i + \sum_{t=1}^{T}\{\gamma_{i,t-1}(\pi) - \gamma_{it}(\pi)\}\widehat{V}_{\pi,t}(X_{i1},\ldots,X_{it})\right].$$

这将非动态情形的 AIPW 推广到了动态情形。

不断修正，直到 $V_{\pi,T+1} = Y$。 $\longrightarrow$ 上面的完整序贯 AIPW 估计量。

哪些条件保证序贯 AIPW 估计量无偏?

补充推导：序贯双重稳健性

设 q_t 是固定的或用独立数据训练的价值函数，$q_{T+1} = Y$，且 $\gamma_0 = 1$。被平均的单项可写为

$$q_1 + \sum_{t=1}^{T}\gamma_t(q_{t+1} - q_t).$$

如果每一期的处理概率都正确，对任意 q_t，加权期望都会通过望远镜消去得到 $E_\pi[Y]$，不需要回归无偏。如果每个 $q_t = V_{\pi,t}$，在目标动作下每个残差的条件均值都为零，此时可容许正的、可预测的倾向概率模型。仅仅要求拟合回归在边际上无偏并不足够，尤其是重复使用同一批观测时。对估得的 nuisance 作渐近论断，通常还需一致性和乘积收敛速度条件。参见 Jiang 和 Li（2016）。

第 13 讲：结构方程建模

SEM 指结构方程模型。回顾前面的方程 $Y_i = \alpha + W_i\tau + \varepsilon_i$：设 $W_i = w$，则观测到 $Y_i(W_i = w) = \alpha + w\tau + \varepsilon_i$。

非参数 SEM

设 $(X_1,\ldots,X_p)$ 是 p 个随机变量，联合分布为 P。假设 P 可以用有向无环图（DAG）G 表示，即

$$P(X_1,\ldots,X_p) = \prod_{j=1}^{p} P(X_j \mid \mathrm{pa}_j), \tag{13.2}$$

其中 pa_j 是图 G 中 X_j 的父节点集合。等价地，

$$\mathrm{pa}_j = \{X_i : E_{ij} = 1\},$$

E_{ij} 表示是否存在边 $X_i \to X_j$。进一步假设存在确定性函数 f_j，$j = 1, \ldots, p$，使得

$$X_j = f_j(\mathrm{pa}_j, \varepsilon_j), \qquad \varepsilon_j \sim F_j, \quad \text{相互独立}. \tag{13.3}$$

SEM / DAG 用父节点和噪声来规定每个节点。

即使上游父节点的取值改变，$f_j(\cdot)$ 也不改变。 $\longrightarrow$ $X_j = f_j(\mathrm{pa}_j, \varepsilon_j)$

这样有了具体含义：f_j 可以看作给定父节点时 X_j 的分布索引。

因果查询从外部设置某些节点的取值，考察其他节点的分布怎样改变。对不相交的节点集 $W, Y \subset X$，把设置 $W = w$ 对 Y 的影响写为

$$P[Y \mid \mathrm{do}(W = w)].$$

在 (13.3) 中，删除对应于 W 的方程，并将其他方程中的 W 替换为 w。对 X_j 的干预，对离散变量，截断分解为

$$P[X \mid \mathrm{do}(X_j = x_j)] = \begin{cases} \dfrac{P[X]}{P[X_j = x_j \mid \mathrm{pa}_j]}, & X_j = x_j, \\ 0, & \text{其他情况}. \end{cases}$$

1? $\longrightarrow$ 分母 $P[X_j = x_j \mid \mathrm{pa}_j]$

被强制设置的节点在 x_j 处的新概率质量是 1。分母的作用是移除旧的观测机制，不能把这个分母换成 1。

Do-calculus：分离与图的修改

对互不相交的节点集 X, Y, Z，考虑一条连接 X 中某节点与 Y 中某节点的无向路径 p。若路径中存在节点 W 满足下列任一条件，路径就被 Z 阻断：

1. W 是路径 p 上的 collider，且 W 本身及其任何后代都不在 Z 中；或
2. W 不是路径 p 上的 collider，且 $W \in Z$。

两幅路径示意图如下（实线箭头是因果边；虚线箭头连接批注）：



当 Z 阻断两个节点集之间的每条路径时，才称它将二者 d-分离。

若 Z 将 X 和 Y d-分离，则 (13.2) 推出 $X \perp Y \mid Z$，记为

$$(X \perp Y \mid Z)_G.$$

图的记号：

- $G_{\overline{X}}$：删除指向 X 的入边。
- $G_{\underline{X}}$：删除从 X 出发的出边。
- $G_{\underline{X}\overline{Z}}$：删除从 X 出发的边，以及指向 Z 的边。

三条规则

$\mathrm{do}(X = x)$ 删除入边，所以在 X 上方加横线。对互不相交的节点集 X, Y, Z, W：

1. **观测的插入 / 删除**。若
$$(Y \perp Z \mid X, W)_{G_{\overline{X}}},$$
则
$$P[Y \mid \mathrm{do}(X = x), Z = z, W = w] = P[Y \mid \mathrm{do}(X = x), W = w].$$
2. **干预与观测的交换**。若
$$(Y \perp Z \mid X, W)_{G_{\overline{X}\underline{Z}}},$$
则
$$P[Y \mid \mathrm{do}(X = x), \mathrm{do}(Z = z), W = w] = P[Y \mid \mathrm{do}(X = x), Z = z, W = w].$$
3. **干预的插入 / 删除**。若
$$(Y \perp Z \mid X, W)_{G_{\overline{X}\overline{Z(W)}}},$$
其中 $Z(W)$ 是 Z 中在 $G_{\overline{X}}$ 内不属于任何 W 节点之祖先的那些节点，则
$$P[Y \mid \mathrm{do}(X = x), \mathrm{do}(Z = z), W = w] = P[Y \mid \mathrm{do}(X = x), W = w].$$

我的简记。

共同的 $\mathrm{do}(X = x)$，以及额外的上横线 / 下横线。 $\longrightarrow$ 上面的三条 do-calculus 规则。

三个式中都有 $\mathrm{do}(X = x)$；$\overline{X}$ 提供 $\mathrm{do}(X = x)$ 条件。之后，在相应分离条件成立时，删掉 Z 的出边，就可以把 “do Z” 换成 “control Z”；删掉 $Z(W)$ 的入边，则 “do Z” 相当于没 do。$Z(W)$ 是 Z 中不具有上述被排除的 W 祖先关系的部分。

反复使用 do-calculus，将因果查询化简为关于 P 的可观测查询：表达式中不再有 do 算子，只依赖观测到的随机变量。Do-calculus 是完备的：如果无法把某个因果查询化为这样的观测表达式，那么在给定的 SEM 框架下，该查询就不能非参数识别。

完备性说的是：在指定因果模型和可观测变量集合中，不存在任何有效化简。某次尝试失败本身不能证明不可识别。调整公式还需要相应的支持条件。

例 1：后门准则

取互不相交的节点集 X, Y, W，查询 $P[Y \mid \mathrm{do}(W = w)]$。假设 X 不包含 W 的任何后代，并且删除 W 的出边后，X 将 W 与 Y d-分离：
$$(Y \perp W \mid X)_{G_{\underline{W}}}. \tag{13.8}$$
则
$$\begin{aligned} P[Y \mid \mathrm{do}(W = w)] &= \sum_x P[X = x \mid \mathrm{do}(W = w)] P[Y \mid X = x, \mathrm{do}(W = w)] \\ &= \sum_x P[X = x] P[Y \mid X = x, \mathrm{do}(W = w)] \\ &= \sum_x P[X = x] P[Y \mid X = x, W = w]. \end{aligned} \tag{13.9}$$

第二个等号使用了 X 不在 W 下游的事实；最后一个等号使用规则 2。第一次替换与 $(X \perp W)_{G_{\overline{W}}}$ 联系起来。

我对图条件的理解。 把 W 和 Y 看成单个节点。删除 W 的出边，就去掉了它对 Y 的下游因果影响；剩下的依赖关系，就是调整集合必须阻断的部分。若 X 阻断 W 与 Y 之间所有指向 W 的路径，就阻断了后门路径。

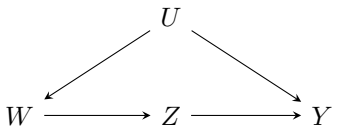
假设 W 和 Y 是单个节点，而且在 G 中，W 除了 Y 以外没有其他后代。剪掉 W 的出边，就去掉其下游影响。这时 (13.8) 变为

$$F_Y(w) \perp W \mid X, \qquad F_Y(w) = f_Y(w, X, \varepsilon_Y). \tag{13.10}$$

从图上推断；一个具体的条件独立论证。 $\longrightarrow$ 式 (13.10) 中的 $F_Y(w) \perp W \mid X$

在 $X_j = f_j(\mathrm{pa}_j, \varepsilon_j)$ 中，除 w 以外的因素都还没有被指定。

例 2：前门准则



我们要得到 $P[Y \mid \mathrm{do}(W = w)]$。由于 U 不可观测，不能使用 $X = U$ 作后门调整。但假设 Z 完全中介了 W 对 Y 的影响，并且不受 U 影响。

$$\begin{aligned} P[Y \mid \mathrm{do}(W = w)] &= \sum_z P[Z = z \mid \mathrm{do}(W = w)] P[Y \mid Z = z, \mathrm{do}(W = w)] \\ &= \sum_z P[Z = z \mid W = w] P[Y \mid Z = z, \mathrm{do}(W = w)]. \end{aligned}$$

W 与 Z 之间没有后门路径。 $\longrightarrow$ Z 对应的项中，将 $\mathrm{do}(W = w)$ 换为 $W = w$。

接着，

$$\begin{aligned} P[Y \mid Z = z, \mathrm{do}(W = w)] &= P[Y \mid \mathrm{do}(Z = z), \mathrm{do}(W = w)] && \text{（规则 2）} \\ &= P[Y \mid \mathrm{do}(Z = z)] && \text{（规则 3）} \\ &= \sum_{w'} P[W = w'] P[Y \mid Z = z, W = w'] && \text{（后门）}. \end{aligned}$$

合并各步，得到

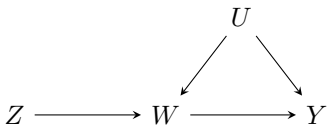
$$P[Y \mid \mathrm{do}(W = w)] = \sum_z P[Z = z \mid W = w] \sum_{w'} P[W = w'] P[Y \mid Z = z, W = w']. \tag{13.11}$$

$W \to Y$ 的整体效应。 $\longrightarrow$ $W \to Z$：$P(Z = z \mid W = w)$；$Z \to Y$：$\sum_{w\prime} P(w\prime) P(Y \mid z, w\prime)$

我的观察： 虽然这里直接描述的是 $\mathrm{do}(W = w)$ 干预，仍然需要对观测分布 $P[W = w']$ 积分。

即使干预 W，也需要对观测分布积分。 $\longrightarrow$ 式 (13.11) 中的 $P[W = w']$ 项。

例 3：工具变量



希望估计 $P[Y \mid \mathrm{do}(W = w)]$。在这张图里，仅靠 do-calculus 不能识别完整的干预分布；工具变量并未消除 W 与 Y 之间的未观测混杂。

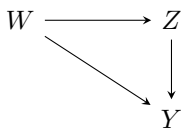
对 LATE 分析，仅有图还不够；单调性是额外的假设。即使这样，也可能只能识别 LATE 等非标准因果量。而把单调性插入 SEM 本身也很复杂。

SEM 与潜在结果

在简单的双节点图 $W \to Y$ 中，两种表述相同：潜在结果 $Y_i(w)$ 与 SEM 中的 $f_Y(w, \varepsilon_Y)$ 可以一一映射。

更一般地，两种表述有何不同？潜在结果记号问的是：若将指定变量设为某些取值，Y 会是多少。SEM 更灵活，可以表达嵌套操作。对于同时包含 $W \to Z \to Y$ 和 $W \to Y$ 的图，定义

$$Z(w) := f_Z(w, \varepsilon_Z).$$



嵌套反事实为

$$Y(0, Z(1)) = f_Y\big(w = 0, z = f_Z(w = 1, \varepsilon_Z), \varepsilon_Y\big).$$

不同的潜在设置可以放在一起讨论；Potential Outcome 不作图也能表达吗？

SEM 能识别这种嵌套操作的因果效应吗？这种额外能力是缺陷，还是说更弱的潜在结果模型过于受限？

可识别？ $\longrightarrow$ 嵌套反事实 $Y(0, Z(1))$。

潜在结果也可用 $Y(0, Z(1))$ 表达它；仅仅定义这个嵌套变量并不需要画图。识别依赖实质性假设，而不是记号的选择。

若图中节点均可观测、结构误差相互独立且支持充分，则 $E[Y(0, Z(1))] = \int E[Y \mid W = 0, Z = z]\, dP(Z = z \mid W = 1)$。这里使用了该 SEM 提供的跨世界独立性；中介与结果之间的潜在混杂或更弱的假设可能使它失效。

第 14 讲：自适应实验

自适应实验动态调整实验设计。此前的固定实验在 IID 框架下进行，而这一假设有时过于严格。

设定与记号

有动作 $k = 1, \ldots, K$ 和受试者 $t = 1, \ldots, T$。不同受试者的潜在结果独立同分布。记

$$Y_t(k) \sim F_k, \qquad Y_t = Y_t(W_t), \qquad \mu_k = \mathbb{E}[Y_t(k)].$$

W_t 是为第 t 个受试者选择的动作，F_k 是臂 k 的潜在结果分布，μ_k 是其均值。定义 regret：

$$R_T = \sum_{t=1}^{T} (\mu^* - \mu_{W_t}), \qquad \mu^* = \sup_{1 \le k \le K} \mu_k.$$

μ^* 是所有可用动作中最大的期望奖励。Regret 衡量：相较于始终选择最优动作，选择当前动作序列损失了多少期望奖励。

定义

$$n_{kt} = \sum_{j=1}^{t} \mathbf{1}\{W_j = k\}, \qquad \widehat{\mu}_{kt} = \frac{1}{n_{kt}} \sum_{j=1}^{t} \mathbf{1}\{W_j = k\} Y_j.$$

n_{kt} ⟶ 截至时点 t，选择臂 k 的次数。

$\widehat{\mu}_{kt}$ ⟶ 臂 k 的平均奖励。

使用的是从第 1 期到第 t 期收集的信息。

我的重新表述。 可以想象有 T 个相似、独立的个体。每个人都有 K 种处理选择，因而有 K 个潜在结果，各臂对应的分布 F_k 对所有人相同。对每个人，只能观测被选择处理的结果 $Y_t = Y_t(W_t)$。向量 μ 收集了各臂的期望奖励。总 regret 就是对 T 个人累加：所选处理与最优处理之间的差距；在这个设定中，最优臂始终是同一个。

在普通随机实验中，W_t 在 $1, \ldots, K$ 上均匀且非自适应地选择，因此 regret 随 T 线性增长：

$$R_T \sim T \sum_{k=1}^{K} \frac{\mu^* - \mu_k}{K}.$$

求和项的平均是每个个体的期望损失。自适应实验的首要目标是使 regret 次线性增长。

Regret 不应随实验次数或时间线性增长；
选择要逐渐接近最优。 ⟶ 次线性 regret。

这需要平衡探索（尝试）与利用（使用已有知识）。

面对不确定性时保持乐观

置信上界（UCB）方法平衡探索与利用：

1. 对每个臂抽样 t_0 次进行初始化：选择并观测 t_0 次，一共 Kt_0 次初始抽样。
2. 对每个 $t = Kt_0 + 1, Kt_0 + 2, \ldots$，基于截至 $t-1$ 收集的数据，为每个 μ_k 构造置信区间 $\widehat{U}_{kt}$。
3. 选择置信区间上端点最大的动作 W_t，观测 $Y_t = Y_t(W_t)$。

每过一个 t，只多了一个数据点。

为理解 UCB 控制 regret 的原理，将奖励简化为高斯分布：

$$Y_t(k) \sim \mathcal{N}(\mu_k, b^2), \tag{14.4}$$

其中 b^2 已知。

这里已知是为了简化计算。 ⟶ 高斯 UCB 半径中的 b^2。

使用

$$\widehat{U}_{kt} = \widehat{\mu}_{k,t-1} \pm b\sqrt{\frac{4 \log T}{n_{k,t-1}}}. \tag{14.5}$$

当 $t_0 = 1$ 且 $T \geq \max\{K, 2\}$ 时，regret 的上界为

$$R_T \leq \sum_{k:\mu_k < \mu_{k^*}} \left\{ \frac{16 b^2 \log T}{\mu_{k^*} - \mu_k} + (\mu_{k^*} - \mu_k) \right\}, \tag{14.6}$$

以至少 $1 - K/T$ 的概率成立，其中 k^* 表示最优臂。

我对这个界的直觉。

分母中的差距 $\mu_{k^*} - \mu_k$。 $\longrightarrow$ 臂与最优臂越接近，UCB 越需要更长的时间分辨；很差的臂可快速丢弃。

UCB 的 regret 只以对数增长。$\mu_{k^*} - \mu_k$ 很小时，看起来会使上面的界趋向无穷。实际上有两个相互竞争的界：effect 强时，UCB 在置信区间分离后丢弃该臂；effect 弱时，总 regret 至多为 $T(\mu_{k^*} - \mu_k)$。结合两者就得到有限上界；当均值差一致有界时，可得到 $K\sqrt{T \log T}$ 阶的上界。

在置信事件上，每只臂的贡献至多为 $\min\{T\Delta_k, 16b^2 \log T/\Delta_k + \Delta_k\}$。一致的 $O(K\sqrt{T \log T})$ 比较需要固定 b 且差距一致有界；仅初始化就有 $\sum_k \Delta_k$ 的代价。

UCB 的 regret 上界

将 regret 写成

$$R_T = \sum_{k:\Delta_k>0} n_{kT}\Delta_k, \qquad \Delta_k = \mu^* - \mu_k.$$

主要任务是控制 UCB 选择次优臂的次数。

我也用这一点理解 UCB 的设计。 $\longrightarrow$ 控制选择次数 n_{kT}。

设 ζ_{kj} 是臂 k 第 j 次被选择的时间。对每个臂，设想有一列 IID 奖励 $Y'_\ell(k) \sim \mathcal{N}(\mu_k, b^2)$，每次选择该臂时揭示下一个观测。于是

$$\begin{aligned}
&P\left[\sup_{K<t\le T}\left\{\mu_k - \widehat{\mu}_{k,t-1} - b\sqrt{\frac{4\log T}{n_{k,t-1}}}\right\} \ge 0\right] \\
&\le P\left[\sup_{1\le j\le n_{kT}}\left\{\mu_k - \widehat{\mu}_{k,\zeta_{kj}} - b\sqrt{\frac{4\log T}{j}}\right\} \ge 0\right] \\
&= P\left[\sup_{1\le j\le n_{kT}}\left\{\mu_k - \frac{1}{j}\sum_{\ell=1}^{j} Y'_\ell(k) - b\sqrt{\frac{4\log T}{j}}\right\} \ge 0\right] \\
&\le P\left[\sup_{1\le j\le T}\left\{\mu_k - \frac{1}{j}\sum_{\ell=1}^{j} Y'_\ell(k) - b\sqrt{\frac{4\log T}{j}}\right\} \ge 0\right] \le \frac{1}{T}.
\end{aligned}$$

扩大索引集合，上确界及相应事件只会变大。 $\longrightarrow$ $K < t \le T \rightsquigarrow 1 \le j \le n_{kT} \rightsquigarrow 1 \le j \le T$

这里把日历时间改为同一只臂的观测次数。最后的集中不等式是我想进一步检查的一步。

我对 Hoeffding 不等式的疑问。 对相互独立的随机变量 $Z_1, \dots, Z_n$，若几乎必然有 $Z_i \in [a, b]$，且 $s > 0$，则

$$P\left(\frac{1}{n}\sum_{i=1}^{n}(Z_i - \mathbb{E}[Z_i]) \ge s\right) \le \exp\left(-\frac{2ns^2}{(b-a)^2}\right).$$

下尾有相同的界，双侧界多一个因子 2。

几乎肯定有界。 $\longrightarrow$ $Z_i \in [a, b]$

对事件 $A_1, \dots, A_n$，

$$P(A_1 \cup \cdots \cup A_n) \le \sum_{i=1}^{n} P(A_i).$$

我把这个 union bound 与所需的置信水平 $1 - K/T$ 联系起来。

我的计算尝试：猜吧，也许只需证明

$$P\left(\mu_k - \frac{1}{j}\sum_{\ell=1}^{j} Y'_\ell(k) - b\sqrt{\frac{4\log T}{j}} \geq 0\right) \leq \frac{1}{T}.$$

左边可以写成

$$P\left(\frac{1}{j}\sum_{\ell=1}^{j} Y'_\ell(k) - \mu_k \leq -b\sqrt{\frac{4\log T}{j}}\right).$$

尝试套用有界变量的不等式，会得到下面这个表达式：

$$\exp\left(-\frac{2j\,b^2(4\log T)/j}{(b-a)^2}\right) = \exp\left(-\frac{8b^2}{(b-a)^2}\log T\right) \overset{?}{\leq} \frac{1}{T}.$$

但 $Y'_\ell(k)$ 无界，k 是否写错了？不知道最后一步怎么化，可能有未说明的假设。

选择次数的论证需要以下同时成立的事件，其概率至少为 $1 - K/T$：

$$|\widehat{\mu}_{k,t-1} - \mu_k| \leq b\sqrt{\frac{4\log T}{n_{k,t-1}}} \quad \text{对所有} k,\ t = K+1,\dots,T. \tag{14.8}$$

补充推导：高斯分布的集中不等式

高斯假设提供了所需的尾概率界，不必要求奖励有界。记 $\overline{Y}'_{kj} = j^{-1}\sum_{\ell=1}^{j} Y'_\ell(k)$。当 $T \geq 2$ 时，

$$\sqrt{j}(\overline{Y}'_{kj} - \mu_k)/b \sim N(0,1), \qquad P\left(|\overline{Y}'_{kj} - \mu_k| > b\sqrt{4\log T/j}\right) = 2\Phi(-2\sqrt{\log T}) \leq T^{-2}.$$

最后一步使用正态尾界 $2\Phi(-x) \leq 2e^{-x^2/2}/(x\sqrt{2\pi})$。对至多 KT 个臂 / 次数组合使用 union bound，即得到 (14.8)。如果每个计数只有 $1/T$ 的界，再对所有计数取并集就不够。高斯标准差 b 与有界变量不等式中区间端点的 b 也不是同一个量。讲义在这段推导中两次出现的 $Y'_\ell(0)$ 应为 $Y'_\ell(k)$。

继续推导选择次数界。 在事件 (14.8) 上，记 $r_{kt} = b\sqrt{4\log T/n_{k,t-1}}$。若 $W_t = k$，由 UCB 的选择规则，

$$\begin{aligned}\mu^* &\leq \widehat{\mu}_{k^*,t-1} + r_{k^*t} \\ &\leq \widehat{\mu}_{k,t-1} + r_{kt} \\ &\leq \mu_k + 2r_{kt}.\end{aligned}$$

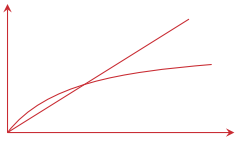
第一步和最后一步分别用到 (14.8) 的两个偏差方向。因此，当 $\Delta_k > 0$ 时，

$$n_{k,t-1} \leq \frac{16b^2\log T}{\Delta_k^2}, \qquad n_{kT} \leq \frac{16b^2\log T}{\Delta_k^2} + 1.$$

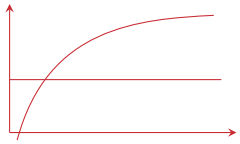
置信事件（1），再加上 UCB 选择 k。 $\longrightarrow$ 次数阈值（2）：$n_{k,t-1} \leq 16b^2\log T/\Delta_k^2$。

我的理解：选择臂 k，说明它的置信区间上端点还必须高于最优臂的上端点。一旦选择次数超过阈值，而阈值只随 $\log T$ 增长，在这个论证中就不能再选择它了。

这两幅草图分别比较增长速度、示意越过阈值。



增长速度的定性比较



越过阈值

将次数上界代入 regret：

$$R_T = \sum_{k:\Delta_k>0} \Delta_k n_{kT} \leq \sum_{k:\Delta_k>0} \left\{ \frac{16 b^2 \log T}{\Delta_k} + \Delta_k \right\}.$$

最后加上的均值差 Δ_k。 $\longrightarrow$ 该臂初始化时 $t_0 = 1$ 次选择带来的 regret；第一项对应其余选择。

自适应随机化方案

UCB 有局限性：很难与 IID 抽样方法结合，也难以推广到复杂的抽样设计。各臂的 b_k^2 可以不同，需要构造基于不同标准误的、可比较的置信区间。

UCB 的 W_t 依赖过去的观测。 $\longrightarrow$ 许多熟悉的方法，包括统计检验和条件均值模型拟合，依赖随机化的 IID 数据。

Thompson 采样。 这是 UCB 的替代方案：基于 Bayesian 更新的启发式算法。

1. 为每个潜在结果分布 F_k 选择先验 $\Pi_{k,0}$。
2. 在时点 t，计算臂 k 是最优臂的后验概率：

$$e_{k,t-1} = P_{\Pi_{t-1}}(\mu_k = \mu^*).$$

3. 随机选择动作：

$$W_t \sim \text{Categorical}(e_{\cdot,t-1}).$$

4. 观测 $Y_t = Y_t(W_t)$，并将后验更新为 Π_t。

Thompson 采样与 UCB 有相似的统计行为：周期性地对每个臂采样，直到基本确信该臂较差。

后验概率降到 $1/T$ 以下。 $\longrightarrow$ 基本确信该臂较差。

若后验允许并列最优臂，需指定平局规则，使各概率之和为一。$1/T$ 的比较是直觉，并不是 Thompson sampling 的停止规则。

Thompson 采样中的动作是随机的，自适应随机化概率依赖过去的数据。这自然可以与因果推断结合。

Thompson 采样使用依赖历史数据的概率随机选择动作。 $\longrightarrow$ 与因果推断结合。

调整先验 Π_0 可能比调整 UCB 区间 $\widehat{U}_{kt}$ 更合理。

自适应实验中的统计推断

分析由 UCB 或 Thompson 采样得到的数据，并对问题背后的参数给出置信结论。这比 IID 情形困难得多。

μ_k 的两个自然估计量，一是样本均值：

$$\widehat{\mu}_k^{\text{AVG}} = \widehat{\mu}_{kT} = \frac{1}{n_{kT}} \sum_{t=1}^{T} \mathbf{1}\{W_t = k\} Y_t, \tag{14.11}$$

二是 Thompson 采样下的 IPW 估计量：

这里 $e_{tk} = P(W_t = k \mid \mathcal{H}_{t-1}) > 0$ 在当前结果出现前计算，对应前面的 $e_{k,t-1}$。IPW / AW 公式需要随机探索；确定性 UCB 未必给每只臂正的选择概率。

$$\widehat{\mu}_k^{\mathrm{IPW}} = \frac{1}{T}\sum_{t=1}^{T}\frac{\mathbf{1}\{W_t = k\}Y_t}{e_{tk}}. \tag{14.12}$$

由于数据收集是自适应的，这些估计量未必具有渐近正态极限分布，所以置信区间难以构造。

自适应加权估计量可以得到高斯枢轴量：高斯枢轴量接近，或依分布收敛到 $N(0,1)$。

$$\widehat{\mu}_k^{\mathrm{AW}} = \frac{\displaystyle\sum_{t=1}^{T}\frac{\mathbf{1}\{W_t = k\}Y_t}{\sqrt{e_{tk}}}}{\displaystyle\sum_{t=1}^{T}\frac{\mathbf{1}\{W_t = k\}}{\sqrt{e_{tk}}}}. \tag{14.13}$$

例如，设当前潜在结果 IID 且独立于过去，$0 < b_k^2 < \infty$，$E|Y_t(k) - \mu_k|^4 < \infty$，可预测概率满足 $e_{tk} \geq ct^{-\alpha}$，其中 $c > 0$、$0 \leq \alpha < 1$。则

$$\widehat{V}_k^{-1/2}(\widehat{\mu}_k^{\mathrm{AW}} - \mu_k) \Rightarrow \mathcal{N}(0,1),$$

其中

$$\widehat{V}_k = \frac{\displaystyle\sum_{t=1}^{T}\left\{\frac{\mathbf{1}\{W_t = k\}(Y_t - \widehat{\mu}_k^{\mathrm{AW}})}{\sqrt{e_{tk}}}\right\}^2}{\left\{\displaystyle\sum_{t=1}^{T}\frac{\mathbf{1}\{W_t = k\}}{\sqrt{e_{tk}}}\right\}^2}. \tag{14.14}$$

我的解释：由于估计量稳定了方差，便可以恢复 CLT。它的方差变得可控制，从而能应用中心极限定理。

推导：估计量背后的鞅。 鞅 M_t 适应于可用历史 $\mathcal{H}_t$，满足 $E|M_t| < \infty$，且 $E[M_t \mid \mathcal{H}_{t-1}] = M_{t-1}$。特别地，$M_t$ 只使用截至时点 t 的信息。

由 (14.13)，

$$\widehat{\mu}_k^{\mathrm{AW}} - \mu_k = \frac{\displaystyle\sum_{t=1}^{T}\frac{\mathbf{1}\{W_t = k\}(Y_t - \mu_k)}{\sqrt{e_{tk}}}}{\displaystyle\sum_{t=1}^{T}\frac{\mathbf{1}\{W_t = k\}}{\sqrt{e_{tk}}}}.$$

令分子中的部分和为

$$M_t = \sum_{j=1}^{t}\frac{\mathbf{1}\{W_j = k\}(Y_j - \mu_k)}{\sqrt{e_{jk}}}.$$

W_t 根据时点 t 之前可用的信息随机选择，并且给定过去后与 $Y_t(k)$ 独立。因此，M_t 是鞅：

$$\mathbb{E}[M_{t+1} \mid M_1, \ldots, M_t] = M_t, \qquad \text{对所有} t.$$

由加权方案，

$$\mathrm{Var}[M_t \mid M_1, \ldots, M_{t-1}] = b_k^2, \qquad b_k^2 = \mathrm{Var}[Y_t(k)]. \tag{14.18}$$

给定之前的部分和后，这也就是新增加一项的条件方差。

只要 e_{tk} 不衰减得太快，由鞅 CLT 可得

$$\frac{M_T}{\sqrt{Tb_k^2}} \Rightarrow \mathcal{N}(0,1).$$

自适应加权的 CLT；有限二阶矩；抽样概率 e_{tk} 的衰减速度应慢于 $1/t$。这排除了最激进的强有效探索方案：一个臂只抽样 $\log T$ 量级的次数。

补充条件：鞅枢轴量

一组清楚的充分条件是：$0 < b_k^2 < \infty$，$E|Y_t(k) - \mu_k|^4 < \infty$，可预测的 $e_{tk} \geq ct^{-\alpha}$，其中 $c > 0$、$0 \leq \alpha < 1$，且当前潜在结果独立于过去的数据。对 $D_t = \mathbf{1}\{W_t = k\}(Y_t - \mu_k)/\sqrt{e_{tk}}$，

$$E[D_t \mid \mathcal{H}_{t-1}] = 0, \quad E[D_t^2 \mid \mathcal{H}_{t-1}] = b_k^2, \quad T^{-2}\sum_{t \leq T} E[D_t^4] = O(T^{\alpha-1}) \to 0.$$

由此得到鞅 Lyapunov 条件，以及 $T^{-1}\sum D_t^2$ 的集中性。AW 分母的可预测均值量级至少为 $T^{1-\alpha/2}$，波动为 $O_P(\sqrt{T})$，因此可得一致性，并允许在方差中使用拟合残差。这些条件充分但非必要。更一般的条件见 Hadad 等（2021）。

接着，

$$\frac{1}{Tb_k^2}\sum_{t=1}^{T}\left\{\frac{\mathbf{1}\{W_t = k\}(Y_t - \widehat{\mu}_k^{\mathrm{AW}})}{\sqrt{e_{tk}}}\right\}^2 \xrightarrow{P} 1.$$

这一步证明集中性；再次要求概率不要衰减得太快。$\widehat{\mu}_k^{\mathrm{AW}} - \mu_k$ 与 $\widehat{V}_k^{1/2}$ 的分母相消，就得到前面的高斯枢轴量。

$\widehat{\mu}_k^{\mathrm{AW}} - \mu_k$ 与 $\widehat{V}_k^{1/2}$ 的分母相消。 $\longrightarrow$ 式 (14.14) 中的高斯枢轴量。